

不平衡数据集分类方法综述

王 乐, 韩 萌, 李小娟, 张 妮, 程浩东

北方民族大学 计算机科学与工程学院, 银川 750021

摘 要: 不平衡数据集的特点导致了在分类时产生了诸多难题。对不平衡数据集的分类方法进行了分析与总结。在数据采样方法中从欠采样、过采样和混合采样三方面介绍不平衡数据集的分类方法; 在欠采样方法中分为基于 K 近邻、Bagging 和 Boosting 三种方法; 在过采样方法中从合成少数过采样技术 (Synthetic Minority Over-sampling Technology, SMOTE)、支持向量机 (Support Vector Machine, SVM) 两个角度来分析不平衡数据集的分类方法; 对这两类采样方法的优缺点进行了比较, 在相同数据集下比较算法的性能并进行分析与总结。从深度学习、极限学习机、代价敏感和特征选择四方面对不平衡数据集的分类方法进行了归纳。最后对下一步工作方向进行了展望。

关键词: 不平衡数据集; 分类; 采样方法; K 近邻 (KNN); 合成少数过采样技术 (SMOTE); 深度学习

文献标志码: A **中图分类号:** TP391 **doi:** 10.3778/j.issn.1002-8331.2107-0097

Review of Classification Methods for Unbalanced Data Sets

WANG Le, HAN Meng, LI Xiaojuan, ZHANG Ni, CHENG Haodong

School of Computer Science and Engineering, North Minzu University, Yinchuan 750021, China

Abstract: The characteristics of unbalanced data sets lead to many difficult problems in classification. The classification methods of unbalanced data sets are analyzed and summarized. Firstly, the classification methods of unbalanced data sets are introduced from three perspectives of under-sampling, over-sampling and mixed sampling in detail. In the under-sampling method, it is divided into three technical methods based on K -Nearest Neighbor (KNN), Bagging and Boosting. In the over-sampling method, the classification method is analyzed from the perspectives of Synthetic Minority Over-sampling Technology (SMOTE) and Support Vector Machine (SVM). The advantages and disadvantages of the algorithm are compared, and the performance of the algorithm is analyzed and summarized under the same data sets. Then, the classification methods of unbalanced data sets are summarized from four aspects: deep learning, extreme learning machine, cost sensitivity and feature selection. Finally, the future work direction is prospected.

Key words: unbalanced data set; classification; sampling method; K -Nearest Neighbor (KNN); Synthetic Minority Over-sampling Technology (SMOTE); deep learning

数据随着时间流逝总是趋向于改变其特性。不平衡数据集的主要特征就是类别中的实例数量不相等, 也就是类别不平衡。类别不平衡是因为不满足条件的数据在处理问题时由于一些实例的数量较少, 优先级过低而导致被忽略的现象。

分类是处理数据集的一个非常有用的方法, 对不平衡数据集进行分类时关注的实例往往都是少数类实例, 但是这种实例的数量特别少。现实生活中的数据出现这种问题是很常见的, 像处理欺诈检测^[1]、医疗诊断^[2]或垃圾邮件过滤^[3]等领域的任务时都会出现此现象, 因此

类不平衡学习总是面临少数类实例不足的挑战。

现有的不平衡数据分类方法综述大多数都从数据级方法开始进行研究, 主要分为欠采样方法和过采样方法, 文献[4]就从这两方面介绍不平衡数据分类方法。还有从集成学习角度介绍不平衡数据分类算法, 其中文献[5]就是基于集成分类算法介绍不平衡数据的分类算法; 文献[6]针对集成方法按照单个正类和多类数据进行总结归纳。但是以往的不平衡数据集分类方法综述中只单独介绍欠采样和过采样方法, 并不能突出采样算法所使用的主要技术, 并且对涉及的算法总结得不够全

基金项目: 国家自然科学基金 (62062004); 宁夏自然科学基金 (2020AAC03216); 北方民族大学研究生创新项目 (YCX20082)。

作者简介: 王乐 (1994—), 女, 硕士研究生, CCF 会员, 研究方向为数据挖掘、数据流集成分类; 韩萌 (1982—), 通信作者, 女, 博士, 副教授, CCF 会员, 研究方向为大数据挖掘, E-mail: 2003051@nmu.edu.cn; 李小娟 (1994—), 女, 硕士研究生; 张妮 (1996—), 女, 硕士研究生; 程浩东 (1996—), 男, 硕士研究生。

收稿日期: 2021-07-06 **修回日期:** 2021-08-18 **文章编号:** 1002-8331 (2021) 22-0042-11

面。本文使用采样方法对不平衡数据集分类算法按照使用的技术类型进行归纳,并且总结其采样类型;还结合了当下研究热点,综合各种技术,总结并分析了不平衡数据集的分类方法。

本文详细地总结了不平衡数据集的几种分类方法,如图1所示。本文的主要贡献有:

(1)从采样方法、深度学习方法、极限学习机方法和代价敏感学习方法等方面详细总结和分析了不平衡数据集的分类方法,并且涵盖了更新的相关方法。

(2)采用数据采样方法对不平衡数据集的分类方法进行介绍,以欠采样、过采样以及混合采样为入手点,在每小节以使用的技术作为总结和分析的落脚点,使用实验结果进行详细的分析和比较。

(3)基于深度学习和极限学习机的方法是近几年研究热点,这种方法在不平衡数据集的分类中起到了很大的作用。本文对基于深度学习、极限学习机的方法进行了详细的研究与分析,有助于不平衡数据集的研究。

(4)总结了不平衡数据集的代价敏感分类方法、特征层面的分类方法,对以上的几种方法进行了详细的分析和对比总结。




图1 文章框架图

Fig.1 Article frame diagram

1 基于采样方法的不平衡数据集分类方法

采样方法的分类方法是不平衡数据集分类时比较常见的方法,在预处理过程中对数据进行采样来重新平衡高度偏斜的类分布。本文将主要从欠采样、过采样和混合采方法三个角度来详细分析不平衡数据集的分类方法。

1.1 不平衡数据集欠采样分类方法

最简单的欠采样方法就是随机欠采样方法(Random Under Sampling, RUS)^[7],该方法随机地在多数类样本中采样,随机选择大多数类实例并将其从数据集中移除,直到达到所需的类分布^[8]。下面主要基于 K 近邻(K

Nearest Neighbor, KNN)、Bagging 和 Boosting 方法来介绍不平衡数据集欠采样分类方法。

1.1.1 基于 K 近邻的欠采样分类方法

不平衡数据的特点导致了在处理不平衡数据集时很难获得理想的分类结果,很多研究者根据 KNN 方法的优点和不平衡数据集的特点提出了一些提高分类器精度的欠采样方法。

Kang 等^[9]提出了一种新的欠采样方案,其结合一种具有代表性的欠采样技术 EasyEnsemble (EE) 来实现噪声滤波的采样方案 (Noise-filtered Under-sampling Scheme, NUS)。该方法并未使用所有少数实例,而是从原始少数实例数据集中过滤出嘈杂的实例,然后使用新的少数类数据集训练分类器,这也是第一次将噪声滤波和欠采样方法相结合。

Hou 等^[10]开发了一种欠采样策略以保留有用的实例并消除嘈杂的实例。首先将每一类例子分为三类,引入一个相似系数来区分每个类别的例子,通过这种选择机制保留了有用的样本,并去除了噪声样本。

同时他们提出了一种基于密度的欠采样方法 (Density-based Undersampling algorithm, DBU),其同样使用了 KNN 聚类方法,并且使用了密度用以选取有用的实例和潜在的实例。还引入了一个相似系数来区分每个类别中的实例,这些实例的相似系数等于 0。对于多数类,根据样本的相似性系数选取一定数量的样本作为重采样多数类的元素。对于少数类,通过删除相似系数为 0 的例子来消除噪声,以达到对数据进行采样调节不平衡现象的目的。

1.1.2 基于 Bagging 的欠采样分类方法

UnderBagging^[11]在每次 Bagging 迭代中对数据集进行随机欠采样,将所有少数类实例都保留在每次迭代中。UnderBagging 用一个不平衡的训练样本代替一个单独的使用 1-NN 规则的分类模型,每个分类器都使用一个平衡的训练样本作为其学习过程。通过实验证明了集成模型可以更好地提高分类器的精度。

Hido 等^[12]提出了一种新的采样方法 RB-Bagging 来改进带有倾斜类分布的数据集。RB-Bagging 充分利用了所有少数实例的欠抽样。通过实验表明,该算法可以保持原有 Bagging 的性质,同时在 AUC (Area Under ROC Curve) 和 ISE (Improved Squared Error) 等指标上也被认为是解决不平衡类问题的合适方法。其中伯努利实验失败次数的概率分布如式 (1) 所示。

$$p(m|n) = \binom{m+n-1}{n} q^n (1-q)^m \quad (1)$$

为了在训练过程中最大限度地利用多数类数据, Li 等^[13]提出了一种将欠采样思想与 Bagging 方法相结合的方法。在训练中包含尽可能多的目标类数据,每个分类器生成一个类别标签用于投票。实验结果表明,该方

法在分类过程中产生了一个具有较高灵敏度、特异性和 G-Means 值的集成分类器。

1.1.3 基于 Boosting 的欠采样分类方法

基于 Boosting 的不平衡数据集分类相关算法是使用整个数据集对每个分类器进行串行训练。Seiffert 等^[14]提出了一种新的混合采样 RUSBoost。RUSBoost 使用随机欠采样技术,从 AdaBoost.M2^[15]的每次迭代中从多数类中删除实例,对新的欠采样数据集中的实例权重进行归一化。将 RUS 引入 Boosting 过程的动机是简单、快速,虽然它很简单^[16],但其表现出较好的性能。

一些研究人员也提出了解决随机欠采样可能会丢失一些有用信息问题的算法,例如 Galar 等^[17]提出的 EUSBoost, Gong 等^[18]提出的 RHSBoost, Lin 等^[19]提出的 CBUBOost 等。在 EUSBoost 算法中将不平衡比定义为负类实例数除以正类实例数,随机采样几个数据子集,然后对其进行迭代,直到无法进一步改善当前最佳的重新采样数据集为止。

Liu 等^[20]提出了两种算法来克服欠采样时多数类实例被忽略的缺陷。EasyEnsemble 的表现与 UnderBagging 相似,尽管为每个新块训练了一个分类器,但他们还是使用 AdaBoost 训练了每个块。BalanceCascade 不再考虑被正确分类的多数类实例。通过实验证明,由于 Easy-Ensemble 对独立的子集进行采样,而 BalanceCascade 使用训练好的分类器来指导后续分类器的欠采样过程,这一区别使 BalanceCascade 算法在为不平衡数据集进行分类时有着更高的准确率。

1.1.4 小结

除了前面总结不平衡数据集的欠采样分类方法,崔彩霞等^[21]提出了一种基于密度峰值聚类的自适应欠采样方法。该方法根据子簇中样本的密度计算采样权重并欠采样,利用近邻搜索算法识别重叠区的多数类样本并将其删除。

通过使用相同参数的数据集来对算法的 AUC 值进行分析与比较,结果如表 1 所示。

表 1 欠采样方法实验性能

Table 1 Experimental performance of under-sampling methods

算法	Pima	Satimage	Glass
NUS	0.767	0.931	—
DBU	0.766	—	0.825
RB-Bagging	—	0.954	—
EUSBoost	0.731	—	0.731
RUSBoost	0.740	—	0.695
EasyEnsemble	0.809	0.947	—

表中 Pima 数据集有 768 个数据,8 个属性,目标类使用 1 个少数类,其中少数类和多数类的数据数量分别为 268 个和 500 个,多数类和少数类的比例为 1.9; Satimage 数据集有 6 435 个数据,36 个属性,目标类使用 4 个

少数类,其中少数类和多数类的数据数量分别为 626 个和 5 809 个,多数类和少数类的比例为 9.3; Glass 数据集有 214 个数据,9 个属性,不平衡比例为 11.9。从表 1 中可以看出,在不平衡比例较大的 Glass 数据集中,DBU 算法具有较高的 AUC 值,因为 DBU 方法同时引入了密度和一个相似系数来区分实例; Satimage 数据集中不平衡比例只有 9.3,虽稍弱于 Glass 数据集,但是仍然是很高的不平衡比例,而且数据量远大于其他两个数据集。从 AUC 值结果中可以看出 NUS、RB-Bagging 和 Easy-Ensemble 三种算法都取得了较高的结果,在 Pima 数据集上 EasyEnsemble 方法效果较为突出,取得了 0.809 的 AUC 值,因为其使用 AdaBoost 算法训练了每个数据块。结合 Satimage 和 Pima 数据集可以得出,将欠采样算法与集成方法相结合可以取得更好的效果。但是欠采样方法在数据采样的过程中经常会出现多类实例被忽略的现象,这样就会导致采样后的数据不均衡。有关欠采样的不平衡数据集的分类方法就要关注这一点,从其他技术上来弥补这一不足,提升不平衡数据集的分类效果。

1.2 不平衡数据集过采样分类方法

过采样技术就是通过复制少数类别样本中的例子来对两种类别样本的数量进行平衡。下面将基于合成少数过采样技术(Synthetic Minority Over-sampling Technique, SMOTE)以及支持向量机技术(Support Vector Machine, SVM)来分析不平衡数据集的过采样分类方法。

1.2.1 基于 SMOTE 的过采样分类方法

合成少数过采样技术(SMOTE)的采样方法是基于 Chawla 等^[22]提出的过采样算法,继承了该算法优秀的部分并进行了一系列改进。

因为 SMOTE 方法目前无法处理具有所有特征的数据集,Chawla 等^[22]提出了一种“综合少数群体过采样” SMOTE-NC (SMOTE - Nominal Continuous)。SMOTE 与不同的分类器结合,允许分类器切割更广泛的决策区域,从而使更多的少数类覆盖。在 48 个实验中,SMOTE-NC 方法也仅在 4 个实验中表现不佳。

Han 等^[23]提出了 Borderline-SMOTE,使用与 SMOTE 相同的过采样技术,但仅对少数类的边界实例进行过采样。Bunkhumpornpat 等^[24]提出了 Safe-Level-SMOTE 算法。该算法沿着同一条线以不同的权重程度仔细地对少数实例进行采样,在生成实例前为每个正实例分配安全等级。通过实验证明,该方法实现了比 SMOTE 和 Borderline-SMOTE 更好的准确性。

Bunkhumpornpat 等^[25]提出了一种新的过采样技术 DBSMOTE (Density-Based SMOTE)。DBSMOTE 沿着从每个正实例到少数类聚类伪质心的最短路径生成合成实例。实验结果表明,DBSMOTE 比 SMOTE、Borderline-SMOTE 和 Safe-Level-SMOTE 更有效地提高了精度、F 值和 AUC 测量值。

Wang 等^[26]提出了 SMOTEBagging 算法,将其扩展到求解多类数据集。实验表明,在两类数据集和多类数据集上对每一个类的多样性都有相似的影响,其总体性能和多样性都有提高。但是 SMOTEBagging 方法的多类研究只包含两个数据集,对于两类和多类之间的性能差异还没有全面地分析到。

分类器在不平衡数据集中进行分类时通常会产生有偏分类器,Chawla 等^[27]提出了 SMOTEBoost 方法,通过利用 SMOTE 来改进少数类的预测,提升分类器的性能。SMOTEBoost 减少了类不平衡学习中固有的偏差,但是在噪声存在的情况下 Boosting 的性能并不好,错误标记噪声对 SMOTEBoost 性能的影响极大,还需要更深入地研究。

1.2.2 基于支持向量机的过采样分类方法

支持向量机(SVM)是一种新的二分类问题学习机器。SVM 在特征空间中构造了一个线性决策面^[28],决策面的特殊性质保证了学习机具有较高的泛化能力。

为了缩小正负类样本数据集上的偏差,黄海松等^[29]提出一种基于样本特性的新型过采样 SVM 算法 NOBDF (New Over-sampling Based on Data Feature)进行数据集的重构,使用支持向量机进行分类。该算法在正负类分类精度上、总体分类性能上都取得了较好的结果,提供了一个有效的理论模型。

在支持向量机分类中支持向量对分类超平面起着决定性的作用。Zhang 等^[30]将改进的随机合成少数过采样算法与 SVM 方法相结合,能够对少数类样本进行聚类,并根据少数类聚类中心与多数类中心的距离确定支持向量作为父样本以及少数类样本,实验证明该算法对不平衡数据集具有显著的分类效果。

Ma 等^[31]为解决入侵检测类不平衡问题学习算法准确度较低的问题,提出了一种新的混合方法 FSVMs,将现有的过采样方法与模糊半监督 SVM 学习方法相结合,在分割策略的基础上进一步解决多类不平衡问题。最后的实验表明该方法对不平衡数据集具有较高的精度。

1.2.3 小结

除了前面两小节介绍的两类方法,也有结合其他新技术的过采样方法。Tao 等^[32]提出了一种新的过采样技术,使用实值负选择(Real-value Negative Selection, RNS)生成少数类实例,以调整不平衡数据集的类别数量的比例,从而确定最优决策函数。Tao 等^[33]提出了一种基于密度峰值聚类和启发式滤波的自适应加权过采样方法,这种方法可以同时适应由各种原因引起的类间和类内的不平衡。

表 2 列举了主流数据增强算法所使用的相同的数据集,以便进行详细的对比分析;表 3 列举了本文所介绍的算法多次在实验中使用的数据集的参数。

表 2 数据增强 SMOTE 方法使用的数据集情况

Table 2 Data sets used in data augmentation SMOTE methods

算法	数据集
SMOTE-NC	Pima, Satimage
Borderline-SMOTE	Pima, Satimage
Safe-Level-SMOTE	Satimage
DBSMOTE	Pima, Satimage
SMOTEBagging	Pima
SMOTEBoost	Satimage

表 3 数据集参数

Table 3 Data set parameters

数据集	实例数	属性	类数目	不平衡比率
Pima	768	8	2	1.90
Satimage	6 435	36	4	9.30
Haberman	306	4	4	2.78

本小节分析使用以上几个数据集进行实验的算法,这样更易于对几种不平衡数据的过采样算法进行比较。对于 Pima 和 Haberman 两个数据集,Borderline-SMOTE 在 TP 率上优于 SMOTE 和 RUS 算法。因为 Borderline-SMOTE 强调边界性,其仅对少数类的边界实例进行过采样,而其他过采样算法直接对所有实例进行过采样。对于 Satimage 数据集,Borderline-SMOTE 的 TP 率大于 RUS,与 SMOTE 的 TP 率相当。这证明了在不同数据集上统一效果的算法会有不同,但在大方向上的优劣趋势是几乎相同的。在 Satimage 数据集上,使用朴素贝叶斯作为分类器时 Safe-Level-SMOTE 算法的 Recall 值也是高于 SMOTE 的 Recall 值,但比 Borderline-SMOTE 算法的 Recall 值略低,当使用 C4.5 作为分类器时,Safe-Level-SMOTE 算法取得了最优的 Recall 值。这是因为 Safe-Level-SMOTE 仔细地对数据集进行了过采样,考虑实例的安全等级比,在安全位置生成每个合成实例,同时使用 C4.5 和朴素贝叶斯作为分类器,取得了完全不同的结果,这也说明了分类器的选取对算法性能的优劣有很大的影响。在 Haberman 数据集中使用支持向量机方法,Safe-Level-SMOTE 算法取得了最优的 AUC 值。在 Pima 数据集中,DBSMOTE 算法比 Safe-Level-SMOTE 算法获得了更好的精度和 AUC 值,在 Recall 和 F 值上 Safe-Level-SMOTE 更胜一筹。在 Haberman 数据集中,DBSMOTE 除了召回率以外都很优秀。在 SMOTE-Bagging 算法的实验中,与 OverBagging 进行了对比,SMOTEBagging 都取得了更高的 G-mean 值;SMOTE-Boost 算法与 SMOTE 算法进行对比,极大地提高了召回率和精度,在 F 值方面也都得到了明显的提高。NOBDF 在 Pima 数据集上也取得了 0.925 的 G-mean 值和 0.834 的 F 测量值,与 SMOTE 和 RUS 算法相比,都高出了约 0.2 个点,因为 NOBDF 算法综合考虑数据样本的类内间距、类间间距以及不平衡度等因素。在表 2 以及表 3 给出的几个数据集中分析上面给出的算法,可以发现单独的

SMOTE 算法并不能很好地处理不平衡数据集, SMOTE 对数据的复杂性很敏感, 如果数据集中存在一个以上的少数类别就会使 SMOTE 方法难以通过调整生成率来平衡类别, 而且简单的过采样算法中也可能在采样过程中产生大量的冗余, 进一步增加训练时间, 降低训练样本的质量, 但是将采样技术与其他方法结合时, 例如加入簇的概念、结合集成的方法等, 都可以有效提高算法的性能, 得到更好的不平衡数据集的分类结果。

1.3 不平衡数据集混合采样分类方法

混合采样方法结合了欠采样和过采样方法的优点, Estabrooks 等^[34]进行了大量的实验, 证明了这一优点, 他们对构成组合的各种分类器做出不同的决策, 使组合方法的效果发挥到最好, 这种组合方案的整体效果十分可观。

Seiffert 等^[35]提出了一种混合数据采样方法, 该方法用一种抽样技术对训练数据进行部分抽样, 然后用另一种方法完成整个过程。Estabrooks 等^[36]将基于两种采样数据的分类器结合在一起, 输出的结果为两种分类器结果的结合。两组实验结果都表明混合采样方法要优于单独的采样技术。

许多研究者也提出随机森林和采样策略结合的方法处理不平衡数据集。郑建华等^[37]提出了一种基于混合采样策略的随机森林不平衡数据分类算法 ARIRF (ADASYN RUS Improved Random Forest), 通过对随机森林中的每一个子树采用混合采样策略, 提高基分类器的多样性, 增强了分类器的效果。杨霞霞^[38]提出了一种改进的不平衡数据集分类算法 AEIRF (ADASYN ENN Improved Random Forest), 采用混合抽样方法生成训练子集, 然后通过加权投票的方式选择最终的分类结果, 充分利用了高精度的决策树。通过混合采样策略和随机森林结合的方法, 不但利用了混合采样可以更全面地处理数据集的优点, 还结合了随机森林可以平衡误差、抗过拟合能力较强等优势, 在不平衡数据集的分类上取得了不错的效果。

通过 2.3 节对不平衡数据集混合采样分类方法的介绍与分析, 研究者通过大量的实验证实了混合采样方法对于不平衡数据集的分类要优于单独的欠采样和过采样方法。Estabrooks 等^[34, 36]和 Seiffert 等^[35]都采用了 UCI 中的部分数据集, 使用混合采样的方法与前面小节中所介绍的 RUS、随机过采样、SMOTE、Borderline-SMOTE 以及 AdaBoost 五个算法进行了对比, 实验结果表明混合采样在大多数 UCI 数据集上的 AUC 值均是提高的。后来越来越多的研究学者在不平衡数据集分类方面开始关注混合采样方法, 并将其与随机森林算法相结合, 也取得了不错的效果。ARIRF 算法使用 UCI 中的数据集在 AUC 和 G-mean 上均优于不平衡数据集欠采样分类方法 RUSBoost, 可以说明混合采样方法优于单独的

欠采样或者过采样方法。但是对于特征较少的数据或者低维数据, 随机森林方法可能不能产生很好的分类效果, 而且混合采样方法和随机森林方法在处理数据的过程中都比较耗时, 因此在时间方面还有待加强。

表 4 对基于采样方法的不平衡数据集分类方法从优缺点、数据集以及对比算法等方面进行了总结与比较。

2 其他不平衡数据分类方法

2.1 基于深度学习的的海不平衡数据集分类方法

深度学习是近几年的研究热点, 研究者利用其优秀的学习数据规律的特点, 将其运用于处理不平衡数据集, 从而使分类和预测更容易。

周霄晗^[39]提出了一种基于深度去噪自编码器的深度生成对抗网络 (Adversarial Deep Denoising Autoencoder, GAN-DAE), 其通过生成器和判别器的对抗训练获取不平衡数据中正负样本的特征, 改善数据样本的不平衡状况。周霄晗^[39]还提出了以 GAN-DAE 作为成员神经网络的集成模型, 每个 GAN 的子训练集空间不同, 因此训练得到的 GAN 可以互补, 提高了少数群体的分类率, 限制了多数类群体的误分类率。最后实验也验证了该方法在识别少数样本上性能良好, 而且更适合处理高维度和高不平衡比率的数据集。

解晓波^[40]提出一种基于生成对抗网络 (Generative Adversarial Network, GAN) 的不平衡数据集分类方法, 使用 WGAN (Wasserstein GAN) 对 GAN 的损失函数以及网络结构做了适当修改, 使得在训练方面更加稳定。与 SMOTE 做数据增强的实验相比, WGAN 对阈值的敏感程度比 SMOTE 要低, 这也说明了 WGAN 检查错误样本更为准确, SMOTE 在预测时可能会产生更多误判。

Konno 等^[41]使用深度神经网络 (Deep Neural Network, DNN) 提取少数样本的特征作为基本特征, 然后加入一部分伪特征 (Pseudo Feature) 产生新样本来弥补少数类样本的不足, 有效改善了不平衡数据集分类的结果。实验结果证明, 一旦在少数类确定的情况下, 该方法在准确率、查全率和 F 值上相对于欠采样、过采样和 SMOTE 都有明显的提高, 在精度上各算法相当。

类别不平衡导致神经网络模型被多数类所主导, 致使分类效果不佳, 针对这种现象陈志等^[42]提出将卷积神经网络训练过程中损失函数引入类别标签权重, 强化少数类对模型参数的影响。文本分类实验也表明了此方法可以显著地提升 F1 值, 提高神经网络对不平衡数据集的分类能力。

2.2 基于极限学习机的不平衡数据集分类方法

极限学习机 (Extreme Learning Machine, ELM) 作为集成网络的基础分类器可以保证单个网络的精度, 将 ELM 与集成方法相结合可以很好地改善不平衡数据集分类效果。

表4 基于采样方法的不平衡数据集分类方法
Table 4 Unbalanced data set classification method based on sampling method

算法	技术	采样方法	数据集	对比算法	优点	缺点
NUS ^[9]	KNN	欠采样	Pima,Haberman, CMC,Yeast, Balance等	UA,UA-KF, RUSB,RUSB-KF, UB,UB-KF,EE, EE-KF	首次将噪声滤波和欠采样方法结合在一起,也是第一次讨论和处理少数类中的噪声问题	对于不平衡比率较高的数据集还需要进一步研究与分析,特别是比率为1 000:1的数据集
DBU ^[10]	KNN	欠采样	pimaimb, glass016vs2等	RUSBoost, EUSBoost, CBUBBoost等	引入了一个相似系数来区分每个类别中的实例,消除了噪声,调节不平衡现象	
SMOTE ^[22]	SMOTE	过采样	Pima,Phoneme, Forest Cover等	UnderC4.5,Ripper, Naive Bayes,Hull	通过创建“合成”实例而不是通过替换进行过采样来对少数群体进行过采样	只选定最近邻的数据随机合成少数实例,忽略附近的多数实例;对数据集的数据复杂性很敏感
Borderline-SMOTE ^[23]	SMOTE	过采样	Circle,Pima, Satimage, Haberman	Borderline-SMOTE1, Borderline-SMOTE2等	仅对少数类的边界实例进行过采样,划分为不同的区域、噪声和边界,减少了运算时间	没有给边界实例定制不同的策略
Safe-Level-SMOTE ^[24]	SMOTE	过采样	Satimage, Haberman	SMOTE, Borderline-SMOTE	为每个实例配置安全级别,获得了比 SMOTE 和 Borderline-SMOTE 更好的精度	没有解决其自动确定生成的合成实例的数量
DBSMOTE ^[25]	SMOTE	过采样	Pima, Haberman, Glass, Segmentation等	SMOTE, Borderline-SMOTE, SAFE-level-SMOTE	DBSMOTE其他几种SMOTE相关方法更有效地提高了精度、F值和AUC测量值	没有解决 Eps、MinPts 自动测定的问题
SMOTEBagging ^[26]	SMOTE/Bagging	过采样	Hepatitis,Heart, Liver,Pima, Ionosphere, Breast-w, Glass, Yeast	under-sampling, over-sampling, SMOTE	将SMOTE算法结合到Bagging模型中,并将其扩展到求解多类数据集,其总体性能和多样性都有提高	其多样性导致了对多数类的召回率更差;研究的多类只包含两个数据集,尚不能分析两类和多类之间的差异
SMOTEBoost ^[27]	SMOTE/Boosting	过采样	KDDCup-99 Intrusion, Satimage等	AdaBoost.M2等	在 Boosting 每次迭代中引入 SMOTE,从而学习到更广泛的少数类决策区域	要在每次学习一个分类器之前,通过添加新的少数类案例来最大化扭曲类数据集的边界
NOBDF ^[29]	SVM	过采样	Pima,German, WPBC, Haberman, Yeast等	SVM,RU,SMOTE, DBSMOTE,Weight, RUS,AdaSyn,SPU	在正负类分类精度上、总体分类性能上都取得了较好的结果,为不平衡数据的分类提供了一个有效的理论模型	没有对数据进行合理的划分,这将会影响样本合成及数据集分类结果
FSVMs ^[31]	SVM	过采样	Balance,Car, Satimage	Bayes,BP,DT, KNN,RF,SVM, FSVMs	利用模糊分治策略对训练数据进行分割,可以实现高效采样,还可以避免过度拟合现象	对多数类的检测率低于其他分类器;效果受到数据集不平衡率的限制,整体仍有一定的局限性

李晗曼等^[43]提出了一种基于分层交叉验证的集成超限学习机,将集成学习方法和分层交叉验证策略引入到网络训练过程中,减轻过度拟合,提高泛化能力。因为在训练过程中,训练集和验证集每类样本的分布和测试集一致,所以能更好地学习样本的特征,保证了测试的效果。

孙庆帅^[44]提出了基于数据分布的加权极限学习机 D-WELM(Data Distribution based Weighted Extreme Learning Machine)。该算法不仅考虑了样本类别数量的影响,同时考虑了全局损失,设计了一个新的加权方

案。其中加权方案的数学表达式为:

$$W_{new_i} = \left(\frac{1}{r_{i1}} + r_{i2} \right) \left(1 - \frac{\#(t_i)}{\#(T)} \right) \tag{2}$$

这个公式不仅考虑到类样本数量不同的影响,更重要的是考虑了数据分布特性即数据离散程度的影响。实验结果也表明该算法的加权方案不受使用者的主观因素影响,完全依托于数据集的分布特性,具有较强的可迁移性。

2.3 代价敏感学习不平衡数据集分类方法

除了以上提到的方法来分类不平衡数据集,很多研

研究者还会选择采用代价敏感学习方法来调整不平衡数据在分类时所出现的状况。Li等^[45]提出了一种代价敏感的混合属性测度多决策树(Cost-sensitive and Hybrid attribute measure Multi-Decision Tree, CHMDT)方法用于非平衡数据集的二值分类,对两个类进行不平衡的惩罚以提高分类精度。基于类似的原理,Veropoulos等^[46]为多数类和少数类分配不同的代价,但是此方法未考虑相同类别的样本对分类器形成的不同影响,这可能导致噪声和离群值出现过拟合现象。

Tao等^[47]提出了一种新的基于自适应成本权重的支持向量机代价敏感集成方法,使用成本敏感的支持向量机作为基分类器,并使用改进的成本敏感的Boosting方案,这个策略有利于最终分类边界略微偏离少数类。平瑞等^[48]提出基于聚类的弱平衡代价敏感随机森林算法(Weak Balance Cost-sensitive Random Forest, WBCRF)用于不平衡数据分类,采用K-means聚类方法进行欠采样,选择使误分类代价下降值最大的属性进行划分。实验结果表明该方法可以有效提高单棵决策树的分类性能。

Elkan等^[49]提出了一个定理,该定理说明了如何通过使用标准的非代价敏感学习方法学习的分类器来改变训练集中的负数比例,但该定理没有说明反例的数量应该以什么方式改变。改进后的定理允许使用从一个概率分布中提取的训练集学习的分类器,放宽了最基本的假设,即训练集和测试集都来自同一总体。

2.4 特征选择不平衡数据集分类方法

数据集中若没有一个足够大的训练集,一个分类器可能无法概括数据的特征;分类器也可能过度拟合训练数据,特别是对于高维数据在测试点上容易被误导^[50]。对软件缺陷预测的研究表明^[51],特征选择和特征提取的方法可以为研究提供很大的帮助。Putten等^[52]分析了Coil Challenge 2000的数据集,发现特征选择能更有效地解决过度拟合问题。

Nam等^[53]提出了一种从特征映射角度出发的TCA(Transfer Component Analysis)方法,将源项目和目标项目的特征映射到一个最接近两者的潜在空间上,平衡不同项目间的数据分布差异。之后他们基于TCA优点提出了TCA+^[54],这种方法不但可以将两个项目映射到一个空间上,还能对其进行特征分析,自动分析出一个数据归一化方法。

刘树毅等^[55]提出了一种基于多策略的特征选择方法,对软件静态缺陷数据进行评估然后排序,随后根据每个特征出现的频率进行二次排序,选取靠前的特征组成新的最优特征子集来平衡项目中数据的缺失。Gao等^[56]提出了一种名为AHS(Automatic Hybrid Search)的属性子集选择方法,选择一致性率最高的属性子集生成超集以减少搜索空间。Laradji等^[57]结合特征选择和集成学习也可以提高软件缺陷预测的准确性,提出了几种特

征选择技术,通过大量的实验证明,选择少量的质量特征可以获得比其他方法更高的AUC值。

2.5 小结

本章从深度学习、极限学习机、代价敏感学习以及特征选择四方面介绍了不平衡数据集的分类方法,其中深度学习多使用神经网络的方法,因为神经网络的稳健性可以自然地应用于在线学习和大型数据集中。使用神经网络的基于深度学习的的海量数据集分类方法和前面介绍的采样分类方法最大的不同点就是采样方法多对多数类和少数类实例进行采样,而基于深度学习的分类方法会通过生成伪特征,利用神经网络对伪特征进行操作;也可以将神经网络和集成方法结合,赋予各个成员神经网络权重,或者在损失函数中引入类别标签权重,这样就可以构建具有较强的泛化能力的预测模型。基于深度学习的方法与SMOTE方法、ADASYN方法以及EUSBoost相比,在AUC和召回率方面都取得了更好的结果,而且通过实验证明,基于深度学习的方法相比于其他方法更适合高不平衡比率的数据集。

极限学习机近几年也在机器学习领域中发挥着重要作用,2.2节所分析的算法都应用了极限学习机结构简单、训练速度快、泛化能力强等优点,结合基于代价敏感和集成的思想,进一步提高了极限学习机对不平衡数据集的分类能力。在不平衡率为0.02的二分类数据集中,与其他极限学习机算法相比准确率,最低提高了2%,最高提高了15%左右,这是一个可观的提升。但是有些基于极限学习机的方法可能会忽略相同类别的样本对分类器形成的不同影响,导致出现噪声和离群值,从而出现过拟合现象。极限学习机方法未来还要对相同类别的样本数据进行重点研究。

2.3节中基于代价敏感学习的不平衡数据集分类方法多是将代价敏感方法与各类分类算法结合,类似于决策树、支持向量机和随机森林等方法。将代价敏感学习引入到分类方法中调节误分类代价,可以对不平衡数据集做出更好的决策,调节类别不平衡比例。在各类评价指标中,如SE、SP、G-mean和AUC等,不平衡数据集代价敏感学习分类算法都要比AdaBoost、CUSBoost和RUSBoost等算法提高很多,这也说明了代价敏感与分类算法结合能够有效地提高准确率。

2.4节中介绍的算法是将特征选择方法运用于不平衡数据集分类中,相较于前面提到的方法,特征选择方法可以更好地处理过拟合的问题。当处理高维数据时,特征选择会根据一定的评价标准在样本集中选择符合评价的最优的数据作为特征子集,有效地将样本集中的数据区分开,处理高维数据中的类别不平衡现象。随后,更多研究者开始对特征进行分等级、赋予权重、与集成方法相结合等操作,从中选择信息量和特征子集,从而提高不平衡数据集分类的效果。但是极个别特征选

择方法面对类别实例度量差异过大,类别间分布差异急剧增大时就可能面临着失效的可能。

下面对本章不平衡数据集分类算法按照使用的技术进行了一个简单的总结与分析,如图2所示。

3 未来展望

近年来不平衡数据集的分类方法越来越多,而且研究者们也从多方面根据不平衡数据集的特点提出不同的方法,但面对不平衡数据集仍有很多方面需要去简化和克服。下面探讨针对不平衡数据集的进一步研究方向。

(1) 基于采样技术的不平衡数据集分类算法

采样技术是很常见的一种处理不平衡数据集的分类算法。已经有很多算法开始针对不平衡数据集中的噪声进行处理,类似于噪声滤波器,但使用的技术还是比较局限,应尝试使用更多的优化技术来处理一些难以平衡的数据集。也可以针对特定的数据集研究采样方法的不足,直接改进采样比率等可以影响不同级别类不平衡表现的因素,以便提高算法在不平衡数据集上的分类效果。

(2) 基于特征层面的不平衡数据集分类算法

高维的不平衡数据集是分类中一个棘手的问题,现有的针对高维不平衡数据集分类多采用特征层面的方法,当样本数增加或不平衡度降低时,特征选择解决不

平衡数据集的优势可能逐渐减弱。未来研究不仅可以采用基于特征等级的最简单特征子集搜索方法,也可以通过其他方法进行改进,如顺序回溯浮动选择等。还可以对特征层面方法给分类性能带来突变做一个更好的预测与估计,以免造成更多的资源浪费。

(3) 基于代价敏感学习的不平衡数据集分类算法

现有的代价敏感学习通过为基分类器设置不同的误分代价来使算法可以对不平衡数据更好地分类。在单个分类器中引入代价敏感函数,从而提高对少数类样本的关注度,提高对不平衡数据集的分类精度。针对使用代价敏感函数进行不平衡数据集分类的研究现状,在未来的研究中可以使用更多种类的代价函数,例如主动学习代价、计算代价、存储代价等,来尝试解决不平衡数据集的分类问题。

(4) 基于深度学习的不平衡数据集分类算法

基于深度学习的不平衡数据集分类算法在近两年取得了不错的成效,尤其是在深度神经网络集成模型中。在之后的研究中可以尝试优化单个深度神经网络,改进优化策略,提高神经网络模型性能等。在使用深度生成对抗网络的生成样本数据时通常只输入少数类样本,在这个过程中也可以尝试使用传统的数据增强方法先对不平衡数据集进行数据增强,再使用深度生成对抗网络去生成数据,效果可能会更佳。




图2 不平衡数据集分类算法

Fig.2 Unbalanced data set classification algorithms

(5) 基于集成方法的不平衡数据集分类算法

目前针对不平衡数据集的集成分类问题,研究者们已经提出了很多方法,在一定程度上解决了不平衡数据集分类问题。但是现有的集成算法大多是针对二分类不平衡数据集进行研究的,在现实场景中很多问题都是多分类问题,虽然有个别研究工作针对多类分类问题进行了探讨,但对不平衡数据集的多类集成分类问题研究仍然不足,还需要进一步深入研究。再者还可以针对特定的算法,从集成规模的大小和分配给基分类器的权重上进一步研究,选择合适的集成大小和基分类器权重都可以使算法得到更好的效果。

4 总结

对不平衡数据集的多类分类问题研究仍然不足,还需要进一步深入研究,不平衡数据在现实生活中非常普遍,其问题也越来越明显,因此这项研究具有重要的现实意义。随着分类技术研究的一步步深入,越来越多的研究者开始从不平衡数据集类别数量分布极度不平衡的特点着手来进行研究,针对不平衡数据集的分类算法也越来越全面。本文主要基于数据的采样方法介绍了不平衡数据集的分类方法,分为欠采样、过采样和混合采样进行了介绍,在每一种采样方法中又分为不同的侧重点进行详细对比与分析,并使用实验数据进行了总结;还分析了其他不平衡数据集的分类方法,从基于深度学习、极限学习机、代价敏感学习以及特征选择四方面对不平衡数据集分类方法进行了分析与总结。最后展望了不平衡数据集分类方法现阶段还存在的问题,讨论了以后的解决思路。

参考文献:

- [1] PHUA C, ALAHAKOON D, LEE V. Minority report in fraud detection: classification of skewed data[J]. ACM SIGKDD Explorations Newsletter, 2004, 6(1): 50-59.
- [2] KRAWCZYK B, GALAR M, JELE N L, et al. Evolutionary under-sampling boosting for imbalanced classification of breast cancer malignancy[J]. Applied Soft Computing, 2016, 38: 714-726.
- [3] ALQATAWNA J, FARIS H, JARADAT K, et al. Improving knowledge based spam detection methods: the effect of malicious related features in imbalance data distribution[J]. International Journal of Communications Network & System Sciences, 2015, 8(5): 118-129.
- [4] 刘定祥, 乔少杰, 张永清, 等. 不平衡分类的数据采样方法综述[J]. 重庆理工大学学报(自然科学), 2019, 33(7): 102-112. LIU D X, QIAO S J, ZHANG Y Q, et al. A survey on data sampling methods in imbalance classification[J]. Journal of Chongqing University of Technology (Natural Science), 2019, 33(7): 102-112.
- [5] 李勇, 刘战东, 张海军. 不平衡数据的集成分类算法综述[J]. 计算机应用研究, 2014, 31(5): 1287-1291. LI Y, LIU Z D, ZHANG H J. Review on ensemble algorithms for imbalanced data classification[J]. Application Research of Computers, 2014, 31(5): 1287-1291.
- [6] 杨明, 尹军梅, 吉根林. 不平衡数据分类方法综述[J]. 南京师范大学学报(工程技术版), 2008, 8(4): 7-12. YANG M, YIN J M, JI G L. Classification methods on imbalanced data: a survey[J]. Journal of Nanjing Normal University (Engineering and Technology Edition), 2008, 8(4): 7-12.
- [7] PRUSA J, KHOSHGOFTAAR T M, DITTMAN D J, et al. Using random under-sampling to alleviate class imbalance on tweet sentiment data[C]//Proceedings of the 16th IEEE International Conference on Information Reuse and Integration, Aug 13, 2015, Piscataway: IEEE, 2015: 197-202.
- [8] BATISTA G E, PRATI R C, MONARD M C. A study of the behavior of several methods for balancing machine learning training data[J]. ACM SIGKDD Explorations Newsletter, 2004, 6(1): 20-29.
- [9] KANG Q, CHEN X S, LI S S, et al. A noise-filtered under-sampling scheme for imbalance classification[J]. IEEE Transactions on Cybernetics, 2017, 4: 4263-4274.
- [10] HOU Y, LI L, LI B, et al. An anti-noise ensemble algorithm for imbalance classification[J]. Intelligent Data Analysis, 2019, 23(6): 1205-1217.
- [11] BARANDELA R, SÁNCHEZ J S, VALDOVINOS R M. New applications of ensembles of classifiers[J]. Pattern Analysis & Applications, 2003, 6(3): 245-256.
- [12] HIDO S, KASHIMA H, TAKAHASHI Y. Roughly balanced bagging for imbalanced data[J]. Statal Analysis & Data Mining, 2010, 2(5/6): 412-426.
- [13] LI C. Classifying imbalanced data using a bagging ensemble variation (BEV) [C]//Proceedings of the 45th Annual Southeast Regional Conference on ACM-SE, Mar 23, 2017: 203-208.
- [14] SEIFFERT C, KHOSHGOFTAAR T, HULSE J V, et al. RUSBoost: a hybrid approach to alleviating class imbalance[J]. IEEE Transactions on Systems, Man and Cybernetics, 2010, 40(1): 185-197.
- [15] FREUND Y, SCHAPIRE R E. A decision-theoretic generalization of on-line learning and an application to boosting[J]. Journal of Computer and System Sciences, 1997, 55(1): 119-139.
- [16] BROWN G, WYATT J, HARRIS R, et al. Diversity creation methods: a survey and categorisation[J]. Information Fusion, 2005, 6(1): 5-20.
- [17] GALAR M, FERNÁNDEZ A, BARRENECHEA E, et al. EUSBoost: enhancing ensembles for highly imbalanced data-sets by evolutionary under-sampling[J]. Pattern Recognition, 2013, 46: 3460-3471.

- [18] GONG J, KIM H. RhsBoost: improving classification performance in imbalance data[J]. *Computational Statistics and Data Analysis*, 2017, 111: 1-13.
- [19] LIN W C, TSAI C F, HU Y H, et al. Clustering-based under-sampling in class-imbalanced data[J]. *Information Sciences*, 2017, 409/410: 17-26.
- [20] LIU X Y, WU J, ZHOU Z H. Exploratory under-sampling for class-imbalance learning[J]. *IEEE Transactions on Systems, Man and Cybernetics*, 2009, 39(2): 539-550.
- [21] 崔彩霞, 曹付元, 梁吉业. 基于密度峰值聚类的自适应欠采样方法[J]. *模式识别与人工智能*, 2020, 33(9): 811-819.
- CUI C X, CAO F Y, LIANG J Y. Adaptive undersampling based on density peak clustering[J]. *Pattern Recognition and Artificial Intelligence*, 2020, 33(9): 811-819.
- [22] CHAWLA N V, BOWYER K, HALL L, et al. SMOTE: synthetic minority over-sampling technique[J]. *Journal of Artificial Intelligence Research*, 2002, 16(1): 321-357.
- [23] HAN H, WANG W Y, MAO B H. Borderline-SMOTE: a new over-sampling method in imbalanced data sets learning[C]//*Proceedings of the 2005 International Conference on Intelligent Computing*, Aug 23-26, 2005. Berlin, Heidelberg: Springer, 2005: 878-887.
- [24] BUNKHUMPORNPAT C, SINAPIROMSARAN K, LUR-SINSAP C. Safe-level-SMOTE: safe-level-synthetic minority over-sampling technique for handling the class imbalanced problem[C]//*Proceedings of the 2009 Pacific-Asia Conference on Knowledge Discovery and Data Mining*, Apr 19, 2009. Berlin, Heidelberg: Springer, 2009: 475-482.
- [25] BUNKHUMPORNPAT C, SINAPIROMSARAN K, LUR-SINSAP C. DBSMOTE: density-based synthetic minority over-sampling technique[J]. *Applied Intelligence*, 2012, 36(3): 664-684.
- [26] WANG S, YAO X. Diversity analysis on imbalanced datasets by using ensemble models[C]//*Proceedings of the 2009 IEEE Symposium on Computational Intelligence and Data Mining*, Mar 2-Apr 30, 2009. Piscataway: IEEE, 2009: 324-331.
- [27] CHAWLA N V, LAZAREVIC A, HALL L O, et al. SMOTE-Boost: improving prediction of the minority class in boosting[C]//*Proceedings of the 2003 Knowledge Discovery in Databases*, Jan 2003. Berlin, Heidelberg: Springer, 2003: 107-119.
- [28] CORTES C, VAPNIK V N. Support-vector networks[J]. *Machine Learning*, 1995, 20(3): 273-297.
- [29] 黄海松, 魏建安, 康佩栋. 基于不平衡数据样本特性的新型过采样SVM分类算法[J]. *控制与决策*, 2018, 33(9): 1549-1558.
- HUANG H S, WEI J A, KANG P D. New over-sampling SVM classification algorithm based on unbalanced data sample characteristics[J]. *Control and Decision*, 2018, 33(9): 1549-1558.
- [30] ZHANG L M, TAN L M, LIU T S, et al. Classification study for the imbalanced data based on biased-SVM and the modified over-sampling algorithm[J]. *Journal of Physics: Conference Series*, 2019, 1237(2): 1-5.
- [31] MA T, HOU Y, CHENG J J, et al. A novel method combining fuzzy SVM and sampling for imbalanced classification[J]. *International Journal of Applied Systemic Studies*, 2018, 8(1): 1-31.
- [32] TAO X, LI Q, REN C. Real-value negative selection over-sampling for imbalanced data set learning[J]. *Expert Systems with Applications*, 2019, 129: 118-134.
- [33] TAO X, LI Q, GUO W. Adaptive weighted over-sampling for imbalanced datasets based on density peaks clustering with heuristic filtering[J]. *Information Sciences*, 2020, 519: 43-73.
- [34] ESTABROOKS A, JO T, JAPKOWICZ N. A multiple re-sampling method for learning from imbalanced data sets[J]. *Computational Intelligence*, 2010, 20(1): 18-36.
- [35] SEIFFERT C, KHOSHGOFTAAR T M, VAN H J. Hybrid sampling for imbalanced data[J]. *Integrated Computer Aided Engineering*, 2009, 16(3): 193-210.
- [36] ESTABROOKS A, JAPKOWICZ N. A mixture-of-experts framework for learning from imbalanced data sets[C]//*Proceedings of the 4th International Conference on Advances in Intelligent Data Analysis*, Sep 3, 2001. Berlin, Heidelberg: Springer, 2001: 34-43.
- [37] 郑建华, 刘双印, 贺超波, 等. 基于混合采样策略的改进随机森林不平衡数据分类算法[J]. *重庆理工大学学报(自然科学版)*, 2019, 33(7): 113-123.
- ZHENG J H, LIU S Y, HE C B, et al. Improved random forest classification algorithm for imbalance data based on hybrid sampling strategy[J]. *Journal of Chongqing University of Technology(Natural Science)*, 2019, 33(7): 113-123.
- [38] 杨霞霞, 苏锋, 黄戊霞. 基于改进随机森林算法的不平衡数据分类方法研究[J]. *网络安全技术与应用*, 2020(10): 70-71.
- YANG X X, SU F, HUANG X X. Research on unbalanced data classification method based on improved random forest algorithm[J]. *Network Security Technology and Application*, 2020(10): 70-71.
- [39] 周霄晗. 基于深度神经网络对抗与集成的不平衡数据分类方法研究[D]. 杭州: 浙江工业大学, 2019.
- ZHOU X H. Research on imbalanced data classification method based on deep neural network adversarial and ensembles[D]. Hangzhou: Zhejiang University of Technology, 2019.
- [40] 解晓波. 基于生成对抗网络的非均衡数据分类研究[D]. 南京: 南京邮电大学, 2020.
- XIE X B. Research on classification of imbalanced dataset based on generative adversarial networks[D]. Nanjing: Nan-

- jing University of Posts and Telecommunications, 2020.
- [41] KONNO T, IWAZUME M. Pseudo-feature generation for imbalanced data analysis in deep learning[J]. arXiv:1807.06538, 2018.
- [42] 陈志, 郭武. 不平衡训练数据下的基于深度学习的文本分类[J]. 小型微型计算机系统, 2020, 41(1): 1-5.
CHEN Z, GUO W. Text classification based on depth learning on unbalanced data[J]. Journal of Chinese Computer Systems, 2020, 41(1): 1-5.
- [43] 李晗曼, 王丽丹, 段书凯. 改进的超限学习机及其在不平衡数据中的应用[J]. 西南大学学报(自然科学版), 2020, 42(6): 140-148.
LI H M, WANG L D, DUAN S K. An improved extreme learning machine and its application in imbalance data[J]. Journal of Southwest University(Natural Science Edition), 2020, 42(6): 140-148.
- [44] 孙庆帅. 基于不平衡数据分布的加权极限学习机算法研究[D]. 湘潭: 湘潭大学, 2019.
SUN Q S. Research on weighted extreme learning machine algorithm based on imbalanced data distribution[D]. Xiangtan: Xiangtan University, 2019.
- [45] LI F L, ZHANG X Y, ZHANG X Q, et al. Cost-sensitive and hybrid-attribute measure multi-decision tree over imbalanced data sets[J]. Information Sciences, 2018, 422: 242-256.
- [46] VEROPOULOS K, CAMPBELL C, CRISTIANINI N. Controlling the sensitivity of support vector machines[C]// Proceedings of the 1999 International Joint Conference on Artificial Intelligence, 1999: 55-60.
- [47] TAO X, LI Q, GUO W, et al. Self-adaptive cost weights-based support vector machine cost-sensitive ensemble for imbalanced data classification[J]. Information Sciences, 2019, 487: 31-56.
- [48] 平瑞, 周水生, 李冬. 高度不平衡数据的代价敏感随机森林分类算法[J]. 模式识别与人工智能, 2020, 33(3): 249-257.
PING R, ZHOU S S, LI D. Cost sensitive random forest classification algorithm for highly unbalanced data[J]. Pattern Recognition and Artificial Intelligence, 2020, 33(3): 249-257.
- [49] ELKAN C. The foundations of cost-sensitive learning[C]// International Joint Conference on Artificial Intelligence, 2001: 973-978.
- [50] CUI Y J, DAVIS S, CHENG C K, et al. A study of sample size with neural network[C]// Proceedings of the 3rd International Conference on Machine Learning & Cybernetics, Aug 26-29, 2004. Piscataway: IEEE, 2004: 3444-3448.
- [51] CHEN J, LIU S, LIU W, et al. A two-stage data preprocessing approach for software fault prediction[C]// Proceedings of the 8th International Conference on Software Security & Reliability, Jun 30-Jul 2, 2014. Piscataway: IEEE, 2014: 20-29.
- [52] PUTTEN P V D, SOMEREN M V. A bias-variance analysis of a real world learning problem: the CoIL challenge 2000[J]. Machine Learning, 2004, 57(1/2): 177-195.
- [53] NAM J, PAN S J, KIM S. Transfer defect learning[C]// Proceedings of the 35th International Conference on Software Engineering. Washington: IEEE Computer Society, 2013: 382-391.
- [54] PAN S J, TSANG I W, KWOK J T, et al. Domain adaptation via transfer component analysis[J]. IEEE Transactions on Neural Networks, 2011, 22(2): 199-210.
- [55] 刘树毅, 翟晔, 刘东升. 融合多策略特征筛选的跨项目软件缺陷预测[J]. 计算机工程与应用, 2019, 55(8): 53-58.
LIU S Y, ZHAI Y, LIU D S. Cross-project software defect prediction with multi-strategy feature filtering[J]. Computer Engineering and Applications, 2019, 55(8): 53-58.
- [56] GAO K, KHOSHGOFTAAR T M, WANG H, et al. Choosing software metrics for defect prediction: an investigation on feature selection techniques[J]. Software: Practice and Experience, 2011, 41(5): 579-606.
- [57] LARADJI I H, ALSHAYEB M, GHOUTI L. Software defect prediction using ensemble learning on selected features[J]. Information & Software Technology, 2015, 58: 388-402.