

分类号_____

密级_____

UDC^{注1}_____

学 位 论 文

不平衡数据集分类算法的研究

(题名和副题名)

孟 军

(作者姓名)

指导教师姓名_____张永_____副教授

申请学位级别_____硕 士_____专业名称_____控制理论与控制工程

论文提交日期_____2014.02_____论文答辩日期_____2014.03

学位授予单位和日期_____南京理工大学

答辩委员会主席_____


评阅人_____

年 月 日

注 1: 注明《国际十进分类法 UDC》的类号。


声 明

本学位论文是我在导师的指导下取得的研究成果，尽我所知，在本学位论文中，除了加以标注和致谢的部分外，不包含其他人已经发表或公布过的研究成果，也不包含我为获得任何教育机构的学位或学历而使用过的材料。与我一同工作的同事对本学位论文做出的贡献均已在论文中作了明确的说明。

研究生签名：  2014年3月27日

学位论文使用授权声明

南京理工大学有权保存本学位论文的电子和纸质文档，可以借阅或上网公布本学位论文的部分或全部内容，可以向有关部门或机构送交并授权其保存、借阅或上网公布本学位论文的部分或全部内容。对于保密论文，按保密的有关规定和程序处理。

研究生签名：  2014年3月27日

摘 要

随着科技进步、计算机技术和互联网资源共享的高速发展,数据挖掘成为近年来人们关注的研究热点。数据挖掘是指从海量数据信息中获取有效、新颖、隐含有价值的信息。不平衡数据集分类算法是数据挖掘的一个重要分支,针对不平衡数据集分类算法的研究,本文主要工作如下:

首先从不平衡数据集的采样法入手,设计出约束型欠采样法。该方法先对不平衡数据集用 c-均值聚类法处理,接着对处理过的数据集进行欠采样,减小多类样本在数据集不平衡率,最后将约束型欠采样法和支持向量机算法(SVM)结合起来,对不平衡数据集进行分类研究。

然后研究了基于遗传算法的不平衡数据集模糊分类系统的构造方法,首先采用 GK 聚类算法辨识初始的模糊分类系统,然后利用遗传算法优化初始的模糊分类系统,提高了模糊分类系统的精确性。

最后为解决模糊分类系统解释性较差的问题,研究了不平衡数据集模糊分类系统的协同进化算法,该方法对所获得的初始的模糊系统进行结构和参数的优化,在保证精确性的前提下,最大程度提高分类系统的解释性。

关键词:不平衡数据集; 采样法; 支持向量机; 模糊分类系统; 协同进化算法

Abstract

With the rapid development of computer technology and the internet resource sharing, data mining becomes a hot spot in recent years. Data mining is the meaning that access to effective, innovative, hidden valuable information from massive data. Unbalanced data set classification algorithm is an important branch of data mining. In the study of unbalanced data sets classification algorithm, the main work is completed as follows:

Starting from the sampling method unbalanced datasets, this article designs the constraint sample method. Firstly, this method treatments with c-means clustering method on unbalanced datasets, and then executes subsampling deal on the processed data to reduce imbalance ratio of many types of samples in the dataset. Finally, combines the constraint sample method with SVM, and classifies the unbalanced datasets.

Then this article study the construction method unbalanced datasets fuzzy classification system based on genetic algorithm. Firstly, identify the initial classification system based on fuzzy clustering algorithm GK. Then this article optimizes initial fuzzy classification system using genetic algorithms to improve the accuracy of fuzzy classification system.

Finally, explanatory problem of the fuzzy classification system obtained by the above algorithm is poor. So the article studies the coevolutionary algorithm of unbalanced datasets fuzzy classification system, which can optimize structure and parameters of the obtained initial fuzzy system. Improve the explanatory classification system maximizngly under the premise of ensuring accurate.

Key words: imbalanced data sets; sampling; support vector machine (SVM) ; fuzzy classification system; MOCOEA

目 录

摘 要	I
Abstract.....	III
1 绪论	1
1.1 论文研究的目的和意义	1
1.2 国内外研究现状	1
1.3 论文的主要内容和结构	4
1.4 本章小结	5
2 不平衡数据集概述及其分类算法	7
2.1 不平衡数据集概述	7
2.2 典型的不平衡数据集分类算法	8
2.2.1 AdaBoost 算法	8
2.2.2 SMOTE 算法	9
2.2.3 其它分类算法	11
2.3 不平衡数据集分类算法的性能指标	12
2.4 不平衡数据集分类特点	14
2.4.1 样本缺失和噪声数据	14
2.4.2 不恰当的评价指标	14
2.4.3 不恰当的归纳偏置	15
2.5 本章小结	15
3 不平衡数据集的约束型欠采样支持向量机算法	17
3.1 数据集的采样法	17
3.1.1 过采样法	17
3.1.2 欠采样法	17
3.1.3 智能式采样法	18
3.1.4 其他采样方法	18
3.2 约束型欠采样方法	19
3.2.1 设计思想	19
3.2.2 算法描述	20
3.3 支持向量机算法	21
3.4 基于约束型欠采样的支持向量机	23
3.4.1 设计思想	23

3.4.2 算法描述	24
3.5 仿真结果及分析	25
3.6 本章小结	29
4 不平衡数据集的遗传模糊分类算法	31
4.1 模糊系统	31
4.1.1 模糊系统的结构	31
4.1.2 模糊系统类型	33
4.1.3 模糊分类系统	34
4.2 模糊分类系统的初始化	35
4.3 不平衡数据集的遗传模糊分类算法	37
4.4 不平衡数据集的遗传模糊分类算法步骤	39
4.5 仿真结果及分析	40
4.5.1 Wisconsin Breast Cancer 分类问题	40
4.5.2 Glass7 分类问题	42
4.5.3 Ecoli5 分类问题	42
4.6 本章小结	43
5 不平衡数据集的协同进化分类算法	45
5.1 模糊系统的分解和各种群染色体编码	45
5.2 子种群染色体之间的合作	46
5.2.1 种群个体的适应度计算策略	47
5.2.2 适应度函数	48
5.3 种群的遗传操作	49
5.4 多目标协同进化算法 (MOCOEA) 步骤	49
5.5 仿真结果及分析	52
5.5.1 Wisconsin Breast Cancer 分类问题	52
5.5.2 Class7 分类问题	53
5.5.3 Ecoli5 分类问题	54
5.6 本章小结	56
6 结论与展望	57
致 谢	59
参考文献	61

1 绪论

1.1 论文研究的目的和意义

随着科技进步、计算机技术和互联网资源共享的高速发展，各个领域都涌现出大量的数据信息。面对各行各业庞大的且不断增长的数据信息，人们迫切需要从这些海量的数据信息中分类出有价值的信息和知识，因此在计算机领域就出现了一个新的技术——数据挖掘。数据挖掘是指获取有效、新颖、隐含有价值的信息，并且最终可被理解的特殊处理过程^[1]。数据挖掘的目标是为了找到各个数据间隐含的联系、特征等关联信息，从而发现以前的未知信息，而且是有价值的信息，这些信息对于即将进行的分类是重要的依据。

不平衡数据集分类问题是数据挖掘的一种特殊情况。人们在日常工作和学习过程中，虽然要处理的数据量很大，但人们要获得的真正有价值的信息通常是很少。例如，银行信用卡诈骗记录^[2]，信用卡消费记录中绝大多数信用卡消费是合法的，只有少数信用卡消费是信用卡诈骗，但这些少数信息对银行是非常有价值的信息。针对这类数据挖掘问题，人们提出了不平衡数据集分类算法。

在理论上，传统的数据分类法认为将两类样本分错（任意一类被误分成另一类）造成相同的分类损失，但在不平衡数据集分类中，拥有更大价值的少类样本要比多类样本更加重要，少类样本的分类错误会带来更大的损失。因此，传统的数据分类算法对不平衡数据集分类效果并不十分理想。所以，不平衡数据集分类算法就需要寻求新的分类方法和判别准则，提高分类算法对不平衡数据集的分类效果。

不平衡数据集分类广泛应用在日常工作和学习过程中，例如，文本分类、图像监测、图形处理、诈骗检测、金融贷款风险预测、医疗诊断预测、企业破产风险预测、电子设备与机器设备故障预测等多个领域^[3-7]，所以研究不平衡数据集具有广泛的应用前景和极高的现实意义。

综上所述，对不平衡数据集分类算法的研究，主要目的是提高算法对少类样本的识别率，且同时满足错分的代价最小。随着社会发展的需要，不平衡数据集分类已经成为数据挖掘和机器学习的一个重要研究课题。

1.2 国内外研究现状

近几年以来，不平衡数据集分类问题已引起国内外数据挖掘和机器学习领域的专家和学者的关注，自 2003 年国际机器学习会议（ICML）至近几年的国际知识和数据挖掘会议（KDD）都有针对不平衡数据集分类问题作了专门的会议研究，并发表了很多不平

衡数据集和相关分类问题的论文^[8-10]。

不平衡数据集是数据集中的特殊情况,针对不平衡数据集分类问题,目前主要的分类算法有:支持向量机算法(Support Vector Machine, SVM)、模糊分类算法、Boosting 算法、Fisher 线性判别分析方法(Fisher Linear Discriminant, FLD)、代价敏感学习方法(Cost Sensitive Learning)、Bagging 算法和决策树算法等。

(1) 支持向量机算法(SVM)

支持向量机由 Cortes 和 Vapnik^[11-12]于 1995 年提出,它是建立在统计学习理论和结构风险最小化原理基础上,在训练样本小,非线性,高维识别等分类领域表现出独特的优势,并得到了广泛实际应用,例如,在文本分类、语音识别、计算机入侵检测等领域的应用。在不平衡数据集分类问题中,支持向量机算法是通过多类样本和少类样本的支持向量(SV)来确定最佳分类超平面。随着计算机技术的不断发展,支持向量机理论也在逐步地完善。

目前,我国在支持向量机技术的发展上落后于国外先进水平,但随着我国经济社会发展的迫切需要,我国的科技工作者做了很多支持向量机技术的研究工作并取得了大量的科研成果,这些科研成果将对推动我国支持向量机的发展和发挥它的巨大作用有着重要的意义。

(2) 模糊分类算法

模糊分类系统^[13-14]是模糊系统和分类器共同组成的系统,是模糊系统在机器学习领域中的重要应用。模糊分类系统广泛应用在人类日常工作和学习领域中的实际分类问题,自 1965 年美国加州大学 Zadeh 教授^[13]首次提出模糊集合的概念后,模糊概念就加入了机器学习领域中,使得分类算法更适合实际分类问题的应用。

目前,国内外对于模糊系统的研究有很多是集中在优化系统的准确率和解释性指标上,主要有以下途径:① 基于传统方法的模糊建模,传统方法的特点是首先构建准确率较高的初始模糊系统,对得到的初始模糊系统进行简化(如模糊规则数、模糊集合数等),提高系统的解释性;② 基于神经网络的模糊建模,该方法的特点是用神经网络原理来优化模糊系统,通过神经网络来实现模糊系统的准确率与解释性的折衷;③ 基于生物进化思想的模糊建模,该方法的特点是将初始模糊系统编码为染色体的形式,以具备较好准确率和解释性的模糊系统为主要目标,采用生物进化算法同时优化该目标,最终得到二者折衷的模糊系统。

(3) Boosting 算法

1990 年, Schapire^[15]最初构造出一种多项式级的算法,即也就是最初的 Boosting 算法。但由于该算法在解决实际问题时存在诸多缺陷,1995 年, Schapire 和 Freund^[16]对 Boosting 提出通过调整权重来对该算法进行改进,改进后的算法称为 AdaBoost(Adaptive Boosting)算法。AdaBoost 算法特点是不需要提前知道弱分类器的任何性能指标(先验

知识)就能得到较好的分类效果。因此, Boosting 算法改进后更便于在实际中应用。

Joshi^[17]提出少类样本和多类样本迭代可以分别赋予不同的权重值的改进方法——即在每次迭代时只给某一类样本(多类或少类)重建权重值改为在每次迭代时少类样本和多类样本都要重新构建权重值,改进后的算法称为 RareBoost 算法。该算法改进后直接影响少类样本分类的召回率(Recall)和准确率(Precision)。

Guo^[18]提出了 DataBoost 算法,该方法也是在 Boosting 算法基础上进行改进的,它是将选中的具有少类样本和多类样本的特征样本加到原始的训练样本中,并得到新训练样本,最终使新训练样本的权重值和空间的划分重新平衡。由此可看出,DataBoost 算法主要是通过采用调整权重值使得训练样本重新平衡来改进 Boosting 算法。

Boosting 算法与其它传统分类算法相比有着较好的准确率和召回率,这些优点使 Boosting 算法一直成为广大研究者的研究热点。因此,针对该算法的其他不足人们提出了很多不同的改进方法,在 Boosting 算法的众多改进算法中除 Adaboost 算法、RareBoost 算法、DataBoost 算法外还有 BrownBoost 算法、LogitBoost 算法等。

(4) Fisher 线性判别分析方法

Fisher 线形判别算法^[19]具有计算简单、且在满足一定条件时能够实现最优分类效果的优点,因此该算法具有广泛的实际应用价值。但当两类样本的协方差矩阵不相同,会导致 FLD 算法的分类性能下降。针对这一问题,北京交通大学裘正定教授^[19]提出了对 Fisher 线形判别算法的改进——(Weighted Fisher Linear Discriminant 简称 WFLD)算法,改进的思想是通过 Fisher 线形判别算法加权来减小样本不平衡带来的影响。WFLD 算法能有效地提高 FLD 算法对不平衡数据集的泛化性能。

(5) 代价敏感学习方法

代价敏感学习方法^[20]的基本思想是根据不同的错误分类样本类型会导致不一样的代价原则,在设计分类器过程中修改分类过程中的错分代价函数 $H(i|x)$,使少类样本错分的代价远远大于多类样本错分的代价。因此,代价敏感学习方法的本质就是寻找降低总决策的代价函数 $H(i|x)$ 。

代价函数 $H(i|x)$ 数学表达式如下:

$$H(i|x) = \sum_j p(j|x) * c(j,i) \quad (1.1)$$

其中, $H(i|x)$ 表示分类器将样本 x 判定为类别 i 的代价, p 表示分类器将样本 x 判为类别 i 的概率, c 为代价矩阵。

(6) 其他分类算法

此外一些专家学者还利用 Bagging 算法、决策树、粗糙集等方法来探讨和研究不平衡数据集的分类问题。同时,还有些研究者通过重构新训练样本和分类算法改进相结合的方法来研究不平衡数据集的分类问题。例如,李正欣^[21]等人提出 SMOTE Boost SVM

集成方法,该算法思想是:首先利用 SMOTE 算法^[22]人工生成正类样本,然后再使用 SVM 算法作为弱分类器来构成 AdaBoost 算法的分类器,最后利用集成得到的分类算法来处理不平衡数据集。

1.3 论文的主要内容和结构

本文是针对不平衡数据集的分类问题进行研究,分析了不平衡数据集中样本分布的特点和不平衡数据集分类算法的特点,重点研究了数据集采样和预处理的方法和不平衡数据集模糊分类算法,其具体探讨和研究如下:

(1) 对采样方法进行研究。在常用的采样方法中,重点研究欠采样方法,本文设计出先对不平衡数据集采用 c-均值聚类法聚类处理,得到若干(通常取定 c)训练样本聚类子样本,接着对多类样本聚类子样本进行欠采样技术处理,然后将经过欠采样处理的多类样本聚类子样本和少类样本聚类子样本合并得到新的训练样本,最后使用支持向量机算法处理新训练样本。

(2) 对不平衡数据集分类算法的研究。本文基于模糊分类法和生物链的协同进化思想设计出一种不平衡数据集模糊分类系统的协同进化方法。该方法由以下二步组成:

① 利用模糊聚类算法辨识初始的模糊模型;② 利用协同进化算法对所获得的初始的模糊模型进行结构和参数的优化,最后得到符合要求的模糊分类系统。

全文共有五章:

第 1 章主要介绍不平衡数据集分类问题研究的目的、意义和国内外研究现状;最后列出本文的各个章节的主要内容。

第 2 章主要介绍不平衡数据集和它的常见分类算法及其优点和不足,不平衡数据集分类算法的性能标准等。

第 3 章介绍一种不平衡数据集的约束型欠采样的支持向量机算法,本章把该算法分类两个部分介绍:首先是介绍数据集的采样法、接着介绍约束型欠采样方法设计思想和具体描述、支持向量机算法;然后介绍不平衡数据集的约束型欠采样的支持向量机算法;最后介绍该算法的实验仿真。该算法思想是首先对不平衡数据集采用 c-均值聚类法聚类处理;接着对处理过的数据集进行欠采样技术处理,并得到新训练样本;然后对新训练样本采用支持向量机算法(SVM)进行分类,最后得到分类结果。

第 4 章介绍不平衡数据集的遗传模糊分类算法,该方法将模糊分类系统应用到不平衡数据集的分类,建立遗传算法的不平衡数据集模糊分类系统。该方法由以下二步组成:

(1) 利用 GK 聚类算法辨识初始的模糊分类系统;(2) 为了提高模糊分类系统的精确性,利用遗传算法优化初始的模糊分类系统。

第 5 章针对上述算法所获得的模糊分类系统解释性较差的问题,研究了不平衡数据

集模糊分类系统的协同进化算法,该方法对所获得的初始的模糊系统进行结构和参数的优化,在保证精确性的前提下,最大程度提高分类系统的解释性。

第6章是对全文进行总结,总结出本文所做的工作和不足,并对今后的相关工作进一步展望。

1.4 本章小结

本章主要介绍不平衡数据集分类问题研究的目的、意义和研究现状。首先介绍不平衡数据集分类问题研究的目的和意义;接着简述了不平衡数据集分类算法国内外研究现状;最后列出本文的各个章节的主要内容。

2 不平衡数据集概述及其分类算法

不平衡数据集广泛存在于文本分类、图像监测、图形处理、电子设备与机器设备故障预测等多个领域，所以研究它具有极高的应用前景和现实意义。不平衡数据集分类算法常见方法主要有：AdaBoost 算法、随机欠采样支持向量机算法、SMOTE 算法等。不平衡数据集分类算法的性能标准主要有：准确率（precision）、召回率（recall）、几何平均准则（g-mean）和 ROC 曲线等。

2.1 不平衡数据集概述

不平衡数据集是相对于平衡数据集而言得名的，所以也称不平衡数据集为非平衡数据集；它是指一个数据集（即训练样本）某一个样本子集元素的数目远少于其他样本子集元素的数目，其中样本元素数目多的称为多类样本（也称为负类样本）；样本元素数目少的称为少类样本（也称为正类样本），这类样本是我们最关心和主要研究的对象。由此可以看出：不平衡数据集只是训练样本中一类样本元素远远少于其它样本元素的一个特殊情况。平衡数据集与不平衡数据集二维比较图如图 2.1 所示。由于在不平衡数据集中，少类样本元素数目与多类样本元素数目不相等，甚至这两类样本数目相差很大，所以用传统的机器学习方法来对不平衡数据集进行分类时，会出现对少类样本分类准确率很低，但对多类样本分类准确率相对较高的情况，但是，在实际的日常生活、工作和学习中，对不平衡数据集少类样本的正确分类往往要比多类样本正确分类具有更大的实际应用价值。




图 2.1 二维平衡数据集与不平衡数据集比较图

不平衡数据集广泛存在于文本分类、图像监测、图形处理、诈骗检测、金融贷款风

险预测、医疗诊断预测、企业破产风险预测、电子设备与机器设备故障预测^[3-7]等多个领域，所以研究不平衡数据集具有广泛的应用前景和极高的实际意义。

2.2 典型的不平衡数据集分类算法

不平衡数据集分类算法常见方法主要有：AdaBoost 算法、SMOTE 算法、随机欠采样支持向量机算法，Fisher 线性判别分析方法（Fisher Linear Discriminant, FLD）、代价敏感学习方法（Cost Sensitive Learning）等。第三章对随机欠采样方法和支持向量机算法有专门的介绍，所以本章先不做介绍。

2.2.1 AdaBoost 算法

1990 年，Schapire 最初构造出一种多项式级的算法，即也就是最初的 Boosting 算法。Boosting 算法的突出优点是可以把弱分类规则转化为强分类规则，但它的弱点是早期用该算法来解决问题时要提前知道弱分类算法的分类正确率下限，实际上这很不容易做到。因此，1995 年，Schapire 和 Freund 对 Boosting 提出通过调整权重来对改进进行算法，改进后的算法称为 AdaBoost（Adaptive Boosting）算法，这种算法的分类效率和最先的 Boosting 算法的效率不相上下，但 AdaBoost 算法的优点是不需要提前知道弱分类器的任何性能指标，因此这种算法在实际应用中很简便。

随着机器分类算法的发展越来越成熟，机器分类算法在人们的学习、工作和生活中的应用也越来越广泛。近年来，AdaBoost 算法被广泛的应用在文本分类、图像监测、图形处理、人类语言理解和人类语音识别、远程教育、诈骗检测、金融贷款风险预测、医疗诊断预测、光谱分析等多个领域。下面简单地介绍和分析 AdaBoost 算法。

（1）Adaboost 算法介绍

AdaBoost 算法描述如下：

考虑训练样本为 $(x_1, y_1), \dots, (x_i, y_i), \dots, (x_m, y_m)$ ， $x_i \in X$ ， $y_i \in Y$ 。其中， X 是样本空间， $Y = \{-1, +1\}$ 。AdaBoost 算法在初始化时划分训练样本的权重值为 $1/m$ ，并按照此划分反复调用弱分类器分类算法对训练样本进行训练。每次对训练样本训练后，根据对训练样本的训练效果更新训练样本上的权重值，并按照新训练样本权重值进行训练——即训练效果不好的样本得到更大的权重值。反复迭代 T ($t=1, \dots, T$) 次，最终得到一个新的权重值。

AdaBoost 算法步骤如下：

输入：训练样本 $L=(x_1, y_1), \dots, (x_i, y_i), \dots, (x_m, y_m)$ ， $x_i \in X$ ， $y_i \in \{-1, +1\}$ ；迭代次数 T ($t=1, \dots, T$)、权重 $D_1(i) = 1/m$ ， $i=1, 2, \dots, m$ ；弱分类器 h 。

输出：AdaBoost 算法

主要步骤：

- (1) 对训练样本进行权重划分, 得到一个估计最佳的弱分类器 h_t : $h(x_i) \in \{-1, +1\}$;
- (2) 根据 h_t 弱分类器误差计算弱分类器的权重系数 a_t , 且 $a_t \in \mathbb{R}$;
- (3) 进行循环迭代运行;
- (4) 根据迭代更新计算权重值: $D_{t+1}(i) = \frac{D_t(i) \exp[-a_t y_i h_t(x_i)]}{Z_t}$, 其中 Z_t 标准化因子

为 $\sum_{i=1}^m D_t(i) \exp[-a_t y_i h_t(x_i)]$;

- (5) 结束循环;
- (6) 输出结果: $f(x_i, L) = \sum_{t=1}^T a_t h_t(x_i)$ 。

其中权重系数 a_t 计算公式为:

$$a_t = \frac{1}{2} \ln \frac{1 - \varepsilon_t}{\varepsilon_t} \quad (2.1)$$

(2) AdaBoost 算法的分析

随着人们对 AdaBoost 算法的研究和改进, 最终在理论上导出了弱分类器的分类误差公式, 即公式如下:

$$\varepsilon_t = \Pr_{i \sim D_t} [h_t(x_i) \neq y_i] \quad (2.2)$$

其中 ε_t 为 h_t 弱分类器的分类误差。

由以上式 (2.1)、式 (2.2) 和 AdaBoost 算法步骤中的公式可以看出: 在每一次迭代中可以通过选择 a_t 和 h_t 来使 Z_t 最小化达到减小弱分类器分类误差的效果。

通过大量的实验表明, AdaBoost 算法和其他的机器分类算法相比较, 有着它突出的优点: 通过对简单的弱分类器循环挑选, 每次得到一个最佳的弱分类器, 然后组合这些分类器得到一个更佳的分器, 从而很大程度的提高了分类准确率, 并且可以方便解决复杂分类问题; 同时 AdaBoost 算法可以对训练样本进行特征选取; 还有随着循环迭代次数的逐渐增多, 此时算法的运算重点也就转移到那些难分类的样本或样本点上, 因此那些难分类的样本或样本点的权重值就成指数增长, 从而 AdaBoost 算法有效的降低泛化误差。但 AdaBoost 算法也有对训练样本的噪声十分敏感和对弱分类器过于依赖等缺点。

2.2.2 SMOTE 算法

少类样本合成过采样技术简称为 SMOTE 算法, 它是由 Chawla.N^[22]等人提出的一种与传统的基于少类样本简单复制的过采样方法不同的新型过采样技术。SMOTE 算法是通过合成少类样本来的数量和分布特征来产生新的训练样本, 从而使新的训练样本中的多类样本与少类样本基本趋向平衡。

为了便于数学描述,在介绍 SMOTE 算法基本原理前,我们首先做出如下说明:

(1) 假设训练样本 S 中每个元素最多有 q 个属性,且少类样本记为 $x_i, i=1,2,\dots,n$, n 为少类样本元素的数目,少类样本 x_i 的第 h 个属性记为 $x_{ih}, h=1,2,\dots,q$, 若当 $x_{ik}=0$ 时,表示 i 个元素没有对应的第 k 个属性;多类样本记为 $y_j, j=1,2,\dots,m$, m 为多类样本元素的数目,多类样本的第 h 个属性记为 $y_{jh}, h=1,2,\dots,q$ 。

(2) 假设训练样本中少类样本 x_i 的同类 k -近邻集合记为:

$$P_i = \{p_{ik} | k=1,2,\dots,k, p_{ik} \in \text{少类样本} \cap p_{ik} \text{ 在少类样本中 } x_i \text{ 的 } k\text{-近邻}\};$$

且记少类样本 x_i 的异类 k -近邻集合为:

$z_j = \{z_{jk} | k=1,2,\dots,k, z_{jk} \in \text{多类样本} \cap z_{jk} \text{ 在多类样本中 } x_i \text{ 的 } k\text{-近邻}\}$; 样本 x_i 的 k -近邻备选集合记为 $D_i = \{D_{ik} | k=1,2,\dots,k\}$, 只有在备选集合 D_i 中元素参与下才能合成新的少类样本。

SMOTE 算法基本原理如下: 在训练样本 S 中对于少类样本元素 x_i , 第一步计算 x_i 同类 k -近邻集合 P_i , 在 SMOTE 算法中 k 一般取 $[5,10]$ 。从 P_i 中随机选择一个样本, 不妨设为 x_a , 则少类样本 x_i 与同类 k -近邻集合 P_i 中的 x_a 对应属性 q 上的差值记为 $\text{diff}(q)=x_{aq}-x_{iq}$ 。由此可以得出合成新的少类样本 f_{iq} 的数学表达式:

$$f_{iq} = x_i + (x_{aq} - x_{iq}) \times \text{rand}(0,1) \quad (2.3)$$

其中 $\text{rand}(0,1)$ 是表示在区域 $(0,1)$ 内的随机数。接下来按照开始设定的过采样率重复进行以上过程的操作, 并将合成的新的少类样本元素加入到初始训练样本中使得少类样本的数量增加, 从而不平衡程度会有大幅度降低, 得到新的训练样本, 这时得到的新训练样本中多类样本与少类样本在数量上基本达到平衡, 最后将这个新的训练样本利用分类器进行分类并得到结果。SMOTE 算法基本原理如图 2.2 所示。




图 2.2 SMOTE 算法基本原理示意图

SMOTE 算法基本步骤如下:

输入: 训练样本 S , 过采样率 (即少类样本扩大倍数) N , k -近邻参数 k , 少类样本

数目 n ;

输出: SMOTE 算法

主要步骤:

- (1) 计算少类样本 x_i 的 k -近邻同类集合;
- (2) 在样本 x_i 的 k -近邻同类集合中随机选择样本 x_a ;
- (3) 按照式 (2.3) 在 x_i 、 x_a 之间合成新样本;
- (4) 按照过采样率 N 重复以上操作;
- (5) 得到新的训练样本 S^1 ;
- (6) 对新的训练样本 S^1 采用分类器做分类处理;
- (7) 输出分类结果。

从几何角度上理解, SMOTE 算法本质就是在少类样本元素和它被选中的同类 k -近邻元素的连线上进行合成产生新的少类样本。通过 SMOTE 算法对训练样本进行采样处理并合成新的少类样本后, 使得少类样本拥有更大的泛化空间和特征属性, 从而可有效弥补传统过采样方法的不足, 使得分类器更方便和更高效的处理新的训练样本, 最终达到提高不平衡数据集分类的准确率、召回率等其他性能指标的目的。随着人们对 SMOTE 算法研究的逐步深入, 所以就随之出现了很多改进的思路和方法^[23-24]。例如, 将 SMOTE 算法和 AdaBoost 算法、 k -近邻算法思想的优点整合出新的采样法对数据集进行采样, 然后再将 SVM 算法和代价敏感 (Cost Sensitive Method) 算法思想的优点结合整合出新的分类算法, 最后得到分类结果。

尽管 SMOTE 算法的优点很多, 但它还是有一些缺点^[22]。例如由于合成少类样本过程中将少类样本元素的 k -近邻均作为同类, 没有考虑少类样本附近邻域中多类样本的分布和不平衡数据集的本身分布特征信息, 因此, 在 k -近邻选择上存在一定程度的盲目性; 如果新合成的少类样本不能表达原样本的分类特征信息时, 就会导致拟合过学习现象; 还有过采样本身就有容易导致分类器的过学习现象, 从而这些不足都是降低该算法分类效果的原因。

2.2.3 其它分类算法

除了以上介绍的不平衡数据集分类算法外, 还有基于 K-Means 聚类的分类算法、Fisher 线性判别分析方法、代价敏感学习方法、基于 k -近邻修剪技术的分类算法、基于 Bagging 的欠采样集成分类算法等。由于不平衡数据集分类算法很多, 在这就不赘述了, 下面简单介绍基于 K-Means 聚类的分类算法。

基于 K-Means 聚类的分类算法

基于 K-Means 聚类的分类算法^[25]是由 K-Means 聚类算法和分类器相结合而成, 即先通过 K-Means 聚类算法对训练样本处理后, 再运用分类器对聚类后的数据集做分类处

理。所以基于 K-Means 聚类的分类算法核心是 K-Means 聚类算法。下面重点介绍 K-Means 聚类算法。

K-Means 聚类算法是由 MacQueens^[26]提出的一个解决聚类问题的算法，它的算法基本思想大致是：首先从训练样本 S 中随机选择 N 个样本元素作为初始聚类中心点；然后根据这些聚类中心点在训练样本中的位置计算其它样本元素与聚类中心点的欧几里得距离（几何距离），再将其它样本元素划分到距离最近的聚类中心；最后计算新产生的聚类中心点集合或聚类质心，得到新的聚类中心。不断重复迭代以上过程，使 K-Means 聚类算法快速收敛——即聚类中心点不再变化。

基于 K-Means 聚类的分类算法基本步骤如下：

输入：训练样本 S ，聚类数目 N ；

输出：K-Means 聚类算法

主要步骤：

- （1）从训练样本 S 中随机选择 N 个样本元素作为初始聚类中心点；
- （2）计算其余的每个样本元素到 N 个聚类中心点的欧几里得距离，并根据欧几里得距离将其他样本元素划分到最近的聚类中心点；
- （3）计算新产生的聚类中心点集合，得到新的聚类中心；
- （4）当各个聚类中心点发生变化时，返回第二步；当各个聚类中心点不发生变化时，进行下一步；
- （5）得到 N 个聚类数目；
- （6）对处理过的训练样本 S 采用分类器做分类处理；
- （7）输出分类结果。

由此可以看出，基于 K-Means 聚类的分类算法是一个较为简单的不平衡数据集的分类算法。由于基于 K-Means 聚类的分类算法采用了 K-Means 聚类技术，使得分类器运算量有效减小，所以也有较好的分类准确率等性能。同时基于 K-Means 聚类的分类算法也有不少成功的应用，例如模式识别、文本分类等相关邻域。但该算法也有其不足之处，例如由于基于 K-Means 聚类的分类算法中 K-Means 聚类技术对选择聚类中心点十分敏感，所以选择初始聚类中心很小的变化就会对分类结果产生很大的影响。

2.3 不平衡数据集分类算法的性能指标

在分类问题中，性能指标是用来衡量分类算法分类效果的优劣。目前，不平衡数据集分类算法常见的性能指标主要有：准确率（precision）、召回率（recall）、几何平均准则（g-mean）和 ROC 曲线等。本文讨论的不平衡数据集问题都是二类分类问题（多类与少类问题），所以性能指标也都是建立在二类分类问题的基础上。

二类分类问题常用混淆矩阵^[27]如表 2.1 所示。在不平衡数据集中，我们把多类样本称为负类样本（Negative），少类样本称为正类样本（Positive）。表 2.1 中，TP 表示正确分类的正类样本数目；FP 表示分类算法将负类样本错分为正类样本的数目；TN 表示正确分类的负类样本数目；FN 表示分类算法将正类样本错分为负类样本的数目。

表 2.1 二类分类问题的混淆矩阵

样本类标	分类类标		
	被分正类样本	被分负类样本	总数
正类样本	TP	FN	n^+
负类样本	FP	TN	n^-

(1) 精确度（accuracy）:

$$accuracy = \frac{TP + TN}{n^+ + n^-}$$

(2.4)

式（2.4）是分类问题中常用的评价标准，它反映分类算法对数据集的整体分类性能，但该性能指标不能恰当的反映不平衡数据集分类算法的分类性能^[27]，这是由不平衡数据集自身特点决定的。

(2) 准确率（precision）:

$$precision = \frac{TP}{TP + FP}$$

(2.5)

准确率反映了分类算法正确分类的正类样本数目与所有被分为正类样本数目的比值。

(3) 召回率（recall）:

$$recall = \frac{TP}{TP + FN}$$

(2.6)

召回率反映了分类算法正确分类的正类样本数目与所有正类样本数目的比值。

(4) 几何平均准则（g-mean）:

$$g - mean = \sqrt{\frac{TP}{TP + FN} * \frac{TN}{TN + FP}}$$

(2.7)

几何平均准则是不平衡数据集分类算法的一个常用性能指标，它反映了分类算法对不平衡数据集两类样本分类性能的均衡程度，故能较全面的反映不平衡数据集分类算法的性能。

(5) ROC 曲线

ROC 曲线^[28](receiver operating characteristic curve)最初是在统计决策理论中提出，它是一种能全面反映分类算法的性能指标。ROC 曲线是在直角坐标系上，以虚假负类

准确率 ($FP/(FP+TN)$) 为 X 轴, 以真负类准确率 ($TN/(FP+TN)$) 为 Y 轴。分类算法的每一个阈值参数对应一个(x, y)点, 改变阈值参数时, 阈值参数所对应的点也相应的改变, 最后将改变后得到的点连起来就是分类算法在该数据集上的 ROC 曲线。

2.4 不平衡数据集分类特点

不平衡数据集分类特点主要有: (1) 数据层面的样本缺失和噪声数据; (2) 判别准则层面不恰当的评价指标; (3) 分类算法层面的不恰当的归纳偏置。

2.4.1 样本缺失和噪声数据

所谓数据层面是针对不平衡数据集的数据而言, 主要包含两个方面: 一是不平衡数据集本身的数据特点; 二是不平衡数据集的数据采样策略 (具体采样方法见第三章)。本节介绍的不平衡数据集样本缺失和噪声数据是在数据层面的研究。

在不平衡数据集中, 样本缺失主要是针对少类样本而言, 且它有两种情况。第一种是少类样本绝对的缺少, 即不平衡数据集中的少类样本数目本身就很少, 在分类过程中很难找出其内在规律和分布的特性信息, 从而使得分类器对少类样本的识别困难。第二种是少类样本相对的缺少, 即不平衡数据集中的少类样本绝对数目并不少、甚至数量还很大, 但是与多类样本数目相比要少得多——即多类样本数目和少类样本数目比值很大。因此多类样本会淡化少类样本的边界, 使分类器难以把少类样本与多类划分开来, 导致分类器更加有利于多类样本的分类^[29]。所以样本缺失的两种情况都会最终导致分类算法对不平衡数据集中的少类样本分类效果差。

大部分机器分类算法都会受噪声数据的影响。而噪声数据对不平衡数据集分类问题的影响更大。在不平衡数据集分类问题中, 由于少类样本数量很少, 且噪声数据和少类样本在分类器的处理过程中都会形成许多小析取项^[30], 因此分类器很难正确区分少类样本和噪声数据, 所以噪声数据对少类样本的负面影响要比对多类样本的负面影响大。由此可以看出, 噪声数据对不平衡数据集分类的影响也有其独特性。

2.4.2 不恰当的评价指标

所谓的判别准则层面是针对分类器性能的评价标准而言, 主要包括分类准确率、召回率、g-mean 性能、ROC 曲线等。本节介绍的不平衡数据集不恰当的评价指标是在判别准则层面的研究。

在传统机器分类中通常采用分类精确度作为分类器性能的评价指标, 但对不平衡数据集进行分类时, 由于多类样本远远多于少类样本, 如果分类算法过于追求高精确度, 在分类时分类器就会倾向于多类样本, 同时就会错分少类样本^[31]。若不平衡数据集是极端不平衡, 分类的结果就可能没有针对少类样本的分类规则——即分类器把训练样本几

乎全部分为多类样本。例如不平衡数据集 S , 仅有 1% 的正类样本, 那么分类算法只要把所有训练样本分为负类样本, 即可获得很高的精确度 (99%)。但这样的分类算法是没有意义^[32]。由此可以看出, 在不平衡数据集分类中, 把高分类精确度作为分类器的目标是不合适的。

2.4.3 不恰当的归纳偏置

所谓的算法层面是针对机器学习的分类算法而言。本节介绍的不平衡数据集不恰当的归纳偏置是对分类算法进行的研究。

在对不同的样本进行归纳时一般需要特定的合理偏置。分类算法的归纳偏置对算法的分类性能有较大的影响, 很多分类算法都通过采用合理的归纳偏置来提高分类算法的泛化能力与避免过拟合。许多分类算法的归纳推理系统在处理不确定样本时常常倾向于把该样本分类为多类样本^[30], 从而导致少类样本分类准确率降低, 由此可见, 不恰当的归纳偏置对不平衡数据的分类效果有很大负面影响。

2.5 本章小结

本章首先简单地概述了不平衡数据集及其特点, 接着介绍了不平衡数据集的几种典型分类算法, 并介绍了不平衡数据集分类算法的性能指标, 最后归纳了不平衡数据集分类特点, 通过学习不平衡数据集及其研究现有不平衡数据集分类算法, 为总结改进分类效果的思路和方法做准备。

3 不平衡数据集的约束型欠采样支持向量机算法

通过第二章对现有不平衡数据集分类算法的学习,本章设计出一种不平衡数据集的约束型欠采样的支持向量机算法。该分类算法主要采用如下步骤实现:首先对不平衡数据集采用 c-均值聚类法做聚类处理;接着对处理过的数据集进行欠采样技术处理,并得到新训练样本;然后对新训练样本采用支持向量机算法(SVM)进行分类,最后得到分类结果。约束型欠采样的支持向量机算法的主要优点是实现了减小训练样本中正负样本数目的不平衡率对分类效果的负面影响,同时最大化的保留删减样本后的内部特征的分布信息,从而使分类算法有较好的分类效果。

3.1 数据集的采样法

目前对数据集的采样处理,人们提出很多不同的数据采样方法。根据对不平衡数据集训练样本的正负类样本数目差别可分为:过采样法——即增加训练样本中正类样本(少类样本)的数目;欠采样法——即约减训练样本中分类样本(多类样本)中的数目。按照对训练样本分类方法的智能性可分为:智能式采样法和非智能式采样法。过采样法和欠采样法一般认为是非智能式采样法。

3.1.1 过采样法

过采样法是针对不平衡数据集的正负样本数目严重不平衡提出的采样方法,它是简单地复制训练样本中少类样本来增加少类样本的数目^[33],减缓少类样本在训练样本中的失衡现象,从而提高分类算法对不平衡数据集的分类准确率、召回率和几何平均准则 g-mean 和其它分类性能。但由于目前所能搜索到的参考文献和资料中使用的过采样方法多数都是基于随机过采法,它是简单的、随机的复制少数样本,所以就会产生很多没有分布特性和结构特性价值的少类样本给分类器的计算量加大,使分类器在庞大的训练样本中计算、运行,从而容易导致分类器的过学习现象,降低分类算法的分类效果。

3.1.2 欠采样法

欠采样法也是针对不平衡数据集的正负样本数目严重不平衡提出的采样方法,它的采样法思想与过采样法思想相反,它是简单地删减训练样本中多类样本的数目,降低多类样本在训练样本中的严重不平衡程度^[34],从而提高分类算法对不平衡数据集的分类效率。但目前所能搜索到的参考文献和资料中使用的欠采样方法一般都是基于随机欠采法,这类方法不能考虑训练样本中的多类样本的内部真实的分布特性和结构特性,因此这类采样方法具有较大的盲目性和随机性,采样后得到的新训练样本难以保证原训练样

本的分布特性和结构特性，从而导致分类信息失真和丢失。同时一些训练样本中的多类样本邻域密度高，约减涉及到多类样本之间的距离计算和排序，计算成本非常高，难于实际广泛应用，并降低分类算法对训练样本的分类效果。

3.1.3 智能式采样法

智能式采样法是相对于传统的随机欠采样和随机过采样而言的，它在删减和增加训练样本中样本时考虑到了其内部特征消息^[35]。智能式采样法的基本思想是：在训练样本Q中指定两个样本 x_i, y_i ，且 x_i, y_i 是属于不同的样本类，记它们之间的距离为 $d(x_i, y_i)$ 。若不存在其他的样本 β 满足： $d(x_i, \beta) \leq d(x_i, y_i)$ 或 $d(y_i, \beta) \leq d(x_i, y_i)$ 时；则是对训练样本Q智能采样。若 x_i, y_i 是智能采样的两类样本，且满足上述条件；则这两个样本一定有一个是噪声点，或两个样本都在两类样本的边界上。如图3.1所示。

由此我们可看出，智能式采样法在删除多类样本的同时，也尽可能的保留了原样本的分布特性和结构特性，减少了因对多类样本随机的、盲目的约减导致多类样本的分类信息失真和丢失，同时也尽可能的避免对少类样本简单的、随机的复制而给分类器的计算量加大，导致机器学习分类器的过学习现象。




图 3.1 智能采样法定位边界和噪声点原理图

3.1.4 其他采样方法

除了上述的不平衡数据集采样法外，还有许多数据采样法，例如邻域清理采样法(NCL)，混合采样法(MSM)等。

邻域清理采样法^[36](Neighborhood cleaning rule, NCL)是由 Wilson 改进的最近邻规则(edited nearest neighbor, ENN)——对多类样本进行欠采样改进而来。邻域清理(NCL)采样法的方法思想是：设训练样本为Q，在Q中的每个子样本 x 找出离 x 最近的三个子

样本，若 x 为负类样本（多类样本），并且这三个最近样本有两个或三个是正类样本（少类样本），则删除 x ；若 x 为正类样本，并且这三个最近样本有两个或三个是负类样本，则删掉三个最近样本中的负类样本。邻域清理采样法是根据已知样本和它最近邻样本的分类特性来决定删减样本，所以比传统的欠采样法更精确。

混合采样法^{[27][37]}(Mixed sampling method, MSM)是欠采样和过采样的混合方法。混合采样法的方法思想是：首先对训练样本进行修剪处理，可以降低分类器的计算复杂度；接着通过增加少类样本的数量，减小少类样本在训练样本中的不平衡程度；最后删减多类样本的数量，减缓多类样本在训练样本中的严重不平衡程度。对训练样本的修剪方法一般用模糊样本修剪法(FSCT 修剪法)和传统的单边采样方法(过采样法或欠采样法)。




图 3.2 基于混合采样法的 SVM 分类算法流程图

混合采样法是将欠采样法和过采样法有机的结合在一起，充分利用了欠采样法删减多类样本数量降低分类器的计算复杂度的优点；同时，又利用了过采样法增加少类样本的数量减轻训练样本的严重不平衡度的优点。所以混合采样法相对于传统的单边采样法有较大的优越性。混合采样法的算法流程图如上图 3.2 所示。

3.2 约束型欠采样方法

3.2.1 设计思想

综合前面学习到的知识，我们可以从不平衡数据集的数据采样中总结出：不平衡数

数据集采样方法是对少类样本进行过采样法或是对多类样本进行欠采样法来消除不平衡数据集的不平衡程度。同时,过采样法和欠采样法分别有其固有的不足之处——分类器过学习和样本失真。因此,我们得出约束型欠采样方法(Restricted subsampling method, RSM)的设计思想是:尽可能保留采样法对消除不平衡数据集的不平衡程度的优点,且改进采样法自身的不足。约束型欠采样方法(RSM)的具体思路是:首先对不平衡数据集 S 进行 c -均值聚类技术(fuzzy c -means algorithm, FCA)处理,得到 c 个聚类子样本,对每个子样本集进行采样,当一个聚类中多类样本远远多于少类样本时,那么这个聚类就可近似的看作为多类样本聚类子样本;相反,当一个聚类中少类样本远远多于多类样本时,该聚类就可近似的看作为少类样本聚类子样本。接着对多类样本聚类子样本依照预先设置的比例 T 进行欠采样;最后将经过欠采样处理的多类样本聚类子样本和少类样本聚类子样本合并得到新的训练样本 S_1 。约束型欠采样方法的主要优点是:先用 c -均值聚类对训练样本进行处理就可以保证采样的样本均匀分布,同时,欠采样法减缓了训练样本的不平衡度,实现了减小多类样本在训练样本中的不平衡对分类效果的负面影响和最大化的保留删减样本的内部特征的分布信息。

3.2.2 算法描述

首先输入不平衡数据集利用聚类算法辨识并聚类数据集,保证欠采样技术合理的采样,这样有效节省搜索的空间和时间。目标函数的聚类是最常用的方法之一,本章采用 c -均值聚类法^[38-39]。

c -均值聚类法的目标函数为:

$$J_m(V, P) = \min \left\{ \sum_{i=1}^n \sum_{k=1}^c u_{ik}^m d_{ik}^2(x_i, p_k) \right\} \quad (3.1)$$

其中, P_k 为第 k 类的聚类中心, $x_i \in S$, $i=1,2,3,\dots,n$, S 为训练样本,且 n 为训练样本总数目, V 为数据集 S 的划分矩阵, P 是聚类中心矩阵——即隶属函数的中心, $d_{ik}(x_i, p_k)$ 表示样本元素 x_i 到聚类中心 P_k 的欧几里得距离, c 是聚类数目, m 是加权指数,通常经验取值为 2,且目标函数满足以下约束条件:

$$\sum_{i=1}^n u_{ik} = 1, \quad 1 \leq k \leq n, \quad u_{ik} \in [0,1] \quad (3.2)$$

$d_{ik}(x_i, p_k)$ 欧几里得距离表达式为:

$$d_{ik}(x_i, p_k) = \|x_i - p_k\|^2 = (x_i - p_k)^T (x_i - p_k) \quad (3.3)$$

利用拉格朗日乘法可以求得使目标函数最小的必要条件为:

$$u_{ik} = \frac{1}{\sum_{j=1}^c \left(\frac{d_{ik}}{d_{jk}} \right)^2}, \quad \text{且 } d_{ik} \neq 0 \tag{3.4}$$

$$p_k = \frac{\sum_{i=1}^n (u_{ik})^2 x_i}{\sum_{j=1}^n (u_{jk})^2} \tag{3.5}$$

假设在训练样本 S 中，样本总数目为 N，使用 c-均值聚类技术，可以得到每个聚类子样本中要选取的样本数量 N/c ，在根据一定的聚类规则，如根据欧几里得距离公式得出的距离，属性等规则将同种类型样本（少类或多类样本）聚类在一个聚类子样本中，并选出多类样本聚类子样本，然后对选出多类样本聚类子样本进行欠采样技术处理，最后将经过欠采样处理的多类样本聚类子样本和少类样本聚类子样本合并得到新的训练样本 S_1 。

约束型欠采样方法(RSM)步骤如下：

输入：训练样本 S；

输出：新训练样本 S_1 ；

主要步骤：

- （1）输入训练样本 S；
- （2）对训练样本 S 用 c-均值聚类技术处理，得到 c 个聚类样本
- （3） $i \in [1, c]$ ，在 c 中依次查询，找出重复的 i 子样本；
- （4）对 c 中重复的多类样本子样本进行欠采样；
- （5）将经过欠采样处理的多类样本聚类子样本和少类样本聚类子样本合并得到新训练样本 S_1 ；
- （6）输出新训练样本 S_1 。

3.3 支持向量机算法

支持向量机^{[11]·[12]}(Support Vector Machine, SVM)由 Cortes 和 Vapnik 于 1995 年提出，它是建立在统计学习理论和结构风险最小原理基础上，在训练样本小，非线性，高维识别等分类领域表现出独特的优势，并得到了广泛应用。支持向量机 (SVM) 的算法思想主要就是在训练样本的特征空间中找出一个最佳分类超平面，使得正负样本集之间的距离达到最大——即支持向量机的缓冲间隔达到最大。支持向量机算法对标准的训练样本有很好的分类效果，如图 3.3 所示，H 为标准数据集中 SVM 的最佳分类超平面，图 3.3 中的正方形和圆形代表训练样本的两类样本，在平面线性可分的分类模式中，分类平面表示为分类线。H₁, H₂ 之间的距离为 SVM 缓冲间隔，记为 Margin。但支持向量机(SVM)

对不平衡数据集训练样本分类效果不好, 主要会对正类样本(少数类样本)错误分类, 即每个样本都可能会被 SVM 分类器简单地识别为负类样本, 导致分类准确率下降。导致 SVM 对不平衡数据集分类效率下降的原因之一是由于 SVM 缓冲间隔自身存在的缺陷。记任意训练样本集为 S , l 为样本集 S 的大小, 训练样本集的数学表达式为: $S = \{(x_i, y_i), i = 1, 2, 3, \dots, l\}, x_i \in R^N, y_i \in \{-1, 1\}$ 。SVM 缓冲间隔的数学表达式:

$$\text{Sgn } f(x) = \left\{ \sum_{i=1}^l y_i a_i K(x, x_i) + b \right\} \quad (3.6)$$

式 (3.6) 是 SVM 缓冲间隔数学方程式, a_i 是拉格朗日系数, b 为阈值。假设训练样本集




图 3.3 标准训练样本 SVM 的最佳分类超平面

S 存在最佳分类超平面, 且记最佳分类超平面为:

$$w \bullet \phi(x) + b = 0 \quad (3.7)$$

将最佳分类超平面问题转化为二次规划问题:

$$\begin{cases} \frac{1}{2} \|w\|^2 + C \sum_{i=1}^l \beta_i \\ \text{St. } y_i (w \bullet \phi(x)) + b \geq 1 - \beta_i \end{cases} \quad (3.8)$$

式 (3.8) 中, C 为惩罚常数, $\beta_1, \beta_2, \dots, \beta_l$ 为松弛变量因子。由式 (3.6), 式 (3.8) 可知, 要求 SVM 缓冲间隔的最佳分类超平面问题 (即最大缓冲间隔或最大正负类样本间的距离) 就可转化为根据拉格朗日系数求拉格朗日极值的驻点问题, 由拉格朗日极值法可得:

$$\begin{cases} \max L_p = \frac{1}{2} \|w\|^2 + C \sum_{i=1}^l \beta_i - \sum_{i=1}^l a_i [y_i (w \bullet \phi(x)) + b - 1 + \beta_i] - \sum_{i=1}^l r_i \beta_i \\ \text{St. } 0 \leq a_i \leq C \\ \sum_{i=1}^l a_i y_i = 0 \end{cases} \quad (3.9)$$

得最佳分类超平面的法向量为:

$$w = \sum_{i=1}^l a_i y_i \phi(x_i) \quad (3.10)$$

求得阈值 b 为:

$$b = y_i - \sum_{i=1}^l a_i y_i K(x_i, y_i) \quad (3.11)$$

由以上数学公式推导可得出支持向量机在不平衡数据集分类中效果差的原因主要有以下三个^[40-41]:

(1) 式 (3.8) 中 $1/2 \|w\|^2$ 的最小化作用等价于分类缓冲间隔 $\text{Margin}(H) = 2/\|w\|^2$ 的最大化; 式 (3.8) 中第二部分 $C \sum_{i=1}^l \beta_i$ 是 $1/2 \|w\|^2$ 最小化分类中的必然误差 (也称风险误差), 在不平衡数据集分类时, 当 C 的取值较小时, 那么 $C \sum_{i=1}^l \beta_i$ 的值也会较小, 那么几乎每个训练样本的子样本都会被 SVM 分类为负类样本 (多数样本), 大大降低了正类样本 (少数样本) 的分类准确率, 当 C 较大时, 会出现分类过学习现象, 从而降低分类的准确率。

(2) 在不平衡数据集里, 少类样本的特征信息较弱于多类样本的特征信息, 容易被多类样本的特征信息所屏蔽, 导致缓冲间隔很窄, 结果会将最佳分类超平面向多类样本方向偏移, 因此少类样本分类效果较差。

(3) 当不平衡数据集训练样本数目严重失衡时, 多类样本的支持向量 (SV) 数明显多于正类样本的支持向量数, 由于最佳分类超平面是由支持向量来决定, 必然导致最佳分类超平面向正类样本方向移动。综上可得出, 现有的支持向量机分类法在不平衡数据集中应用时, 对负类样本 (多数样本) 分类有较好的精确性, 但对正类样本 (少数样本) 的分类效果较差。

3.4 基于约束型欠采样的支持向量机

3.4.1 设计思想

为了克服训练样本的不平衡造成最佳分类超平面的偏移, 人们使用了欠采样对不平衡数据集进行处理。如图 3.4 所示, 利用欠采样法对多类样本进行处理, 理想上能使正负类样本数量基本相等, 然后再对处理后生成的新训练样本用 SVM 分类器分类处理。由图 3.4 可以看出, 这样做确实能使正负类样本距最佳分类超平面的距离基本相等, 并且实际分类平面也与最佳分类超平面很接近。但在实际应用中出现了一个问题, 由于在对训练样本中的多类样本做欠采样处理的过程中, 我们不了解多类样本的内部真实的分布特性和结构特性, 必然出现盲目的欠采样, 造成多类样本中所含分类特征信息的大量

丢失，因此分类器分类得到的实际最佳分类超平面与理想中的最佳分类超平面有较大出入，因此实际应用的分类效果不好。所以上面我们设计出约束型欠采样方法来改进传统数据集的欠采样法。

大量实验研究和文献证明欠采样技术结合 SVM 分类器处理数据集时主要有下面几个优点^[41]：

- (1) 支持向量机算法拥有扎实的理论依据，且欠采样技术结合 SVM 分类器处理数据集时分类效果好；
- (2) 欠采样技术能够有效减少数据集中样本的数量，从而有效的缓减了支持向量机算法在分类中的核矩阵求解复杂度，因此提高了分类系统的响应灵敏度；
- (3) 支持向量机算法便于理解和用计算机语言来实现。




图 3.4 对多类样本进行欠采样后用 SVM 分类法示意图

综合所述，我们得出基于约束型欠采样的支持向量机算法的思想是将约束型欠采样技术和支持向量机相结合的方法—即首先对不平衡数据集 S 采用约束型欠采样方法做数据采样处理，并得到新的训练样本 S_1 ，然后对新训练样本 S_1 用支持向量机算法做分类处理，最终得到分类结果。

3.4.2 算法描述

由于模糊 c -均值聚类法的计算能力强，同时又对聚样本进行了欠采样技术的处理，形成了新训练样本，减小了 SVM 分类器的计算复杂度，所以分类的速度和效果都有明显的提高。基于约束型欠采样的支持向量机(RSM-SVM)算法步骤如下：

输入：训练样本 S
输出：RSM-SVM
主要步骤：

- (1) 输入训练样本 S ；
- (2) 对训练样本 S 用 c -均值聚类技术处理，得到 c 个聚类样本

- (3) $i \in [1, c]$, 在 c 中依次查询, 找出重复的 i 子样本;
- (4) 对 c 中重复的多类样本子样本进行欠采样;
- (5) 将经过欠采样处理的多类样本聚类子样本和少类样本聚类子样本合并得到新的训练样本 S_1
- (6) 使用 SVM 处理新训练样本 S_1 ;
- (7) 测试分类器的分类效果: 若分类结果正确, 就输出结果; 若分类结果不确, 则返回到 c -均值聚类法重新运行;
- (8) 结束运算。

基于约束型欠采样的支持向量机(RSM-SVM) 算法流程图如图 3.5 所示。




图 3.5 RSM-SVM 算法流程图

3.5 仿真结果及分析

为了验证本章算法 (RSM-SVM) 的有效性和实用性, 我们从 (<http://www.ics.uci.edu/epository.html>, 简称 UCI) 机器学习数据集中获得五个数据集, 分别是: Pima、Glass、Sick、Yeast、Abalone 数据集。首先对实验数据集分别做如下处理: Pima 数据集选取类标 6 的一类为少类样本, 其余类都划分为多类样本; Glass 数据集选取类标 7 的一类为少类样本, 其余的都划分为多类样本; Sick 数据集选取类标 2 的一类为少类样本, 其余的都划分为多类样本; Yeast 数据集选取类标 5 的一类为少类样本, 其余的都划分为多类样本; Abalone 数据集选取类标 19 的一类为少类样本, 其余的都划分了多类样本。各数据集具

体数据如表 3.1 所示。

表 3.1 实验数据集数据

数据集	属性	少类样本	多类样本	样本总数目	不平衡率
Pima	8	268	500	768	1:2
Glass	10	29	185	214	1:7
Sick	9	231	3541	3772	1:15
Yeast	8	51	1433	1484	1:28
Abalone	8	32	4145	4177	1:130

在验证 RSM-SVM 算法的有效性和实用性前，我们要确定 RSM 采样法中的最佳参数。RSM 涉及到 c -均值聚类法的 c 参数和欠采样比例 T 。所以我们在 UCI 中找出两个常用数据集——Pima 和 Abalone 数据集进行实验，确定最佳参数 c 和 T 。我们先对数据集分别用 RSM 采样法和随机欠采样法处理后，再用 SVM 分类器做分类处理。在两个数据集上的分类效果如图 3.6 和图 3.7 所示。图中横轴是欠采样比例 T ，纵轴是 precision 准确率， c 分别取 10,25,50。




图 3.6 RSM 采样法与随机欠采样法的准确率比较图（Pima 数据集）




图 3.7 RSM 采样法与随机欠采样法的准确率比较图（Abalone 数据集）

综合图 3.6 和图 3.7 我们可以看出：欠采样比例 T 渐进于不平衡数据集的不平衡率时，分类效果就逐渐变好；当其他参数不变时，欠采样比例 T 等于不平衡数据集的不平衡率时，分类效果最好； c -均值聚类的 c 参数不宜过大或过小，通过对多个 UCI 数据集的实验发现， c 参数的取值范围在 $[20,40]$ 内效果较好， c 参数过大会给分类器的计算量大大增加， c 参数过小就会在删减多类样本时使少类样本内部特征信息丢失。因此我们在以下的实验中 c 参数取 25，欠采样比例 T 取数据集的不平衡率时效果最佳。

仿真程序在 Matlab R2010a 中运行完成。在确定了本章算法（RSM-SVM）中参数后，我们用表 3.1 所示的五种数据集做分类实验来测量 AdaBoost 算法，随机欠采样+SVM 算法，SMOTE+SVM 算法，本章算法（RSM-SVM）的分类 precision 准确率、recall 召回率和几何平均准则 g-mean 性能。各种分类算法在 Pima、Glass、Sick、Yeast、Abalone 数据集中的 precision 准确率如表 3.2 所示。

表 3.2 各种算法分类准确率（precision）（%）比较				
数据集	AdaBoost 算法	随机欠采样+SVM	SMOTE+SVM	本章算法
Pima	69.3	70.9	70.4	70.2
Glass	79.8	90.9	91.7	81.4
Sick	73.5	85.9	76.3	76.5
Yeast	60.8	73.2	61.1	77.8
Abalone	66.7	68.2	87.3	88.6

各种分类算法在 Pima、Glass、Sick、Yeast、Abalone 数据集中的 recall 召回率如表 3.3 所示。

表 3.3 各种算法分类召回率（recall）（%）比较				
数据集	AdaBoost 算法	随机欠采样+SVM	SMOTE+SVM	本章算法
Pima	67.8	88.6	83.4	75.5
Glass	70.4	87.1	87.3	86.4
Sick	68.4	86.4	73.5	86.9
Yeast	98.3	98.9	97.8	100
Abalone	71.1	88.1	78.2	87.6

虽然从以上表 3.2 和表 3.3 仔细比较还是可以看出各种分类算法的准确率和召回率的优缺点，但不够明显，所以为了更直观的比较各种分类算法的优缺点，我们同时给出了各种算法在 Matlab R2010a 中的仿真比较图。

各种分类算法在 Pima、Glass、Sick、Yeast、Abalone 数据集中分类的 precision 准确率和 recall 召回率比较图如图 3.8 和图 3.9 所示：




图 3.8 本章各种算法准确率比较图




图 3.9 本章各种算法召回率比较图

综合表 3.2 和表 3.3、图 3.8 和图 3.9 的对比可明显的看出：各种算法对各个不同数据集的分类性能指标有较大的差别——即随着数据集的不平衡率增大而各种算法分类的 precision 准确率和 recall 召回率有所提高。表 3.2 中本章算法对 Pima 和 Abalone 的准确率分别为 70.2%和 88.6%；表 3.3 中本章算法对 Pima 和 Yeast 的召回率分别为 75.5%和 100%。但由于不平衡数据集的训练样本分布的严重不均衡通常会导致不均衡的错分分类损失——即错分少类样本损失要远远大于错分多类样本的损失。所以 precision 准确率和 recall 召回率在评价不平衡数据集分类算法上有其不足。因此我们要进一步研究各种分类算的几何平均准则 g-mean 性能。

各种分类算法在 Pima、Glass、Sick、Yeast、Abalone 数据集集中的几何平均准则 g-mean

性能如表 3.4 所示:

表 3.4 各种算法分类 g-mean (%) 性能比较

数据集	AdaBoost 算法	随机欠采样+SVM	SMOTE+SVM	本章算法
Pima	68.5	79.2	76.9	72.8
Glass	74.9	88.9	89.4	83.8
Sick	70.9	86.1	74.9	81.5
Yeast	77.3	85.1	77.3	88.2
Abalone	68.8	77.5	82.3	87.4

各种分类算法在 Pima、Glass、Sick、Yeast、Abalone 数据集中的几何平均准则 g-mean 性能比图如图 3.10 所示。




图 3.10 本章各种算法在各个数据集中分类的 g-mean 性能比较图

由以上表 3.2、表 3.3、表 3.4 和图 3.8、图 3.9、图 3.10 可以看出无论是哪种分类算法，都不能使准确率（Precision）性能和召回率（Recall）性能同时提高。但本章算法（RSM-SVM）与其他几种算法相比，对五个不同数据集分类的准确率性能和召回率性能也有明显的优势，同时 g-mean 性能也不逊色于其他分类算法。由此可以发现，RSM-SVM 算法对不平衡率较高的数据集分类效果比较好。

3.6 本章小结

在不平衡数据集分类处理中，对数据集采样法的改进是提高不平衡数据集分类算法的分类准确率（precision）、召回率(recall)和 g-mean 性能等性能指标不理想的重要方法之一。本章分析了现有的数据采样方法的不足之处，针对过采样法容易导致分类器的过学习现象和欠采样法具有较大的盲目性和随机性容易导致分类信息失真和丢失等问题，

得出了一些改进的思路，设计了不平衡数据集的约束型欠采样支持向量机算法。

不平衡数据集的约束型欠采样的支持向量机算法的设计方法由以下三步组成：(1) 使用模糊 c -均值聚类算法 (FCA) 对训练样本 S 的进行聚类，得到 c 个聚类样本；(2) 对每个多类的聚样本依照预先设置的比例 T 进行欠采样，产生一个新的训练样本 S_1 ；(3) 应用 SVM 分类器来处理新训练样本 S_1 。不平衡数据集的约束型欠采样的支持向量机算法的主要优点是：该算法在对不平衡数据集采样时，既实现了减小多类样本在数据集中的不平衡对分类效果的负面影响又最大化的保留删减样本的内部特征的分布信息，二者兼顾，并在实验仿真中得到了验证。

4 不平衡数据集的遗传模糊分类算法

针对不平衡数据集的分类问题第三章设计出约束型欠采样的支持向量机算法，该算法有效地提高了不平衡数据集的分类性能。本章将模糊分类系统应用到不平衡数据集的分类，建立遗传算法的不平衡数据集模糊分类系统。该方法由以下二步组成：（1）利用 GK 聚类算法辨识初始的模糊分类系统；（2）为了提高模糊分类系统的精确性，利用遗传算法优化初始的模糊分类系统。

4.1 模糊系统

模糊分类系统是模糊系统和分类器共同组成的系统，是模糊系统在机器学习领域中的重要应用。模糊分类系统广泛的应用在人类日常生活和工程领域中的实际分类问题；自 1965 年美国加州大学 Zadeh 教授首次提出模糊集合的概念后，模糊概念加入了机器学习领域中，使得分类算法更适合实际分类问题的应用。

4.1.1 模糊系统的结构

模糊系统^{[42][49]}又称为模糊模型、模糊规则的系统、模糊推理系统、模糊逻辑控制器和模糊联想存储等。模糊系统理论的本质是用归纳近似输出的输入空间，并用模糊集合的形式来描述输入空间。也就是将复杂的或不确定信息的系统用多个输入子空间简化描述。模糊系统主要是由模糊化接口、知识库、模糊推理机和反模糊化接口等部分组成。模糊系统的结构图如图 4.1 所示。对模糊系统结构具体描述如下^[43]：




图 4.1 模糊系统结构图

（1）模糊化接口

由图 4.1 可看出，模糊系统的输入和输出都是精确值，但在模糊系统的核心部分——模糊推理的输入和输出都是模糊量。所以将实际中的精确值输入模糊系统，模糊系统首先要将精确值模糊化。模糊化接口具体产生过程如下：

- ① 输入精确值变换——将输入精确值进行尺度变换, 得到模糊量的论域范围;
- ② 模糊化——将输入精确值变换到论域范围后, 得到的论域范围的输入量进行模糊化处理, 从而使输入精确值转换成模糊量, 同时用对应的模糊集合来标记。

(2) 知识库

知识库包含了实际应用领域模糊系统的数据库和规则集合, 它是由模糊数据库和模糊规则库组成。

① 数据库

数据库主要是模糊集合中语言变量隶属度函数, 同时也包括尺度变换因子、模糊化合成函数和模糊清晰器运算函数等。模糊集合隶属度函数形式较多, 常见的有三角型函数、梯型函数、高斯函数、Z 型函数、 Π 型函数、sigmoid 函数和双高斯函数等^[44]。例如, 四边形模糊集合隶属度函数的数学形式如下:

$$Z_I(x, a, b, c, d, \beta) = \begin{cases} G(x), x \in [a, b) \\ \beta, x \in [b, c] \\ H(x), x \in (c, d) \\ 0, x \in R - (a, b) \end{cases} \quad (4.1)$$

其中, $a \leq b \leq c \leq d$, 且 $a, b, c, d \in R$; $0 \leq \beta \leq 1$, $G(x) \in [0, 1]$, 且 $G(x)$ 在 $[a, b)$ 为非减函数, $H(x) \in [0, 1]$, 且 $H(x)$ 在 (c, d) 为非增函数; $Z_I(x, a, b, c, d, \beta)$ 是模糊集合 I 的一个连续的四边形隶属度函数。当 $\beta = 1$ 时, 四边形隶属度函数为 $Z_I(x, a, b, c, d, \beta)$ 。

若使 $b = c$ 时, 则四边形隶属度函数就是三角形隶属度函数;

若使 $G(x) = \frac{x-a}{d-a}$, $H(x) = \frac{d-x}{d-c}$ 时, 则四边形隶属度函数就是梯型隶属度函数;

若使 $a = -\infty$, $b = c = \bar{x}$, $d = +\infty$, $G(x) = H(x) = \exp\left[-\left(\frac{x-\bar{x}}{\delta}\right)^2\right]$ 时, 则四边形隶属度函数就是高斯型隶属度函数。其中三角型隶属度函数和梯型隶属度函数的分布图分别如图 4.2 和图 4.3 所示。




图 4.2 三角型隶属度函数

② 模糊规则库

模糊规则库是由很多模糊语言形式的模糊控制规则组成。模糊控制规则通常是由该领域专家对模糊系统特性的了解、模糊知识的掌握和多次试验推导出来的定性策略。模糊规则 if-then 以语句表达：

$$\text{if } x \text{ is } A, \text{ then } y \text{ is } B, \quad x=1,2,3,\dots,N, y=1,2,3,\dots,N$$

(4.2)

if 是规则前件部分——判断该规则的条件是否成立，then 是规则后件部分——该规则的条件成立后得出的结论。

(3) 模糊推理机

模糊系统核心的组成部分是模糊推理机，模糊推理的实质是模拟人对模糊概念的推理，模糊推理是运用模糊逻辑中的潜在关系和模糊规则来进行推理的。在模糊推理中，一组不精确的模糊集合（输入值）得到的也是不精确的输出结果。这就使得模糊逻辑在处理模糊信息（即不精确和不确定信息）方面就有着较大的优势。模糊推理根据模糊逻辑




图 4.3 梯型隶属度函数

辑可分为：广义拒式推理、广义取式推理和广义假言推理形式^[45]。模糊推理根据模糊规则可分为：基本推理规则和主观推理规则。

(4) 反模糊化接口

反模糊化接口是将模糊推理输出的模糊量转换成输出精确值的过程。反模糊化接口具体产生过程如下：

- ① 输出模糊量清晰化——将模糊推理输出的模糊量进行尺度还原变换，得到输出精确值的论域范围；
- ② 将输出模糊量变换成输出精确值的论域范围后，得到的论域范围的输出量进行清晰化处理，从而使输出模糊量转换成输出精确值。

4.1.2 模糊系统类型

自模糊系统建立后，有各种各样的模糊系统被广泛的应用在解决实际模糊问题中。本章取两种常见的模糊模型为例，它们是：Mamdani 模糊模型和 T-S 模糊模型。这两种

模型主要是模糊规则后件不同, 因此它们的模糊化和清晰化也就有对应的差别。

(1) Mamdani 模糊模型

Mamdani 模糊模型^[46]具有模糊系统和模糊分类系统的基本结构, 也是一般模糊分类系统的基础。Mamdani 模糊模型的每一个模糊推理规则的后件都是一个模糊集合, 它的输入和输出都是语言值。例如一个 4 模糊规则的单一输入输出的 Mamdani 模糊模型可表示如下:

$$\begin{aligned} R_1: & \text{if } x \text{ is } A_1, \text{ then } y \text{ is } A \\ R_2: & \text{if } x \text{ is } B_1, \text{ then } y \text{ is } B \\ R_3: & \text{if } x \text{ is } C_1, \text{ then } y \text{ is } C \\ R_4: & \text{if } x \text{ is } D_1, \text{ then } y \text{ is } D \end{aligned} \quad (4.3)$$

其中, x 是表示输入量, y 是表示输出量, A, B, C, D 分别表示由输入量变换成输出量的语言描述。

(2) T-S 模糊模型

T-S 模糊模型是由 Takagi 和 Sugeno 提出的、全称 Takagi-Sugeno 模糊模型^{[42][47]}, 它采用输入量的线性或非线性函数作为模糊规则后件。因此, T-S 模糊模型与 Mamdani 模糊模型的区别主要在于规则后件。T-S 模糊模型的典型模糊规则定义形式如下:

$$\begin{aligned} R_i: & \text{if } x \text{ is } A_1^i \text{ and } x_2 \text{ is } A_2^i \text{ and } x_3 \text{ is } A_3^i \text{ and } \dots \text{ and } x_j \text{ is } A_j^i \dots \text{ and } x_n \text{ is } A_n^i, \\ & \text{then } y = F_i(x_1, x_2, x_3, \dots, x_n), \quad i = 1, 2, 3, \dots, Q \end{aligned} \quad (4.4)$$

其中 $x_1, x_2, x_3, \dots, x_j$ 为输入量, $j=1, 2, 3, \dots, n$, A_j^i 是模糊集合, $y = F_i(x_1, x_2, x_3, \dots, x_j)$ 通常是输入量的线性函数, Q 是模糊规则数目。典型 T-S 模糊模型是采用输入量的线性函数来作为模糊规则后件的多输入单输出。T-S 模糊模型以部分输入量的线性化为基础, 通过模糊建模来实现整个模糊模型的非线性, T-S 模糊模型被广泛的应用在样本的模糊建模中。随着模糊控制理论的应用与发展, 模糊系统类型有多种多样。例如, 就模糊模型的模糊规则后件不同来说, 还有 Tsukamoto 模糊模型^[42]等。

4.1.3 模糊分类系统

模糊分类系统是模糊系统和分类器共同组成的系统, 根据 Mamdani 模糊模型规则后件的差异可将模糊分类系统分为两种类型^[48]:

(1) 模糊规则后件仅是模糊规则前件的所属类, 也就是模糊规则后件仅是对应模糊规则前件的结论, if-then 语句表达为:

$$R_I: \text{if } x_I \text{ is } A, \text{ then } y_I \text{ is } y_k(x_I) \quad (4.5)$$

$y_k(x_I)$ 是第 I 条规则、 x_I 输入值对应的输出量。该条模糊规则含义为: 样本集合经过第 I 条模糊规则前件计算, 该规则后件输出对应的输出量为 $y_k(x_I)$ 。

(2) 模糊规则后件是模糊规则前件的所属类同时给出样本集合在该所属类的置信度值, if-then 语句表达为:

$$R_I: \text{if } x_I \text{ is } A, \text{ then } y_I \text{ is } y_k(x_I) \text{ with } CF_k(x_I) \quad (4.6)$$

$y_k(x_I)$ 是第 I 条规则、 x_I 输入值对应的输出量, $CF_k(x_I)$ 是对应的置信度值。该条模糊规则含义为: 样本集合经过第 I 条模糊规则前件计算, 该规则后件输出对应的输出量为 $y_k(x_I)$, 且样本集合属于该规则后件输出量 $y_k(x_I)$ 的置信度值为 $CF_k(x_I)$ 。

模糊分类系统的数学描述如下:

考虑 n 维 N_c 类 N 个样本的分类问题, 其中 $x \in X \subset R^n$, $x = (x_1, x_2, \dots, x_n)$ 为特征变量, $\{g_1, g_2, \dots, g_M\}$ 为输出类别, 则模糊分类系统的典型规则形式如下:

$$R_i: \text{if } x_1 \text{ is } A_{i1} \text{ and } x_2 \text{ is } A_{i2} \text{ and } \dots \text{ and } x_n \text{ is } A_{in}, \\ \text{then the pattern } (x_1, \dots, x_n) \text{ belongs to } g_i \quad (4.7)$$

其中 $A_{i1}, \dots, A_{in}$ 为定义在输入论域范围中的隶属函数, 此隶属函数可以取三角形、高斯型、梯形等。本章采用高斯型隶属函数:

$$A_{ij}(x_j) = \exp\left(-\frac{(x_j - v_{ij})^2}{2\sigma_{ij}^2}\right) \quad (4.8)$$

其中 v_{ij} 代表函数的中心, σ_{ij} 代表函数的方差。

对于未知样本 x_k , 模糊分类系统的输出采用“胜者为王”的计算方法^[48]——系统的输出为具有最大激励强度的模糊规则所对应的类别输出:

$$x_k \in g_{i^*}, i^* = \arg \max(\beta_i(x_k)) \quad (4.9)$$

其中 β_i 为第 i 条模糊规则的激励强度为:

$$\beta_i(x_k) = \prod_{j=1}^n A_{ij}(x_{jk}) \quad (4.10)$$

4.2 模糊分类系统的初始化

首先输入数据集利用模糊聚类算法辨识初始的模糊系统, 保证协同进化算法从较合理的初始系统开始学习, 这样有效节省搜索的空间和时间。

目标函数的模糊聚类是模糊系统建模最常用的方法之一。本章用 Gustafson Kessel (GK) 聚类算法离线辨识模糊系统的前件参数^{[49][51-53]}。GK 聚类算法的目标函数表达式为:

$$J(Z, U, V) = \sum_{i=1}^c \sum_{k=1}^N (u_{ik})^m D_{ik}^2 \quad (4.11)$$

其中, $Z = [z_1, z_2, \dots, z_n]$ 为数据集, $U = [u_{ik}]_{c \times N}$ 为数据集的模糊划分矩阵, $V = [v_1, v_2, \dots, v_c]$ 是聚类中心——隶属函数的中心, c 是聚类总数目, N 是样本数目, m 是模糊指数, D_{ik} 是第 i 个聚类和第 k 个样本间的距离范数, u_{ik} 是第 k 个样本相对于第 i 个聚类中心的隶属度值, 且满足以下条件:

$$u_{ik} \in [0, 1], \sum_{i=1}^c u_{ik} = 1, 0 < \sum_{k=1}^N u_{ik} < N \quad (4.12)$$

第 i 个聚类和第 k 个样本间的距离范数 D_{ik} :

$$D^2_{ik} = \|z_k - v_i\|^2_{A_i} = (z_k - v_i)^T A_i (z_k - v_i) \quad (4.13)$$

其中:

$$A_i = (\rho \det(F_i))^{1/n} F_i^{-1}, \rho = \det(A_i) \quad (4.14)$$

F_i 是模糊协方差矩阵:

$$F_i = \frac{\sum_{k=1}^N (u_{ik})^m (z_k - v_i)(z_k - v_i)^T}{\sum_{k=1}^N (u_{ik})^m} \quad (4.15)$$

利用拉格朗日乘法可以求得使目标函数最小的必要条件为:

$$u_{ik} = \frac{1}{\sum_{j=1}^c \left(\frac{D_{ik}}{D_{jk}} \right)^{\frac{2}{m-1}}}, v_i = \frac{\sum_{k=1}^N (u_{ik})^m z_k}{\sum_{k=1}^N (u_{ik})^m} \quad (4.16)$$

高斯型隶属函数的方差为:

$$\sigma^2_{ij} = \frac{\sum_{k=1}^N u_{ik} (x_{jk} - v_{jk})^2}{\sum_{k=1}^N u_{ik}} \quad (4.17)$$

为确定模糊规则的后件类的标号值, 首先定义如下函数:

$$M_{ij} = \frac{\sum_{k=1}^N u_{ik} f_j(k)}{\sum_{k=1}^N f_j(k)} \quad (4.18)$$

其中:

$$f_j(k) = \begin{cases} 1, x_k \in j \\ 0, x_k \notin j \end{cases} \quad (4.19)$$

则对于第 i 条规则, 其对应后件类的标号值 g_i 为:

$$i^* = \arg(\max(M_{ij})) \quad j = 1, 2, \dots, N_c \quad (4.20)$$

4.3 不平衡数据集的遗传模糊分类算法

不平衡数据集的遗传模糊分类算法是以分类系统的精确性为唯一优化目标（也称单目标模糊分类系统）。单目标模糊分类系统的建立主要是包括模糊规则前件的确定。模糊规则前件的确定包括输入变量的选择、输入空间的划分方式以及输入空间的划分数目等。

利用遗传算法建立模糊系统一般地步骤可分为：首先根据预先确定的编码方式随机地产生一定数目的种群，然后根据目标适应度函数，求取种群中个体的适应度值，接着根据适应度值利用遗传算子对这些个体进行选择、交叉和变异的遗传操作，得到新群体，最终得到准确率高的模糊分类系统。

（1）编码方式

本章采用了二进制编码形式的遗传算法，其编码形式如下：

R_1	R_2	R_3	...	R_i	...	R_c
-------	-------	-------	-----	-------	-----	-------

这里 R_i 取值为 $\{1\ 0\}$ ，当 R_i 的值为 1 时，表示第 i 条模糊规则被激励；当 R_i 的值为 0 时，表示第 i 条模糊规则被屏蔽。遗传算法中的任一种群个体代表一个模糊分类系统的所有规则的前件，种群个体由二进制编码数字串构成，每个二进制编码数字串表示输入空间的信息。

（2）适应度函数选择

适应度函数又称评价函数，是目标函数区分群体中个体优劣的标准，是遗传算法模拟自然选择的唯一根据^[48]。单目标适应度函数可由目标函数优化转换得到，例如：记 $Fit(H(x))$ 是目标函数 $H(x)$ 的适应度函数，直接以待求得目标函数转换成适应度函数^[54]，即：

若目标函数 $H(x)$ 是最大化问题，那么适应度函数 $Fit(H(x))$ 为：

$$Fit(H(x))=H(x)$$

(4.21)

若目标函数 $H(x)$ 为最小化问题，则适应度函数 $Fit(H(x))$ 为：

$$Fit(H(x))=-H(x)$$

(4.22)

所以在设计个体的适应度函数时，系统的精确性指标如下：

$$J_{ERR} = \frac{C}{g - mean}$$

(4.23)

其中 C 为某一常数（本章取值为 10）， g -mean 如式（2.7）所示。所以单目标适应度函数为：

$$Fit = J_{ERR} = \frac{C}{g - mean}$$

(4.24)

(3) 遗传算子的操作

根据式(4.24)所定义的适应度函数,种群不断的选择、交叉和变异,将得到分类正确率比较高的模糊分类系统。种群的染色体采用二进制编码,首先根据交叉概率和变异概率选择将要进行交叉和变异的个体,随机产生基因型中要交叉和变异的位置,交叉操作选用单点交叉。

① 交叉操作

假设 $H_s^g = [s_1, \dots, s_l]$ 和 $H_t^g = [t_1, \dots, t_l]$ 为第 g 代进行交叉的两个染色体, l 为染色体长度。本章随机采用三种交叉操作。

离散交叉: 随机选择染色体位置 $\delta \in [1, l]$, 则第 $g+1$ 代的对应染色体为:

$$H_s^{g+1} = [s_1, \dots, s_\delta, t_{\delta+1}, \dots, t_l] \quad (4.25)$$

$$H_t^{g+1} = [t_1, \dots, t_\delta, s_{\delta+1}, \dots, s_l] \quad (4.26)$$

算术交叉: $\lambda \in [0, 1]$ 为均匀分布的随机数, 则第 $g+1$ 代的对应染色体为:

$$H_s^{g+1} = \lambda H_s^g + (1 - \lambda) H_t^g \quad (4.27)$$

$$H_t^{g+1} = \lambda H_t^g + (1 - \lambda) H_s^g \quad (4.28)$$

启发式交叉: $\lambda \in [0, 1]$ 为均匀分布的随机数, 则第 $g+1$ 代的对应染色体为:

$$H_s^{g+1} = H_s^g + \lambda(H_s^g - H_t^g) \quad (4.29)$$

$$H_t^{g+1} = H_t^g + \lambda(H_t^g - H_s^g) \quad (4.30)$$

其中 $H_s^{g+1} \in [H^{\min}, H^{\max}]$, $H_t^{g+1} \in [H^{\min}, H^{\max}]$ 。

② 变异操作

假设 $H_s^g = [s_1, \dots, s_l]$ 为第 g 代进行变异的染色体, l 为染色体长度, 本文随机采用如下两种变异操作:

均匀变异: 随机选择染色体位置 $\delta \in [1, l]$ 和随机数 $\tilde{s}_\delta \in [s_\delta^{\min}, s_\delta^{\max}]$, 其中 $s_\delta^{\min}$ 和 $s_\delta^{\max}$ 为染色体 δ 位置的最大最小数, 则第 $g+1$ 代的对应染色体为:

$$H_s^{g+1} = [s_1, \dots, \tilde{s}_\delta, \dots, s_l] \quad (4.31)$$

多点均匀变异: 随机选择多个染色体位置 $\delta_k \in [1, l]$ $k \in [1, l]$ 和多个随机 $\tilde{s}_{\delta_k} \in [s_{\delta_k}^{\min}, s_{\delta_k}^{\max}]$, 其中 $s_{\delta_k}^{\min}$ 和 $s_{\delta_k}^{\max}$ 为染色体所对应多个 δ_k 位置的最大最小数, 则第 $g+1$ 代的对应染色体为:

$$H_s^{g+1} = [s_1, \dots, \tilde{s}_{\delta_1}, \dots, \tilde{s}_{\delta_l}, \dots, s_l] \quad (4.32)$$

4.4 不平衡数据集的遗传模糊分类算法步骤

不平衡数据集的遗传模糊分类算法的具体步骤如下：

输入：种群个体；

输出：不平衡数据集的遗传模糊分类算法。

主要步骤：

- (1) 初始化种群输入量：种群进化代数 G 、种群体数目 x 、隶属度函数的参数、适应度函数的参数、交叉率、变异率；
- (2) 第一代种群 $g=1$ ，产生初始种群，评价种群；
- (3) 在当前种群中随机选 1 个个体，记 $H=1$ ，且该个体前有 H 个个体；
- (4) 令输入量产生 H 个空间，确定模糊分类系统的规则前件；
- (5) 求第 H 个个体的适应度函数；
- (6) 当 $H = x$ 时，运行下一步，否则，令 $H = H + 1$ 且至第四步；
- (7) 当 $g = G$ 时，至最后一步输出，否则，令 $g = g + 1$ ，运行下一步；
- (8) 利用交叉操作、变异操作产生 $g+1$ 代个体，然后至第三步；
- (9) 得到适应度函数最好的个体即精确性好的模糊分类系统；
- (10) 结束运算。

不平衡数据集的遗传模糊分类算法流程图如图 4.4 所示：




图 4.4 不平衡数据集的遗传模糊分类算法流程图

4.5 仿真结果及分析

为了检验不平衡数据集的遗传模糊分类算法处理不平衡数据集的精确性性能,本章从 UCI 机器学习数据库中(<http://www.ics.uci.edu/~mllearn/MLrepository.html>)选择了 3 类典型分类问题,表 4.1 中给出了关于这 3 类问题的数据特性汇总。首先对实验数据集分别做如下处理:WIBC 数据集选取类标 malignant 为少类样本,其余的都划分为多类样本; Glass 数据集选取类标 7 为少类样本,其余的都划分为多类样本,Ecoli5 数据集选取类标 5 为少类样本,其余的都划分为多类样本。

表 4.1 各分类问题的数据特性汇总表

不平衡数据集问题	样本数	特征变量维数	正负类名称	不平衡率
WIBC	683	9	Malignant benign	1.86
Glass7	214	9	Headlamps remainder	6.38
Ecoli5	336	7	Om remainder	15.81

仿真程序在 MatlabR2010a 中运行完成,算法各参数设置如表 4.2 所示。下面对这 3 类问题给出详细的仿真说明,并将仿真结果和其他文献方法的结果进行比较。所有文献算法和本章算法都采用 5 次折叠交叉验证法,且初始化聚类数设定为 6。

表 4.2 不平衡数据集的遗传模糊分类算法参数设置

参数	值
最大进化代数	100
种群交叉率	0.5
适应度函数参数 c	10
种群初始个体数	40
种群变异率	0.1

4.5.1 Wisconsin Breast Cancer 分类问题

根据以上表格给定的不平衡数据集的遗传模糊分类算法参数和 3 类问题的数据集特性,可以得出 WIBC 分类问题不同建模方法的 g-mean 性能比较。

WIBC 数据集的输入分布情况如图 4.5 所示。




图 4.5 WIBC 数据集的输入分布图

WIBC 分类问题在不同建模方法的 g-mean 性能比较如表 4.3 所示。

表 4.3 WIBC 分类问题在不同建模方法的 g-mean 性能比较

算法	规则数	集合总数	g-mean
文献[57]	401	--	99.94%
	250	--	94.61%
文献[58]	--	--	98.86%
文献[59]	--	--	98.39%
文献[60]	2	--	99.92%
文献[61]	2	3.4	96.82%
本章算法	301	54.6	100%

表 4.3 给出了不同建模方法对 WIBC 分类问题的 g-mean 性能。从表中可以看出，不平衡数据集的遗传模糊分类算法得到的 g-mean 性能十分优越，最高可以达到 100%。在同一个分类问题中，要得到较好的性能指标，需要的规则数就相对较多。相比于文献 [57] 中的分类方法，本章的方法在规则数少 100 的情况下，g-mean 性能反而更好，这说明本章算法对于处理 WIBC 分类问题具有一定的优越性。

4.5.2 Glass7 分类问题

根据以上表格给定的不平衡数据集的遗传模糊分类算法参数和 Glass7 分类问题的数据集特性，可以得出 Glaas7 分类问题不同建模方法的 g-mean 性能比较。

Glass7 数据集的输入分布情况如图 4.6 所示。




图 4.6 Glass7 数据集的输入分布图

Class7 分类问题在不同建模方法的 g-mean 性能比较如表 4.4 所示

表 4.4 Class7 分类问题在不同建模方法的 g-mean 性能比较

算法	规则数	集合总数	g-mean
文献[57]	107	--	98.59%
	54	--	94.45%
文献[58]	--	--	97.53%
文献[60]	--	--	98.61%
本章算法	121	37.8	98.73%

表 4.4 给出了不同建模方法对 Class7 分类问题的 g-mean 性能,从表中可以看出,与其它文献中的分类方法相比,本章算法处理 Class7 分类问题不逊与其它文献中的方法, g-mean 性能可达 98.73%。

4.5.3 Ecoli5 分类问题

根据以上表格给定的不平衡数据集的遗传模糊分类算法参数和 Ecoli5 分类问题的数据集特性，可以得出 Ecoli5 分类问题不同建模方法的 g-mean 性能比较。

Ecoli5 数据集的输入分布情况如图 4.7 所示。




图 4.7 Ecoli 数据集的输入分布图

Ecoli5 分类问题在不同建模方法的 g-mean 性能比较如表 4.5 所示

表 4.5 Ecoli5 分类问题在不同建模方法的 g-mean 性能比较

算法	规则数	集合总数	g-mean
文献[57]	110	--	98.62%
	16	--	85.86%
文献[58]	--	--	98.61%
文献[60]	2	--	98.69%
本章算法	108	33.4	98.72%

表 4.5 给出了不同建模方法对 Ecoli5 分类问题的 g-mean 性能，本章采算法 g-mean 性能可达 98.72%，比其它几种方法得到的 g-mean 性能好。但是本章算法的规则数比其它几种方法多。这说明本章算法得到的模糊分类系统解释性差。

由表 4.3~4.5 可以发现，本章采用的不平衡数据集的遗传模糊分类算法对不平衡数据集分类的 g-mean 性能更为优越，这说明不平衡数据集的遗传模糊分类算法对不平衡数据集有较好的分类效果。

4.6 本章小结

本章研究了基于遗传算法的不平衡数据集模糊分类系统的构造方法，利用遗传算法优化模糊分类系统，设计出不平衡数据集的遗传模糊分类算法。通过实验仿真结果分析可看出：不平衡数据集的遗传模糊分类算法（本章算法）处理不平衡数据集得到的精确性性能很好，但该模糊系统规则集合较为复杂和难以用自然语言理解，即分类系统的解释性差，不便于该算法理用计算机语言编程。所以，接下来我们考虑把模糊分类系统的

精确性和解释性同时作为优化目标，即在保证系统分类精确性的前提下，最大程度提高系统的解释性，设计出不平衡数据集多目标协同进化算法。

5 不平衡数据集的协同进化分类算法

协同进化思想灵感源于自然界物种的竞争关系和共生关系，因此协同进化算法可分为两种：竞争型的协同进化算法和合作型的协同进化算法。本章主要研究合作型的协同进化算法用于设计精确性和解释性的模糊分类系统。

应用协同进化算法，除常见遗传算法遇到的问题外，还需解决以下问题：（1）求解问题适当的分解；（2）子种群染色体之间的数据约束关系以及相互合作关系；（3）种群个体的适应度计算策略。

本章的协同进化算法采用分而治之的思想把模糊分类系统分解为相互合作的三类种群，第一类种群描述模糊分类系统被激励的模糊规则；第二类种群描述模糊系统的规则前件；第三类种群描述模糊系统隶属函数的参数；三类种群分别采用不同的遗传算法同时进化，多目标适应度函数将模糊分类系统的准确率和解释性指标通过加权同时作为优化目标，采用三类种群合作计算的策略，最终获得解释性好、精确性高的模糊分类系统。

5.1 模糊系统的分解和各种群染色体编码

对式(4.7)所表示的模糊分类系统，在能保证得到符合要求，即具有较高的精确性和较好的解释性模糊系统的前提下，分解的种群越少，则协同进化算法的计算越简单，搜索空间和时间越少。本章将模糊系统（模糊模型）分解为以下三个种群：

（1）模型的规则种群 Species1

模型的规则种群主要是用来优化选择模型的规则数，采用二进制编码方式。其编码形式如下：

R_1	R_2	R_3	...	R_i	...	R_c
-------	-------	-------	-----	-------	-----	-------

这里 R_i 取值为 $\{1\ 0\}$ ，当 R_i 的值为 1 时，表示第 i 条模糊规则被激励；当 R_i 的值为 0 时，表示第 i 条模糊规则被屏蔽。根据即将要解决的问题分类数先给定一个聚类数目 c ，即初始的模糊规则数，本章取专家经验值 $c = 3N_c$ 。

已知种群大小为 L ，第一条染色体取值全为 1，表示选择全部规则，其余的 $L - 1$ 条染色体，在二进制空间内随机均匀生成，从而形成初始规则种群。

（2）模型的规则前件种群 Species2

模型规则前件种群的进化是为了搜索规则库更为合理的模糊集合的组合和规则中冗余的模糊集合。采用二进制编码进化，其中二进制染色体反编码后的表现型为：

{ 规则 1 }			{ 规则 i }			{ 规则 n }		
A_{11}	...	A_{1n}	...	A_{ij}	...	A_{ci}	...	A_{cn}

这里 A_{ij} 取值为 $\{0 \ 1 \ 2 \ \dots \ c\}$, 当 A_{ij} 取值为 0 时, 表示第 i 条规则中的第 j 个变量为变量无关项 (don't care), 这是一条不完整模糊规则, 当 A_{ij} 取其他值时, 则第 i 条规则中的第 j 个变量所对应的相关模糊集合被激励。

在已知初始种群大小 L , 通常取第一条染色体编码对应于 GK 聚类产生的初始模糊分类系统为模型前件, 其余的 $L-1$ 个染色体在二进制空间内随机均匀生成。

(3) 模型的隶属函数参数种群 Species3

对于模糊系统的隶属函数参数种群, 由于实数编码染色体的长度比二进制编码染色体的长度短, 所以采用实数编码方式。实数编码方式减小了遗传算法的计算量, 从而提高了算法运算效率, 能够更好地保持种群多样性。

GK 聚类产生的初始模糊分类系统的前件参数, 该前件参数可直接编码产生第一条染色体, 待编码的参数为隶属函数的中心 v_{ij} 和方差 σ_{ij} , 因此每条染色体共有 $2 * c * n$ 个数, 此时的 n 为经过特征变量选择后的特征变量的维数, 对于第一条染色体其编码为:

$$H_1 = (v_{11}, \dots, v_{cn}, \sigma_{11}, \dots, \sigma_{cn}) \quad (5.1)$$

给定种群大小为 L , 染色体表示为 H_p , $p=1, 2, \dots, L$, 给定搜索空间 $[H^{\min}, H^{\max}]$:

$$\begin{cases} H^{\min} = (v_{11}^{\min}, \dots, v_{cn}^{\min}, \sigma_{11}^{\min}, \dots, \sigma_{cn}^{\min}) \\ H^{\max} = (v_{11}^{\max}, \dots, v_{cn}^{\max}, \sigma_{11}^{\max}, \dots, \sigma_{cn}^{\max}) \end{cases} \quad (5.2)$$

其中, $v_{ij}^{\max}$ 是隶属函数的中心的最大约束值, $v_{ij}^{\min}$ 是隶属函数的中心的最小约束值, $\sigma_{ij}^{\max}$ 是隶属函数的方差的最大约束值, $\sigma_{ij}^{\min}$ 是隶属函数的方差的最小约束值, 其余的 $L-1$ 个染色体, 以染色体 H_1 为中心, 在搜索范围内随机均匀生成, 从而形成初始参数种群。

5.2 子种群染色体之间的合作

本章使用“匹茨堡方法”, 对于常规遗传算法, 该方法的特点是种群中一条染色体代表整个模糊系统。而对于 MOCOEA 算法, 三类种群中的染色体的合并, 需经过反编码操作后才能合并成完整的、符合要求的模糊分类系统, 且各类种群染色体之间的合并有顺序要求, 本章把规则染色体放在前面, 规则前件染色体放在中间, 隶属函数参数染色体放在最后。为了便于更清楚地说明子种群染色体之间如何相互协同进化产生模糊分类系统, 我们举出下面的例子。

设初始规则数 $c=6$ (类别数为 2), 经特征变量选择的特征变量维数 $n=5$, 从三类种群中随机选取三条染色体进行合并, 如图 5.1 所示。




图 5.1 三种群染色体之间的组合

第一行是模糊规则染色体编码；第二行是模糊规则前件染色体二进制编码的表现型；第三行是隶属函数参数编码，则上述编码表示的模糊规则前件为：

$$\begin{aligned}
R_1 : & \text{if } x_1 \text{ is } A_{11}(v_{11}, \sigma_{11}) \text{ and } x_3 \text{ is } A_{13}(v_{33}, \sigma_{33}) \\
& \text{and } x_4 \text{ is } A_{14}(v_{44}, \sigma_{44}) \text{ and } x_5 \text{ is } A_{15}(v_{51}, \sigma_{51}) \\
R_3 : & \text{if } x_1 \text{ is } A_{31}(v_{11}, \sigma_{11}) \text{ and } x_3 \text{ is } A_{33}(v_{33}, \sigma_{33}) \\
& \text{and } x_4 \text{ is } A_{34}(v_{44}, \sigma_{44}) \text{ and } x_5 \text{ is } A_{35}(v_{51}, \sigma_{51}) \\
R_4 : & \text{if } x_2 \text{ is } A_{42}(v_{21}, \sigma_{21}) \text{ and } x_3 \text{ is } A_{43}(v_{31}, \sigma_{31}) \\
& \text{and } x_4 \text{ is } A_{44}(v_{43}, \sigma_{43}) \text{ and } x_5 \text{ is } A_{45}(v_{55}, \sigma_{55}) \\
R_5 : & \text{if } x_1 \text{ is } A_{51}(v_{11}, \sigma_{11}) \text{ and } x_2 \text{ is } A_{52}(v_{21}, \sigma_{21}) \\
& \text{and } x_3 \text{ is } A_{53}(v_{36}, \sigma_{36}) \text{ and } x_5 \text{ is } A_{55}(v_{55}, \sigma_{55})
\end{aligned}$$

6条模糊规则中 R_2 , R_6 被屏蔽, 其它模糊规则均被激励, 被激励的模糊规则均为不完整规则, R_1 , R_3 中的 x_2 , R_4 中 x_1 和 R_5 中 x_4 为变量无关项; R_4 和 R_3 在表现形式上不相同, 但它们的模糊集合参数相同, 因此在相似性的模糊规则组合过程中可以删除其中任意一条, 所以上编码本质上只表示含有 R_3 、 R_4 和 R_6 或 R_1 、 R_4 和 R_6 的三条规则的模糊系统, 相对应的模糊集合数为9个, 若此模糊系统的精确性能满足要求, 则该模糊系统就是精确性较高、解释性较好的模糊系统。

通过以上分解和编码方法能够获得模糊系统规则的则前件,其对应的后件类标可以通过式(4.18)、式(4.19)和式(4.20)计算获得,从而得到完整的、满足要求的模糊分类系统。

5.2.1 种群个体的适应度计算策略

不同于传统的遗传算法,在协同进化中,个体适应度的计算依赖于该个体与其他种群的代表合作产生该个体适应度的值^[49]。

这里首先介绍种群代表的概念：种群代表是指典型个体或者是种群全体^[49]。如果选择种群全体作为种群代表，此时计算量会很大，考虑到算法的计算复杂性，本章选用典型个体作为种群代表。每个种群代表的选取以下两种方式构成：一是抽取 N_{cf} 个适应度值最高的个体；二是随机地抽取 N_{cr} 个体。则该种群代表的个体总数为 $N_{rep} = N_{cf} + N_{cr}$ 。该种群个体适应度值的计算方法为：该个体与其他种群代表合作产生 N_{rep} 个模糊系统，对每个模糊系统计算其适应度值，取其中最佳的适应度作为该个体的适应度值。种群代表的产生和个体适应度的计算策略如图 5.2 所示。协同进化算法对个体适应度的计算经历了一个局部学习的过程，体现了协同进化算法与其他遗传算法的不同，强调个体进化与种群间个体学习的相互影响和相互作用。

5.2.2 适应度函数

多目标优化问题可以分解为：满足约束条件的变量看作为一个目标向量组，最终目的是优化目标函数的向量组，而这些目标函数之间通常是相互制约、相互影响。所以，多目标协同进化适应度函数可由多个单目标函数优化转换得到。

多目标协同进化适应度函数的公式依据模糊分类系统的性能指标——精确性和解释性而定。根据第二章和第四章可得出，精确性主要是正确分类率、错误分类率和正确




图 5.2 种群代表的产生和个体适应度的计算策略

率的几何平均值 $g\text{-mean}$ 等；解释性主要是模型结构、特征变量和模糊规则数目、隶属函数特性等。

多目标协同进化适应度函数的选择：模糊规则数目是模糊系统解释性的一个重要指标，解释性作为本章模糊分类系统的目标之一，所以要在适应度函数中突显出来。由以上可总结可得出，模糊系统的规则数目越多，它的解释性就越差。专家实验经验认为^[55-56]：模糊系统的解释性好，对应它的模糊规则数会在 10 左右，但这只是一般情况下的经验值，并不是绝对的。本章模糊规则数取 10。

当种群中的个体与其他种群代表中的个体合作，经过反编码产生模糊系统的前件，首先利用基于相似性的模型简化技术约简模糊系统，有效地保证了模糊集合的解释性。所以在设计个体的适应度函数时，系统的精确性指标如式（4.23）所示。系统的解释性指标主要考虑 J_{nRule} 和 J_{nFS} ，三个指标函数均为越小越好，采用加权适应度函数为：

$$Fit = w_1 * J_{ERR} + w_2 * J_{nRule} + w_3 * J_{nFS} \quad (5.3)$$

加权因子 w_1 , w_2 , w_3 为正实数，且适应度函数 Fit 为非负数，在计算适应度函数时预先根据经验给值。

5.3 种群的遗传操作

本章提出 MOCOEA 算法，把模糊分类系统分解为相互合作的三类种群，采用不同编码方式，但都利用遗传算法进化。遗传操作主要包括以下三种：选择、交叉和变异。三类种群都选用精英保留和随机遍历抽样法（SUS）相结合的选择操作。由于算法采用分而治之的思想把复杂的问题分解为简单的各个子问题，且 MOCOEA 算法中又采用精英保留的策略，为防止算法未成熟就盲目收敛，所以协同进化算法的交叉概率和变异概率要比常规遗传算法高，这是协同进化算法的特点。

（1）Species1 种群的遗传操作

Species1 种群中的染色体采用二进制编码，首先根据交叉概率和变异概率选择将要进行交叉和变异的个体，随机产生基因型中要交叉和变异的位置，交叉操作选用单点交叉；变异操作选用二进制变异。

（2）Species2 种群的遗传操作

Species2 种群中的个体有两种表现形式：染色体型和表现型。表现型为染色体的反编码，两者是一一对应的关系，表现型用于和规则种群及参数种群中的代表协作，产生规则库的前件。染色体型采用二进制编码，在遗传算法中对其执行遗传操作，首先根据交叉概率和变异概率选择将要进行交叉和变异的个体，随机产生基因型中要交叉和变异的位置，交叉操作选用单点交叉；变异操作选用二进制变异。

（3）Species3 种群的遗传操作

为保证 Species3 种群个体多样性和算法的有效性，对于交叉和变异操作以上几种具体的实现方法，在实际的操作过程中，由算法随机选择。

5.4 多目标协同进化算法（MOCOEA）步骤

本章利用三类不同的遗传算法控制三个种群的协同进化思想，MOCOEA 算法的具体步骤如下：

输入：种群 SpeciesS;

输出：MOCOEA 算法。

主要步骤：

- (1) 初始化种群输入量：MOCOEA 算法进化代数 G （种群进化代数）、种群个体数目 x 、隶属度函数的参数、适应度函数的参数、交叉率、变异率；
- (2) 第一代种群 $g=1$ ，产生初始种群，评价种群；
- (3) 在当前种群中随机选 1 个个体，记 $H=1$ ，且该个体前有 H 个个体；
- (4) 令输入量产生 H 个空间，确定模糊分类系统的规则前件；
- (5) 求第 H 个个体的适应度函数；
- (6) 当 $H=x$ 时，运行下一步，否则，令 $H = H + 1$ 且至第四步；
- (7) 当 $g=G$ 时，至最后一步输出，否则，令 $g=g+1$ ，运行下一步；
- (8) 利用交叉操作、变异操作产生 $g+1$ 代个体，然后至第三步；
- (9) 得到适应度函数最好和模糊规则数少的个体，即完整的、符合设计要求（高精确性和好解释性）的模糊分类系统；
- (10) 结束运算。

模糊分类系统的性能指标参数主要有准确性和解释性。因此要得到符合要求的模糊分类系统应该是适应度值最高、准确性高和解释性好的系统，即三者同时都要兼顾。根据式 (4.26) 所定义的加权适应度函数，应使种群不断的进行选择操作、交叉操作和变异操作，使最终得到的模糊分类系统分类精确性高和模糊模型具有较少的模糊规则和输入变量数目、模糊规则之间存在较少或不存在冗余和矛盾的模糊分类系统。

在利用多目标协同进化算法建立初始模糊分类系统过程中采用的遗传算子主要是精英保留和随机遍历抽样法 (SUS) 相结合的选择操作、单点交叉操作、二进制变异操作和精英法则。

MOCOEA 算法的伪代码如下：

```

Begin MOCOEA
  g:=0
  for each species S
    Initialize population Pops(0)
    Evaluate population Pops(0)
    Reps(1)=Select-representation[Pops(0)]
  end for
  while not done
    for each species S
      g:=g+1
      Es(g)=Elite-select[Pops(g-1)]
    
```

```

Pop1s(g)=Select[Pops(g-1)]
Pop2s(g)=Crossover[Pop1s(g)]
Pop3s(g)=Mutate[Pop2s(g)]
Pops(g)= Pop3s(g)+ Es(g)
Model1s(g)= Merge[Pops(g), Reps(g)]
Model2s(g)=Similarity-simplify[Model1s(g)]
Models(g)= Model2s(g)+Class[Model2s(g)]
Evaluate Fitness Models(g)
Reps(g+1)=Select-representation[Pops(g)]
    end for
end while
end MOCOEA
    
```

其中 Rep_s(g)表示是另外二类种群代表；Model¹_s（g）表示三个种群中染色体合并后代表的模糊模型前件；Model²_s（g）表示经过在相似性模型简化技术约简的基础后的模糊系统前件；Class [Model²_s（g）]表示利用式（4.16）和式（4.18）计算模糊分类系统的后件类标；Model_s（g）表示完整的、符合要求的模糊分类系统；用 Evaluate Fitness Model_s（g）算法计算策略，计算结果作为 Pop_s（g）相应染色体的适应度函数。

MOCOEA 算法流程图如图 5.3 所示：




图 5.3 MOCOEA 算法流程图

5.5 仿真结果及分析

为了检验协同进化算法构造精确性和解释性较好折衷的模糊分类系统处理不平衡数据集的性能,本章从(<http://www.ics.uci.edu/~mlearn/MLrepository.html>)UCI 机器学习数据库中选择了 3 类典型分类问题,关于这 3 类问题的数据特性汇总具体见表 4.1,这 3 类问题的数据归一化处理 and 输入分布图见 4.5 节。

仿真程序在 Matlab R2010a 中运行完成,MOCOEA 算法各参数设置如表 5.1 所示。所有文献算法和本章算法都采用 5 次折叠交叉验证法。

表 5.1 MOCOEA 算法参数设置

参数	值	参数	值
最大进化代数	100	种群 3 精英率	0.05
种群初始个体数	40	N_{cf}	1
种群 1 交叉率	0.85	N_{cr}	2
种群 1、2 变异率	0.15	权值 w_1	0.89
种群 1 精英率	0.025	权值 w_2	0.1
种群 2 精英率	0.1	权值 w_3	0.01
种群 2、3 交叉率	1	集合融合阈值	0.4
种群 3 变异率	0.15	规则融合阈值	1

5.5.1 Wisconsin Breast Cancer 分类问题

初始化聚类数设定为 6,表 5.2 中给出某次的模糊分类系统的规则库及每条规则所对应的前件参数。

表 5.2 模糊分类系统的规则及前件参数

WIBC 模糊分类系统	
R1: if x1 is high and x2 is high and x4 is low, then output is malignant(少类)	
R2: if x1 is low and x2 is low and x4 is low and x6 is media, then output is benign(多类)	
R3: if x1 is low and x2 is high and x4 is high, then output is malignant(少类)	
模型规则前件参数	
x1: low=[3.555, 7.403]	high=[4.575,8.698]
x2: low=[1.164, 5.408]	high=[5.789, 12.147]
x4: low=[2.654, 8.270]	high=[9.457, 7.327]
x6: media=[8.8529, 10.269]	

根据以上表格给定的 MOCOEA 算法规则和参数，可以得出 WIBC 分类问题在不同建模方法的 g-mean 性能比较如表 5.3 所示。

表 5.3 WIBC 分类问题在不同建模方法的 g-mean 性能比较				
算法	规则数	集合总数	训练 g-mean	检验 g-mean
文献[57]	401	--	99.94%	52.25%
	250	--	94.61%	90.03%
	2.8	--	46.57%	45.88%
文献[58]	--	--	98.86%	89.04%
文献[59]	--	--	98.39%	96.05%
	--	--	97.65%	95.75%
文献[60]	2	--	99.92%	88.24%
文献[61]	2	3.4	96.82%	--
本章算法	2.8	6.2	97.47%	96.05%

5.5.2Class7 分类问题

初始化聚类数设定为 6，表 5.4 中给出某次的模糊分类系统的规则库及每条规则所对应的前件参数。

表 5.4 模糊分类系统的规则及前件参数	
Class7 模糊分类系统	
R ₁ : if x ₁ is media and x ₂ is media and x ₃ is media and x ₄ is low and x ₅ is high and x ₆ is low and x ₇ is media and x ₈ is low and x ₉ is media, then output is (多类)	
R ₂ : if x ₁ is media and x ₂ is media and x ₃ is media and x ₄ is high and x ₅ is low and x ₆ is high and x ₇ is media and x ₈ is high and x ₉ is media, then output is (少类)	
模糊系统规则前件参数	
x ₁ : media=[0.1602, 0.0444]	
x ₂ : media=[0.7561, 0.0279]	
x ₃ : media=[0.6150, 0.1677]	
x ₄ : low=[0.7557, 0.0203]	high=[0.9804, 0.0090]
x ₅ : low=[1, 0.0411]	high=[0.5536, 0.0291]
x ₆ : low=[0.0313, 0.0022]	high=[0.1866, 0.0053]
x ₇ : media=[0.3927, 0.0525]	
x ₈ : low=[0.0001, 0.0010]	high=[0.0447, 0.0249]
x ₉ : media=[0.1216, 0.1532]	

根据以上表格给定的 MOCOEA 算法规则和参数，可以得出 Class7 分类问题在不同

建模方法的 g-mean 性能比较如表 5.5 所示。

表 5.5 Class7 分类问题在不同建模方法的 g-mean 性能比较

算法	规则数	集合总数	训练 g-mean	检验 g-mean
文献[57]	107	--	98.59%	84.23%
	54	--	94.45%	86.80%
	2	--	64.88%	66.22%
文献[58]	--	--	97.53%	84.30%
文献[60]	--	--	98.61%	86.95%
本章算法	2	10.8	99.13%	98.60%

5.5.3Ecoli5 分类问题

初始化聚类数设定为 6，表 5.6 中给出某次的模糊分类系统的规则库及每条规则所对应的前件参数。

表 5.6 模糊分类系统的规则及前件参数

Ecoli5 模糊分类系统	
R ₁ : if x ₁ is media and x ₂ is media and x ₃ is media and x ₄ is media and x ₅ is media and x ₆ is media, then output is (多类)	
R ₂ : if x ₁ is media and x ₃ is media and x ₅ is media and x ₆ is media, then output is (少类)	
模糊系统前件参数	
X ₁ : media=[0.7896, 0.0008]	x ₂ : media=[0.6028, 0.0657]
X ₃ : media=[0.8269, 0.0156]	x ₄ : media=[1.0000, 0.0021]
X ₅ : media=[0.7663, 0.0034]	x ₆ : media=[0.9799, 0.0048]

根据以上表格给定的 MOCOEA 算法规则和参数，可以得出 Ecoli5 分类问题在不同建模方法的 g-mean 性能比较如表 5.7 所示。

表 5.7 Ecoli5 分类问题在不同建模方法的 g-mean 性能比较

算法	规则数	集合总数	训练 g-mean	检验 g-mean
文献[57]	110	--	98.62%	89.81%
	16	--	85.86%	78.88%
	4	--	49.92%	49.69%
文献[58]	--	--	98.61%	91.90%
文献[60]	2	--	98.69%	93.02%
本章算法	2	5.4	98.52%	97.78%

各种分类问题在不同建模方法中分类结果的 g-mean 性能比较如图 5.4 所示。




图 5.4 各种分类问题在不同建模方法中分类结果的 g-mean 性能比较图

表 5.3 给出了不平衡数据集的协同进化分类算法与其它文献算法处理 WIBC 分类问题的 g-mean 性能。本章算法的规则数较少（仅有 2.8），而得到的检验 g-mean 性能指标最高（96.05%）。文献[60][61]中的规则数少但得到的 g-mean 性能指标没有本章算法好。

表 5.5 给出了不平衡数据集的协同进化分类算法与其它文献算法处理 Class7 分类问题的 g-mean 性能。从表中可以发现本章算法不仅规则数少，而且得到的检验 g-mean 性能达 98.69%，比起他几种方法至少高十个百分点。这说明不平衡数据集的协同进化分类算法在处理不平衡数据集分类问题时能得到准确率和解释性较好的兼顾。

表 5.7 给出了不平衡数据集的协同进化分类算法与其它文献算法处理 Ecoli5 分类问题的 g-mean 性能。虽然文献[58]和文献[60]的 g-mean 性能也较高。但从表 5.7 中可以发现本章算法规则数只有 2 个，而且检验 g-mean 性能指标更高，可达 97.78%。

根据以上不平衡数据集分类系统的协同进化算法与文献[57]、文献 [58]、文献[59]、文献[60]、文献[61]中所用的模糊建模方法得到的模糊分类系统对 Wisconsin Breast Cancer（WIBC）、Glass7 和 Ecoli5 问题进行分类仿真实验的结果可以看出：

- （1）MOCOE 算法对 WIBC、Glass 和 Ecoli5 问题进行分类得到的 g-mean 性能优于文献[60]、文献[61]得到的 g-mean 性能；
- （2）本章算法对不平衡率高的不平衡数据集分类有较好的分类性能指标，例如 Ecoli5 问题；
- （3）尽管 MOCOE 算法对不平衡数据集的分类效果略差于文献[57]和遗传算法的不平衡数据集模糊分类系统的效果，但 MOCOE 算法有较少的模糊规则数目和便于理解，即有很好的解释性。

5.6 本章小结

本章在不平衡数据集的遗传模糊分类算法的基础上提出一种基于多目标协同进化算法的模糊分类系统。多目标协同进化算法的模糊分类系统的性能指标主要是精确性和解释性。平衡数据集的协同进化分类算法是将模糊分类系统和协同进化思想有机结合。协同进化思想起源于自然界的食物链关系和共生关系，本章主要研究合作型的协同进化算法用于设计精确性和解释性的模糊分类系统，该设计方法由以下二步组成：（1）利用模糊聚类算法辨识初始的模糊系统；（2）利用协同进化算法对所获得的初始的模糊模型进行结构和参数的优化。

本章算法的优点为：（1）GK 聚类算法有效减小了 MOCOEA 算法的计算量；（2）模糊模型的结构和模型隶属函数参数的同时优化，保证了优化后模型的精确性；在 MOCOEA 算法运行中利用基于相似性的模型简化技术约简模糊分类系统，有效地保证了模糊分类系统解释性；（3）由于本章算法的模糊分类系统解释性较好，因此该模糊系统有较少的模糊规则数目，从而该算法便于理解和用计算机语言编程。

最后利用本章算法对几个典型分类问题如：Wisconsin Breast Cancer、Class7 和 Ecoli5 分类问题进行研究，并给出仿真结果。最终通过仿真实验证明本章算法对不平衡数据集分类有较好的几何平均准则 g-mean 等性能指标。

6 结论与展望

数据挖掘是从庞大的数据信息中分类出有价值的信息和知识。不平衡数据集分类问题是数据挖掘的一种特殊情况。本文主要做了如下工作：

(1) 从不平衡数据集的采样法入手，设计出约束型欠采样法。该方法先对不平衡数据集用 c -均值聚类法处理，接着对处理过的数据集进行欠采样，最后将约束型欠采样法和支持向量机算法(SVM)结合起来，对不平衡数据集进行分类研究。

(2) 设计出一种不平衡数据集模糊分类系统的协同进化方法，该方法由以下二步组成：① 利用模糊聚类算法辨识初始的模糊模型；② 利用协同进化算法对所获得的初始的模糊模型进行结构和参数的优化。该算法研究了一种基于协同进化算法的模糊建模方法。将种群协同进化运用到模糊系统的结构和参数编码中，研究了种群的分解、协作和个体适应度的计算策略，实现了基于协同进化算法的模糊建模，并在实验中得到验证了该模糊系统有较好的解释性和精确性。

尽管本文对不平衡数据集分类问题作了一些工作，但还有一些需要进一步改进和深入研究的地方：

(1) 约束型欠采样方法是按照原始数据集的不平衡率进行聚类划分，再根据需求或经验设定欠采样比例 T 对训练样本进行欠采样，这就要求有原始数据集的先验知识。因此以后可以考虑在不需要原始数据集的先验知识的条件下，能够对原始数据集做欠采样处理并使训练样本不失真，所以需要进一步提出量化的标准，这一点是我们以后要进一步做的工作。

(2) 目前模糊系统的解释性还没有明确的完整概念和数学表达式。很多的影响模糊系统解释性的因素尚停留在定性分析阶段，因此需要对这些因素进一步提出量化的标准。

致 谢

本论文从选题到最终完稿，每一步的研究工作都是在张永副教授的悉心指导下完成的。张老师渊博的学识、严谨的治学作风和无微不至的关心，不仅使我收获了知识，还教会了我很多做人的道理。在此即将毕业之际，向张老师致以由衷的感谢。

感谢邢宗义老师在论文的修改过程中提出了许多宝贵的建议和有益的指导。在此致以诚挚的谢意！

感谢342教研室的全体老师和师兄弟！尤其是刘彪师兄和姜建飞同学。他们在生活和学习上给予我很多帮助，不仅使得我能够顺利完成毕业论文，同时也使我三年的研究生涯充满乐趣，在此向他们致以诚挚的谢意！

最后，感谢我的父母和亲人！培育我倾注了你们很多的心血。尤其感谢我的妻子三年来的鼓励。你的理解和关心，是我不断努力学习动力。在此向你们致以永远的谢意！

参考文献

- [1] 赵自翔, 王广亮, 李晓东. 基于支持向量机的不平衡数据分类的改进欠采样方法 [J]. 中山大学学报, 2011, 51(6)
- [2] 姚冰. 一种改进的非平衡数据集支持向量机分类算法 [D]. 吉林大学, 2010, 4
- [3] Wilk S, Sloeinski R, Miçhaloeski W, Greco S. Supporting triage of children with abdominal pain in the emergency [J]. European Journal of Operational Research, 2005, 160(3):696-709
- [4] Miroslav K, Robert C H, Stan M. Machine learning for the detection of oil spills in the satellite radar images [J]. Machine Learning, 1998, 30:195-216
- [5] Tom F, Foster P. Adaptive Fraud Detection [J]. Data mining and knowledge discovery, 1997, 3(1):291-316
- [6] Chan P K, Stolfo S J. Toward scalable learning with non-uniform class and cost distributions. A case study in credit card fraud detection [C]. Proceedings of the 4 th International Conference on Knowledge Discovery and Data Mining, New York, 1998:164-168
- [7] Huang K Z, Yang H Q, Irwin K, Michael R L, Chan L W. Biased minimax probability machine for medical diagnosis [C]. Proceedings of 8th International Symposium on Artificial Intelligence and Mathematics, Florida, 2004
- [8] Japkowicz N. Proceedings of the AAAI'2000 workshop on learning from imbalanced
- [9] data sets [J]. Aaai Tech Report 2000:1-5
- [10] Visa S, Ralescu. Issues in mining imbalanced data sets review paper [C]. Proceedings of the Sixteen Midwest Artificial Intelligence and Cognitive Science Conference, 2005:16~17
- [11] 唐珂. 数据不平衡分类问题研究 [D]. 中国科学技术大学, 2011, 4
- [12] Vapnik V. The nature of statistical learning theory [M]. New York, Springer-Verlag, 1995
- [13] 郑恩辉, 李平, 宋执环. 不平衡数据挖掘:类分布对支持向量机的影响 [J]. 信息与控制, 2005, 34(6):703-708
- [14] L A Zadeh. FuzZy sets [J]. Information and Control, 1965, 8: 338-353
- [15] 李继东. 遗传模糊分类系统构建中规则获取和解释性优化的关键技术研究 [D]. 云南大学, 2011, 10:2-5
- [16] Schapire R E. The strength of weak learnability [J]. Machine Learning, 1990, 5(20):197-223
- [17] Freund Y, Schapire R E. A decision-theoretic generalization of on-line learning and an

- application to boosting. *Journal of Computer and System Sciences*, 1997, 55(1):119-138
- [18] Mahesh V, Vipin K, Ramesh C. Evaluating boosting algorithms to classify rare classes: Comparison and Improvements [C]. *Proceedings of the 1st IEEE International Conference on Data Mining*, San Jose, Canada, 2001:257-264
- [19] Guo H Y, Hemal V. Learning from imbalanced data sets with boosting and data generation: The data boost-IM approach [J]. *SIGKDD Explorations*, 2003, 6:30-39
- [20] 谢纪刚, 裘正定. 非平衡数据集 Fisher 线性判别模型 [J]. *北京交通大学学报*, 2006, 30(5):15-18
- [21] Ross A McDonald. The mean subjective score, a novel metric for cost-sensitive classifier evaluation. *Pattern Recognition Letters*, 2006, 27(13):1472-1477
- [22] 李正欣, 赵林度. 基于 SMOTEboost 的非均衡 SVM 分类器 [J]. *系统工程研究所*, 2008(5):80-85
- [23] Chawla N, Bowyer K, Hall L, Kegelmeyer W. SMOTE: Synthetic minority over-sampling technique. *Journal of Artificial Intelligence Research*, v 16, January/June, 2002:321-357
- [24] R Akbani, S Kwek, N Japkowicz. Applying support vector machines to imbalanced datasets. *15th European Conference on Machine Learning*, 2004:39-50
- [25] 杨智明. 面向不平衡数据的支持向量机分类方法研究 [D]. 哈尔滨工业大学, 2009:20-31
- [26] 赵丽. 全局 K-均值聚类算法研究与改进 [D]. 西安电子科技大学, 2013:14-18
- [27] Sulaiman S N, Isa N A M. Adaptive fuzzy-K-means clustering algorithm for image segmentation. *IEEE Transactions on Consumer Electronics*, November, 56(14): 2661-2668
- [28] 王和勇, 樊泓坤, 姚正安, 李成安. 不平衡数据集的分类方法研究 [J]. *计算机应用研究*, 2008, 5(25):1
- [29] Bradley A. The use of the area under The ROC: Curve in the evaluation of machine learning algorithms [J]. *Pattern Recognition*, 1997, 30(6): 1145-1159
- [30] Holte R C, Acker L E, Porter B W. Concept learning and the problem of small disjuncts [C]. *Proceedings of the 11th International Joint Conference on Artificial Intelligence*, Austin Morgan Kaufmann, 1989:813-818
- [31] 缪志敏. 基于单分类器的数据不平衡问题研究 [D]. 中国人民解放军理工大学指挥自动化学院, 2008
- [32] Weiss G M, Provost F. Learning when training data are costly: The effect of class distribution on tree induction [J]. *Journal of Artificial Intelligence Research*, 2003,

19:315-354

- [33]杨明, 尹军梅, 吉根林. 不平衡数据分类方法综述 [J]. 南京师范大学学报, 2008, 4(8):7
- [34]Maloof M A. Learning when data sets are imbalanced and when costs are unequal and unknown [C]. ICML-2003 Workshop on Learning from Imbalanced Data Sets II, Washington DC: AAAI Press, 2003
- [35]C.Li. Classifying imbalanced data using a bagging ensemble variation (BEV). Proceedings of the 45th Annual Southeast Regional Conference, Winston-Salem, North Carolin, March, 2007:23-24
- [36]Kubat M, Matwin S. Addressing the curse of imbalanced training sets: one-sided selection [A]. Proc of the 14th International Conference on Machine Learning [C]. San Francisco, CA: Morgan Kaufmann, 1997:217-225.
- [37]Ratnara J S, Jagannathan S, Rao V. OEDSR:optimized energy delay sub-network routing in wireless sensor network [C]. Proc of IEEE International Conference on Networking, Sensing and Control, 2006:330-335
- [38]Sanlih O, Cam H, Cheng Xiu-zhen. EQOS: an energy efficient QOS protocol for wireless sensor networks [C]. Proc of Western Simulation Multi Conference, San Diego, 2004
- [39]Bezdek J C. Pattern recognition with fuzzy objective function algorithms [M]. New York, Plenum Press, 1981
- [40]张忠平, 陈丽, 王爱杰, 林志杰. 基于自适应模糊 C-均值的增量式聚类算法 [J]. 计算机工程, 2009, 35(6):60-62
- [41]Veropoulos K, Campbell C, Cristianini N. Controlling the sensitivity of support vector machines, 1999:36-44
- [42]郝妹雯. 基于支持向量机的不平衡数据集分类算法研究 [D]. 哈尔滨工程大学, 2011:26
- [43]黄岚. 基于遗传算法的模糊分类系统的设计 [D]. 南京理工大学, 2005:5-6
- [44]孙增沂 等. 智能控制理论与技术 [M]. 第一版, 北京:清华大学出版社, 1997
- [45]吴晓莉, 林哲辉. MARLAB 辅助模糊系统设计 [M]. 西安:西安电子科技大学出版社, 2002
- [46]罗承忠. 模糊集引论 [M]. 北京:北京师范大学出版社, 1989
- [47]E H Mamdani, S Assilian. An experiment in linguistic synthesis with a fuzzy logice controller [J]. International Journal of Man-Machine Studies, 1975, 7:1-113
- [48]Takagi T, Sugeno M. Fuzzy identification of systems and its application to modeling and control [J]. IEEE Trans on Systems, Man and Cybernetics, 1985, 15(1): 116-132

- [49] Ludmila I K. How good are fuzzy if-then classifiers. IEEE Transactions on Systems, Man, and Cybernetics-Part: B, Cybernetics, Vol. 30, No.4, August 2000
- [50] 张永. 基于解释性与精确性的模糊建模方法研究 [D]. 南京理工大学, 2006:13
- [51] 张永 等. 基于 Pareto 协同进化算法的 TS 模糊模型设计 [J]. 控制与决策, 2006
- [52] Gustafson D, Kessel W. Fuzzy Clustering with a Fuzzy Covariance Matrix [A]. Proc of IEEE Conf on Decision and Control [C]. San Diego, 1979:761-766.
- [53] 张忠平, 陈丽萍, 王爱杰, 林志杰. 基于自适应模糊 c-均值的增量式聚类算法 [J]. 计算机工程, 2009, 35(6):60-62
- [54] 邢宗义 等. 基于模糊聚类和遗传算法的具备解释性和精确性的模糊分类系统设计 [J]. 电子学报, 2006
- [55] 周明, 孙树栋. 遗传算法原理及应用 [M]. 第一版, 北京:国防工业出版社, 1999
- [56] 张道强. 典型相关分析的局部保持以及代价敏感的研究及应用 [D]. 南京航空航天大学, 2012
- [57] Pedro Villar, Alberto Fernández, Francisco Herrera. Studying the Behavior of a Multiobjective Genetic Algorithm to design Fuzzy Rule-Based Classification Systems for Imbalanced Data-Sets [A]. IEEE International Conference on Fuzzy Systems [C]. 2011: 1239-1246
- [58] Alberto Fernández, María José del Jesus, Francisco Herrera. On the influence of an adaptive inference system in fuzzy rule based classification systems for imbalanced data-sets [J]. Expert Systems with Applications, 2009, 36: 9805-9812
- [59] José Antonio Sanz, Alberto Fernández, Humberto Bustince, Francisco Herrera. Improving the performance of fuzzy rule-based classification systems with interval-valued fuzzy sets and genetic amplitude tuning. Information Sciences, 2010, 180, 3674-3685
- [60] Alberto Fernández, María José del Jesus, Francisco Herrera. Hierarchical fuzzy rule based classification systems with genetic rule selection for imbalanced data-sets [J]. International Journal of Approximate Reasoning, 2009, 50: 561-577
- [61] Abonyi J, Roubos J A, Szeifert F. Data-driven generation of compact, accurate, and linguistically sound fuzzy classifiers based on a decision-tree initialization [J]. International journal of approximate reasoning, 2003, 32: 1