

分类号_____
学校代码 10488

学号 202205703045
密级_____

武汉科技大学

硕士学位论文

全日制学术学位

基于 Benford-LightGBM 的上市公司 财务风险预警研究

学位申请人：张伟龙

学科专业：工商管理

指导教师：潘丹

答辩日期：2025 年 5 月

**A Dissertation Submitted in Partial Fulfillment of the Requirements
for the Degree of Master in Management**

**Research on Financial Risk Early Warning
of Listed Companies Based on
Benford-LightGBM**

Master Candidate:

Weilong Zhang

Major:

Business Administration

Supervisor:

Prof.Dan.Pan

Wuhan University of Science and Technology

Wuhan, Hubei 430081, China

May, 2025

摘要

尽管我国政府不断加大对上市公司的监管力度,但各公司经营策略不当、成本控制不力、股权结构不稳定、违规操作等问题屡见不鲜,导致目前仍有较多的ST公司,这不仅会损害投资者利益、扭曲市场资源配置,还可能削弱公众对市场的信任,并对就业和社会稳定产生不利影响。因此,构建准确、可靠的财务风险预警模型,提前识别公司财务风险,预防公司被ST,成为学界和业界亟待解决的问题。

Benford定律在财务数据质量评估领域中有广泛的应用,是一种有效的手段来检验财务数据的质量。LightGBM能够高效处理海量数据,显著减少内存消耗,同时提升模型训练的精度,尤其适合处理复杂的预测问题。鉴于此,本文将Benford定律和LightGBM模型相结合,构建预警模型。首先,通过Benford定律对财务数据的质量进行检验,并在此基础上构造出Benford因子。其次,将Benford因子作为重要的补充变量,纳入财务指标体系中,建立Benford-LightGBM模型。最后,以中国A股2925家上市公司作为样本,用Benford-LightGBM模型对财务风险进行预警,并评价Benford-LightGBM模型的预警效果。

研究结果显示:融合了Benford因子的Benford-LightGBM模型可以用于预测上市公司财务风险,在878家测试集公司中,Benford-LightGBM模型预警准确的有865家,Benford-LightGBM模型召回率为0.76、精确率为0.84、F1值为0.8、AUC值为0.9757。Benford-LightGBM模型准确性高于LightGBM模型、基于Benford律的随机森林模型、随机森林模型。召回率比上述模型分别高了0.14、0.26、0.29;精确率比上述模型分别高了0.6、0.7、0.11;F1值比上述模型分别高了0.11、0.19、0.23,AUC值比上述模型分别高了0.0272、0.0296、0.0433。

关键词: 上市公司; 财务风险预警; Benford-LightGBM模型; 防控策略

Abstract

Although the Chinese government continues to strengthen its supervision of listed companies, issues such as improper business strategies, poor cost control, unstable equity structures, and illegal operations remain prevalent. These problems have led to an increase in the number of Special Treatment ST companies, which not only harm investor interests and distort the allocation of market resources but may also weaken public trust in the market and adversely affect employment and social stability. Therefore, constructing an accurate and reliable financial risk early warning model to identify companies' financial risks in advance and prevent them from becoming ST has become an urgent issue for both academia and industry.

Benford's Law has been widely used in the field of financial data quality assessment and is an effective tool for testing the quality of financial data. LightGBM, on the other hand, can efficiently process massive amounts of data, significantly reduce memory consumption, and improve the accuracy of model training, making it particularly suitable for complex prediction problems. In light of this, this thesis attempts to combine Benford's Law with the LightGBM model to construct an early warning model. First, the quality of financial data is tested using Benford's Law, and the Benford factor is constructed based on the results. Second, the Benford factor is incorporated into the financial indicator system as an important supplementary variable, and the Benford-LightGBM model is established. Finally, using a sample of 2925 A-share listed companies in China, the Benford-LightGBM model is applied to provide early warnings of financial risks, and its effectiveness is evaluated.

The results show that the Benford-LightGBM model can effectively predict the financial risks of listed companies. Among the 878 companies in the test set, the Benford-LightGBM model accurately provided early warnings for 865 companies. The model achieved a recall rate of 0.76, a precision of 0.84, an F1 score of 0.8, and an AUC value of 0.9757. The accuracy of the Benford-LightGBM model is higher than that of the LightGBM model, the Benford-based random forest model, and the

standard random forest model. Specifically, the recall rate is 0.14, 0.26, and 0.29 higher than these models, respectively; the precision is 0.6, 0.7, and 0.11 higher; the F1 score is 0.11, 0.19, and 0.23 higher; and the AUC values are 0.0272, 0.0296, and 0.0433 higher, respectively.

Keywords: Listed Companies; Financial Risk Early Warning; Benford-LightGBM Mode; Prevention and control strategies

目 录

第 1 章 绪论.....	1
1.1 研究背景与研究意义.....	1
1.1.1 研究背景.....	1
1.1.2 研究意义.....	2
1.2 国内外研究现状.....	2
1.2.1 财务风险预警指标体系的相关研究.....	2
1.2.2 财务风险预警模型的相关研究.....	3
1.2.3 财务风险防范策略的相关研究.....	5
1.2.4 国内外研究述评.....	7
1.3 研究内容.....	7
1.4 研究思路与方法.....	8
1.4.1 研究思路.....	8
1.4.2 研究方法.....	10
1.5 创新点.....	10
第 2 章 相关概念及基本理论	12
2.1 财务风险预警的概念和特点	12
2.1.1 财务风险预警的概念.....	12
2.1.2 财务风险预警的特点.....	12
2.2 基本理论.....	13
2.2.1 风险管理理论.....	13
2.2.2 危机管理理论.....	13
2.2.3 利益相关者理论.....	14
2.3 财务风险预警模型的比较与选择	14
2.3.1 财务风险预警模型的比较.....	15
2.3.2 财务风险预警模型的选择.....	15
第 3 章 基于 Benford-LightGBM 的上市公司财务风险预警模型的构建	17
3.1 Benford-LightGBM 预警模型的构建过程	17
3.1.1 构造 Benford 因子.....	18
3.1.2 构建 Benford-LightGBM 预警模型	18
3.1.3 模型准确性评估.....	20
3.2 上市公司财务风险预警指标体系的初选	21
3.2.1 指标选取的原则.....	21
3.2.2 指标的初步选定.....	22

3.3 上市公司财务风险预警指标体系的筛选	26
3.3.1 筛选原因	26
3.3.2 筛选方法	26
3.3.3 筛选结果	26
第 4 章 实证研究	29
4.1 样本选取	29
4.1.1 样本选取标准	29
4.1.2 样本选取范围及时间	29
4.1.3 样本的初步确定	29
4.2 数据来源与处理	29
4.2.1 数据来源	29
4.2.2 数据处理	30
4.3 财务风险预警	32
4.3.1 描述性统计分析	32
4.3.2 构造 Benford 因子	35
4.3.3 模型预警结果	38
4.4 模型的可靠性和稳定性检验	39
4.4.1 模型的可靠性检验	39
4.4.2 模型的稳定性检验	43
第 5 章 上市公司财务风险防控策略	45
5.1 构建财务数据监控平台	45
5.1.1 开展数据采集与整合	45
5.1.2 设计异常预警机制	45
5.2 定期发布 Benford 分析报告	46
5.2.1 明确 Benford 分析标准	46
5.2.2 发布行业对比分析报告	46
5.2.3 发布公司深入分析报告	47
5.2.4 实时披露分析报告	47
5.3 优化对预警企业的监管	47
5.3.1 培训预警企业	47
5.3.2 跟踪监测预警企业	48
5.3.3 帮扶预警企业	48
5.4 引入新型技术赋能监管	49
5.4.1 引入大数据与人工智能技术提高监管效率	49
5.4.2 探索区块链技术保障数据安全	49
第 6 章 结论与展望	51
6.1 研究结论	51
6.2 不足与展望	52

参考文献.....	53
-----------	----

第 1 章 绪论

1.1 研究背景与研究意义

1.1.1 研究背景

在当前全球经济波动加剧和数字化进程快速推进的形势下,企业财务风险预警机制的研究价值愈发显著。伴随国际经济融合程度不断提高,企业经营环境变得愈加错综复杂,财务风险表现出多样化的表现形式、不易察觉的特性以及快速传播的特点。值得关注的是,以大数据分析和机器学习为代表的现代信息技术的突飞猛进,为财务风险监测与预警带来了全新的技术支撑。但是,现有财务风险预警系统往往存在响应迟缓、预测精度有限等缺陷,无法有效应对瞬息万变的市场状况。面对这一现状,开发具备智能分析和即时响应能力的财务风险预警系统已成为学术界和实务界的共同需求。这一研究不仅能够强化企业的风险管控水平,保障投资人利益,同时对于健全金融监管框架、预防系统性金融风险也具有积极的实践价值。正因如此,研究如何运用前沿技术手段创新财务风险预警方法,构建合理高效的预警指标系统,已然成为当下财务风险管控领域的关键研究课题。

Benford 定律是检验财务数据真实性的工具之一。该定律指出以 1 为首位数字的数的出现概率约为总数的三成,接近期望值 $1/9$ 的 3 倍,且随着数字增大,其作为首位数字的概率呈递减趋势。若财务数据的分布显著偏离 Benford 定律的预期模式,则可能表明数据存在人为操纵或舞弊风险。Benford 定律在会计、审计及税务监管等领域具有广泛应用。Carslaw (1988) 在 1988 年最早将该定律引入会计研究,并成功识别出财务舞弊的异常数据特征。此后,该定律在数据真实性检验方面的作用不断得到验证,成为评估财务数据质量的重要依据。通过运用 Benford 定律对财务数据进行初步筛查,可以有效降低数据失真对财务风险预警模型准确性的干扰,从而提升风险预测的可靠性。

基于上述分析,本研究提出一种融合 Benford 定律与 LightGBM 算法的财务风险预警模型。该模型首先运用 Benford 定律对财务指标进行数据质量检测,识别可能存在的异常值;其次,采用数据平衡技术优化样本分布,以提升模型的稳定性和泛化能力;此外,利用 Benford 因子标记企业财务指标数据存在异常的本点,将 Benford 因子与财务指标相结合引入 LightGBM 模型中,并将其与原始财务指标共同输入 LightGBM 模型进行训练。在模型验证阶段,通过精确率、召回率、F1 值及 AUC 等指标综合评估模型性能。为进一步验证模型的有效性,本研究同时构建基于 Benford 定律的随机森林模型作为对照模型。实验结果表明,相

较于传统方法，Benford-LightGBM 模型在财务风险预警的准确性和稳定性方面均表现出显著优势。

1.1.2 研究意义

从理论上，研究通过融合集成算法与数据采样技术，构建了一种新型组合预测模型。该方法创新性地将Benford因子纳入LightGBM框架，在分析财务数据首位数字实际分布与理论期望差异的基础上，建立了Benford-LightGBM预测体系，显著提高了模型的预警性能。针对财务风险预警研究中的样本不平衡问题，虽然已有学者注意到财务危机样本的稀缺性，并采用配对抽样方法平衡样本分布，但对非平衡数据处理方法的系统性研究仍显不足。本文重点解决了这一关键问题，通过采用数据采样技术对非平衡数据集进行优化处理，有效提升了模型的整体预测能力和稳定性。

在实践上，研究为市场参与者提供了重要的应用价值：首先，基于模型的财务数据分析能够有效识别潜在财务异常企业，帮助投资者规避可能存在舞弊风险的投资标的，从而显著降低投资决策风险，保障投资者合法权益。其次，该模型的推广应用能够提升企业财务信息的真实性和可靠性，有效缓解资本市场中的信息不对称问题。从监管视角来看，该模型可为监管机构提供客观的企业运营评估工具，有助于及时发现异常经营情况。这些应用效果将共同促进资本市场信息环境的改善，增强市场运行效率，对维护公平有序的市场秩序和推动资本市场长期健康发展具有积极的现实意义。

1.2 国内外研究现状

1.2.1 财务风险预警指标体系的相关研究

财务风险预警指标主要包括财务预警指标和非财务预警指标。

关于财务风险预警指标的研究发展历程，国际学术界最早可追溯至1932年。Beaver（1966）开创性地运用单变量分析法，从众多财务指标中筛选出最具代表性的变量进行财务困境预测^[1]。后续研究中，Cassy等（1985）尝试引入现金流量指标，但实证结果显示其对模型预测能力的提升效果有限^[2]。我国学者选取财务预警指标对企业风险进行分析，大多还是从偿债、盈利、营运、成长能力四个方面。聂丽洁等（2011）的创新性研究证实，基于现金流的预警指标体系相较于传统指标具有更低的误判率和更高的预测精度^[3]。李清等（2012）则通过21个多维财务指标构建了更为全面的预警模型^[4]。Finishtya（2019）针对印尼制造业的实证研究表明，经营现金流量和盈利能力指标具有显著预警价值^[5]。雷艳丽等（2022）考虑会计准则与会计制度特殊性的基础，调整5种基本财务比率作为判别

函数进行财务风险预警^[6]。田任均（2020）则专门针对新能源行业构建了包含经营状况、外部风险等维度的特色指标体系^[7]。Tedeschi等（2020）的实证研究表明，股东权益净利率和债务保障率这两个关键财务指标对企业财务风险具有显著预警作用。具体而言，股东权益净利率能够有效反映企业的盈利水平，而债务保障率则可以准确评估企业面临的偿债压力，这两个指标的协同分析为判断企业财务健康状况提供了重要依据^[8]。王昱等（2020）创新性地突破了传统财务指标的局限，将经营效率、融资效率和人力资本效率等非传统指标纳入预警体系，构建了多维效率指标体系。其实证结果显示，这种综合性的指标体系显著提升了模型的预测精度^[9]。王洋洋（2020）的研究更进一步，不仅选取了32个具有代表性的财务指标，还创新性地引入了网络舆情这一非结构化数据，构建了融合定量与定性指标的综合预警模型。该模型的测试结果表明，其对财务健康企业和困境企业均展现出优异的判别能力^[10]。

关于非财务指标的研究，学术界普遍认为非财务因素对企业财务危机具有显著预警作用。杨华（2007）在研究中引入了一系列非财务变量，包括企业年报信息、规模特征、治理结构以及地域因素等，并将其纳入财务预警模型的构建。研究结果表明，相较于单纯依赖财务指标的模型，融合非财务变量的预警模型具有更优的预测效果^[11]。李志强（2009）在财务预警模型构建过程中，对指标体系的优化选择进行了系统研究。该研究重点探讨了非财务指标在风险预警中的关键作用，具体涵盖组织文化特征、人力资源质量、股权配置模式、治理机制完善程度、独立审计质量、市场竞争优势以及宏观经济环境等多个维度^[12]。郑立（2019）在针对制造业上市公司的研究中，创新性地将股权特征变量纳入财务风险预警体系，并通过科学方法对初始指标进行优化筛选。研究发现，经过精简后的预警指标体系中，第一大股东持股比例这一关键变量仍被保留，实证结果表明该指标对提升模型预测效能具有显著贡献^[13]。余杰（2014）在研究中采用多元化的指标体系，综合选取了五类财务指标及反映公司治理状况的非财务指标，构建了适用于制造业企业的财务风险预警模型^[14]。鲍新中（2016）在上市公司财务动态监测体系研究中，创新性地将独立审计意见作为重要预测变量纳入评估框架^[15]。吕景胜（2016）通过实证分析方法探讨了董事会结构特征对企业内控有效性的作用机制，研究发现董事会特征会通过影响其决策行为进而对内部控制缺陷产生显著影响^[16]。李扬（2016）在构建预警模型时采用了更为全面的指标体系，共选取包含财务与非财务维度的60个预测变量^[17]。

1.2.2 财务风险预警模型的相关研究

随着人工智能技术的快速发展，各类先进的机器学习方法在财务风险预警领域得到广泛应用。众多学者相继将回归分析、深度学习网络、树状分类模型、集

成学习算法以及支持向量机等智能算法引入财务预警研究,显著提升了预测的准确性和可靠性。这一趋势表明,基于机器学习的预测技术已在各学科领域展现出强大的适用性,逐渐取代了统计模型和统计方法。早期学者多从统计角度对企业财务危机预测进行研究。Fitzpatrick (1932) 开创性地运用单变量分析方法研究企业财务风险,其研究证实特定财务指标确实具有风险预警功能,但该方法难以全面评估上市公司的整体财务风险状况^[18]。Altman (1968) 通过对比分析破产与非破产企业的财务特征,创新性地构建了具有里程碑意义的Z-Score多变量判别模型,为后续财务分析研究奠定了重要基础^[19]。

在财务危机预测研究的发展历程中, Logistic回归模型曾占据主导地位。Martin (1977) 通过实证研究对比了Z-Score模型和Logistic模型在美国银行业中的应用效果, 研究发现Logistic模型在区分正常经营银行与高风险银行方面表现出更优越的性能^[20]。Ohlson (1980) 的研究进一步证实, Logistic模型能够更好地刻画企业财务指标与财务危机之间的非线性关系^[21]。然而, 随着企业财务数据的日益多元化, 数据间的复杂关联性使得传统统计方法的局限性逐渐显现。为应对这一挑战, 学者们开始探索引入更先进的建模技术。杨潇 (2017) 创新性地提出了具有更强判别稳定性的RU-logit模型, 有效提升了预测效果^[22]。杨贵军 (2021) 的研究则发现, 通过引入修正的Benford因子, 可以显著优化Logistic模型的预测性能, 不仅提高了整体模型的预测准确率, 还成功降低了第一误错误类和第二类错误率^[23]。

近年来, 越来越多的学者尝试采用集成学习方法来提升财务风险预警的准确性。Chen (2012) 创新性地采用自组织映射 (SOM) 技术对企业财务特征进行降维处理, 随后将其与自适应模糊神经网络相结合, 构建了混合智能预警系统^[24]。Hsieh (2012) 则通过人工蜂群算法优化支持向量机 (SVM) 的参数选择, 成功开发了基于群体智能的集成预测模型^[25]。Chen (2013) 进一步引入粒子群优化算法, 实现了最优聚类中心与模糊推理系统的有机结合, 显著提升了模型的分类性能^[26]。

在集成学习方法的应用研究中, 多位学者验证了随机森林算法在财务风险预警中的优越性。方匡南 (2011) 通过实证分析发现, 随机森林算法采用Bootstrap重抽样技术集成多个弱分类器, 不仅有效克服了单一决策树模型的过拟合缺陷, 而且显著提高了分类预测的稳定性, 使财务风险识别的准确率得到明显提升^[27]。Katsuyuki (2016) 将该算法创新性地应用于银行业财务报表分析, 其研究数据证实, 相比传统的风险识别方法, 随机森林模型在银行破产风险预警方面展现出更出色的判别能力^[28]。方若男等人 (2020) 针对第三方支付违约风险问题构建的预警模型进一步表明, 随机森林算法在降低第一类错误率和第二类型错误率方面均显著优于传统的Logistic回归模型^[29]。杨贵军 (2019) 创新性地 将Benford定律

应用于模型改进,通过计算财务数据首位数字实际分布与理论分布的差异度,对传统Logistic模型进行优化,实验证明该方法能有效提升模型的预测精度^[30]。孙玲莉等(2021)在此基础上进一步深化研究,将Benford因子作为新的特征变量纳入指标体系,并采用随机森林算法构建预警模型,为财务风险研究开辟了新的技术路径^[31]。Aidas等(2021)系统评估了Logistic回归、神经网络和随机森林三种算法的预测性能,实证结果显示集成学习方法在财务风险预测中具有明显优势^[32]。黄志刚(2020)的研究不仅证实了随机森林在财务舞弊识别中的卓越表现,还特别指出特征选择对模型性能的重要影响,同时警示了财务数据中普遍存在的类别不平衡问题可能导致模型预测偏差^[33]。赵浩等(2020)提出了基于SmoteBoost算法的改进方案,该方法不仅能提高预测准确率,还能有效识别关键风险因素。其研究发现,每股资本公积、营运资金规模、成本率以及每股收益增长率等指标对企业财务风险具有显著影响^[34]。

作为一种高效的机器学习算法,LightGBM凭借其卓越的计算性能和预测准确度在多个领域获得广泛应用。该算法采用基于梯度的单边采样和互斥特征捆绑等创新技术,不仅显著提升了大规模数据处理的效率,还能有效降低内存消耗,这使得其在处理复杂预测问题时展现出独特优势。顾桐等(2020)使LightGBM模型在保持较高运算速度的同时,其预测结果与实际观测值具有良好的一致性,充分体现了数据挖掘技术的实用价值^[35]。李梅芳(2021)的对比研究发现,相较于传统算法,LightGBM在业绩预测和分类任务中表现更为优异,尤其适用于上市公司财务困境的早期识别^[36]。叶志宇(2019)通过实证分析证实,LightGBM集成学习模型能够深入挖掘数据中的潜在规律,其特有的特征选择和组合机制可以捕捉更复杂的非线性关系,从而获得更高的预测精度^[37]。

作为一种有效的数字分析工具,Benford律在财务数据真实性检验中发挥着重要作用。该定律基于自然形成数据中数字出现的特定概率分布规律,当实际财务数据的数字分布显著偏离这一理论分布时,往往暗示着可能存在数据异常或人为操纵的情况。因此,在会计实务和审计工作中,Benford法则被广泛运用于识别潜在的财务舞弊行为和数据质量问题。Carslaw(1988)开创性地将该理论引入会计审计领域,通过分析财务数据的数字分布特征,首次系统性地揭示了舞弊性财务数据的数字分布规律^[38]。杨贵军研究团队(2019)在此基础上进行了创新性拓展,通过量化分析财务数据首位数字的实际分布与理论分布的偏离程度,成功构建了Benford-Logistic混合预警模型。实证研究表明,该改进模型较传统Logistic模型在财务风险预警准确率方面实现了显著提升^[30]。

1.2.3 财务风险防范策略的相关研究

现有研究主要从企业主体视角出发,探讨财务风险防控机制的构建策略。韩冬梅(2015)通过实证研究发现,培育积极的风险管理文化对组织行为的影响显著优于强制性管理指令。这种文化导向能够有效引导个体行为与组织目标保持一致,从而促进企业风险管控水平的提升和经营效益的改善。研究进一步指出,企业组织架构的设计合理性与管理行为的有效性之间存在显著的正相关关系,这种关系直接影响企业各项经营活动的管理效能^[39]。内控制度的完善也是财务风险防范策略的重要环节,漆颖斌(2023)认为提升会计信息质量需要构建全方位的监管体系。研究建议通过以下措施强化会计监督:首先,针对性质恶劣的财务舞弊行为实施严厉惩处,完善责任追溯机制;其次,建立多层次的检查评估制度,将定期检查与随机抽查相结合;最后,系统性地完善财务管理制度框架,为会计信息的准确性和及时性提供制度保障^[40]。随着时代的快速发展,大数据和机器学习在财务风险预警模型中也发挥着不可替代的作用,杨子晖等(2022)认为应当系统性地整合机器学习等智能化监测技术,通过深度学习算法和实时数据分析提升监管效能,将系统性风险指标纳入企业财务危机预警框架,完善财务风险防控长效机制^[41]。高扬(2022)在研究中指出,财务专业人员作为企业财务管理核心主体,其专业胜任能力和职业操守对风险防控具有决定性影响,应当系统性地提升财务团队的专业技术水平与职业道德水平^[42]。杭慧芹(2022)的研究表明,数字化转型为企业风险管理带来了革命性的变革机遇。首先,新兴的智能化技术装备为企业风险识别与应对提供了创新工具;其次,数字化转型推动了企业经营模式和商业生态的创新发展。研究特别指出,以大数据分析、物联网感知和云计算平台为代表的数字技术已深度融入企业管理实践,这些技术不仅显著提升了财务数据处理的自动化水平,更能实现对企业财务风险的动态监测与智能分析,从而构建起更加精准、高效的风险防控体系^[43]。李心地(2021)的研究发现,随着企业经营规模的持续扩张,财务数据处理需求呈现指数级增长趋势。研究指出,传统财务分析模式受限于计算能力和分析方法,难以应对海量数据的深度挖掘需求。因此,要重点突破财务数据挖掘与分析的核心技术,通过算法优化提升风险识别的精准度,并且构建基于大数据的决策支持平台^[44]。

现有文献中基于市场监管视角的研究相对匮乏,尽管企业财务风险预警研究已取得丰硕成果,但多数研究仍局限于微观企业层面,缺乏从宏观监管视角的系统性探讨。杨凡(2025)探讨了财政部监管局与证监局协同监管对上市公司会计信息质量的影响。研究结果表明,协同监管机制对会计信息质量的提升效果显著,主要体现在两个方面:其一,财务报告的客观性与可信度得到实质性改善;其二,企业信息披露的完整性与可理解性明显增强。机制分析表明,协同监管通过强化监管威慑、优化监管资源配置和促进信息共享等途径发挥作用。研究为完善资本市场会计监管体系提供了实证依据,进一步推进监管协同,提升监管效能^[45]。

1.2.4 国内外研究述评

通过对现有文献的系统梳理可以发现,当前财务风险预警研究主要呈现以下特征:在研究方法上,学者们普遍采用判别分析法、Logistic回归模型、BP神经网络以及随机森林等机器学习算法;在研究变量选择方面,则主要依赖于各类财务指标作为核心解释变量。这种研究方法在财务风险预警领域已形成相对成熟的分析框架,为上市公司财务风险识别提供了重要的方法论支持。但随着企业财务数据规模的指数级增长和业务复杂度的不断提升,对模型预测的准确率的要求也越来越高,从实际和规范的角度来看,传统机器学习方法在应对大规模数据集时可能会存在一定的复杂性与局限性。尽管LightGBM模型在财务风险预警领域的应用尚未得到广泛研究,但其卓越的技术特性已展现出显著优势。作为一种基于梯度提升框架的高效算法,LightGBM通过创新的直方图优化和单边采样技术,在保证模型准确性的同时,实现了对大规模数据的高速处理能力。并且,该模型采用独特的内存优化机制,显著降低了计算资源需求,这使得其在处理企业财务数据时具有突出的性能表现。值得注意的是:一方面,虽然财务数据首位数字分布特征已被证实对风险预警模型性能具有显著影响,但现有文献中结合Benford定律构建组合模型的研究仍然较为匮乏;另一方面,多数研究采用1:1的样本匹配方法或较小比例的不平衡数据,这与现实中财务异常企业与正常企业数量存在显著差异的实际情况不相符,且小样本可能导致信息表达不充分。针对这些局限性,本研究融合Benford定律的数字分布特征分析与先进的非平衡数据处理方法,开发了新型的Benford-LightGBM预警模型,以期更准确地反映真实商业环境中的财务风险分布特征。该模型通过整合数字频率异常检测与不平衡学习技术,为解决传统研究中样本代表性和信息充分性不足的问题提供了新的思路。

此外,现有研究缺乏从宏观监管视角的系统性理论探讨,这种研究视角的局限性可能导致理论框架的完整性受损。本文从市场监管视角切入,提出了上市公司财务风险防范策略,旨在通过优化监管资源配置、强化信息披露机制和完善风险预警体系,为上市公司财务风险防范提供创新性解决方案。这一研究不仅拓展了财务风险预警的理论边界,也为监管部门制定精准化、智能化的监管策略提供了理论依据和实践指导。

1.3 研究内容

本研究将Benford法则与LightGBM算法相结合,构建了一种新型的财务风险预警模型。针对现实场景中财务数据存在的不平衡分布特性,研究特别引入了先进的非平衡数据处理技术,以提升模型在现实环境中的适用性。研究选取我国A

股上市公司作为研究对象，通过整合数字分布特征分析和机器学习算法，旨在建立更加精准、稳健的财务风险预警体系。具体研究内容如下：

首先，本文运用实证研究法、文献研究法等研究方法并结合风险管理理论、深入探究企业财务风险问题。

其次，利用Benford律对企业的财务指标数据进行质量校验，旨在识别并标注出潜在的异常数据点；同时，为了确保模型训练所用数据的平衡性和可靠性，运用非平衡数据处理技术对样本数据进行预处理；并提出Benford因子的构造方法，利用Benford因子标记出企业财务指标中存在的异常数据点。

随后，将这些标记了Benford因子的财务指标数据融入到LightGBM模型中，以此构建了Benford-LightGBM模型来对企业的财务风险进行预警。采用了精确率、召回率、F1值以及AUC值等多个评估指标来对模型进行验证。为了进一步表明Benford-LightGBM模型在财务风险预警方面的优势，还引入了基于Benford律的随机森林模型作为对照模型。

最后，针对目前上市公司存在的财务风险问题提出了相应的防范策略，期望能为政府监管、投资者决策以及企业自我审视提供有力的理论参考。

1.4 研究思路与方法

1.4.1 研究思路

本文的研究思路如图1.1所示。

第一部分是理论研究。这一部分主要围绕财务风险指数的概念及其特点展开，探讨Benford-LightGBM模型的动态特性及适用性。通过文献研究法，结合风险管理理论分析潜在风险预警体系结构的动态变化，为后续研究奠定理论基础。

第二部分是模型构建与指标体系筛选。在这一部分中，重点构建财务风险指标体系，筛选关键指标，并引入Benford因子及其动态特性。同时，明确模型评估标准，为后续实证研究提供科学依据。

第三部分是实证研究和模型的可靠性检验与稳定性检验。这一部分包括样本选取和数据处理，利用Smote过采样技术对数据进行优化。通过构建Benford-LightGBM模型，结合ROC曲线、AUC值和F1值等评估工具，对模型性能进行全面分析。并对模型进行可靠性检验，确保其稳定性和准确性。通过反复验证和优化，进一步提升Benford-LightGBM模型的实际应用价值，为财务风险预警提供可靠的工具。




图 1.1 研究思路导图

1.4.2 研究方法

（1）文献研究法

通过阅读相关文献，掌握了财务风险指标在相关财务风险预警模型中的运用以及财务数据首位数字实际出现频率和理论频率的差异对于财务风险模型的影响，掌握了相关财务风险模型的构建方法。在系统梳理国内外相关文献的基础上，本研究深入分析了企业财务风险预警领域的发展现状。通过文献研究发现，现有研究在模型构建、变量选择和数据样本处理等方面仍存在若干亟待解决的问题。这些研究缺口为本研究提供了重要的理论切入点，进而明确了本文的研究重点和创新方向。

（2）实证研究法

本文选取2020-2022年间A股上市公司作为研究样本，创新性地构建了一个融合多维度特征的财务风险预警组合模型。研究首先基于Benford法则对财务数据的数字分布特征进行系统分析，通过计算实际频率与理论频率的差异构建Benford因子。在数据预处理阶段，采用统计分析与机器学习相结合的方法对原始指标进行优化处理。在此基础上，将Benford因子作为重要特征变量整合进LightGBM算法框架，最终构建出新型的Benford-LightGBM预警模型。实证研究表明，该模型通过有效捕捉财务数据的数字分布异常特征，显著提升了财务危机预测的准确性和可靠性。

（3）比较分析法

本文采用多模型比较的研究方法，在构建LightGBM预警模型的同时，同时建立了随机森林模型作为对照模型。在模型性能评估环节，突破传统单一指标评价的局限性，创新性地设计了包含准确率、召回率、F1值以及AUC等在内的多维评估体系。通过这种综合性的对比分析方法，系统考察了不同模型在财务危机预警任务中的表现差异，最终确定了最适合我国上市公司财务风险预警的最优模型架构。

1.5 创新点

目前的预警模型较少考虑首位数字实际出现频率和理论频率的差异，并且在财务风险预警研究中，鲜有建立LightGBM模型用于财务预警的研究。作为一种高效的梯度提升框架，LightGBM算法在财务风险预警领域展现出卓越的技术优势。该算法通过基于直方图的决策树算法和leaf-wise的生长策略，显著提升了大规模数据集的处理效率。本文通过比较首位数字实际出现频率和理论频率的差异来判断企业是否存在财务风险，从而在Benford律的基础上，构建了Benford-LightGBM模型。

现有研究在样本选择上普遍采用1:1的平衡抽样方法，或仅保持较小程度的不平衡比例。然而，这种抽样设计与实际情况存在明显偏差，现实中两类公司的数量分布往往呈现显著不平衡特征。更重要的是，小样本容量可能导致关键信息缺失，影响模型的泛化能力。针对这一问题，本研究创新性地结合Benford律与非平衡数据处理技术，构建了Benford-LightGBM预警模型。该方法不仅更符合真实环境中企业的分布特征，还能有效提升模型对少数类样本的识别能力。

第2章 相关概念及基本理论

2.1 财务风险预警的概念和特点

2.1.1 财务风险预警的概念

财务风险是指企业在经营管理过程中,由于各种内外部因素的不确定性而导致的财务状况恶化或资金链断裂的可能性。这种风险源于企业筹资、投资、运营和分配等财务活动的各个环节,主要表现为偿债能力不足、资金周转困难、盈利能力下降等财务困境。财务风险具有隐蔽性、累积性和传导性等特征,其形成往往受到宏观经济环境、行业竞争态势、企业管理水平等多重因素的影响。有效的财务风险管理需要建立在对企业财务状况全面监测和科学分析的基础上,通过及时发现财务异常信号,评估风险程度,并采取针对性措施来防范和化解潜在危机。财务风险预警作为风险管理的重要工具,通过对关键财务指标的持续跟踪和分析,为企业提供风险预判和决策支持。

作为企业经营预警系统的核心组成部分,财务风险预警不仅承担着风险预警的角色,还为企业调整经营战略、优化经营决策及高效调配资源提供了坚实的数据支撑与可靠依据。

2.1.2 财务风险预警的特点

财务风险预警的特点主要体现在以下几个方面:

(1) 前瞻性与预见性

财务风险预警的核心在于其前瞻性与预见性。通过对企业财务报表、经营规划及相关会计资料的分析,能够提前发现潜在的风险因素,为决策者提供足够的时间来制定和实施应对措施,从而避免或减轻风险带来的负面影响。

(2) 系统性与综合性

预警机制并不是单独存在的,而是存在与企业经营预警系统中。它融合了财会、统计、金融、企业管理及市场营销等多个领域的知识,采用多种分析方法,对企业经营活动与财务活动进行全面、系统的分析,以确保财务风险预警结果的准确与可靠。

(3) 动态性与实时性

在动态变化的商业环境中,企业面临的财务风险具有显著的时变特征,这就要求财务风险预警系统必须建立动态响应机制。该机制通过实时采集最新的经营数据和市场情报,持续优化预警指标体系和分析模型,从而保证风险监测的及时性和判断的准确性。

(4) 定量分析与定性分析相结合

预警机制不仅依赖于定量数据（如财务报表中的比率指标）进行分析，还结合定性信息（如市场环境、政策法规变化等）进行综合判断。

(5) 灵活性与适应性

由于不同企业所处的行业特征、发展阶段和经营模式存在显著差异，其面临的财务风险类型也呈现出明显的不同。这就要求财务风险预警系统必须具备高度的可配置性和自适应能力，能够根据特定企业的业务属性、风险偏好和管控需求进行个性化定制。

2.2 基本理论

2.2.1 风险管理理论

风险管理理论是在复杂多变的环境中，运用系统化方法对组织运营过程中潜在的不确定性因素进行识别、测度、评价和管控的理论体系。该理论旨在通过对各类风险的全面管理，既降低可能对组织战略目标产生负面影响的威胁，又把握潜在的发展机遇以提升组织价值。作为以企业风险管控为核心研究领域的理论集合，其本质特征在于采用定量与定性相结合的分析工具，构建完整的风险管理框架，通过科学的风险要素管控机制，有效规避经营过程中的不确定性风险，确保组织战略目标的顺利达成。

风险管理理论在财务风险预警中的应用，主要体现在通过系统性方法识别、评估和应对企业潜在的财务危机。企业通过构建财务风险预警模型，结合定量与定性分析，对偿债能力、盈利能力、营运能力等关键指标进行动态监测，及时发现异常信号。例如，运用Z-score模型或随机森林模型量化财务风险概率。同时，风险管理理论强调预警机制的持续优化，通过情景分析和压力测试模拟极端情况下的财务表现，并制定应急预案。最终目标是实现财务风险的早发现、早干预，为企业稳健经营提供决策支持。

风险管理理论为本研究构建财务风险预警模型奠定了重要的理论基础。基于该理论框架，本研究通过开发科学的预警模型，致力于识别和预测上市公司可能面临的财务困境。通过这种风险预警机制，相关利益方能够在风险显性化之前采取预防性措施，从而有效降低财务危机可能造成的经济损失。

2.2.2 危机管理理论

该理论将危机视为一个动态演化的过程，强调通过系统的预防和控制措施来降低危机发生的可能性和影响程度。该理论体系建立在危机演进模型基础之上，将危机发展过程系统性地解构为四个关键演进阶段：潜在累积期、显性爆发期、

持续影响期和恢复调整期。每个发展阶段都呈现出差异化的风险特征，需要采取针对性的管理策略。在财务风险预警领域，危机管理理论为风险识别、评估和应对提供了系统的理论框架，指导研究者构建动态预警指标体系，设计风险预警模型，并建立全过程的风险防控机制。该理论强调事前预防的重要性，主张通过持续监测和及时预警来降低风险发生的概率，同时注重危机应对策略的灵活性和适应性。然而，面对日益复杂的商业环境，危机管理理论在应对突发性风险和系统性风险方面仍存在一定局限性，需要与其他风险管理理论相结合，以提高财务风险预警的准确性和有效性。

危机管理理论强调通过预防、准备、响应和恢复的全周期管理来应对潜在的财务风险。企业通过建立动态监测机制，识别早期风险信号，如现金流异常、债务违约等，并借助压力测试和情景模拟评估危机冲击程度。在预警阶段，结合定量模型和定性分析，快速判断危机等级；在响应阶段，制定应急预案，如流动性调配或债务重组，以控制危机蔓延。同时，危机管理理论注重事后复盘，优化预警系统韧性，确保企业在财务危机后快速恢复，并提升未来抗风险能力。这一理论的应用使企业从被动应对转向主动防控，增强财务稳定性。

2.2.3 利益相关者理论

利益相关者理论为现代企业经营管理提供了重要的分析框架，该理论突破了将企业视为独立经济主体的传统认知，转而将其理解为由多元利益主体构成的复杂价值网络。在这个网络中，股东、债权人、员工、供应商、客户及政府监管部门等各方都与企业建立着特定的权益关系，并通过不同渠道影响着企业的经营决策和发展方向。将这一理论引入财务风险预警研究具有三重重要意义：其一，风险预警指标的設置需要兼顾不同利益主体的风险偏好和信息获取特点；其二，预警系统的设计应当整合关键利益相关者的专业判断；其三，风险信息的传递机制需满足各类主体的差异化决策需求。这种理论视角的创新，打破了传统财务风险预警局限于企业内部数据分析的固有模式，突出了风险管理的系统性和协同效应，为建立多方联动的综合性风险预警机制奠定了理论基础。

利益相关者理论在财务风险预警中的应用强调企业需关注多方主体的利益诉求及其对财务风险的影响。不同于传统预警模型仅聚焦财务指标，该理论通过股东、债权人、员工、供应商及政府等利益相关者的行为与反馈作为风险信号。通过监测利益相关者的动态变化，如债权人态度转变、客户集中度波动或监管处罚等非财务信息，企业能更全面地识别潜在风险。同时，良好的利益相关者关系管理可降低风险传导效应，如通过稳定供应链或优化融资结构缓解流动性压力，从而构建更具韧性的财务预警体系。

2.3 财务风险预警模型的比较与选择

2.3.1 财务风险预警模型的比较

(1) Z-score模型

Z-score模型是一种基于线性判别分析的财务风险预警模型，由Altman^[19]提出，主要用于预测企业破产风险。其优点在于简单易用，计算过程直观，适合快速评估企业的财务状况。此外，模型的解释性强，能够清晰地反映各项财务指标对企业风险的影响。然而，Z-score模型的局限性也很明显：它假设财务指标与风险之间呈线性关系，可能无法捕捉复杂的非线性模式；

(2) Logistic回归模型

Logistic回归模型是一种广泛应用于财务风险预警的统计方法，通过拟合财务数据来预测企业发生风险的概率^[46]。其优点在于灵活性高，能够处理多种类型的财务数据，适用于不同行业。模型输出的概率结果便于决策者进行风险评估，同时其解释性较好，可以通过系数分析各财务指标对风险的影响程度。然而，Logistic回归模型的缺点在于其线性边界假设，可能无法捕捉复杂的非线性关系；此外，模型对数据中的异常值敏感，且需要较大的样本量和高质量的数据支持，否则可能影响预测效果。

(3) 随机森林模型

随机森林模型能够处理高维数据，适用于复杂的财务数据集，能够同时分析多个变量，捕捉非线性关系；其次，随机森林通过集成多棵决策树，减少了过拟合风险，提升了模型的泛化能力；此外，其还能够评估特征的重要性，帮助企业识别关键风险因素^[47]。然而，随机森林模型的可解释性较差，尽管能够提供特征重要性，但具体决策过程仍较为复杂；同时，训练过程计算量较大，尤其在数据量庞大时，可能消耗较多时间和资源；最后，随机森林模型对噪声数据较为敏感，可能影响预测精度。

(4) LightGBM模型

LightGBM作为一种高效的梯度提升框架，具有显著优势。其采用基于直方图的决策树算法，大幅提升了计算效率，尤其适合处理大规模数据集^[48]。通过leaf-wise生长策略，模型能够实现更精准的分割，提高预测准确率。同时，LightGBM支持类别特征直接输入，避免了独热编码带来的维度问题。其内置的并行学习机制和分布式计算支持，进一步加快了训练速度。此外，LightGBM对缺失值具有天然处理能力，且不易过拟合，这些特性使其在实际应用中表现出色，成为处理结构化数据的首选算法之一。

2.3.2 财务风险预警模型的选择

Benford 定律能够有效检测财务数据中的异常分布，识别潜在的数据异常或操纵行为，提供初步的风险信号，通过检验财务数据首位数字是否符合 Benford

定律，可以作为一种有效的手段来识别潜在的财务风险行为，评估财务数据的质量，并据此评估企业的财务风险。并且 LightGBM 作为一种高效的机器学习模型，能够处理大规模数据，捕捉复杂的非线性关系，进一步提升预测精度。两者结合既能利用 Benford 定律的统计特性，又能发挥 LightGBM 的强大学习能力，从而提高财务风险预警的准确性和可靠性。

第3章 基于 Benford-LightGBM 的上市公司财务风险预警模型的构建

3.1 Benford-LightGBM 预警模型的构建过程

Benford 定律是数据的一种内在规律，指所有自然数据首位数字为 1-9 各数字的概率具有稳定性，其概率分布呈单调递减趋势（Benford, 1938）。Hill (1995) 给出了 Benford 律 的统计解释。记 $d=1,2,3,\dots,9$, 首位数字 D 为 d 的概率为：

$$f_{B,d} = \ln(1+1/d) \quad (3-1)$$

具体而言，当财务数据中首位数字的分布规律与 Benford 定律存在显著的差异时，这一偏差成为了数据可能被修饰或篡改的一个重要信号。这样的数据不仅质量低下，还预示着较高的财务风险，因为数据的不真实性可能掩盖了真实的财务状况，误导了决策者的判断。因此，通过检验财务数据首位数字是否符合 Benford 定律，可以作为一种有效的手段来识别潜在的财务风险行为，评估财务数据的质量，并据此评估企业的财务风险。 χ^2 拟合优度检验是检验一组数据首位数字分布规律是否服从 Benford 定律的最常用方法，检验统计量为：

$$\chi^2 = N \sum_{d=1}^9 [(f_d - f_{B,d})^2 / f_{B,d}] \quad (3-2)$$

其中， N 表示样本总量， f_d 为待检验数据的首位数字 d ($d=1,2,3,\dots,9$) 出现的频率。在给定显著性水平下，若 χ^2 检验统计量的值大于临界值，则拒绝原假设，认为该数据集中首位数字出现的频率不满足 Benford 定律，数据存在被修饰、篡改的可能。但这种检验方式只能评价数据总体质量情况，难以判断某个具体样本点是否存在风险。本文参考已有研究文献，通过 Benford 定律构建 Benford 因子以判断具体样本点是否存在数据质量问题，识别财务风险。

3.1.1 构造 Benford 因子

假设 X_j $\{j=1,2,3,\dots,k\}$ 表示财务指标变量。用 $r_d^{(j)}$ 表示指标 X_j 的首位数字 d 观测频率与 Benford 定律理论频率的差值，则 $r_d^{(j)}$ 的表达式为：

$$r_d^{(j)} = f_d^{(j)} - f_{B-d}^{(j)} \quad (3-3)$$

其中 $f_d^{(j)}$ 、 $f_{B-d}^{(j)}$ 分别表示指标 X_j 的首位数字 d 的观测频率和 Benford 定律理论频率，且满足 $\sum_{d=1}^9 f_d^{(j)} = 1$ 、 $\sum_{d=1}^9 f_{B-d}^{(j)} = 1$ 。则有：

$$\sum_{d=1}^9 r_d^{(j)} = 0 \quad (3-4)$$

当数据被修饰、篡改时，指标 X_j 的首位数字观测频率与理论频率会存在差异。差值 $r_d^{(j)}$ 绝对值越大的样本点出现财务风险越高。本文重点关注观测频率与理论频率差值绝对值最大的首位数字。令首位数字频率差值绝对值最大的数字为 $a^{(j)}$ ，即：

$$a^{(j)} = \operatorname{argmax}_d |r_d^{(j)}| \quad (3-5)$$

构造指标 X_j $\{j=1,2,3,\dots,k\}$ 的 Benford 因子，记为 B_j 。若样本点 i 的指标 $X_{i,j}$ 的首位数字为 $a^{(j)}$ ，则 B_j 取值为 1；否则，取值为 0。有如下表达式：

$$B_{i,j} = \begin{cases} 1 & X_{i,j} \text{ 首位数字为 } a^{(j)} \\ 0 & \text{其他} \end{cases} \quad (3-6)$$

3.1.2 构建 Benford-LightGBM 预警模型

Benford-LightGBM 模型的构造步骤如下：

首先, 利用 Benford 定律对数据集 D 中的自变量进行数据质量检验, 构造 Benford 因子。令 $D=\{(X_1, Y_1), (X_2, Y_2), \dots, (X_N, Y_N)\}$, X_i 表示自变量, $X_i=(X_{i,1}, X_{i,2}, \dots, X_{i,k}) \{i=1, 2, \dots, N\}$ 。 Y_i 表示分类变量, N 表示数据量, k 表示变量个数。计算观测频率与理论频率差值最大的首位数字。依据式(1.6) 标记 Benford 因子 B_j 。将构造好的 Benford 因子作为新的自变量加入模型中, 记新的变量为 $X_i^B=(X_{i,1}, X_{i,2}, \dots, X_{i,k}, B_{i,1}, B_{i,2}, \dots, B_{i,k}) \{i=1, 2, \dots, N\}$, 此时的数据集可记 $D^B=\{(X_1^B, Y_1), (X_2^B, Y_2), \dots, (X_N^B, Y_N)\}$ 。

其次, 将数据集 D^B 作为新的变量加入到 LightGBM 模型中。LightGBM (Light Gradient Boosting Machine) 是微软在 2017 年正式提出的一种算法。LightGBM 性能非常强大, 可以快速处理大规模数据, 大大降低对于内存的占用, 且准确度更高。LightGBM 算法为了指定的损失函数最小化, 通过训练找近似值, 也叫优化函数, 表示为:

$$\hat{f}(x) = \operatorname{argmin}_f E_{y,x} L(y_1, f(x)) \quad (3-7)$$

在模型中回归树用 $Mq(x)$, $q \in \{1, 2, \dots, J\}$ 表示, M 为叶子节点样本权重向量, J 为回归树中叶子个数。特别的, 在生成第 t 颗树时之前的 $(t-1)$ 颗树的信息均会被利用, 因此经过 t 次迭代生成的目标函数将如下所示:

$$\eta_t = \sum_{i=1}^n L(y_i, F_{t-1}(x_i)) g_i f_i(x_i) + \sum_{m=1}^m \Omega(f_m(x)) \quad (3-8)$$

在 LightGBM 模型中集成 K 颗回归树来拟合最终的模型, 这一过程可以表示为:

$$f_k(x) = \sum_{i=1}^k f_i(x) \quad (3-9)$$

其中为正则化项, 避免模型对训练数据过分拟合, 常用的正则化项主要有 L1 正则与 L2 正则。在目标函数的优化中, lightGBM 对目标函数进行二阶泰勒展开, 经过展开的目标函数表示为:

$$H(X^B) = \operatorname{argmax} \sum_{s=1}^n I(h_s(X^{B(s)}) = Y) \quad (3-10)$$

在确定树结构为 $q(x)$ 后, 相应的目标函数为:

$$\eta_t^* = -\frac{1}{2} \sum_{j=1}^J \frac{\left(\sum_{i \in I_j} g_i \right)^2}{\sum_{i \in I_j} h_i + \lambda} + \gamma^J \quad (3-11)$$

上式给出了各叶子节点最优权值得分，最小化目标函数，通过对回归树叶子节点分裂收益的计算，使得分裂收益最大化，并且筛选出了收益最高的分裂特征在条件满足之前，也就是该模型需要达到的最优的方案，这个过程将会不断迭代下去，分裂收益可采用下式：

$$F = \frac{1}{2} \left(\frac{(\sum_{i \in I_L} g_i)^2}{\sum_{i \in I_L} h_i + \lambda} + \frac{(\sum_{i \in I_R} g_i)^2}{\sum_{i \in I_R} h_i + \lambda} - \frac{(\sum_{i \in I_K} g_i)^2}{\sum_{i \in I_K} h_i + \lambda} \right) \quad (3-12)$$

3.1.3 模型准确性评估

对于本文所研究的两类上市公司样本，由于其属于高度不平衡的数据集（数量比例约为1:27），直接采用准确率作为评价标准将存在显著的局限性。如果一个模型简单地将所有样本都预测为多数类（即非ST公司），那么即便其准确率看似高达96%，但由于其忽略了少数类公司（ST公司）的重要信息，模型应用价值有待商榷。鉴于此，模型的评价标准采用了更为全面和客观的评价指标组合，包括AUC值、精确率、召回率和F1值，预测结果的分类矩阵如表3.1所示。

AUC值作为评估模型整体性能的常用指标，能够反映模型在正负样本间的区分能力；精确率则关注模型预测为正类的样本中实际为正类的比例；召回率则衡量了模型在所有实际为正类的样本中成功预测为正类的比例；而F1值则是精确率和召回率的调和平均数，能够综合反映两者的重要性，为模型评价提供一个更为全面的视角。这些指标能够从不同维度反映模型的性能，特别是在处理不平衡数据集时，其能够更准确地衡量模型对少数类的识别能力和整体分类效果。

表 3.1 预测结果的分类矩阵

实际分类	预测为 ST 公司	预测为正常公司
ST 公司	TP	FN
正常公司	FP	TN

AUC值根据ROC曲线计算得出，ROC曲线的纵轴代表的是真正例率，即实际为ST公司且被模型正确预测为ST公司的样本比例，横轴则代表假正例率，即实际为正常公司但被错误预测为ST公司的样本比例。AUC值是衡量ROC曲线下与坐标轴围成的面积大小的一个指标。AUC值的大小直接反映了模型的分类性能：当AUC值大于0.9时，表明模型的分类效果极其出色；若AUC值位于0.8至0.9之间，则代表模型分类效果优秀；AUC值在0.7至0.8范围内时，模型的分类能力被认为是一般；而若AUC值低于0.6，则通常认为该分类模型在实际应用中的价值不高，可能需要进一步改进或考虑其他模型。

精确率表示训练集中的实际ST公司样本个数占被预测为ST公司样本个数的比例，即： $Pre = TP / (TP + FP)$ 。精确率的取值范围为0到1，值越接近1表示模型的预测正例的能力越强，而值越接近0表示模型的预测正例的能力越弱。

召回率表示测试集中预测正确的ST公司样本个数占数据集中所有实际ST公司个数的比例，即： $Rec = TP / (TP + FN)$ 。召回率的取值范围也为0到1，值越接近1表示模型能够捕捉到更多的实际正例，而值越接近0表示模型的捕捉能力越弱。

F1值是精确率和召回率的调和均值，即： $F1 = (2 \times Pre \times Rec) / (Pre + Rec)$ 。F1值越接近1，说明模型的性能越好；反之，则说明模型的性能越差。

3.2 上市公司财务风险预警指标体系的初选

3.2.1 指标选取的原则

财务指标作为反映企业财务健康状况的重要量化工具，其选择标准应当与研究采用的分析方法相匹配。鉴于本研究主要运用机器学习技术构建财务预警模型，在指标筛选过程中特别注重以下原则：首先，确保指标体系的完整性，尽可能覆盖企业偿债能力、营运能力、盈利能力和发展能力等多个财务维度；其次，强调数据驱动的客观性，通过算法筛选减少主观判断的干扰；最后，保证信息含量的充分性，使所选指标能够全面捕捉上市公司财务危机的预警信号。在构建上市公司财务预警体系时，非财务指标发挥着不可替代的重要作用。单纯依赖财务指标进行分析存在明显的局限性，因为这些指标主要反映企业历史经营成果，难以揭示财务危机的深层次成因。事实上，许多非财务因素往往是财务表现的内在驱动力，二者的有机结合能够形成更加完整的风险识别框架。这种互补性体现在：财务指标提供量化的结果性数据，而非财务指标则揭示了经营过程中的质量性因素，二者协同作用可以显著提升预警系统的全面性和前瞻性。需要注意的是，非财务指标的获取和处理具有其特殊性。与直接从财务报表提取的财务指标不同，非财务信息通常分散于企业经营管理的各个层面，呈现出碎片化特征。因此，在筛选

非财务指标时,需要建立双重评估标准:一是考察指标对风险预警的重要性程度,二是评估数据获取的可行性。这种权衡方法有助于构建既科学合理又具操作性的非财务指标体系,为财务危机预警提供多维度的决策依据。

3.2.2 指标的初步选定

参考杨贵军等(2019)^[30]与李扬等(2016)^[17]等的研究,两位学者在构建指标体系时从盈利能力、营运能力、偿债能力、获现能力、成长能力、公司治理六个维度构建了指标体系。本文在构建财务风险预警指标体系时,考虑到企业规模是衡量企业在市场中占有率和影响力的关键因素,其反映了企业的市场地位与竞争力,对评估其财务稳健性至关重要,规模较大的企业,往往在市场中具有更强的话语权和资源整合能力,抗风险能力相对较强;而规模较小的企业,可能在面临市场波动、竞争压力时,财务风险更易凸显;内部管理能力指标是衡量企业内部运营效率和效果的关键参数,研发人员数量占比、研发投入占营业收入比例这两项指标,能衡量企业在产品开发、技术创新、管理创新等方面的能力和成果,企业的内部管理能力直接关系到其运营效率和长期发展潜力,高效的内部管理可以优化资源配置、降低成本、提高产品质量和市场竞争力,进而提升企业的盈利能力和财务稳定性。故本文在两位学者的基础上增加了企业规模指标以及内部管理能力指标。综上,本文共初选了财务和非财务领域的8个一级指标下共计74个二级指标作为财务风险预警指标体系,如表3.2所示。

盈利能力是指企业获取利润的能力。利润是企业长远而稳定的资金来源,良好的盈利能力能够帮助企业更好地防御财务风险。共选取资产报酬率、总资产净利润率等15个指标衡量盈利能力。

营运能力是指企业管理和运用存货、应收账款、固定资产、总资产等资产进行周转运作以赚取利润的能力。企业由于运作管理不善而造成的财务状况失衡会增加企业面临的财务风险。选取应收账款周转率、存货周转率等7个指标来衡量营运能力。

偿债能力是指企业偿还债务的能力。偿债能力低下容易使企业陷入财务危机,甚至破产清算,因此偿债能力的衡量指标直接揭示了企业财务风险的大小。偿债能力共选取流动比率、速动比率等17个指标。

获现能力体现了将资产、业务或其他资源转化为现金的能力。现金流量短缺会直接影响企业生产经营,容易引发财务危机。现金是企业所有资产中流动性最强的一项资产,也是企业维持日常经营活动和生产活动的基础。获现能力共选取每股经营活动产生的现金流量净额、每股现金净流量等6个指标。

成长能力是指企业扩展经营的能力,用于考察企业通过逐年收益增加或通过其他融资方式获取资金扩大经营的能力。成长能力共选取资本积累率、固定资产增长率等14个指标。

企业规模作为衡量企业在市场中占有率和影响力的关键因素,同样不容忽视,其反映了企业的市场地位与竞争力,对于评估其财务稳健性具有重要意义。选取企业资产规模、企业经营年限两个指标。

内部管理能力指标是衡量企业内部运营效率和效果的关键参数,本文选取了研发人员数量占比、研发投入占营业收入比例两项指标衡量企业在产品开发、技术创新、管理创新等方面的能力和成果。

公司治理指标可以有效衡量公司的治理水平和效率,故选取管理层持股比例、独立董事占比等10个指标来衡量公司的治理效率。

表3.2 财务风险预警指标

类型	指标	符号
盈利能力	资产报酬率	X1
	总资产净利润率	X2
	流动资产净利润率	X3
	固定资产净利润率	X4
	净资产收益率	X5
	息税前利润	X6
	营业毛利率	X7
	营业净利率	X8
	固定资产比率	X9
	综合杠杆	X10
	每股收益	X11
	每股营业总收入	X12
	每股营业利润	X13
	每股未分配利润	X14
	市盈率	X15
营运能力	应收账款周转率	X16
	存货周转率	X17

(续表 3.2)

类型	指标	符号
营运能力	营运资金周转率	X18
	流动资产周转率	X19
	固定资产周转	X20
	总资产周转率	X21
	股东权益周转率	X22
偿债能力	流动比率	X23
	速动比率	X24
	现金比率	X25
	利息保障倍数	X26
	资产负债率	X27
	保守速动比率	X28
	经营活动产生的现金流量净额 / 流动负债	X29
	权益乘数	X30
	有形资产负债率	X31
	产权比率	X32
	流动资产比率	X33
	现金资产比率	X34
	流动负债比率	X35
	营运资金比率	X36
	营运资金对净资产比率	X37
	固定资产对股东权益比率	X38
	每股净资产	X39
获现能力	营业收入现金含量	X40
	净利润现金含量	X41
	企业自由现金流	X42
	每股经营活动产生的现金流量净额	X43
	每股现金净流量	X44
	市现率	X45

(续表 3.2)

类型	指标	符号
成长能力	资本积累率	X46
	固定资产增长率	X47
	基本每股收益增长率	X48
	总资产增长率	X49
	净资产收益率增长率	X50
	净利润增长率	X51
	可持续增长率	X52
	市净率	X53
	归属于母公司净利润增长率	X54
	营业收入增长率	X55
	所有者权益增长率	X56
	每股净资产增长率	X57
	每股资本公积	X58
	托宾 Q 值	X59
	市销率	X60
企业规模	企业资产规模	X61
	企业经营年限	X62
内部管理能力	研发人员数量占比	X63
	研发投入占营业收入比例	X64
公司治理	实际控制人拥有上市公司所有权比例	X65
	实际控制人拥有上市公司控制权比例	X66
	实际控制人两权分离率	X67
	控股股东持股比例	X68
	股权制衡度	X69
	管理层持股比例	X70
	独立董事占比	X71
	独立董事网络中心度	X72
	是否存在一控多情况	X73

(续表 3.2)

类型	指标	符号
公司治理	董事会规模	X74

3.3 上市公司财务风险预警指标体系的筛选

3.3.1 筛选原因

在初始研究阶段，本研究通过系统梳理共筛选出 74 个候选指标作为财务风险预警模型的备选特征变量。然而，实证分析表明，这些指标对 ST 与非 ST 企业的分类判别能力存在显著差异。若不加选择地将全部指标纳入模型，不仅会因特征空间维度膨胀造成模型训练效率下降和计算资源浪费，更可能因噪声特征干扰而降低模型的分类性能和泛化能力。因此，建立科学合理的特征选择机制，从原始特征集中提取最具判别力的指标子集，对于构建高效、稳健的财务风险预警模型具有关键性意义。这一特征优化过程既能有效控制模型复杂度，又能提升预警准确率，是模型构建不可或缺的关键环节。

3.3.2 筛选方法

在机器学习应用中，特征选择技术扮演着关键角色，其核心目标是从初始特征空间中识别并保留最具判别力的特征子集。包裹式特征选择方法是当前实践中较为常用的技术路径，该方法通过建立评估模型来系统性地考察各个特征对预测性能的贡献度，进而确定最优特征组合。本研究基于 LightGBM 这一高效的梯度提升决策树算法构建特征选择框架，该算法因其出色的处理高维数据和大规模样本的能力而备受青睐。具体实施过程中，采用递归特征消除策略作为优化目标函数，该策略通过多轮迭代逐步筛选特征，在每一轮评估中动态调整特征集合，直至获得在预测精度和计算效率之间达到最佳平衡的特征子集。这种特征选择方法不仅能够显著降低数据维度，还能有效提升模型的泛化能力和运算性能。

3.3.3 筛选结果

为了深入探究特征数量如何影响模型性能，绘制了如图 3.1 所示的学习曲线。该曲线的横轴表示指标数量，即模型中使用的特征数量；纵轴则表示模型的预测准确率，即模型对 ST 公司与非 ST 公司分类的准确性。通过这条曲线，可以直观地观察到随着特征数量的变化，模型的预测效果所呈现出起伏的动态趋势。

从曲线的整体走势来看，模型的表现效果在大约 80% 的准确率附近波动。当特征数量调整至 25 至 30 个的区间内时，学习曲线达到最高点。为了进一步确认

最佳特征数量，对这一区间的曲线图进行了放大观察。通过仔细观察和分析，最终确定当使用 26 个特征时，模型的表现效果达到了最佳状态。因此，在后续的研究中，本文将基于这 26 个最优特征来构建和训练模型，以期获得更高的预测精度和更好的泛化能力。




图 3.1 特征选择学习曲线

综上，选取 26 个特征作为后续建模的输入变量，LightGBM 算法前 26 个特征的重要性排序如图 3.2 所示。其中横轴表示各指标，纵轴表示重要性程度。




图 3.2 特征重要性排序

综上所述，本文最终筛选出的 26 个指标如表 3.3 所示。

表 3.3 最终筛选的财务风险预警指标

类型	指标	符号
盈利能力	总资产净利润率	X2
	营业毛利率	X7
	固定资产比率	X9
	每股收益	X11
	每股营业利润	X13
	市盈率	X15
营运能力	营运资金周转率	X18
	股东权益周转率	X22
偿债能力	经营活动产生的现金流量净额 / 流动负债	X29
	权益乘数	X30
	有形资产负债率	X31
	产权比率	X32
	营运资金比率	X36
	固定资产对股东权益比率	X38
	每股净资产	X39
获现能力	每股现金净流量	X44
	市现率	X45
成长能力	资本积累率	X46
	基本每股收益增长率	X48
	可持续增长率	X52
	市净率	X53
	所有者权益增长率	X56
	每股净资产增长率	X57
	托宾 Q 值	X59
内部管理能力	市销率	X60
	研发投入占营业收入比例	X64

第4章 实证研究

4.1 样本选取

4.1.1 样本选取标准

在构建上市公司财务风险预警模型时,研究样本需要包含两类具有显著财务特征差异的企业:一类是存在显著财务风险的ST类公司,另一类是财务状况正常的非ST公司。本研究依据中国证监会的相关规定,将上市公司是否被实施特别处理(ST)或退市风险警示(*ST)作为财务风险的界定标准。需要说明的是,考虑到股权分置改革因素可能带来的数据干扰,研究样本排除了带有SST和S*ST标记的特殊类型公司。同时,鉴于金融类上市公司在业务模式、财务结构和监管要求等方面的特殊性,为保持研究样本的同质性,本研究也排除了所有金融行业上市公司。这种严格的样本筛选标准有助于提高模型训练数据的质量,确保构建的预警模型具有更好的泛化能力和实际应用价值。

4.1.2 样本选取范围及时间

参考李扬等^[17]的研究,本文将上市公司中因财务风险而被特别处理(即标记为ST)的公司视为处于财务风险状态的公司,而未被标记为ST的公司则视为财务状况正常的公司。针对那些在2020年1月1日至2022年12月31日内已发生财务风险的上市公司,选取其在被正式标记为ST之前3年(即第 $t-3$ 年,假设ST标记的年份为第 t 年)的财务数据作为样本。相应地,对于在同期内始终维持财务健康的上市公司,则选取其2019年的数据作为构建模型的样本。遵循上述样本筛选标准,最终选择了103家ST公司以及2822家非ST公司,两者之间的数量比例大致为1:27。

4.1.3 样本的初步确定

综合上述样本选取原则,本文共选取了样本公司2925家,其中ST公司103家,非ST公司2822家,两类公司数量比例约为1:27。

4.2 数据来源与处理

4.2.1 数据来源

所有数据均源自国泰安数据库。为了便于后续的分析与建模,若该公司属于ST公司,令分类变量 $Y=1$,否则记 $Y=0$ 。在后续进行财务风险预警模型分析时,

会将所选样本数据的70%用于模型训练，将其余30%数据作为测试集样本，用于检验模型分类预测的效果。

4.2.2 数据处理

(1) 缺失数据处理

在构建上市公司财务风险预警模型的过程中，本研究通过系统的指标筛选流程，最终确定了26个关键预警指标，研究样本覆盖2925家上市公司。针对数据完整性的分析显示：7个指标表现出较高的数据完整性（缺失样本数<10），14个指标存在中度缺失情况（缺失样本数介于10-500之间），4个指标缺失较为显著（缺失样本数在500-1000范围内），另有1个指标存在严重缺失问题（缺失样本数>1000）。具体指标的缺失值情况如表4.1所示。

表 4.1 数据缺失值频数分布表

缺失值样本数	指标个数
10个以内	7
10至500	14
500至1000	4
1000以上	1

本研究首先对数据完整性进行了系统性评估。在数据缺失分析中，主要存在两种缺失类型：其一是样本个体的整体数据缺失，其二是特定指标的局部数据缺失。鉴于本研究的数据采集均以完整企业为基本单位，排除了第一种缺失类型的可能性，因此研究重点聚焦于指标维度的数据缺失问题。通过对各预警指标的缺失分布进行量化分析，可以精准识别数据缺口，为后续的数据插补策略制定提供科学依据。

在数据预处理阶段，本研究对缺失值处理方案进行了系统评估。针对特征维度存在的缺失问题，通常存在三种基本处理思路：直接删除、保留原状和数据填补。通过深入分析发现，简单删除缺失特征虽然操作简便，但会造成有价值信息的严重损失，因此仅建议对缺失率异常高的个别特征采用此方法。而保留缺失值的处理方式会直接影响后续建模流程的可行性，故同样不予采纳。基于上述考量，本研究最终采用数据填补作为核心处理策略，具体实施过程中根据变量类型差异采用不同的填补技术：对于连续型变量，可选择均值、中位数等统计量进行填补；对于类别型变量，则采用众数填补法。更进一步，本研究还探讨了基于预测模型的智能填补方法，其核心思想是通过构建预测模型来估计缺失值，其中随机森林填补和K近邻插补因其良好的表现成为优先考虑的实现方案。这种多层次、差异

化的缺失值处理框架，在保证数据质量的同时，最大程度地保留了原始数据的信息价值。

本研究针对特征变量的不同类型采用了差异化的缺失值处理策略。对于连续型指标，基于K近邻（KNN）算法的插补方法因其良好的可解释性和实现简便性被优先选用。该方法的实现机理是：首先通过距离度量确定存在缺失值的样本点在特征空间中的K个最近邻完整样本，随后根据缺失数据的性质采取不同的填补策略；若为数值型缺失，则取K个邻近样本的算术平均值进行填补；若为类别型缺失，则采用多数表决机制确定填补值。这种基于邻近样本相似性的填补方法不仅操作简便，而且能够较好地保持原始数据的分布特性，为后续建模分析提供了可靠的数据基础。

最后，处理缺失数据。参考Batista等^[49]的研究成果，并结合了数据的分布特征和相似性度量。在具体实施时，将K值设定为3，这意味着对于每一个含有缺失值的样本点，都会在其周围搜索并找到与其在欧式距离上最接近的3个观测值。这3个观测值被称为该样本点的K近邻。然后，利用这3个近邻观测值在相应指标上的平均值来填补该样本点的缺失值。多重插补法的优点在于通过建立多个合理的填补值来反映数据缺失的不确定性，不仅最大限度地保留了原始数据集的信息含量，还能有效缓解单一填补可能引入的系统偏差。特别是基于K近邻算法的多重插补策略，相较于传统的均值填补方法，能够更好地捕捉数据点之间的局部相似性关系，从而更精确地还原数据的真实分布模式。这种数据驱动的填补方式通过考虑样本间的空间分布特征，显著提升了填补结果的可靠性，为后续的统计分析提供了更为准确的数据基础，最终增强了研究结论的可信度和科学性。

（2）非平衡数据处理

首先，本研究采用ST与非ST公司作为二分类样本。传统机器学习算法通常基于类别平衡假设，通过识别区分性特征来实现样本分类。然而，实际数据往往呈现非平衡分布特征，即某一类别样本量显著少于另一类别。这种数据分布不均衡会导致模型训练过程中过度关注多数类样本的特征模式，而忽视少数类样本的关键判别信息，最终产生分类偏好问题。具体表现为模型对多数类的识别准确率虚高，而对真正需要关注的财务风险样本的识别能力不足，严重影响模型的预警效果和实际应用价值。这种由于数据不平衡导致的模型偏差问题，是财务风险预警研究需要重点解决的技术难点之一。

在解决数据不平衡问题时，可以从两个方面入手：算法层面的适应性优化和数据层面的分布平衡处理。针对财务风险预警这一分类预测任务，研究重点采用了样本平衡化预处理技术来提升模型性能。具体而言，非平衡数据处理方法可划分为三大类：过采样技术通过合成新样本（如随机过采样、SMOTE及其衍生算法）扩充少数类；欠采样技术则通过选择性剔除（如随机欠采样、ENN和Tomek

Link 等方法) 精简多数类; 而混合采样技术则整合前两种方法的优势, 典型代表包括 SMOTETomek 和 SMOTEENN 等复合算法。本研究通过系统比较这些方法的适用性, 最终选择在模型构建前对原始数据集进行平衡化处理, 以确保分类模型既能捕捉 ST 公司的风险特征, 又能保持对非 ST 公司的判别能力, 从而全面提升预警系统的可靠性和实用性。这种预处理方法不仅操作简便, 而且能有效缓解后续建模过程中的类别偏差问题, 为构建稳健的财务风险预警模型奠定数据基础。由于本文数据集不平衡比例高, 采用欠采样方法会损失过多样本数据, 因此本文选取 Borderline-SMOTE 过采样的方式平衡训练集数据。

Borderline-SMOTE 过采样^[50]是对传统 SMOTE 过采样^[51]的重要改进。传统 SMOTE 算法的实现机制是: 针对每一个少数类样本 X_i , 基于欧氏距离度量识别其 k 个最近邻样本, 然后通过线性插值在这些近邻样本与 X_i 之间生成新的合成样本。然而, 这种方法存在明显局限: 它未能充分考虑样本的空间分布特性, 特别是忽略了处于分类边界区域的少数类样本的重要性, 导致生成的部分样本可能成为干扰模型训练的噪声。Borderline-SMOTE 的创新之处在于, 它通过智能识别位于决策边界附近的“边界样本”, 有针对性地对这些关键样本进行过采样。这种基于样本空间分布特性的选择性采样策略, 能够更有效地扩充少数类样本集, 使分类器能够更精确地学习少数类样本的判别特征, 从而显著提升模型对边界样本的分类准确率, 最终获得更优的整体分类性能。该算法通过聚焦关键样本区域, 既避免了盲目过采样可能引入的噪声问题, 又增强了对分类决策边界的学习能力。最后, 在解决类别不平衡问题的最终处理阶段, 本文采用 Borderline-SMOTE 过采样算法。该技术的核心创新在于其对少数类样本的智能分类机制: 首先通过 k 近邻分析将少数类样本划分为三个特征鲜明的子集: “噪声点”(所有近邻均属多数类)、“安全点”(全部近邻同属少数类)以及关键的“边界点”(多数近邻来自多数类)。算法随后仅针对具有重要分类意义的“边界点”子集实施 SMOTE 过采样, 这种选择性采样策略具有双重优势: 一方面有效避免了在非关键区域生成无意义的合成样本, 显著降低了噪声干扰; 另一方面集中增强了分类边界区域的样本密度, 使模型能够更精确地学习决定性的分类特征。通过这种有针对性的样本扩充方式, 不仅优化了数据分布平衡性, 更提升了生成样本的质量价值, 为后续建模提供了更具判别力的训练数据。

4.3 财务风险预警

4.3.1 描述性统计分析

表 4.2 是中国 A 股上市公司各项财务指标的描述性统计分析结果。根据表 4.2 可以发现 ST 公司与正常公司在多个财务指标上存在普遍差异。在本文选取

的指标中,营运资金周转率、市净率以及营运资金比率这三个指标相较于其他指标在 ST 公司和正常公司均值之间存在着较为显著的差异。

营运资金周转率是衡量企业营运资金管理效率的重要指标,它反映了企业营运资金在一定时期内的周转速度和利用效率。ST 公司的营运资金周转率高达 120.75,远高于一般企业的正常水平。这可能意味着 ST 公司在营运资金的管理上非常高效,但同时也可能反映出其营运资金相对不足,或者短期债务过高,导致企业不得不过度利用有限的营运资金来支撑业务运营。另一方面,过高的营运资金周转率也可能意味着 ST 公司为了维持运营,不得不采取较为激进的销售策略或财务政策,这可能会增加企业的财务风险和经营风险。正常公司的营运资金周转率为 12.27,处于一个相对正常的水平。这表明该公司在营运资金的管理上较为稳健,能够合理平衡营运资金的使用效率和风险。适中的营运资金周转率有利于企业保持稳定的现金流和财务状况,为企业的长期发展提供有力支持。

ST 公司市净率为-50.3,意味着其股价远低于每股净资产,这通常反映了市场对该公司未来盈利能力的强烈怀疑,或者公司面临严重的财务困境。市净率在 1 左右通常被认为是一个相对合理的估值区间。正常公司市净率为 0.8,说明其股价略低于每股净资产的价值,但仍在合理范围内。这可能反映了市场对该公司未来盈利能力的适度预期,或者公司当前处于价值被低估的状态。与 ST 公司相比,正常公司的财务状况通常较为稳健,没有面临严重的财务困境。其股价与净资产之间的折价程度较小,说明市场对公司的盈利能力、资产质量等方面持有一定的信心。

营运资金比率是衡量公司短期偿债能力的一个重要财务指标,它反映了公司流动资产与流动负债之间的关系。这一比率越高,通常意味着公司的短期偿债能力越强,财务状况越稳健。对于 ST 公司而言,其营运资金比率为-38.39,说明该公司的流动资产不足以覆盖其流动负债。这通常意味着公司面临严重的短期偿债压力,可能存在资金链断裂的风险。这种情况可能由于多种原因造成,如过度扩张、经营不善、市场环境恶化等。对于投资者和债权人来说,这是一个警示信号,表明该公司可能需要进行财务重组或寻求外部融资以避免破产。相比之下,正常公司的营运资金比率为 11.8。这表明公司的流动资产足以覆盖其流动负债,并有一定的余额用于应对突发情况或抓住市场机遇。这样的财务状况通常意味着公司具有较强的短期偿债能力和较好的运营效率。对于投资者来说,这是一个积极的信号,表明该公司可能具有较好的盈利能力和稳健的财务结构。综上所述,ST 公司和正常公司的营运资金比率差异显著,反映了两者在短期偿债能力和财务状况上的巨大差距。

表 4.2 中国 A 股上市公司各财务指标的描述性统计分析

财务指标	符号	ST 公司		正常公司	
		均值	标准差	均值	标准差
总资产净利润率	X2	0.16	0.40	0.32	0.18
营业毛利率	X7	8.27	16.68	3.17	4.71
固定资产比率	X9	-0.40	2.26	0.26	0.24
每股收益	X11	-1.19	3.17	0.52	1.19
每股营业利润	X13	0.77	3.37	5.94	4.86
市盈率	X15	-0.59	2.94	0.05	0.11
营运资金周转率	X18	120.75	276.17	12.27	115.48
股东权益周转率	X22	3.70	5.94	1.28	1.82
经营活动产生的现金流量净额 / 流动负债	X29	1.22	3.05	0.40	0.19
权益乘数	X30	1.52	4.50	0.44	0.23
有形资产负债率	X31	7.46	14.24	1.93	1.37
产权比率	X32	6.46	14.24	0.93	1.37
营运资金比率	X36	-38.39	320.55	11.80	47.59
固定资产对股东权益比率	X38	-1.52	4.04	0.38	0.46
每股净资产	X39	-6.59	49.65	0.05	0.13
每股现金净流量	X44	0.77	3.37	5.94	4.86
市现率	X45	-1.23	5.11	0.07	0.27
资本积累率	X46	-4.17	25.75	0.17	0.50
基本每股收益增长率	X48	-0.17	0.27	0.16	0.38
可持续增长率	X52	-4.49	25.78	0.08	0.36
市净率	X53	-50.30	378.07	0.80	7.25
所有者权益增长率	X56	-0.98	2.71	0.62	1.44
每股净资产增长率	X57	-4.17	25.75	0.17	0.50
托宾 Q 值	X59	-1.38	7.64	0.05	0.55
市销率	X60	-0.65	3.10	0.04	0.11
研发投入占营业收入比例	X64	11.47	44.08	5.33	7.79

4.3.2 构造 Benford 因子

应用Benford定律对A股上市公司的财务指标进行了数据质量验证。表4.3详细列出了Benford定律的预期频率、A股上市公司财务指标首位数字的实际观测频率，以及这两者之间的差值与统计检验结果。在显著性水平设为0.01的条件下， χ^2 检验的临界值为20.09。

26个财务指标中总资产净利润率X2、营业毛利率X7、固定资产比率X9等20个财务指标的 χ^2 检验值超过了这一临界值，表示这些指标的首位数字分布与Benford定律的理论预测存在显著偏差。具体来说，这些指标的财务风险较高，其中营业毛利率X7、市现率X45、市销率X60的 χ^2 值尤为突出，远超20.09。剩余的6个财务指标虽通过了拟合优度检验，但实际观测频率与理论频率仍有差距，也存在一定财务风险，财务风险低于未通过拟合优度检验的20个财务指标。故利用上述指标构建Benford因子。从表4可以看出财务风险更高的指标X2、X7、X9、X13、X15、X22、X29、X30、X31、X36、X38、X39、X44、X45、X46、X48、X57、X59、X60和X64首位数字的观测频率与理论频率差值绝对值最大的数字分别为1、2、2、1、1、2、1、1、2、2、1、2、3、1、1、1、1、1、1、1，差值分别为4.26、6.36、3.45、4.09、-3.30、2.73、4.29、2.58、3.24、2.46、3.68、-3.70、2.14、5.11、2.11、2.41、2.11、3.51、-5.28、2.52。财务风险相对低的指标X11、X18、X32、X52、X53和X56首位数字的观测频率与理论频率差值绝对值最大的数字分别为2、3、1、1、8、3，差值分别为-1.95、-1.75、1.56、1.22、-1.12、1.46。根据式（1.6）分别建立26个Benford因子，记为 $B_j \{j=1,2,3,\dots,26\}$ 。

表 4.3 中国 A 股上市公司各指标首位数字观测频率及与理论频率的比较

指标	类型	1	2	3	4	5	6	7	8	9	
Benford	理论频率	30.10	17.61	12.49	9.69	7.92	6.70	5.80	5.12	4.58	χ^2
X2	实际频率	34.36	16.85	13.40	8.68	7.15	6.29	5.30	4.72	3.25	40.135
	差值	4.26	-0.76	0.91	-1.01	-0.77	-0.41	-0.50	-0.40	-1.33	
X7	实际频率	32.21	23.97	14.50	8.62	6.39	4.07	3.79	3.01	3.45	176.891
	差值	2.11	6.36	2.01	-1.07	-1.53	-2.63	-2.01	-2.11	-1.13	
X9	实际频率	27.42	21.06	12.31	10.32	8.58	6.22	5.78	4.79	3.52	38.823
	差值	-2.68	3.45	-0.18	0.63	0.66	-0.48	-0.02	-0.33	-1.06	

(续表 4.3)

指标	类型	1	2	3	4	5	6	7	8	9	
Benford	理论 频率	30.10	17.61	12.49	9.69	7.92	6.70	5.80	5.12	4.58	χ^2
X11	实际 频率	30.29	15.66	13.74	10.53	8.48	6.32	5.81	5.23	3.93	16.792
	差值	0.19	-1.95	1.25	0.84	0.56	-0.38	0.01	0.11	-0.65	
X13	实际 频率	34.19	21.50	12.07	7.62	6.05	4.38	5.26	4.31	4.62	96.284
	差值	4.09	3.89	-0.42	-2.07	-1.87	-2.32	-0.54	-0.81	0.04	
X15	实际 频率	26.80	18.32	15.66	11.28	7.45	6.32	5.88	4.79	3.49	52.145
	差值	-3.30	0.71	3.17	1.59	-0.47	-0.38	0.08	-0.33	-1.09	
X18	实际 频率	31.73	18.19	10.74	8.89	8.14	6.26	5.98	5.30	4.79	14.102
	差值	1.63	0.58	-1.75	-0.80	0.22	-0.44	0.18	0.18	0.21	
X22	实际 频率	27.59	20.34	14.32	10.32	7.21	6.29	5.54	4.89	3.49	38.537
	差值	-2.51	2.73	1.83	0.63	-0.71	-0.41	-0.26	-0.23	-1.09	
X29	实际 频率	34.39	15.79	10.77	10.53	8.24	6.32	5.98	4.58	3.38	44.559
	差值	4.29	-1.82	-1.72	0.84	0.32	-0.38	0.18	-0.54	-1.20	
X30	实际 频率	32.68	16.96	14.29	8.27	7.04	6.56	5.85	4.85	3.49	31.844
	差值	2.58	-0.65	1.80	-1.42	-0.88	-0.14	0.05	-0.27	-1.09	
X31	实际 频率	29.47	20.85	12.24	8.68	7.59	6.97	5.47	4.96	3.76	27.094
	差值	-0.63	3.24	-0.25	-1.01	-0.33	0.27	-0.33	-0.16	-0.82	
X32	实际 频率	31.66	16.92	11.15	9.68	8.38	6.91	6.43	4.99	3.90	13.632
	差值	1.56	-0.69	-1.34	-0.01	0.46	0.21	0.63	-0.13	-0.68	
X36	实际 频率	28.55	20.07	14.22	11.18	7.18	5.85	5.40	3.56	4.00	47.885
	差值	-1.55	2.46	1.73	1.49	-0.74	-0.85	-0.40	-1.56	-0.58	
X38	实际 频率	33.78	17.23	10.87	9.44	7.66	6.91	5.47	4.68	3.97	24.286
	差值	3.68	-0.38	-1.62	-0.25	-0.26	0.21	-0.33	-0.44	-0.61	

(续表 4.3)

指标	类型	1	2	3	4	5	6	7	8	9	
Benford	理论 频率	30.10	17.61	12.49	9.69	7.92	6.70	5.80	5.12	4.58	χ^2
X39	实际 频率	28.17	13.91	10.46	9.98	9.74	8.65	7.62	6.46	4.99	93.715
	差值	-1.93	-3.70	-2.03	0.29	1.82	1.95	1.82	1.34	0.41	
X44	实际 频率	29.13	17.26	14.63	9.98	7.69	6.87	5.68	5.74	3.01	30.834
	差值	-0.97	-0.35	2.14	0.29	-0.23	0.17	-0.12	0.62	-1.57	
X45	实际 频率	35.21	14.02	9.68	7.66	7.56	7.25	6.36	5.91	6.36	104.794
	差值	5.11	-3.59	-2.81	-2.03	-0.36	0.55	0.56	0.79	1.78	
X46	实际 频率	32.21	15.62	11.49	8.41	8.24	6.60	5.98	5.95	5.50	28.183
	差值	2.11	-1.99	-1.00	-1.28	0.32	-0.10	0.18	0.83	0.92	
X48	实际 频率	32.51	17.57	11.08	8.27	6.84	6.39	6.22	5.40	5.71	30.371
	差值	2.41	-0.04	-1.41	-1.42	-1.08	-0.31	0.42	0.28	1.13	
X52	实际 频率	31.32	18.50	12.21	8.31	7.76	5.74	5.57	5.81	4.79	16.274
	差值	1.22	0.89	-0.28	-1.38	-0.16	-0.96	-0.23	0.69	0.21	
X53	实际 频率	30.05	17.23	13.44	9.74	8.24	6.56	6.32	4.00	4.41	11.349
	差值	-0.05	-0.38	0.95	0.05	0.32	-0.14	0.52	-1.12	-0.17	
X56	实际 频率	29.81	16.44	13.95	8.27	8.14	6.87	6.02	5.57	4.92	15.866
	差值	-0.29	-1.17	1.46	-1.42	0.22	0.17	0.22	0.45	0.34	
X57	实际 频率	32.21	15.62	11.42	8.41	8.44	6.56	5.88	5.95	5.50	29.089
	差值	2.11	-1.99	-1.07	-1.28	0.52	-0.14	0.08	0.83	0.92	
X59	实际 频率	33.61	16.85	13.74	8.21	7.79	6.50	5.98	4.24	3.08	42.622
	差值	3.51	-0.76	1.25	-1.48	-0.13	-0.20	0.18	-0.88	-1.50	
X60	实际 频率	24.82	12.96	13.09	12.41	8.96	8.68	7.42	6.12	5.54	131.982
	差值	-5.28	-4.65	0.60	2.72	1.04	1.98	1.62	1.00	0.96	

(续表 4.3)

指标	类型	1	2	3	4	5	6	7	8	9	
Benford	理论 频率	30.10	17.61	12.49	9.69	7.92	6.70	5.80	5.12	4.58	χ^2
	实际 频率	32.62	20.10	10.60	8.75	7.25	7.04	6.19	4.72	2.74	
X64	差值	2.52	2.49	-1.89	-0.94	-0.67	0.34	0.39	-0.40	-1.84	53.529

4.3.3 模型预警结果

根据交叉验证的思想,随机选取数据集的70%作为训练集,剩余30%作为测试集。通过训练集建立Benford-LightGBM模型,用测试集的预测准确率判断模型的优劣。

表4.4是基于中国A股上市公司数据构建的Benford-LightGBM模型的预测效果分析。预测准确率代表模型整体预测正确的比例,支持度表示在测试集中,被模型预测为某一类别的公司样本数量,其中测试集包含了数据集总量的30%,即878个公司样本。

从预测结果来看,Benford-LightGBM模型将844个样本判定为正常公司($Y=0$),这一数据充分显示出该模型在正常公司分类预测上具备较高的置信度。

在精确率方面,预测正常公司($Y=0$)时,精确率高达99.06%;预测ST公司($Y=1$)时,精确率也达到了83.87%。

召回率作为评估模型性能的重要指标,体现了模型识别正类样本的能力。Benford-LightGBM模型在识别正常公司($Y=0$)时,召回率为99.41%;识别ST公司($Y=1$)时,召回率达到76.47%。

F1值综合了精确率和召回率,能够更全面地反映模型的性能。Benford-LightGBM模型在各个分类下的F1值均处于较高水平,进一步有力地证明了该模型在整体预测效果上的优越性。

表 4.4 A 股上市公司财务数据模型的预测效果

模型	预测准确率	支持度	Y	精确率	召回率	F1
Benford-LightGBM 模型	98.52%	844	0	99.06%	99.41%	99.23%
		34	1	83.87%	76.47%	80%

具体来说,若一个模型的FPR(将正常公司误判为ST公司的比例)越低并且TPR(准确识别出ST公司的比例)越高,则表明该模型的预测效果好;同时,其

对应的ROC曲线将更靠近左上角，并且AUC值也将更大。图4.1展示的是引入Benford因子后Benford - LightGBM模型的ROC曲线。首先，观察这条曲线，能够清晰地发现它紧紧靠近坐标系的左上方，与代表随机猜测的对角线相比优势十分显著。这一特征充分表明，Benford - LightGBM模型的预测准确率远远超过了随机猜测的50%，有力地体现出该模型具备较高的分类性能。其次，Benford - LightGBM模型的AUC值达到了0.9757，在模型评估中，AUC值越接近1，就代表模型的预测准确性越高，分类效果也就越优异。

综上所述，Benford - LightGBM预警模型不仅能够维持高预测准确率，还进一步增强了自身的分类能力。在识别中国A股上市公司中ST公司与非ST公司时，该模型展现出更为出色的性能，能更精准地对不同财务状况的公司进行分类。




图 4.1 Benford-LightGBM 模型的 ROC 曲线

4.4 模型的可靠性和稳定性检验

4.4.1 模型的可靠性检验

模型的可靠性是指模型在实际应用中的可信度和一致性。一个可靠的模型能够在不同场景下持续提供准确的预测结果，并且其预测结果与实际结果之间的误差在可接受范围内。

为了验证 LightGBM 模型的优越性，本文选取了未加入 Benford 因子的 LightGBM 模型以及随机森林模型作为对比模型，并且通过训练集建立基于

Benford 律的随机森林模型，用测试集的预测准确率判断模型的优劣。仍随机选取数据集的 70%作为训练集，剩余 30%作为测试集。

图 4.2 是 LightGBM 模型的 ROC 曲线，从图中可以看出，该曲线紧紧靠近坐标系的左上方，与代表随机分类的对角线相比优势显著。这一特征充分表明 LightGBM 模型具备较高的分类性能，其预测准确率远超随机猜测的 50%，在财务风险预警方面具有一定的有效性。

随机森林模型的 ROC 曲线如图 4.3 所示，基于 Benford 律的随机森林模型的 ROC 曲线如图 4.4 所示，可以明显看出其都紧密地贴近于坐标系的左上方，并且都显著优于 45° 对角线，表明无论是随机森林模型还是基于 Benford 律的随机森林模型，其预测准确率都远高于随机猜测的 50%，体现出了较高的分类性能。进一步对比两个模型，发现基于 Benford 律的随机森林模型的 AUC 值 0.9461 相较于随机森林模型的 0.9324 有了较为明显的提升。

然而，通过对 AUC 值进行深入对比分析发现，Benford-LightGBM 模型的表现更为出色。Benford-LightGBM 模型的 AUC 值达到了 0.9757，相较于其他三个模型有了较为明显的提升。

在模型评估体系中，AUC 值越接近 1，意味着模型的预测准确性越高，分类能力越强。因此，Benford-LightGBM 模型在维持高预测准确率的基础上，进一步强化了分类能力。这使得该模型在识别中国 A 股上市公司中 ST 公司与正常公司时，能够更加精准地区分不同财务状况的公司，在财务风险预警领域展现出更强的实用性和优越性。




图 4.2 LightGBM 模型的 ROC 曲线




图 4.3 随机森林模型的 ROC 曲线




图 4.4 基于 Benford 律的随机森林模型的 ROC 曲线

表 4.5 是四种模型的 AUC 值对比情况,由表 4.5 可知,当 LightGBM 模型和随机森林模型在原有模型的基础上加入了 Benford 因子后,它们的预测效果都呈现出了一定程度的提升;其中,LightGBM 模型在加入 Benford 因子后的提升效果尤为显著。这表明,Benford 因子的引入对于提升模型的预测能力具有积极的影响。通过对比 Benford-LightGBM 模型和基于 Benford 律的随机森林模型的 AUC

值可知, Benford-LightGBM 模型的 AUC 值高达 0.9757, 而基于 Benford 律的随机森林模型的 AUC 值则为 0.9461。这一显著的差异进一步证明了 LightGBM 模型在预测效果上的优越性。综上所述, 表 4.5 的数据不仅揭示了 Benford 因子对于提升模型预测能力的积极作用, 还明确指出了 LightGBM 模型在利用这一因子进行预测时的卓越表现。

表 4.5 四种模型的 AUC 值对比

模型	AUC 值
Benford-LightGBM 模型	0.9757
LightGBM 模型	0.9485
随机森林模型	0.9324
基于 Benford 律的随机森林模型	0.9461

表4.6是四种模型的预测效果对比, 由表4.6可知, Benford-LightGBM模型以及基于Benford律的随机森林模型的预测准确率、精确率、召回率以及F1值均显著高于未加入Benford因子的传统模型。此外, 对于Benford-LightGBM模型和基于Benford律的随机森林模型来说, Benford-LightGBM模型除预测准确率和预测正常公司 ($Y=0$) 时的召回率与基于Benford律的随机森林模型相同以外, 其余数据均显著优于基于Benford律的随机森林模型。

表 4.6 四种模型的预测效果对比

模型	预测准确率	支持度	Y	精确率	召回率	F1
Benford-LightGBM 模型	98.52%	844	0	99.06%	99.41%	99.23%
		34	1	83.87%	76.47%	80%
LightGBM 模型	97.5%	851	0	98.47%	99.29%	98.9%
		27	1	77.78%	61.76%	68.85%
随机森林模型	97.5%	856	0	97.89%	99.29%	98.59%
		22	1	72.73%	47.05%	57.14%
基于 Benford 律的随机森林模型	98.52%	856	0	98.01%	99.41%	98.71%
		22	1	77.27%	50.00%	60.71%

4.4.2 模型的稳定性检验

模型的稳定性指的是模型在面对数据变化或训练条件变化时，其预测结果或性能表现的一致性。

为了保证模型预测结果的稳定性。将上述建模过程分别重复100次、200次、500次，分别计算随机森林模型、基于Benford律的随机森林模型、LightGBM模型以及LightGBM模型的预测准确率、精确率、召回率、F1值，结果如表4.7所示。随着重复次数的增多，四个模型在预测结果上都展现出了稳定性。进一步对比四个模型的预测准确率可知，其均维持在98%附近，保持较高的预测准确性。但在精确率、召回率以及F1值这三个评估指标上，加入了Benford因子的LightGBM模型和随机森林模型均优于未加入Benford因子的传统模型，尤其是当Y=1时，Benford-LightGBM模型的精确率、召回率和F1值有显著的提升；并且相较于基于Benford律的随机森林模型，Benford-LightGBM模型在四个评估指标上均有不同程度的提升。

表 4.7 A 股上市公司财务数据四个模型的预测效果均值对比

模型	重复次数	预测准确率	Y	精确率	召回率	F1
Benford-LightGBM模型	100	98.51%	1	83.87%	76.47%	80.10%
			0	99.05%	99.41%	99.23%
	200	98.52%	1	83.88%	76.49%	80.10%
			0	99.06%	99.40%	98.97%
	500	98.52%	1	83.87%	76.52%	80.00%
			0	99.05%	99.78%	99.21%
LightGBM模型	100	97.83%	1	77.78%	61.76%	68.85%
			0	98.47%	99.29%	98.88%
	200	97.82%	1	77.82%	61.72%	68.79%
			0	98.35%	99.20%	98.87%
	500	97.83%	1	77.77%	61.77%	68.85%
			0	98.44%	99.28%	98.88%
随机森林模型	100	97.37%	1	76.32%	57.44%	65.44%
			0	97.61%	99.38%	98.98%

(续表 4.7)

模型	重复次数	预测准确率	Y	精确率	召回率	F1
随机森林模型	200	97.44%	1	76.26%	57.57%	66.66%
	500	98.03%	1	76.07%	57.42%	66.41%
			0	97.60%	99.36%	98.99%
基于Benford律的 随机森林模型	100	98.06%	1	79.18%	59.86%	66.47%
			0	98.59%	99.41%	99.01%
	200	98.12%	1	78.26%	61.26%	69.58%
			0	98.60%	99.41%	99.00%
	500	98.05%	1	79.23%	62.97%	69.48%
			0	98.59%	99.43%	99.03%

第5章 上市公司财务风险防控策略

政府在市场监管中扮演着至关重要的角色，具备制定政策、监督执行和惩罚违规行为的权力和责任。上市公司出现财务风险以及退市风险不仅损害投资者利益，还破坏市场公平性和透明度，影响资本市场的健康发展。从政府监管视角提出上市公司财务风险防范策略，不仅能警醒企业，还有利于保障投资者利益、提高市场公平性和透明度、稳定资本市场，保障市场经济的稳定运行。

5.1 构建财务数据监控平台

5.1.1 开展数据采集与整合

市场监管者应建立统一的财务数据监控平台，实时采集上市公司的财务报表数据，比如收入、成本、资产、负债等。这一平台的核心目标是通过集中化、标准化和实时化的数据管理，为市场监管者提供全面、准确的财务信息支持，从而更高效地识别和应对上市公司可能存在的财务风险。在平台的设计和建设过程中，首先需要实现多源数据的接入与整合。财务数据通常分散在上市公司、交易所、第三方审计机构等多个来源，平台应支持从这些不同渠道自动采集数据。同时，平台还需具备强大的数据清洗和校验功能，确保采集到的数据准确、完整，剔除重复、错误或格式不规范的数据，为后续分析提供高质量的数据基础。

5.1.2 设计异常预警机制

在建立的财务数据分析平台中嵌入预警机制，当某家公司的财务数据显著偏离Benford定律时，财务数据分析平台自动发出预警，通过实时分析和智能预警，监管者能够在财务风险尚未完全暴露之前，及时采取应对措施，从而有效防范潜在的财务危机。并且财务数据分析平台会基于Benford定律的理论分布，对每家公司的财务数据进行实时监控和分析。对于一些关键财务指标，会计算其首位数字的实际分布，并与Benford定律的预期分布进行对比。如果某家公司的财务数据在多个指标上均出现显著偏离，财务数据分析平台会自动触发预警机制。这种偏离可能表现为某些数字的出现频率异常高，或者某些数字的出现频率异常低，这些异常往往暗示着财务数据可能存在人为操纵或失真。

预警信息会通过多种渠道及时传递给监管者，确保监管者能够第一时间获知潜在风险。预警信息通常包括公司名称、偏离指标、偏离程度等关键信息，帮助监管者快速定位问题。同时，系统还可生成详细的分析报告，展示财务数据的实际分布与理论分布的对比图表，以及可能的异常原因分析，为监管者提供进一步的决策支持。

为了确保预警的准确性和有效性，财务数据分析平台还会结合其他财务指标和非财务信息进行综合判断。例如，如果某家公司的收入数据偏离Benford定律，但其现金流数据正常，且公司近期没有重大经营变动，就可能会降低预警级别。相反，如果多家财务指标同时偏离，且公司近期存在高管变动、审计意见异常等情况，财务数据分析平台则会提高预警级别，提示监管者重点关注。

5.2 定期发布 Benford 分析报告

5.2.1 明确 Benford 分析标准

为进一步提升财务数据审查的科学性和有效性，监管部门应当考虑将Benford定律的应用纳入监管规范体系，通过制定明确的实施细则和操作标准，推动其在财务数据审查中的规范化、制度化运用。

具体而言，可以在现有的财务信息披露规则和审计准则中增设专门条款，明确Benford定律作为财务数据筛查工具的法律地位和适用范围，规定其在上市公司年报审核、IPO财务核查、重大资产重组审计等场景中的具体应用要求。同时，监管部门应当组织专家团队，结合资本市场特点和财务数据特征，制定统一的Benford定律应用技术标准，包括数据采集范围、分析指标选取、异常阈值设定、结果解释规则等，以确保分析结果的科学性和可比性。此外，还应当建立健全相关的配套机制，如开发标准化的Benford定律分析软件，组织专项培训提升监管人员和审计人员的专业能力，建立典型案例库为实践提供参考等。

通过将Benford定律的应用纳入监管规范，不仅能够为财务数据审查提供更加科学、客观的工具支持，还能够推动监管方式的创新和监管效能的提升，为资本市场的健康发展提供更加坚实的制度保障。同时，这种规范化、标准化的应用方式也有助于提高监管透明度，增强市场参与各方对财务数据审查结果的认可度和信任度。

5.2.2 发布行业对比分析报告

市场监管者可以将上市公司按照行业分类，例如制造业、金融业、信息技术业、消费品行业等。每个行业的财务数据特征可能存在显著差异，因此按行业进行分析可以避免因行业特性导致的误判。例如，制造业的资产规模通常较大，而信息技术业的收入增长可能较快，这些行业特性可能会影响财务数据的数字分布。通过按行业分类，可以更准确地评估每家公司的财务数据是否符合Benford定律的预期分布。基于分析结果，会生成行业整体的数据质量报告。这份报告不仅包括每个行业的财务数据分布情况，还会对偏离程度进行量化评估。报告可以使用

偏差指数或置信区间等统计指标，衡量每个行业的财务数据质量。同时，报告还应该结合行业特点和经济环境，对偏离原因进行深入分析。

5.2.3 发布公司深入分析报告

市场监管者应对个别公司的财务数据进行深入分析，识别潜在的高风险公司，这一过程不仅能够帮助监管者精准定位可能存在财务风险或数据失真的公司，还能为后续的审查和监管行动提供科学依据，从而有效防范系统性风险。提取目标公司的财务数据，包括利润表、资产负债表、现金流量表等核心财务报表，以及相关的附注信息和辅助财务数据。结合Benford律对目标公司的财务数据进行分析，如果某家公司的财务数据在多个指标上均出现显著偏离，则应将其标记为潜在的高风险公司。

5.2.4 实时披露分析报告

市场监管者可以通过新闻发布会、社交媒体、行业论坛等多种渠道，向公众传递分析报告的关键信息，定期发布基于Benford定律的财务数据分析报告，详细展示各行业和个别公司的财务数据质量评分、异常指标及其可能的风险等级。这有利于增强市场透明度，引导投资者理性决策。向社会公开分析结果不仅有助于提升市场的公开性和公平性，还能对上市公司形成有效的监督和约束。

5.3 优化对预警企业的监管

5.3.1 培训预警企业

针对预警企业的财务风险培训干预机制应当更加精准和系统化，以有效应对其特定的风险状况。首先，市场监管部门应根据预警企业的风险等级和具体问题，制定分层次的培训计划。

对于低风险预警企业，培训应侧重于基础财务知识的普及，如会计准则的准确应用、财务报告的规范编制以及内部控制的初步建立，以增强企业的财务合规性和自我监管能力。

对于中高风险预警企业，培训内容应更加深入和具体，包括但不限于风险管理的高级策略、预警系统的建立与优化、以及危机管理的高效应对措施。此外，应引入案例分析，让企业通过实际发生的财务风险事件学习如何识别风险、评估风险影响并采取适当的风险缓解措施。

为了确保培训效果，市场监管部门应建立一个动态的培训效果评估体系。这包括培训前后的能力对比测试、企业财务风险管理的实际改进情况跟踪，以及定

期回访以确保培训成果的长期应用。通过这种持续的监督和评估,可以确保培训内容与企业实际需求相匹配,并真正提升企业的财务风险管理能力。

最终,这种针对性的培训干预不仅能够帮助预警企业有效管理和降低财务风险,还能促进市场监管部门从传统的被动监管向更加积极主动的风险预防和管控转变,构建一个更加健康和稳定的市场环境。

5.3.2 跟踪监测预警企业

对财务数据分析平台筛查出的高风险公司,监管部门应当建立长效的动态监控机制,通过持续跟踪和分析其财务数据的变化趋势,及时识别和预警潜在的财务风险。

具体而言,可以依托大数据技术和智能化监管平台,构建针对高风险公司的专项监控体系,实时采集其定期报告、临时公告、行业数据等多维度信息,并结合宏观经济形势和行业发展趋势,对其财务数据进行深度分析和横向对比。在监控过程中,重点关注高风险公司的关键财务指标,如营业收入增长率、毛利率波动、资产负债率变化等,同时也要密切关注其现金流状况、重大资产重组、关联交易等可能影响财务数据真实性的重要事项。对于监控中发现的异常波动或可疑迹象,监管部门应当及时采取问询函、约谈等监管措施,及时发现公司存在的财务风险并采取适合的帮扶措施。

此外,还可以建立跨部门协作机制,将财务数据监控与舆情监测、投资者投诉等信息相结合,形成全方位的风险预警体系。通过这种持续、动态的监控方式,监管部门能够更加及时、精准地掌握高风险公司的经营状况和财务风险,有效防范和化解可能出现的财务风险,维护资本市场的健康稳定发展。

5.3.3 帮扶预警企业

政府应将预警公司列为重点帮扶对象,采取多种措施相结合的方式,帮助其改善财务状况,防范潜在的财务风险。

首先,政府可以成立专项帮扶小组,深入企业进行调研,了解其财务困境的具体原因,并提供针对性的政策支持。例如,对于因资金链紧张导致财务异常的企业,政府可以通过设立专项纾困基金、提供低息贷款或延长税收缴纳期限等方式,缓解企业的短期资金压力。

其次,政府可以组织专业的财务顾问团队,帮助企业进行财务诊断和优化。通过调取企业的详细财务资料,包括原始凭证、账簿记录、银行对账单等,财务顾问团队可以帮助企业梳理财务流程,发现并纠正财务管理中的漏洞。同时,政府还可以推动企业与第三方专业机构合作,如会计师事务所或资产评估公司,进行专项审计或资产价值评估,确保企业财务数据的真实性和可靠性。

此外，政府还可以通过政策引导，帮助企业优化经营结构，提升盈利能力。例如，对于因市场环境变化导致财务异常的企业，政府可以通过产业政策调整、市场准入优化等措施，帮助企业开拓新的市场渠道或转型升级。对于因内部管理不善导致财务问题的企业，政府可以提供管理培训和技术支持，帮助企业提升内部管理水平。

5.4 引入新型技术赋能监管

5.4.1 引入大数据与人工智能技术提高监管效率

在现有的Benford-LightGBM模型的基础上，引入大数据、人工智能等先进技术，开发智能化的自动化监管工具，以全面提升财务数据监管的效率和覆盖面。

具体而言，可以构建基于Benford定律的风险预警模型的智能监管平台，通过对接上市公司信息披露系统、工商税务数据库、银行资金流水等多源数据，实现对海量财务数据的自动采集、清洗和预处理。在此基础上，运用机器学习算法对基于Benford定律的风险预警模型进行优化，使其能够自适应不同行业、不同规模企业的财务数据特征，提高异常识别的准确性和可靠性。同时，还可以引入自然语言处理技术，实现对财务报告文本信息的智能分析，将其与数值型数据分析结果相互印证，提高风险识别的全面性。此外，智能监管平台还应当具备自动预警功能，能够根据预设的风险阈值和规则，实时监测财务数据异常波动，并及时向监管人员推送预警信息。

通过这种智能化、自动化的监管工具，不仅能够大幅提高财务数据审查的效率，扩大监管覆盖面，还能够通过对历史数据的深度挖掘和分析，发现潜在的风险规律，为监管决策提供更加科学的依据。

5.4.2 探索区块链技术保障数据安全

在现有的Benford-LightGBM模型的基础上，引入区块链技术，通过构建基于区块链的财务数据存证平台，从根本上确保上市公司财务数据的不可篡改性和可追溯性，保障数据安全。

可以在现有信息披露系统的基础上，引入区块链分布式账本技术，将上市公司提交的财务数据实时上链存储，利用区块链的共识机制和加密算法，确保数据的真实性和完整性。每一笔财务数据的上传、修改和查询操作都会被记录在区块链上，形成完整的数据轨迹，任何试图篡改数据的行为都会被系统识别和记录，从而有效防范数据造假行为。

同时，基于区块链的智能合约技术，还可以实现财务数据的自动校验和交叉验证，进一步提高数据的准确性。这种基于区块链的财务数据管理体系，不仅能

够为 Benford 定律分析提供更加可靠、可信的数据基础，提高异常识别和风险检测的准确性，还能够为后续的监管调查和执法提供强有力的证据支持。

第 6 章 结论与展望

6.1 研究结论

财务信息的可靠性对风险预警模型的预测性能具有决定性影响,这使得数据质量管控成为模型构建过程中不可忽视的关键环节。然而,当前多数相关研究在开发预警模型时,未能充分考量财务指标数据的可靠性问题,从而制约了模型预测精度的进一步提升。针对这一不足,本研究提出了一种创新性的解决方案:首先运用 Benford 定律构建 Benford 因子,进而将其整合到 LightGBM 算法框架中,形成新型的 Benford-LightGBM 财务风险预警模型。该方法通过双重机制提升预警效果:一方面利用 Benford 因子识别潜在的异常数据,另一方面借助 LightGBM 算法强大的特征学习能力,最终实现更精准的财务风险预警,为上市公司风险管理决策提供更科学、更可靠的量化依据。

Benford 定律作为一种有效的数字分析工具,在财务数据质量评估领域展现出独特的应用价值。该定律通过对比实际数据首位数字分布与理论期望分布的差异程度,为识别潜在的异常数据提供了量化依据。然而,现有研究存在明显局限:要么孤立地应用 Benford 法则进行质量检验,要么简单地将之与传统分类模型结合,这两种方式都难以实现对个体样本财务风险的精准判别。鉴于此,本文首先基于 Benford 法则构建了综合性的 Benford 质量因子;继而采用包裹式特征选择方法最终筛选出 26 个最具判别力的核心指标。这种融合 Benford 检验与特征选择的技术路线,不仅提升了数据质量评估的精准度,更实现了对具体样本点的识别,为构建高精度的风险预警模型奠定了坚实基础。

本文将 Benford 因子与 LightGBM 模型相结合,提出了 Benford-LightGBM 风险预警模型,并与基于 Benford 定律的随机森林模型进行对比。研究结果显示,Benford-LightGBM 模型在预测上市公司财务风险方面表现优异。在 878 家测试集公司中,Benford-LightGBM 模型准确预测了 865 家,优于传统 LightGBM 模型的 859 家。此外,Benford-LightGBM 模型的召回率提升了 14%,精确率提升了 6%,F1 值提升了 0.11,AUC 值从 0.9485 提升至 0.9757。这表明,融合 Benford 因子的模型在财务风险预警中具有显著优势,为政府监管、投资者决策和企业自我审视提供了有力支持。

为验证模型的稳定性和可靠性,本文对 Benford-LightGBM 模型和随机森林模型分别进行了 100 次、200 次和 500 次重复实验。结果显示,无论是 LightGBM 模型还是随机森林模型,加入 Benford 因子的模型在预测效果上均显著优于未考虑财务数据质量的模型。这一发现进一步证实了财务数据质量在风险预警模型构建中的重要性,同时也为后续模型的优化和改进提供了重要依据。通过对比分析,

本文提出的 Benford-LightGBM 模型相较于随机森林模型在财务风险预警领域展现出了优越的性能和广泛的应用潜力。

从 Benford 律的视角来看,防范上市公司财务风险的核心在于确保财务数据的质量。首先,应构建财务数据分析平台,实时采集上市公司财务数据,并运用 Benford 律进行常态化筛查,识别异常波动和潜在风险行为,为风险预警提供科学依据。其次,定期发布基于 Benford 律的分析报告,向公众传递关键信息,增强市场透明度。此外,针对预警企业,应实施专项培训干预机制,通过分层次的培训计划,提升企业的财务合规性和风险管理能力;同时,政府应将预警公司列为重点帮扶对象,采取政策支持、财务顾问团队介入等措施,帮助其改善财务状况,防范潜在的财务风险。最后,通过引入大数据、人工智能等先进技术,开发智能化自动化监管工具,提升财务数据监管的效率和覆盖面;并且,采用区块链技术确保财务数据的不可篡改性和可追溯性,为 Benford 律分析提供可靠的数据基础。这一系列策略不仅能够有效提升财务风险防范能力,还能为监管部门、投资者和企业提供更加透明、可信的决策支持,从而维护资本市场的健康发展。

6.2 不足与展望

本文通过以上的研究分析虽然得到了较好的研究成果,但在一些方面还存在不足之处,需要继续改进和完善。

首先,在指标的选取方面,本文将新的指标纳入到指标体系建立中。但在实际情况中影响上市公司财务风险的因素还有许多的方面,例如面对目前的大数据技术,可以更多的结合网络信息进行分析,排除对于数据来源的束缚,利用更新的技术手段对非财务指标进行更深入的探索。由此,考虑到数据获取的问题,本文引入的指标有限,在后续的研究中可以更广泛地探索其他指标对上市企业财务风险预警的影响。通过不断地丰富和完善指标体系,可以进一步提高财务风险预警模型的准确性和实用性,为企业的财务管理和决策提供更为有力的支持。这也将促进财务风险预警领域的研究不断向前发展,为学术研究和实际应用注入新的活力和动力。

其次,LightGBM 在实际应用中虽然高效且强大,但仍然存在一些值得注意的限制。首先,它的内存消耗相对较大,尤其是在处理高基数特征或超大规模数据集时,可能面临内存不足的问题,需要依赖分布式训练或数据降采样来解决。其次,尽管 LightGBM 原生支持类别型特征,但当类别取值过多或分布极不平衡时,模型性能可能下降,此时仍需依赖人工编码或特征工程优化。此外,LightGBM 对噪声和异常值较为敏感,如果数据中存在大量噪声或未经过清洗,可能导致过拟合或泛化能力下降。

参考文献

- [1] Beaver W H. Financial ratios as predictors of failure[J]. Journal of accounting research, 1966: 71-111.
- [2] Casey C, Bartczak N. Using operating cash flow data to predict financial distress: Some extensions[J]. Journal of accounting research, 1985: 384-401.
- [3] 聂丽洁, 赵艳芳, 高一帆. 基于现金流的财务危机预警指标体系构建研究——基于我国制造业上市公司数据[J]. 经济问题, 2011 (03): 108-112.
- [4] 李清, 于萍. 财务危机预测主要方法比较研究[J]. 数理统计与管理, 2012(04): 689-706.
- [5] Finishtya F C. The role of cash flow of operational, profitability, and financial leverage in predicting financial distress on manufacturing company in Indonesia[J]. Jurnal Aplikasi Manajemen, 2019, 17(1): 110-117.
- [6] 雷艳丽, 洪丽君, 胡晓峰. 基于改进 Z-SCORE 模型饲料上市公司的财务风险预警研究[J]. 饲料研究, 2022, 45 (02): 107-111.
- [7] 田任均. 新能源企业财务风险预警指标构建与应对策略[J]. 财会学习, 2020 (01): 26-28.
- [8] Tedeschi G, Caccioli F, Recchioni M C. Taming financial systemic risk: models, instruments and early warning indicators[J]. Journal of Economic Interaction and Coordination, 2020, 15: 1-7.
- [9] 王昱, 杨珊珊. 考虑多维效率的上市公司财务困境预警研究[J]. 中国管理科学, 2021, 29 (2): 32-41.
- [10] 王洋洋. 基于大数据环境的企业舆情管理与财务预警研究[J]. 财会通讯, 2020 (08): 130-135.
- [11] 杨华. 财务危机预警模型中的非财务指标应用研究[J]. 财会通讯, 2007(05): 31-32.
- [12] 李志强. 财务预警指标拓展研究探析[J]. 河南大学学报(社会科学版), 2009 (03): 34-39.
- [13] 郑立. 基于 RS-LSSVM 制造业上市公司财务危机预警模型[J]. 工业技术经济, 2019 (07): 108-113.
- [14] 余杰, 田康乐. 我国制造业上市公司财务危机预警研究[J]. 会计之友, 2014 (30): 73-75.
- [15] 鲍新中, 陶秋燕, 傅宏宇. 基于面板离散选择模型的企业财务预警及其行业适用性[J]. 系统管理学报, 2016 (01): 36-44.

- [16]吕景胜, 赵玉梅. 董事会特征对内部控制失效的影响研究——基于中国上市公司的数据分析[J]. 中国软科学, 2016 (05): 93-106.
- [17]李扬, 李竟翔, 马双鸽. 不平衡数据的企业财务预警模型研究[J]. 数理统计与管理, 2016 (05): 893-906.
- [18]Fitzpatrick P J. A comparison of ratios of successful industrial enterprises with those of failed firms[J]. Certified public accountant, 1932(2): 26-32.
- [19]Altman E I. Financial ratios, discriminant analysis and the prediction of corporate bankruptcy[J]. The journal of finance, 1968, 23(4): 589-609.
- [20]Martin D. Early warning of bank failure: A logit regression approach[J]. Journal of banking & finance, 1977, 1(3): 249-276.
- [21]Ohlson J A. Financial ratios and the probabilistic prediction of bankruptcy[J]. Journal of accounting research, 1980: 109-131.
- [22]杨潇. 基于改进 Logit 模型的电力公司财务危机预警研究[J]. 会计之友, 2017 (02): 95-98.
- [23]杨贵军, 孙玲莉, 周亚梦等. 基于修正 Benford 律的财务危机预警 Logistic 模型及其应用[J]. 数理统计与管理, 2021,40 (04): 585-595.
- [24]Chen J H. Developing SFNN models to predict financial distress of construction companies[J]. Expert Systems with Applications, 2012, 39(1): 823-827.
- [25]Hsieh T J, Hsiao H F, Yeh W C. Mining financial distress trend data using penalty guided support vector machines based on hybrid of particle swarm optimization and artificial bee colony algorithm[J]. Neurocomputing, 2012, 82: 196-206.
- [26]Chen M Y. A hybrid ANFIS model for business failure prediction utilizing particle swarm optimization and subtractive clustering[J]. Information Sciences, 2013, 220: 180-195.
- [27]方匡南, 吴见彬, 朱建平, 等. 随机森林方法研究综述[J]. 统计与信息论坛, 2011 (03): 32-38.
- [28]Tanaka K, Kinkyo T, Hamori S. Random forests-based early warning system for bank failures[J]. Economics Letters, 2016, 148: 118-121.
- [29]方若男, 骆品亮. 基于随机森林的第三方支付违规风险预警研究[J]. 技术经济, 2020 (09): 11-21.
- [30]杨贵军, 周亚梦, 孙玲莉. 基于 Benford-Logistic 模型的企业财务风险预警方法[J]. 数量经济技术经济研究, 2019, 36 (10): 149-165.
- [31]孙玲莉, 杨贵军, 王禹童. 基于 Benford 律的随机森林模型及其在财务风险预警的应用[J]. 数量经济技术经济研究, 2021, 38 (9): 159-177.

- [32]Malakauskas A, Lakštutienė A. Financial distress prediction for small and medium enterprises using machine learning techniques[J]. Engineering Economics, 2021, 32(1): 4-14.
- [33]黄志刚, 刘佳进, 林朝颖. 基于机器学习的上市公司财报舞弊识别前沿方法比较研究[J]. 系统科学与数学, 2020, 40 (10): 1882-1900.
- [34]赵浩, 鲁亚军, 高洁等. 基于指导性正则化随机森林 SMOTEBoost 的算法与应用[J]. 统计与决策, 2020 (04): 9-14.
- [35]顾桐, 许国良, 李万林等. 基于集成 LightGBM 和贝叶斯优化策略的房价智能评估模型[J]. 计算机应用, 2020, 40 (9): 2762-2767.
- [36]李梅芳. 基于 LightGBM 的上市公司财务困境预测[J]. 轻工科技, 2021, 37 (05): 129-130+164.
- [37]叶志宇, 冯爱民, 高航. 基于深度 LightGBM 集成学习模型的谷歌商店顾客购买力预测[J]. 计算机应用, 2019, 39 (12): 3434-3439.
- [38]Carslaw C A P N. Anomalies in income numbers: Evidence of goal oriented behavior[J]. Accounting Review, 1988: 321-327.
- [39]韩冬梅. 论企业财务风险控制与防范[J]. 财会通讯, 2015, (14): 104-106.
- [40]漆颖斌. 强化财会监督 防范企业财务风险[J]. 财务与会计, 2023, (11): 14.
- [41]杨子晖, 张平淼, 林师涵. 系统性风险与企业财务危机预警——基于前沿机器学习的新视角[J]. 金融研究, 2022, (08): 152-170.
- [42]高扬. 基于风险意识的企业财务安全管理对策——评《财务管理与风险控制》[J]. 中国安全科学学报, 2022, 32 (07): 209-210.
- [43]杭慧芹, 许苏兰. 数字化转型背景下企业财务风险识别与管控探讨[J]. 财会通讯, 2022, (24): 131-134+170.
- [44]李心地. 人工智能在企业财务风险防控中的应用——基于大数据环境[J]. 财会通讯, 2021, (22): 137-142.
- [45]杨凡. 会计联合监管与上市公司会计信息质量——基于财政部监管局与证监局联合监管的研究[J]. 中南财经政法大学学报, 2025, (01): 16-27.
- [46]王宗军, 李红侠. 上市公司治理因素与财务困境关系的实证研究[J]. 管理学报, 2007, (06): 803-814.
- [47]方匡南, 吴见彬, 朱建平, 等. 随机森林方法研究综述[J]. 统计与信息论坛, 2011, 26 (03): 32-38.
- [48]吴展, 王春晓. LightGBM 算法在上市饲料公司财务预警中的应用[J]. 饲料研究, 2023, 46 (17): 123-126.
- [49]Batista A P A E G ,Monard C M . AN ANALYSIS OF FOUR MISSING DATA

TREATMENT METHODS FOR SUPERVISED LEARNING[J]. Applied Artificial Intelligence, 2003, 17 (5-6): 519-533.

- [50] Han H, Wang W Y, Mao B H. Borderline-SMOTE: a new over-sampling method in imbalanced data sets learning[C]//International conference on intelligent computing. Berlin, Heidelberg: Springer Berlin Heidelberg, 2005: 878-887.
- [51] Chawla N V, Bowyer K W, Hall L O, et al. SMOTE: synthetic minority over-sampling technique[J]. Journal of artificial intelligence research, 2002, 16: 321-357.