

专业学位论文

基于集成学习的不平衡数据集分类问题研究

Research on Unbalanced Data Classification Based on Ensemble Learning

作者姓名：刘雅洁

学科、专业：应用统计

学号：31901015

指导教师：庞丽萍教授

完成日期：2021年6月

大连理工大学

Dalian University of Technology

摘 要

近年来,集成学习算法以其最大化增强学习效果的优点,在机器学习领域备受关注。随机森林与 XGBoost 算法作为集成学习的杰出代表在医疗健康、入侵检测以及语音识别等诸多领域都具有良好表现。但是,当应用于不平衡数据集时,这两种算法都存在对样本量较少的正类样本不能正确分类以至于分类精度不高、泛化误差较大的问题。然而在实际应用中,正类样本的识别才是数据分析的重点,一旦错分造成的后果远比负类样本错分严重得多。考虑到不平衡数据集分类结果容易受样本量较多的负类样本影响,本文将集成学习算法与不平衡数据集数据层面的优化算法组合构造分类性能更好的模型。

本文采用随机森林与 XGBoost 作为基础算法,并分别结合 SMOTE 过采样、随机欠采样以及 SMOTETomek 混合采样构造 RUS-RF、SMOTE-RF、SMOTETomek-RF、RUS-XGBoost、SMOTE-XGBoost 和 SMOTETomek-XGBoost 模型。在实证分析阶段,本文选用了 UCI 中的 Adult 数据集,同时利用与 Adult 数据集不平衡比例不同的 Bank Marketing 数据集与 Credit Card 数据集进行结果对比。实验中选用了 AUC 和 G-mean 作为性能度量指标,以 RF 与 XGBoost 作为基准模型观察各个模型参数调优后的分类表现。通过对比实验发现:(1)从总体来看,以 XGBoost 为基础算法的模型分类效果要优于以随机森林为基础算法的模型;(2)从模型选择的角度来看,当样本量充足时,RUS-XGBoost 模型的 AUC 与 G-mean 取值最高,比起其他模型更适合作为不平衡数据集的有效分类模型;(3)从数据重采样方法的角度来看,采用随机欠采样的模型比采用 SMOTE 过采样或者 SMOTETomek 混合采样的模型分类效果更好。

关键词: 不平衡数据集; 随机森林; XGBoost

Research on Unbalanced Data Classification Based on Ensemble Learning

Abstract

In recent years, ensemble learning algorithms have attracted much attention in the field of machine learning because of their advantages in maximizing the learning effect. Random forest and XGBoost algorithm, as outstanding representatives of integrated learning, have good performance in many fields such as medical health, intrusion detection and speech recognition. However, when applied to imbalanced data sets, the two algorithms can not classify the positive samples with small sample size correctly, which leads to low classification accuracy and large generalization error. However, in practical applications, the identification of positive samples is the focus of data analysis, and the consequences of misclassification are far more serious than the misclassification of negative samples. Considering that the classification results of imbalanced data sets are easily affected by negative samples with a large sample size, this article will combine the ensemble learning algorithm with the optimization algorithm at the data level of unbalanced data sets to construct models with higher classification performance.

This paper uses random forest and XGBoost algorithms to combine SMOTE oversampling, random undersampling and SMOTetomek mixed sampling to construct RUS-RF, SMOTE-RF, SMOTetomek-RF, RUS-XGBoost, SMOTE-XGBoost and SMOTetomek-XGBoost. In the empirical analysis stage, this article chooses the Adult data set in UCI, and compares the results with the Bank Marketing data set and the Credit Card data set with a different imbalance ratio from the Adult data set. In the experiment, AUC and G-mean are selected as performance metrics, and RF and XGBoost are used as benchmark models to observe the classification performance of each model parameter after tuning. Through comparative experiments, it is found that: (1) Overall, the classification effect of the models based on the XGBoost algorithm are better than that of the models based on the random forest; (2) From the perspective of model selection, when the sample size is sufficient, the AUC and G-mean values of the RUS-XGBoost model are the highest, which is more suitable as an effective classification model for imbalanced data sets than other models; (3) From the perspective of data resampling methods, those models that use random undersampling have better classification results than those models that use SMOTE oversampling or SMOTetomek mixed sampling.

Key Words: imbalanced dataset; random forest; XGBoost

目 录

摘 要.....	I
Abstract.....	II
1 绪论.....	1
1.1 研究背景.....	1
1.2 国内外研究现状.....	1
1.2.1 不平衡数据集的研究现状.....	1
1.2.2 集成学习的研究现状.....	2
1.3 论文架构.....	2
2 不平衡数据集.....	4
2.1 不平衡数据集的定义.....	1
2.2 不平衡数据集数据层面的优化方法.....	1
2.2.1 过采样.....	1
2.2.2 欠采样.....	3
2.2.3 混合采样.....	3
2.3 不平衡数据集算法层面的优化方法.....	4
2.4 不平衡数据集的性能度量.....	5
2.4.1 混淆矩阵.....	5
2.4.2 G-mean.....	6
2.4.3 ROC 曲线与 AUC.....	6
3 模型理论基础.....	8
3.1 决策树.....	8
3.1.1 决策树的基本流程.....	8
3.1.2 决策树的特征选择.....	9
3.1.3 决策树的剪枝处理.....	10
3.2 集成学习.....	10
3.2.1 Bagging 与随机森林.....	13
3.2.2 Boosting 与 XGBoost.....	15
4 实证研究.....	19
4.1 数据简介.....	19
4.2 数据前期预处理.....	19
4.2.1 缺失值处理.....	19

4.2.2	数值特征的选取.....	20
4.2.3	数值特征的标准化处理.....	26
4.2.4	类别特征的选取.....	27
4.3	模型构建.....	32
4.3.1	数据重采样.....	32
4.3.2	模型参数调优.....	33
4.4	模型比较.....	36
结 论		41
参考文献		42
致 谢		48
大连理工大学学位论文版权使用授权书		49

1 绪论

1.1 研究背景

机器学习致力于利用机器从已知数据中挖掘数据规律并生成学习模型进而对未知数据做出反馈。随着计算机网络的普及以及大数据时代的来临，现代社会多数领域的数据体量都迎来了前所未有的增长，迫切需要有效的计算机算法来分析利用这些数据，因此该学科领域必然取得长足发展，受到广泛关注。在前 70 年的发展中，机器学习的研究取得了阶段性的成果，特别是有监督机器学习在人脸识别、语音识别、虚拟助手以及交通预测等人工智能基础领域都得到了广泛应用，各种机器学习算法在这些舞台上大放异彩^[1]。

针对分类任务，多数学习算法都有一个共同的基本假设——不同类别的训练样本数目相当。如果不同类别的样本数稍有差别，通常对算法的泛化性能影响不大，但是若不同类别样本数差别很大即存在类别不平衡问题，则会对学习过程造成困扰。不平衡数据集与人类的现实生活息息相关，例如：在医疗领域，癌症患者的比例不到 1%^[2]；在软件开发领域，存在缺陷的软件不到 10%^[3]；在电子商务领域，推荐商品被购买的比例非常低等等。从现实应用的角度出发，这些数据集中的少数样本（正样本）如癌症患者、存在缺陷的软件以及被消费者购买的商品才是数据分析的重点，而传统的机器学习方法如决策树、K 最近邻、支持向量机以及人工神经网络等算法都是根据平衡数据设计的，以提高总体分类精度为目标，这就使得在不平衡数据中进行学习时，极易造成分类器倾向于负样本，导致误分成本上升。综上所述，由于不平衡数据集的普遍性与传统分类器的局限性，本文的研究具有重要的学术研究价值与广泛的实际应用意义。

1.2 国内外研究现状

1.2.1 不平衡数据集的研究现状

近年来，数据不平衡问题一直是机器学习研究的热点。早在 1993 年，Anand 等人就发现类别不平衡会导致构造的训练集中大多数样本属于同一类别进而导致神经网络反向传播速度减慢^[4]；Philip 与 Salvatore 于 1998 年研究观察了构造均衡子集后的算法模型的分类性能^[5]。为了解决数据不平衡问题，陆续有学者提出了针对数据层面的重采样方法。其中，随机欠采样（Random Under-Sampling, RUS）^[6]是最简单的欠采样方法，该算法通过从负类样本中随机抽取与正类样本规模一致的数据来达到数据平衡，然而抽取样本同样会造成关键信息的流失；针对这个缺陷，Liu 等人提出了 EasyEnsemble 算法与

BalanceCascade 算法^[7], 这两种算法都采用了集成的思想, 对负类样本进行多次采样构建不同的分类器, 从而弥补随机欠采样存在的弊端; 此外, 另有基于聚类的欠采样: CBUS^[8]算法和 Fast-CBUS^[9]算法, 基于遗传算法的欠采样: GAUS^[10]算法以及类似于噪声检测的 ENN^[11]算法和 Tomek^[12]算法等等。此外, 随机过采样^[13]是最简单的过采样算法, 它通过人为复制正类样本来达到数据平衡, 故而随机过采样算法会使得正类样本中存在大量相似数据进而导致模型的过拟合; Chawla^[14]等人于 2002 年提出的 SMOTE 算法通过合成少数类样本来改善随机过采样方法带来的问题; 针对 SMOTE 算法没有考虑近邻样本的分布特点带来的样本重叠度高的问题, Han^[15]与 HE^[16]相继于 2005 年与 2008 年提出了 Borderline-SMOTE 算法与 ADASYN 算法。混合采样结合了欠采样和过采样, 目前常用的算法有: 将随机欠采样和 SMOTE 组合的 RU-SMOTE^[17]算法, 将 SMOTE 和 Tomek 结合的 SMOTetomek 算法^[18]以及将 SMOTE 和 ENN 结合的 SMOTEENN 算法。

1.2.2 集成学习的研究现状

本文基于集成学习研究不平衡数据集的分类情况, 因此这里同时介绍集成学习在不平衡数据集领域的研究现状。2003 年 Chawla 提出将 SMOTE 采样与 Boosting 集成^[19]结合构造 SMOTEBoost 模型; Wang^[20]等人于 2009 年分别使用 SMOTE 采样以及欠采样与 Bagging^[21]算法结合得到 SMOTEBagging 和 UnderBagging to Over Bagging (UOBag) 等套袋算法, 在不平衡数据集分类问题上取得显著成效; Chen Chao^[22]在随机森林^[23]的基础上提出了加权随机森林 (WRF) 与平衡随机森林 (BRF) 来提高少数类的预测精度; 2013 年, 吴琼^[24]等人结合 NCL (Neighborhood Cleaning Rule) 技术改进了随机森林, 提高了模型的分类性能; 2016 年, 钟龙申^[25]结合 K-means 算法提出了一种 KSMOTE 算法, 探讨了基于 Mapreduce 框架的随机森林并行化, 提高了随机森林解决不平衡数据集分类问题的运行效率; 2019 年, 赵锦阳、卢会国等人针对随机森林算法提出了一种新的过采样方法: SCSMOTE 算法^[26]; 2020 年王磊、刘雨等人提出了一种基于聚类欠采样的加权随机森林算法^[27]等等。

1.3 论文架构

本文致力于比较两种以决策树为基分类器的集成学习算法——随机森林和 XGBoost 在不平衡数据集分类问题上的表现。具体操作是把随机森林与 XGBoost 分别与 SMOTE 过采样、随机欠采样以及 SMOTetomek 混合采样组合构建不平衡数据集分类模型, 然后利用 Python 软件编程实现模型在三组不平衡数据集上的分类。本文共有四个章节, 其行文框架如下:

第一章为本文的绪论部分, 主要介绍不平衡数据集的研究背景和国内外研究现状,

以及集成学习在不平衡数据集分类领域的国内外研究现状；

第二章主要介绍了不平衡数据集的基础知识，其中包括不平衡数据集的定义、不平衡数据集在数据层面与算法层面的优化方法以及不平衡数据集分类模型的性能度量指标；

第三章介绍了本文所使用模型的理论基础，详细阐述了决策树、随机森林以及 XGBoost 的原理与生成算法；

第四章是本文的实证分析部分，利用 UCI 中的“Adult”数据集训练不平衡数据集分类模型，并选用了同样来自 UCI 的“Bank Marketing”数据集与来自 Kaggle 竞赛数据的“Credit Card”数据集作为对比数据，具体实证分析思路如图 1.1 所示，以 RF 和 XGBoost 模型作为基准模型，然后把这两种算法分别与不同的重采样方法结合构造 RUS-RF、SMOTE-RF、SMOTEtomek-RF、RUS-XGBoost、SMOTE-XGBoost、SMOTEtomek-XGBoost 模型，以 AUC、G-mean 作为性能评价指标，测试构造的模型在上述三组不平衡比例不同的不平衡数据集上的分类表现，从而为研究者在处理类别不平衡问题时选择分类器提供有价值的参考。




图 1.1 实证分析流程图

Fig. 1.1 Flowchart of empirical analysis

2 不平衡数据集

2.1 不平衡数据集的定义

不平衡数据集分为类内不平衡数据集与类间不平衡数据集。本文研究不平衡数据集指的是类间不平衡，即各个类别之间的样本数目相差巨大。如图 2.1 所示，一般将不平衡数据集中拥有较多实例的类别（蓝色）称为负样本，拥有较少实例的类别（橙色）称为正样本，正样本与负样本之间的比例称之为不平衡比例（Imbalanced Ratio, IR）。




图 2.1 不平衡数据分布图

Fig. 2.1 A distribution map of unbalanced data sets

目前，处理不平衡数据集分类问题的办法大致有两类：第一，基于数据层面优化不平衡数据采样算法；第二，基于算法层面优化不平衡数据分类算法。

2.2 不平衡数据集数据层面的优化方法

基于数据层面优化不平衡数据采样算法是指通过优化采样方法将不平衡的数据集改造成平衡的数据集，从而达到使用传统机器学习训练分类器的前提假设。目前常用的重采样方法可分为过采样、欠采样与混合采样。

2.2.1 过采样

过采样^[28]：通过生成足量的正样本实现正样本与负样本的平衡。其优点是提高了正样本的学习量；缺点是生成的正样本并不是通过抽样得到的真正样本，从而容易带来样本噪声，降低算法模型少数类样本的分类正确率^[29]。

随机过采样是最简单的过采样方法，该算法的基本步骤是反复随机地抽取正样本，并将抽取到的样本放入原始样本空间，形成新的样本空间。这种抽样方法速度很快，但是会在正类样本中产生大量相似数据，因此在分类器的训练中容易使模型过拟合。同样，如果正类样本中存在噪声数据，那么在多次抽取正类样本后，噪声数据对模型的影响也会增大^[30]。

SMOTE 作为最常用最经典的过采样方法改善了随机过采样存在的问题。其基本思想是采用数据合成的方式取代数据替换来进行过采样。图 2.2 展示了 SMOTE 算法合成样本的分布情况：对每一个正样本 X ，搜索 K 个同样属于少数类的最近邻样本。假定数据集的过采样倍率为 n ，那么就从这 K 个最近邻样本中随机抽取 n 个样本（ $K > n$ ），并将 n 个样本记为 $y_1, y_2, \dots, y_n$ 。关联数据样本 X 与 y_i ，通过 X 与 $y_i (i = 1, 2, \dots, n)$ 之间的关联公式进行随机的线性插值得到插值样本 p_i ，这样针对每个数据样本都产生了 n 个相对应的正类样本。其中，插值公式为：

$$p_i = X + rand(0,1) * (y_i - X), i = 1, 2, \dots, n \quad (2.1)$$

其中， X 表示正类样本， $rand(0,1)$ 是区间(0,1)内的随机数， y_i 表示样本 X 的 n 个最近邻样本中的第 i 个样本。此外，过采样倍率 n 的取值由数据集的不平衡比例 IR 决定，其计算公式为^[31]：

$$n = round(IR) \quad (2.2)$$




图 2.2 SMOTE 算法合成样本分布图

Fig. 2.2 Sample distribution after SMOTE

2.2.2 欠采样

欠采样：通过选择部分具有典型意义的负样本，构造正样本与负样本数目相当的平衡数据集。随机欠采样^[32]是最简单有效的欠采样方法，它随机抽取出与正样本一致规模的负样本，然后将抽取到的负样本放入正样本空间中组成新的平衡数据集。经过随机欠采样后的数据分布情况如图 2.3 所示。




图 2.3 随机欠采样后的样本分布图

Fig. 2.3 Sample distribution after Random Under-Sampling

2.2.3 混合采样

混合采样^{[33][34]}：通过把过采样算法与欠采样算法结合起来构造平衡数据集。SMOTetomek 是一种常用的混合采样算法，该算法先通过 SMOTE 算法得到初步的平衡数据集 D ，再采用 Tomek 算法对新的数据集 D 中处在胶着状态的点进行删除。其中 Tomek 欠采样的基本思想为：对于任意两个不属于同一类别的样本 X_i 与 X_j ，若不存在样本 X 使得这两个样本的距离满足 $d(X_i, X_j) < d(X, X_i)$ 或者 $d(X_i, X_j) < d(X, X_j)$ ，则称样本 X_i 与 X_j 构成了一个 Tomek link—— X_i 与 X_j 这两个样本点中存在一个噪声点。如图 2.4 所示，算法通过删除 Tomek link 达到消除噪声的效果。




图 2.4 SMOTetomek 采样后的样本分布图

Fig. 2.4 Sample distribution after SMOTetomek

2.3 不平衡数据集算法层面的优化方法

优化不平衡数据分类算法是指结合不平衡数据集的特点，通过对传统分类算法的改进或设计新的分类算法，以适应不平衡数据的分类需要。主要包括代价敏感（Cost-Sensitive）学习、集成学习、单类学习等方法^[35]。传统的机器学习算法以分类精度作为性能评价指标，因此模型对类别错分代价不敏感，但是对于不平衡数据集，类别错分代价的忽视对分类性能影响巨大。例如对于癌症检测方面，将未患病的检测者误判为患病只需要重新检测，但是若将癌症患者误判为未患病则有可能错过最佳治疗时间，后果严重时甚至将付出生命的代价。代价敏感在解决分类问题时对于出现的不同分类错误使用不同的惩罚力度，其核心要素是代价矩阵（cost matrix）^[36]。其中， cost_{FP} 表示正样本误判为负样本的代价， cost_{FN} 表示负样本误判为正样本的代价。当 $\text{cost}_{FP} = \text{cost}_{FN}$ 时，说明代价不敏感，两种误判的代价相等； cost_{FP} 与 cost_{FN} 差异越大，说明代价不平衡程度越大。对于不平衡数据，我们更关注正样本的分类结果，因此可以将正样本的误判代价调高，同时可以将负样本的误判代价调小，即令 $\text{cost}_{FN} \ll \text{cost}_{FP}$ ^[37]。

表 2.1 代价矩阵

Tab. 2.1 Cost Matrix

	预测为正样本	预测为负样本
真实为正样本	0	cost_{FP}
真实为负样本	cost_{FN}	0

代价敏感学习的分类目标是使得分类器对未知样本进行分类时，期望代价最小：

$$\arg \min E_{(x,y)} \sim D[\cos t_{yh(x)}] \quad (2.3)$$

其中， D 表示样本的分布， E 表示期望代价， $h(x)$ 表示 x 的经验风险值， $\cos t_{yh(x)}$ 表示某个类别的分类代价值。由于样本分布 D 未知，故而在训练过程中通过最小化经验风险值来得到分类器 h ：

$$\arg \min \sum_{i=1}^n \cos t_{y_i(x_i)} \quad (2.4)$$

2.4 不平衡数据集的性能度量

性能评价指标在衡量学习器的优劣方面至关重要，同时也为选择合适的模型提供了不可或缺的参考价值^[38]。在对比不同模型的能力时，使用不同的性能度量往往会导致不同的评判结果。当数据不平衡的时候，只考虑整体的分类精度即分类正确的样本数占样本总数的比例并不能反映分类的真实结果，反而容易忽视我们真正关注的少数类。针对传统性能评估标准的缺陷，一些研究者提出可采用混淆矩阵（confusion matrix）、ROC 曲线、AUC 以及 G-mean 等评价指标来评估模型的分类性能。

2.4.1 混淆矩阵

针对二分类问题，按照学习器的预测类别与实际类别的差别可将样本划分为真正例、真反例、假正例以及假反例，并以矩阵的形式直观地展示出来从而得到混淆矩阵如表 2.2 所示。其中， TP 表示真实值与预测值都为正类的样本个数； FP 表示真实值为负类而预测值为正类的样本个数； FN 表示真实值为正类而预测值为负类的样本个数； TN 表示真实值与预测值都为负类的样本个数。

表 2.2 混淆矩阵

Tab.2.2 Confusion Matrix

		预测值	
		正样本	负样本
真实值	正样本	TP （真正例）	FN （假反例）
	负样本	FP （假正例）	TN （真反例）

2.4.2 G-mean

根据上述的分类结果，可分别定义灵敏度（Sensitivity）与特异度（Specificity）如下：

$$Sensitivity = \frac{TP}{TP + FN} , \quad (2.5)$$

$$Specificity = \frac{TN}{TN + FP} . \quad (2.6)$$

灵敏度指的是正样本的分类正确率；特异度指的是负样本的分类正确率。为了综合考虑每个类别对最终性能的贡献，研究者提出了新的性能评价指标——G-mean，只有当灵敏度与特异度两者都高时，G-mean 的取值才会高，其表达式为：

$$G-mean = \sqrt{Sensitivity * Specificity} . \quad (2.7)$$

2.4.3 ROC 曲线与 AUC

根据上述分类结果，可分别定义真正例率（TPR）与假正例率（FPR）如下：

$$TPR = \frac{TP}{TP + FN} , \quad (2.8)$$

$$FPR = \frac{FP}{TN + FP} . \quad (2.9)$$

在实践中，学习器能够为测试样本产生一个实值或概率预测，然后将这个预测值与分类阈值比较，若大于阈值则归为正类，否则为负类。基于不同的阈值可以计算出唯一的真正例率与假正例率，进而能够以假正例率为横坐标，真正例率为纵坐标绘制出 ROC 曲线，以可视化的方式展示错误分类的代价与正确分类的获益之间的关系。如图 2.5 所示，AUC 是 ROC 曲线下的面积，ROC 曲线越靠近于左上角，AUC 越大，模型分类性能越好；ROC 曲线越接近于对角线，AUC 越近似等于 0.5，模型越接近于随机猜测，分类性能越差。




图 2.5 ROC 曲线与 AUC
Fig. 2.5 ROC curve and AUC

3 模型理论基础

3.1 决策树

决策树^[39]是随机森林与 XGBoost 的基学习器，是一种常见的机器学习方法。该算法致力于从一组没有次序、没有规则的训练样本中挖掘总结出树结构的分类或回归规则用以对测试样本进行分类。决策树凭借其结构简单、学习效率高、计算量小、分类精度高、输出结果易于理解以及擅长处理类别型数据的优点被广泛应用于各种领域。最具影响的决策树算法为 Quinlan 于 1986 年提出的 ID3 算法和 1993 年在 ID3 算法的基础上提出的 C4.5 算法以及 Breiman 等人提出的 CART 算法^[40]。

3.1.1 决策树的基本流程

决策树学习的目标是利用训练数据集构建决策树模型，并基于树结构对测试及样本进行正确的决策。决策树中一般存在一个根结点、多个叶结点以及多个内部结点；唯一的根结点包含所有样本，每个叶结点表示一个决策结果，每个内部结点代表一个特征测试，可以按照特征测试的结果将当前结点中的实例分配到相应的子结点。决策树是特征空间到类别空间的一种映射关系，决策过程一般如图 3.1 所示：在对“这是诈骗短信吗？”这样的问题进行决策时，通常要进行一系列的判断或“子决策”：先看“它是来自陌生号码吗？”，如果是，再看“它存在私人信息泄露风险吗？”，如果存在，则再看“它涉及金钱交易么？”，最后，我们得到最终决策：这是诈骗信息。




图 3.1 诈骗短信问题的一棵决策树

Fig. 3.1 A decision tree for fraudulent text messages issues

3.1.2 决策树的特征选择

决策树学习的重心在于如何选择最优特征来划分样本。随着样本划分过程的持续推进,算法的目的是使得每个分支结点中的样本尽可能地属于一个类别,即不断提升结点的“纯度”(purity)。目前有三种常用的指标来度量结点的纯度:信息增益、信息增益比以及基尼指数。

(1) 信息增益 (information gain)

为了衡量样本集合的信息纯度,信息学之父香农引入了“信息熵”(information entropy)的概念,针对样本集合 D 给出计算信息熵的数学公式为:

$$\text{Ent}(D) = -\sum_{k=1}^K p_k \log_2 p_k \quad (3.1)$$

其中, $p_k (k=1,2,\dots,K)$ 表示第 k 类样本占总样本的比例。 $\text{Ent}(D)$ 的取值越小,则样本集合 D 的纯度越高,信息不确定性越小。

信息增益是相对于特征而言的,信息增益越大代表选择该特征划分样本集后当前结点的“纯度提升”越大。给定特征 a 与训练集 D ,假定该特征有 V 个可能值 $\{a^1, a^2, \dots, a^V\}$,则存在 V 个分支结点,并且第 v 个分支结点包含了训练集 D 中所有在特征 a 上取值为 a^v 的样本,记为 D^v ,按照式 (3.1) 可计算出 D^v 的信息熵,又因为分支结点不同,包含的样本数也不同,故而按照分支结点的样本数越多影响越大的规则为该分支结点赋予权重 $|D^v|/|D|$,可得到选择特征 a 划分样本集合 D 的“信息增益”如下:

$$\text{Gain}(D, a) = \text{Ent}(D) - \sum_{v=1}^V \frac{|D^v|}{|D|} \text{Ent}(D^v) \quad (3.2)$$

(2) 信息增益比 (information gain ratio)

由于使用信息增益准则选择划分特征的 ID3 算法偏向于取值较多的特征,即取值比越多的特征信息增益越明显,因此 Quinlan 在提出 C4.5 决策树时改用“信息增益比”来进行特征选择,表达式如下:

$$\text{Gain_ratio}(D, a) = \frac{\text{Gain}(D, a)}{\text{IV}(a)} \quad (3.3)$$

其中,

$$\text{IV}(a) = -\sum_{v=1}^V \frac{|D^v|}{|D|} \log_2 \frac{|D^v|}{|D|} \quad (3.4)$$

是特征 a 的“固有值”。一般情况下,特征数越多的特征固有值越大,它作为分母能有效校正信息增益偏好取值较多的特征的问题。与信息增益准则不同,增益比准则反而偏

向于取值较少的特征，因此 C4.5 算法没有直接按照信息增益比大小选择划分特征，而是先所有的特征中挑选信息增益比平均水平高的特征，然后从中挑选信息增益比最高的特征属性。

(3) 基尼指数 (Gini index)

不同于 C4.5 决策树只能用于分类问题，CART 决策树不仅可以应用于分类也可以应用于回归。在分类问题中，该算法使用了一种新的指标“基尼指数”来进行特征选择。假设有 K 个类， p_k 表示样本点属于第 k 类的概率，则基尼指数的表达式为：

$$\text{Gini}(D) = \sum_{k=1}^{|K|} \sum_{k' \neq k} p_k p_{k'} = 1 - \sum_{k=1}^{|K|} p_k^2. \quad (3.5)$$

$\text{Gini}(D)$ 表示从集合 D 中随机抽取的两个样本不属于同一类别的概率，因此， $\text{Gini}(D)$ 越大，则集合 D 的不确定性越大。基尼指数可定义为：

$$\text{Gini_index}(D, a) = \sum_{v=1}^V \frac{|D^v|}{|D|} \text{Gini}(D^v). \quad (3.6)$$

求取特征集合 A 中使得基尼指数最小的特征，即 $a_* = \arg \min_{a \in A} \text{Gini_index}(D, a)$ 。

3.1.3 决策树的剪枝处理

剪枝 (pruning) 的目的是为了降低决策树学习算法中出现“过拟合”问题的风险。在决策树模型的训练过程中，如果决策树选择的特征过多，决策树会不断划分直到能够“完美”地把训练集中的样本分类，进而导致训练样本训练得“太好”了，以至于把训练样本自身的一些数据特征当作原始数据集具有的共同性质。因此，为了防止构建出过于复杂的决策树，可以主动剪掉多余的分支，其基本策略有：“预剪枝” (prepruning) 和“后剪枝” (postpruning)。其中，预剪枝是指在构造决策树的过程中进行剪枝。具体步骤为先在划分前对每个结点进行估计，若该结点的划分无法提高决策树的分类性能，则把当前结点作为叶结点，不再对其进行划分。后剪枝指的是在决策树成功生成后再进行剪枝。具体步骤为先根据训练样本构造决策树，进而逐层向上地评估每个结点，若用叶结点替换掉该结点对应的子树能提高决策树的分类性能，则删除该子树并替换为叶结点，同时归类为该子树中出现最频繁类别。

3.2 集成学习

集成学习 (ensemble learning) 致力于把多个学习器组合起来构建一个更好更全面的强监督模型。图 3.2 显示出集成学习的构造过程：首先，利用现有的机器学习算法从实例数据集中训练一组“个体学习器” (individual learner)；然后，利用给定的策略将个

体学习器组合起来完成学习任务。根据集成模型中是否只存在相同类型的个体学习器，可以把集成模型分为“同质”（homogeneous）集成与“异质”（heterogeneous）集成。同质集成中的个体学习器也被称为“基学习器”（base learner），对应的学习算法被称为“基学习器算法”（base learning algorithm）；相应地，异质集成中的个体学习器被称为“组件学习器”（component learner）或直接称为个体学习器^[41]。




图 3.2 集成学习示意图

Fig. 3.2 The schematic of integrated learning

从生活经验中我们可以感受到，如果把好坏不等的东西混合在一起，那么结果往往会比最差的要好一些，比最好的要坏一些。这也是集成学习分类器往往比单个的个体学习器分类性能更好的原因。通过一个简单的实验来分析如何制定适当的策略来保证多个个体学习器组合起来后拥有超越单一个体学习器的分类性能：针对二分类任务，比较三种不同组合策略下的集成学习在测试样本上的分类表现，其中√表示对样本正确分类，×表示对样本错误分类，并且通过投票法（voting）即“少数服从多数”的策略决定集成模型的分类结果。结果对比如表 3.1 所示：在表 3.1（a）中，每个分类器对测试样本的分类结果不同，分类精度相同，皆为 66.66%，而集成学习的分类精度则达到了 100%；在表 3.1（b）中，三个分类器分类结果完全相同，分类精度同样达到了 66.66%，但是分类性能在集成之后没有任何提高；在表 3.1（c）中，每个分类器的分类结果不同，分类精度相同且都只有 33.33%，但是集成学习的分类结果反而变得更差。显而易见，要获得好的集成，集成学习应该本着“好而不同”的策略选择个体学习器，即个体学习器不仅

准确率高，并且要有显著的区别。值得注意的是：在现实任务中，个体学习器都是根据相同的实例样本集训练出来的，故而它们不可能完全相互独立。

表 3.1 集成学习作用效果

Tab. 3.1 Effect of integration learning

(a) 集成提升性能			
	测试例 1	测试例 2	测试例 3
h_1	√	√	×
h_2	×	√	√
h_3	√	×	√
集成	√	√	√
(b) 集成不起作用			
	测试例 1	测试例 2	测试例 3
h_1	√	√	×
h_2	√	√	×
h_3	√	√	×
集成	√	√	×
(c) 集成起负作用			
	测试例 1	测试例 2	测试例 3
h_1	√	×	×
h_2	×	√	×
h_3	×	×	√
集成	×	×	×

当前的集成学习方法可根据个体学习器的生成方式大致分为两大类：第一，以 Bagging 算法和随机森林为代表的并行化方法，其特点是多个个体学习器可同时生成并且不存在强依赖关系；第二，以 Boosting 算法为代表的序列化方法，其特点是多个个体学习器必须串行生成并且存在强依赖关系。

3.2.1 Bagging 与随机森林

(1) Bagging

由上可知，欲得到泛化性能强的集成，集成模型中的个体学习器需要尽可能地“不同”。故而初步考虑的方法为：针对给定的训练数据集，通过对训练样本的采样制造出多个不同的子集，从而根据多个训练子集训练出若干个个体学习器。这样，由于训练数据不同，我们获得的个体学习器之间可以具有比较好的独立性。然而，为了获得较好的集成，我们同时期望个体学习器具有较高的准确性。此时，为了保证个体学习器的独立性，每个个体学习器只用到了一个训练子集，甚至不足以进行有效学习，这显然无法确保生成比较好的个体学习器。为了解决这个问题，我们考虑使用相互交叠的采样子集。

Bagging 算法是在自助采样法 (boosting sampling) 的理论基础上提出的并行化集成方法。该算法的基本流程如图 3.3 所示：针对给定的包含 m 个样本的训练集，随机有放回地抽取样本放入采样集中，即每次采样时初始训练集中的每个样本都有被选中的可能，如此经过 m 次的随机采样后，可以得到一个包含 m 个样本的训练子集，并且初始训练集中约有 63.2% 的样本出现在该训练子集中。重复 n 次上述步骤，可以得到 n 个包含 m 个样本的训练子集，如此，可以根据这 n 个训练子集分别训练出 n 个基学习器，最后采用投票法构造集成学习器完成学习任务。




图 3.3 Bagging 算法基本框架

Fig. 3.3 Procedure of Bagging algorithm

(2) 随机森林

随机森林是在 Bagging 算法^[42]与随机子空间^[43]的理论基础上提出的一种集成学习算法。顾名思义，该算法以互不相关的决策树为基学习器构建一片森林完成分类或回归的学习任务，其随机性体现在算法在训练决策树时引入了随机特征选择。不同于传统决策树在结点分裂时从所有特征（假定有 d 个特征）中选择一个最优划分特征，随机森林选择从当前结点的特征集合中随机选择 k （通常取 $k = \log_2 d$ ）个特征构造特征子集，然后再从该子集中求取结点的划分特征的最优解，从而避免出现过拟合问题。其基本流程如图 3.4 所示。

随机森林易于实现、思路简单、计算代价小、能够评估数据特征在分类问题上的重要性并且在高维数据上有较好的表现。相比于 Bagging 算法，两者都是通过降低基学习器中的方差来降低分类误差，不同于 Bagging 基学习器的多样性仅来自于样本扰动，加入特征扰动的随机森林由“确定性”决策树转变为“随机性”决策树，进一步提高了训练效率与泛化性能。




图 3.4 随机森林分类流程图

Fig. 3.4 Procedure of Random Forest Classification

3.2.2 Boosting 与 XGBoost

(1) Boosting

Boosting 是一族可将分类效果略好于随机猜测效果的弱学习器提升为强学习器的框架算法。该算法的工作流程如图 3.5 所示：首先利用初始训练集训练出一个弱学习器，再基于弱学习器的分类误差调整训练样本点的分布，即调高学习误差率高的训练样本权重，从而使得这些样本在后续学习中获得更多的关注，然后根据更新后的训练样本分布继续训练下一个弱学习器。重复上述步骤，直至得到 n 个弱学习器，再根据集成策略组合这 n 个弱学习器得到最终的强学习器。




图 3.5 Boosting 算法基本流程

Fig. 3.5 Procedure of Boosting algorithm

(2) XGBoost

XGBoost 算法是一种基于 Boosting 算法的迭代决策树思想的具体实现^[44]，它既可用于非线性分类，也可用于线性分类，两者的区别在于是否加入了正则化的参数。比起传统梯度提升算法，XGBoost 对损失函数进行了二阶泰勒展开，同时用到了一、二阶导数

信息，并且引入了正则项，提高了个体学习器的泛化能力；此外，该算法最大的优势在于 XGBoost 能够自动利用 CPU 的多线程进行并行运算，运行效率与分类精度都得到了显著提高^{[45][46]}。

假定 XGBoost 算法中集成了 K 个决策树，那么可得复合树的函数模型如下：

$$y_i = \sum_{k=1}^K f_k(x_i), f_k \in \mathcal{F}. \quad (3.7)$$

其中， f_k 表示一个基分类器——CART 回归树， K 表示决策树的个数， $\mathcal{F}$ 表示基分类器空间。此时，XGBoost 的目标函数可表示为：

$$Obj(\theta) = \sum_{i=1}^n L(y_i, \hat{y}_i) + \sum_{k=1}^K \Omega(f_k) . \quad (3.8)$$

该函数由两部分构成：损失函数和正则化项。前者可以衡量模型在训练数据集上的预测能力，通常损失函数越小，拟合效果越好；后者可以控制模型的复杂度，防止模型学习到仅存在于训练数据集中的噪声，使得模型过于复杂进而发生过拟合。参数 θ 为模型的待定部分，可通过训练数据集求取最优参数。

XGBoost 是基于 GBDT 改进的加法模型，每添加一棵树，就是学习了一个新函数 $f_k(x_i)$ ，去拟合上次预测的残差，故而没办法一次性得到每棵回归树，只能根据前 $t-1$ 次迭代的模型训练得到第 t 棵树。令初始提升树定义为 $f_0(x_i) = \hat{y}_i^{(0)} = 0$ ，则第 t 次迭代得到的基学习器可表示为：

$$\begin{aligned} \hat{y}_i^{(1)} &= f_1(x_i) = \hat{y}_i^{(0)} + f_1(x_i) \\ \hat{y}_i^{(2)} &= f_1(x_i) + f_2(x_i) = \hat{y}_i^{(1)} + f_2(x_i) \\ \hat{y}_i^{(3)} &= f_1(x_i) + f_2(x_i) + f_3(x_i) = \hat{y}_i^{(2)} + f_3(x_i) \\ &\dots\dots \\ \hat{y}_i^{(t)} &= \sum_{k=1}^t f_k(x_i) = \hat{y}_i^{(t-1)} + f_t(x_i) . \end{aligned} \quad (3.9)$$

将 t 次迭代后的模型代入，可得到目标函数如下：

$$Obj^{(t)} = \sum_{i=1}^n L(y_i, \hat{y}_i^{(t)}) + \sum_{i=1}^t \Omega(f_i) = \sum_{i=1}^n L(y_i, \hat{y}_i^{(t-1)} + f_t(x_i)) + \Omega(f_t) + \text{const} , \quad (3.10)$$

对目标函数的误差项二阶泰勒展开后可得到：

$$Obj^t \approx \sum_{i=1}^n [L(y_i, \hat{y}_i^{(t-1)}) + g_i f_t(x_i) + \frac{1}{2} h_i f_t^2(x_i)] + \Omega(f_t) + \text{const} . \quad (3.11)$$

其中 $g_i = \partial_{\hat{y}^{t-1}} L(y_i, \hat{y}^{t-1})$, $h_i = \partial^2_{\hat{y}^{t-1}} L(y_i, \hat{y}^{t-1})$ ，移除常数项后有目标函数如下：

$$Obj^{(t)} \approx \sum_{i=1}^n [g_i f_t(x_i) + \frac{1}{2} h_i f_t^2(x_i)] + \Omega(f_t) . \quad (3.12)$$

显然, XGBoost 目标函数的优化只依赖于损失函数的二阶导数, 有利于梯度下降得更快更准, 增强 XGBoost 的适用性。

接下来探讨如何定义 XGBoost 的正则项。决策树的映射函数可表示为:

$$f_t(x_i) = w_q(x_i), w \in R^T, q: R^d \longrightarrow \{1, 2, \dots, T\} . \quad (3.13)$$

其中, q 为表示树的结构函数, w 表示叶结点的权重向量。在 XGBoost 中, 决策树的复杂度可表示为:

$$\Omega(f_t) = \gamma T + \frac{1}{2} \lambda \sum_{j=1}^T w_j^2 . \quad (3.14)$$

其中, γT 为叶结点的数量复杂度, 各叶结点的权重平方和项为 L2 正则项。假定 $G_j = \sum_{i \in I_j} g_i$, $H_j = \sum_{i \in I_j} h_i$, 则可得到目标函数如下:

$$\begin{aligned} Obj^{(t)} &\approx \sum_{i=1}^n [g_i f_t(x_i) + \frac{1}{2} h_i f_t^2(x_i)] + \Omega(f_t) \\ &= \sum_{i=1}^n [g_i w_q(x_i) + \frac{1}{2} h_i w_q^2(x_i)] + \gamma T + \frac{1}{2} \lambda \sum_{j=1}^T w_j^2 \\ &= \sum_{j=1}^T [(\sum_{i \in I_j} g_i) w_j + \frac{1}{2} (\sum_{i \in I_j} h_i + \lambda) w_j^2] + \gamma T \\ &= \sum_{j=1}^T [G_j w_j + \frac{1}{2} (H_j + \lambda) w_j^2] + \gamma T . \end{aligned} \quad (3.15)$$

假定 $q(x_i)$ 固定, 至此求取最小化目标函数的问题就转化成了一元二次函数求极值问题。此时得到叶结点的最优权重:

$$w_j^* = \frac{G_j}{H_j + \lambda} , \quad (3.16)$$

目标函数为:

$$Obj^{(t)} = -\frac{1}{2} \sum_{j=1}^T \frac{G_j^2}{H_j + \lambda} + \gamma T . \quad (3.17)$$

此外, 类似于 CART 回归树, XGBoost 模型同样利用贪心算法遍历所有特征的所有特征划分点, 寻找最优划分结点, 并根据上一次迭代过程中的残差不断地优化自身。XGBoost 算法的运行流程如图 3.6 所示。




图 3.6 XGBoost 算法基本流程

Fig. 3.6 Procedure of XGBoost algorithm

4 实证研究

4.1 数据简介

本论文研究的数据集是来自于 UCI 数据库的“Adult”数据集，分类目标是根据普查数据预测劳动者的年收入是否超过 50K 美元。该数据集共包含 48842 个样本，14 个特征变量，其中包括 6 个数值特征和 8 个类别特征，存在缺失数据。变量的具体说明如表 4.1 所示：

表 4.1 数据说明
Tab.4.1 Data description

变量	变量类型
age (age)	年龄
workclass (wc)	工作类别
fnlwgt (fw)	序号
education (ed)	受教育程度
education-num (edn)	受教育时间
marital-status (ms)	婚姻状况
occupation (oc)	职业
relationship (re)	社会角色
race (race)	种族
sex (sex)	性别
capital-gain (cg)	资本收益
capital-loss (cl)	资本支出
hours-per-week (hpw)	每周工作时间
native-country (nc)	国籍

4.2 数据前期预处理

4.2.1 缺失值处理

对“Adult”数据集进行缺失值识别可得到表 4.2 如下：其中，表格内部的 0 表示该属性存在缺失值，即属性“nc”、“wc”以及“occ”这三个属性存在缺失值；汇总数据中的最后一行数据表示“Adult”数据集总共存在 6465 个缺失值并且上述三个属性分别

存在 857、2799 以及 2809 个样本存在缺失值；第一列以及最后一列数据说明有 45222 个样本没有缺失数据；10 个样本于“occ”属性缺失数据；2753 个样本于“wc”和“occ”这两个属性都缺失数据；811 个样本只在“nc”属性上存在缺失数据；46 个样本在这三个属性上都存在缺失数据。由于“Adult”数据集存在充足的样本，因此本文采取最简单的缺失值处理方式，删除 6465 个存在缺失数据的样本。

表 4.2 数据缺失情况

Tab.4.2 Lack of data

	age	fw	ed	edn	ms	re	race	sex	cg	cl	hpw	Class	nc	wc	occ	
45222	1	1	1	1	1	1	1	1	1	1	1	1	1	1	1	0
10	1	1	1	1	1	1	1	1	1	1	1	1	1	1	0	1
2753	1	1	1	1	1	1	1	1	1	1	1	1	1	0	0	2
811	1	1	1	1	1	1	1	1	1	1	1	1	0	1	1	1
46	1	1	1	1	1	1	1	1	1	1	1	1	0	0	0	3
	0	0	0	0	0	0	0	0	0	0	0	0	857	2799	2809	6465

4.2.2 数值特征的选取

如表 4.3 所示，对 6 个数值型特征变量进行统计分析。

表 4.3 数值型变量分布情况

Tab.4.3 Distribution of numerical variable

	age	fw	edn	cg	cl	hpw
n	45222.00	45222.00	45222.00	45222.00	45222.00	45222.00
Min.	17.00	12285	1.00	0	0	1.00
1st Qu.	28.00	117551	9.00	0	0	40.00
Median	37.00	178145	10.00	0	0	40.00
Mean	38.64	189664	10.08	1079	87.5	40.42
3rd Qu.	48.00	237642	12.00	0	0	45.00
Max.	90.00	1490400	16.00	99999	4356	99.00
stdev	13.22	105639.20	2.55	7506.43	404.96	12.01
skew	0.53	1.45	-0.31	11.79	4.52	0.34
kurtosi	-0.16	6.18	0.63	150.13	19.36	3.20

分析表 4.3 可得：原数据集在进行过缺失值处理后，还存在 45222 个有效样本。其中，变量“age”的最小值为 17，四分之一分位数为 28，中位数为 37，四分之三分位数为 48，最大值为 90，标准差为 13.71，偏度为 0.53，分布呈现右偏，峰度为-0.16；变量

“cg”的偏度为 11.79，变量“cl”的偏度为 4.52，皆呈现出非常明显的右偏分布，且存在大量样本在这两个特征上取值为 0。

根据样本年收入是否大于 50K 美元分组分析这 6 个数值变量与目标变量的关系，可得到表 4.4 如下。其中，表 4.4 的上半部分表示年收入大于 50K 美元的 11208 个样本的变量分布特征，第二部分表示年收入小于等于 50K 美元的 34014 个样本的变量分布特征；可以看出年收入大于 50K 美元的样本平均年龄（age）明显大于年收入小于等于 50K 美元的样本的平均年龄；年收入大于 50K 美元的样本平均受教育时间（edn）明显大于年收入小于等于 50K 美元的样本的平均受教育时间；另外，年收入大于 50K 美元的样本平均资本收益（cg）与平均资本支出（cl）远远大于年收入小于等于 50K 美元的样本的平均资本收益与平均资本支出；年收入大于 50K 美元的样本每周平均工作时间略大于年收入小于等于 50K 美元的样本每周平均工作时间。显然，上述数值变量都与目标变量密切相关。

表 4.4 数值变量分组描述性分析

Tab. 4.4 Descriptive analysis of numerical variable group by Class

mydata\$Class: >50K\$						
	age	fw	edn	cg	cl	hpw
n	11208.00	11208.00	11208.00	11208.00	11208.00	11208.00
mean	44.01	188397.97	11.60	3991.79	193.49	45.69
stdev	10.34	102492.12	2.37	14616.54	592.64	10.80
skew	0.49	1.34	-0.32	5.83	2.80	0.85
kurtosis	0.25	4.66	-0.18	35.10	6.13	4.09
mydata\$Class: <=50K\$						
	age	fw	edn	cg	cl	hpw
n	34014.00	34014.00	34014.00	34014.00	34014.00	34014.00
mean	36.75	190175.21	9.63	149.02	54.03	39.37
stdev	13.56	106653.66	2.42	927.45	312.22	11.97
skew	0.73	1.48	-0.43	17.05	5.91	0.31
kurtosis	0.02	6.59	1.03	578.22	35.30	3.26

接下来，对数值变量绘制根据目标变量 Class 分组后的箱线图，进一步观察上述 6 个数值变量对目标变量的影响，可得图 4.1、图 4.2、图 4.3、图 4.4、图 4.5 以及图 4.6 如下。

(1) 年龄 (age)




图 4.1 变量 “age” 的箱线图

Fig. 4.1 Box plot of "age"

从图 4.1 可以看出：年收入小于等于 50K 美元的样本年龄分布更为均匀，年收入小于等于 50K 美元的样本人群与年收入大于 50K 美元的样本相比中位数明显偏低，即年收入小于等于 50K 美元的样本人群整体更为年轻，越年轻年收入越高。

(2) 序号 (fw)




图 4.2 变量 “fw” 的分布

Fig. 4.2 Box plot of "fw"

从图 4.2 可以看出，年收入大于 50K 美元时，变量“fw”分布更为集中，平均水平没有太大区别。

（3）受教育时间（edu）




图 4.3 变量“edu”的分布

Fig. 4.3 Box plot of "edu"

从图 4.3 可以看出，年收入大于 50K 美元的样本的平均受教育时间明显大于年收入小于等于 50K 美元样本的平均受教育时间，且年收入小于等于 50K 美元的样本受教育时间分布相对集中，但是受教育时间较长或较短的时间段都存在离群点，而年收入大于 50K 美元的样本受教育时间离群点的分布相对集中，仅在受教育时间小于 6 年的范围内存在离群点。

（4）资本收益（cg）




图 4.4 变量“cg”的分布

Fig. 4.4 Box plot of "cg"

由图 4.4 可以看出，变量“cg”根据目标变量 Class 分组后，两组数据的分布没有呈现出较大差异，大部分数据的取值都为 0，但是在年收入大于 50K 美元的样本中存在一个极大值离群点。

(5) 资本支出 (cl)




图 4.5 变量“cl”的分布

Fig. 4.5 Box plot of "cl"

由图 4.5 可以看出,年收入小于等于 50K 美元的样本人群的资本支出分布更为离散。

(6) 每周工作时间 (hpw)




图 4.6 变量 “hpw” 的分布

Fig. 4.6 Box plot of "hpw"

由图 4.6 可以看出,年收入小于等于 50K 美元的样本人群的周工作时间更为分散,近似于均匀分布;周工作时间越长的样本越有可能年收入大于 50K 美元(中位数更大)。

皮尔逊相关性系数可以对数值变量进行相关性度量,输出范围为 $(-1,1)$,输出值的绝对值越接近 1 相关性越强,绝对值越接近 0 相关性越弱;方差膨胀系数 VIF 可以用来判断数值变量之间是否存在多重共线性,VIF 越接近 1 多重共线性越轻。求取 6 个连续型数值变量之间的相关系数矩阵以及 VIF,进而决定是否需要对数值变量进行降维或取舍。

表 4.5 皮尔逊相关系数

Tab. 4.5 Pearson correlation coefficient of numerical variables

	age	fw	edn	cg	cl	hpw
age	1.0000	-0.0758	0.0376	0.0797	0.0594	0.1020
fw	-0.0758	1.0000	-0.0420	-0.0041	-0.0043	-0.0187
edn	0.0376	-0.0420	1.0000	0.1269	0.0817	0.1462
cg	0.0797	-0.0041	0.1269	1.0000	-0.0321	0.0839
cl	0.0594	-0.0043	0.0817	-0.0321	1.0000	0.0542
hpw	0.1020	-0.0187	0.1462	0.0839	0.0542	1.0000

表 4.6 方差膨胀因子
Tab. 4.6 Variance Inflation Factor

	fw	edn	cg	cl	hpw
VIF	1.0019	1.0441	1.0231	1.0107	1.0287

由表 4.5 可以看出，所有数值变量之间的皮尔逊相关系数绝对值都非常小，因此变量之间没有明显的线性相关性；由表 4.6 可以看出，各个变量的都满足 $\sqrt{VIF} < 2$ ，因此所有数值特征之间不存在多重共线性，不需要对主成分进行降维分析。综上，选择所有的数值变量作为输入特征构建模型。

4.2.3 数值特征的标准化处理

数据标准化（归一化）处理是数据分析的一项基础工作，为了减弱数值变量之间的量纲不同对模型分类结果造成的影响，需要进行数据无量纲化处理，使得标准化后的变量符合均值为 0 标准差为 1 的正态分布，从而具有可比性。由表 4.3 可以看出，变量“fw”、“cg”以及“cl”与其他数值变量明显不处于同一数量级别上，故而需要对其进行数据标准化处理，使得数值变量原数据转换为无量纲化测评值，然后进行综合对比评估。数值型变量（前十行）在经过数据标准化处理后如表 4.7 所示。

表 4.7 标准化数据
Tab. 4.7 Standardized data

age	fw	edn	cg	cl	hpw
0.0342	-1.0623	1.1287	0.1429	-0.2188	-0.0781
0.8664	-1.0074	1.1287	-0.1467	-0.2188	-2.3267
-0.0415	0.2453	-0.4381	-0.1467	-0.2188	-0.0781
1.0934	0.4258	-1.2215	-0.1467	-0.2188	-0.0781
-0.798	1.4074	1.1287	-0.1467	-0.2188	-0.0781
-0.1171	0.8978	1.5205	-0.1467	-0.2188	-0.0781
0.7908	-0.2797	-2.005	-0.1467	-0.2188	-2.0769
1.0177	0.1884	-0.4381	-0.1467	-0.2188	0.3383
-0.571	-1.3627	1.5205	1.7295	-0.2188	0.7547
0.2612	-0.2867	1.1287	0.5431	-0.2188	-0.0781

4.2.4 类别特征的选取

表 4.8 类别特征分布情况

Tab. 4.8 Distribution of categorical variables

wc		ed		ms	
Federal-gov	:1406	HS-grad	:14783	Divorced	:6297
Local-gov	:3100	Some-college	:9899	Married-AF-spouse	:32
Private	:33307	Bachelors	:7570	Married-civ-spouse	:21055
Self-emp-inc	:1646	Masters	:2514	Married-spouse-absent	:552
Self-emp-not-inc	:3796	Assoc-voc	:1959	Never-married	:14598
State-gov	:1946	11th	:1619	Separated	:1411
Without-pay	:21	(Other)	:6878		
occ		re		race	
Craft-repair	:6020	Husband	:18666	Amer-Indian-Eskimo	:435
Prof-specialty	:6008	Not-in-family	:11702	Asian-Pac-Islander	:1303
Exec-managerial	:5984	Other-relative	:1349	Black	:4228
Adm-clerical	:5540	Own-child	:6626	Other	:353
Sales	:5408	Unmarried	:4788	White	:38903
Other-service	:4808	Wife	:2091		
(Other)	:11454				
nc		sex			
United-States	:41292	Female	:14695		
Mexico	:903	Male	:30527		
Philippines	:283				
Germany	:193				
Puerto-Rico	:175				
Canada	:163				
(Other)	:2213				

表 4.8 对于 8 个类别特征变量,计算了各个类别取值的频数,可以看出除了性别(sex)以外的类别变量都有 5 个及 5 个以上的取值。接下来,根据样本年收入是否大于 50K 美元分组分析这 8 个类别变量分组后的各个取值的占比情况,分析上述 8 个类别变量与目标变量的关系。

(1) 工作类别 (wc)

表 4.9 变量 “wc” 占比情况
Tab. 4.9 Proportion of the variable “wc”

工作类别 (wc)	年收入	
	>50K\$	<=50K\$
Federal-gov	39.05%	60.95%
Local-gov	29.52%	70.48%
Private	21.77%	78.23%
Self-emp-inc	55.41%	44.59%
Self-emp-not-inc	27.90%	72.10%
State-gov	26.72%	73.28%
Without-pay	9.52%	90.48%

由表 4.9 可以看出, 不同工作类别对于年收入是否大于 50K 美元有显著的影响。例如差异最大的 “Without-pay” 工作, 年收入大于 50K 美元的样本数仅占总样本的 9.52%, 而年收入小于等于 50K 美元的样本数占总样本的比例则达到了 90.48%; 差距最小的 “Self-emp-inc” 工作者有 55.41% 的样本数年收入大于 50K 美元, 44.59% 的工作者年收入小于等于 50K 美元, 差别不大。

(2) 受教育程度 (ed)

表 4.10 变量 “ed” 占比情况
Tab. 4.10 Proportion of the variable “ed”

受教育程度 (ed)	年收入	
	>50K\$	<=50K\$
Preschool	1.39%	98.61%
1st-4th	3.60%	96.40%
5th-6th	4.90%	95.10%
7th-8th	6.68%	93.32%
9th	5.62%	94.38%
10th	6.70%	93.30%
11th	5.50%	94.50%
12th	7.45%	92.55%
Some-college	20.10%	79.90%
Assoc-acdm	26.41%	73.59%
Assoc-voc	25.73%	74.27%
Bachelors	41.98%	58.02%
Masters	55.41%	44.59%
Doctorate	73.35%	26.65%
Prof-school	75.41%	24.59%

由表 4.10 可以看出,不同受教育程度对于年收入是否大于 50K 美元也具有显著的影响,并且随着样本集的受教育程度越高,年收入大于 50K 美元的样本比例越高。当受教育程度为“Preschool”时,年收入大于 50K 美元的比例最低,仅为 1.39%;当受教育程度为“Prof-school”时,年收入大于 50K 美元的样本比例达到最高为 75.41%。

(3) 婚姻状况 (ms)

表 4.11 变量“ms”占比情况
Tab. 4.11 Proportion of the variable “ms”

婚姻状况 (ms)	年收入	
	>50K\$	<=50K\$
Divorced	10.40%	89.60%
Married-AF-spouse	43.75%	56.25%
Married-civ-spouse	45.42%	54.58%
Married-spouse-absent	9.78%	90.22%
Never-married	4.80%	95.20%
Separated	7.02%	92.98%
Widowed	9.48%	90.52%

由表 4.11 可以看出,仅有“Married-AF-spouse”与“Married-civ-spouse”这两种婚姻状况年收入大于 50K 美元的样本较多,其他婚姻状态很少有样本的年收入大于 50K 美元。

(4) 职业 (occ)

表 4.12 变量“occ”占比情况
Tab. 4.12 Proportion of the variable “occ”

职业 (occ)	年收入	
	>50K\$	<=50K\$
Adm-clerical	13.65%	86.35%
Armed-Forces	28.57%	71.43%
Craft-repair	22.51%	77.49%
Exec-managerial	47.91%	52.09%
Farming-fishing	11.62%	88.38%
Handlers-cleaners	6.60%	93.40%
Machine-op-inspct	12.29%	87.71%
Other-service	4.08%	95.92%
Priv-house-serv	1.29%	98.71%
Prof-specialty	45.01%	54.99%

表 4.12 续
Tab. 4.12 Cont

职业 (occ)	年收入	
	>50K\$	<=50K\$
Protective-serv	31.45%	68.55%
Sales	26.90%	73.10%
Tech-support	28.94%	71.06%
Transport-moving	20.64%	79.36%

由表 4.12 可以看出, 不同的职业对于年收入是否大于 50K 美元影响很大。例如“Priv-house-serv”这一职业年收入大于 50K 美元的样本仅占总体的 1.29%, 而从事“Exec-manageria”这一职业的样本年收入大于 50K 美元的样本比例高达 47.91%。

(5) 社会角色 (re)

表 4.13 变量“re”占比情况
Tab. 4.13 Proportion of the variable “re”

社会角色 (re)	年收入	
	>50K\$	<=50K\$
Husband	45.6%	54.4%
Not-in-family	10.5%	89.5%
Other-relative	3.7%	96.3%
Own-child	1.6%	98.4%
Unmarried	6.3%	93.7%
Wife	48.6%	51.4%

由表 4.13 可以看出, 在社会角色这一变量中仅有“Husband”与“Wife”这两种角色的样本年收入大于 50K 美元的样本比例较大, 其他社会角色很少有样本的年收入大于 50K 美元。

(6) 种族 (race)

表 4.14 变量“race”占比情况
Tab. 4.14 Proportion of the variable “race”

种族 (race)	年收入	
	>50K\$	<=50K\$
Amer-Indian-Eskimo	12.18%	87.82%
Asian-Pac-Islander	28.32%	71.68%
Black	12.63%	87.37%

表 4.14 续

Tab. 4.14 Cont

种族 (race)	年收入	
	>50K\$	<=50K\$
Other	12.75%	87.25%
White	26.24%	73.76%

由表 4.14 可以看出, “White” 与 “Asian-Pac-Islander” 这两种种族样本年收入大于 50K 美元的样本比例较大 (都大于 20%), 其他种族年收入大于 50K 美元的样本比例较小 (都接近于 12%)。

(7) 性别 (sex)

表 4.15 变量 “sex” 占比情况

Tab. 4.15 Proportion of the variable “sex”

性别 (sex)	年收入	
	>50K\$	<=50K\$
Female	11.36%	88.64%
Male	31.25%	68.75%

由表 4.15 可以看出, 男性年收入大于 50K 美元的样本比例较大, 女性年收入大于 50K 美元的样本比例较小, 大约占男性年收入大于 50K 美元样本比例的 1/3。

(8) 国籍 (nc)

表 4.16 变量 “nc” 占比情况

Tab. 4.16 Proportion of the variable “nc”

国籍 (nc)	年收入		国籍 (nc)	年收入	
	>50K\$	<=50K\$		>50K\$	<=50K\$
Cambodia	34.62%	65.38%	Laos	9.52%	90.48%
Canada	36.81%	63.19%	Mexico	5.20%	94.80%
China	31.86%	68.14%	Nicaragua	6.25%	93.75%
Columbia	4.88%	95.12%	Outlying-US (Guam-USVI-etc)	4.55%	95.45%
Cuba	25.56%	74.44%	Peru	8.89%	91.11%
Dominican-Republic	5.15%	94.85%	Philippines	29.68%	70.32%
Ecuador	13.95%	86.05%	Poland	19.75%	80.25%
El-Salvador	7.48%	92.52%	Portugal	19.35%	80.65%
England	39.50%	60.50%	Puerto-Rico	11.43%	88.57%
France	44.44%	55.56%	Scotland	10.00%	90.00%

表 4.16 续
Tab. 4.16 Cont

年收入			年收入		
国籍 (nc)	>50K\$	<=50K\$	国籍 (nc)	>50K\$	<=50K\$
Germany	30.05%	69.95%	South	17.82%	82.18%
Guatemala	3.49%	96.51%	Thailand	17.24%	82.76%
Haiti	13.04%	86.96%	Trinidad&Tobago	7.69%	92.31%
Holand-Netherlands	0.00%	100.00%	United-States	25.30%	74.70%
Honduras	10.53%	89.47%	Vietnam	8.43%	91.57%
Hong	28.57%	71.43%	Yugoslavia	34.78%	65.22%
Hungary	33.33%	66.67%	Italy	33.00%	67.00%
India	42.18%	57.82%	Jamaica	13.59%	86.41%
Iran	39.29%	60.71%	Japan	34.83%	65.17%
Ireland	27.78%	72.22%	Greece	36.73%	63.27%

由表 4.16 可以看出，不同的国籍对于年收入是否大于 50K 美元影响很显著。例如“Holand-Netherlandsv”国家没有任何样本年收入大于 50K 美元，而“France”国家的样本年收入大于 50K 美元的样本比例高达 44.44%。

综上，基于数值特征变量的统计分析、相关性分析和多重共线性分析以及对于类别特征变量的统计分析，最终选择原数据集中数据标准化后的所有的数值变量以及所有的类别变量作为特征变量构建模型。

4.3 模型构建

4.3.1 数据重采样

在本文的模型构建部分，首先采用随机欠采样、SMOTE 过采样以及 SMOTetomek 混合采样这三种重采样方法处理数据不平衡问题，令 70%为训练集样本，30%为测试集样本，利用 Python3.7 编程工具可得到不同的重采样数据集如表 4.17 所示。显然，不同于原始训练集中年收入大于 50K 美元的样本个数远远少于年收入低于 50K 美元的样本个数，经过三种方法处理后，可以得到三组相对平衡的训练数据集。其中，随机欠采样方法舍弃了 22802 个样本；SMOTE 过采样生成了 15963 个少数类样本；SMOTetomek 混合采样先用 SMOTE 过采样扩大样本，再用 Tomek Link 法删除了处在胶着状态的 718 个样本点。由图 4.7 可以看出，经过重采样后的训练集中两种类别的样本比达到了 1:1，满足了学习算法的基本假设。

表 4.17 样本分布

Tab. 4.17 Distribution of samples

处理方法	Class	总样本 (个数)	训练集样本 (个数)	测试集样本 (个数)
未处理	>50K\$	11208	7846	3362
	<=50K\$	34014	23810	10204
RUS	>50K\$	11195	7839	3356
	<=50K\$	11225	7856	3369
SMOTE	>50K\$	27172	23810	3362
	<=50K\$	34014	23810	10204
SMOTETomek	>50K\$	26454	23092	3362
	<=50K\$	33296	23092	10204




图 4.7 重采样后的训练集样本分布

Fig. 4.7 Sample distribution of training set after resampling

4.3.2 模型参数调优

上一节中对数据进行重采样后，得到了三组平衡数据集。接下来，利用处理好的训练数据集构建随机森林模型与 XGBoost 模型。训练这两种模型十分简单，前者只需要从 scikit-learn 库中导出随机森林分类器（RandomForestClassifier）；后者只需要从 xgboost 库中调用 XGBoost 分类器（XGBClassifier）。但是提高两种模型的泛化性能却有些困难，需要对模型参数进行调优，从而使得训练出的模型效果达到最优。

(1) 随机森林调参

该分类器需要调参的参数主要包括两部分，第一部分是 Bagging 框架的参数，第二部分是 CART 回归树的参数。本文在随机森林模型的调参过程中，除了将 `oob_score` 由默认的 `False` 改为 `True` 以外，重点优化 `n_estimators`、`max_depth`、`min_samples_leaf` 这三个对评估性能影响最大的参数。其中，设置参数 `oob_score=True` 代表使用袋外样本来评估模型的泛化能力；参数 `n_estimators` 为弱学习器的最大迭代次数，即决策树的个数，一般来说 `n_estimators` 太小，容易欠拟合，`n_estimators` 太大，计算量会过大，并且 `n_estimators` 增加到一定的数量后，再增大 `n_estimators` 获得的模型提升会很小；参数 `max_depth` 决定决策树生成时的最大深度，常用的取值介于 10-100 之间，如果该参数过大，容易造成决策树模型的过拟合，由于本文数据集样本较多，故而考虑限制决策树的最大深度；`min_samples_leaf` 是叶结点的最小样本数，这个值限制了叶结点最少的样本数，若某叶结点的个数比样本数小，那么该叶结点会和兄弟结点一起被剪枝。经过网格搜索法（grid search）调优参数后，未经过数据重采样的 RF 模型找到的评分机制最好的一组参数设置为 `n_estimators=105`，`max_depth=23`，`min_samples_leaf=1`，模型的评估指标 AUC 与 G-mean 由 0.7798 与 0.7664 上升为 0.7846 与 0.7701。针对 RUS-RF 模型、SMOTE-RF 模型以及 SMOTetomek-RF 模型重复上述步骤，可得到上述三种模型调优后的参数取值如表 4.18 所示，调优后的模型表现如图 4.8 所示。显然，在经过参数调优后，上述四种模型的泛化性能都得到了较为明显的提升。

表 4.18 随机森林模型调参后的参数取值

Tab. 4.18 Parameter values after tuning the RF model

模型	n_estimators	max_depth	min_samples_leaf
RF	105	23	1
RUS-RF	211	15	1
SMOTE-RF	211	10	1
SMOTetomek-RF	438	10	1




图 4.8 随机森林调参前后的结果比较

Fig. 4.8 Results of RF before and after tuning parameters

(2) XGBoost 调参

由于本文选择决策树作为基学习器，故而 XGBoost 模型选择与随机森林相似的调参办法，对参数进行网格搜索优化。首先，选择较高的学习速率（learning rate），一般情况下，将学习速率的取值设置为 0.1；其次，针对给定的学习速率确定决策树的数量：n_estimator；最后，对 CART 决策树的特定参数进行调优：参数 max_depth 最好在 3-10 之间，参数 min_child_weight 根据数据集的平衡性进行调节。经过网格搜索法进行调优参数后，未经过数据重采样的 XGBoost 模型找到的评分机制最好的一组参数设置为 n_estimators=150, max_depth=6, min_child_weight=1。此时，模型的 AUC 与 G-mean 由 0.7594 与 0.7335 上升为 0.7953 与 0.7820。针对 RUS-XGBoost 模型、SMOTE-XGBoost 模型以及 SMOTetomek-XGBoost 模型重复上述步骤，可得到上述三种模型调优后的参数取值如表 4.19 所示，调优后的模型表现如图 4.9 所示。显然，在经过参数调优后，上述四种模型的泛化性能都得到了明显的提升。

表 4.19 XGBoost 模型调参后的参数取值

Tab. 4.19 Parameter values after tuning the XGBoost model

模型	n_estimators	max_depth	min_child_weight
XGBoost	150	6	1
RUS-XGBoost	205	5	1
SMOTE-XGBoost	200	5	2
SMOTetomek-XGBoost	100	5	1




图 4.9 XGBoost 调参前后的结果比较

Fig. 4.9 Results of XGBoost before and after tuning parameters

4.4 模型比较

在上一节的实验中，我们对八个模型进行了参数调优。在本节的实验中我们利用调优后的模型对“Adult”数据集 45222 个样本的年收入状况进行建模分析，得到各大模型的混淆矩阵如图 4.10 所示，AUC 与 G-mean 的取值如表 4.20 所示。




图 4.10 各个模型的混淆矩阵

Fig. 4.10 The confusion matrixs of all models




图 4.10 续
Fig. 4.10 Cont

表 4.20 各个模型的表现 (Adult)

Tab. 4.20 The performance of all models(Adult)

模型	AUC	G-mean
RF	0.7846	0.7701
RUS-RF	0.8317	0.8206
SMOTE-RF	0.8218	0.8208
SMOTetomek-RF	0.8217	0.8204
XGBoost	0.7953	0.7820
RUS-XGBoost	0.8424	0.8421
SMOTE-XGBoost	0.8319	0.8317
SMOTetomek-XGBoost	0.8281	0.8279

由表 4.20 对比各个模型的分类表现可以得到以下结论：（1）在对“Adult”数据集进行相同的数据重采样后，XGBoost 模型的 AUC 与 G-mean 取值明显高于随机森林模型的 AUC 与 G-mean 取值，即与相同的重采样算法组合后，XGBoost 模型的分类效果要比随机森林模型的分类效果更好；（2）在上述八个不平衡数据集分类模型中，RUS-XGBoost 模型的分类表现最好，两个性能度量指标都达到了最大值，AUC 取值为 0.8424，G-mean 取值为 0.8421；（3）比起未进行数据处理的 RF 模型与 XGBoost 模型，经过数据重采样后的两种模型的分类性能都有显著提升，AUC 与 G-mean 都达到了 0.80 以上。（4）从数据重采样方法的角度看，采用随机欠采样的模型比采用 SMOTE 过采样或者 SMOTetomek 混合采样的模型分类效果更好。

表 4.21 各个模型的表现（三个数据集）

Tab. 4.21 The performance of all models (Three data sets)

模型	性能指标	Adult	Credit Card	Bank Marketing
RF	AUC	0.7846	0.8750	0.7402
	G-mean	0.7701	0.8660	0.7053
RUS-RF	AUC	0.8317	0.9491	0.8851
	G-mean	0.8206	0.9483	0.8843
SMOTE-RF	AUC	0.8218	0.8986	0.8168
	G-mean	0.8208	0.8928	0.8093
SMOTetomek-RF	AUC	0.8217	0.9188	0.8231
	G-mean	0.8204	0.9152	0.8164
XGBoost	AUC	0.7953	0.9332	0.7613
	G-mean	0.7820	0.9229	0.7336

表 4.21 续
Tab. 4.21 Cont

模型	性能指标	Adult	Credit Card	Bank Marketing
RUS-XGBoost	AUC	0.8424	0.9454	0.8996
	G-mean	0.8421	0.9459	0.8990
SMOTE-XGBoost	AUC	0.8319	0.9406	0.8633
	G-mean	0.8317	0.9307	0.8628
SMOTetomek-XGBoost	AUC	0.8281	0.9342	0.8709
	G-mean	0.8279	0.9326	0.8705

考虑到不平衡数据集的不平衡比例不同时模型的分类表现可能有所不同，故而另外选取来自 Kaggle 竞赛数据的不平衡数据集“Credit Card”以及来自 UCI 数据库的不平衡数据集“Bank Marketing”进行深入对比分析。其中，“Credit Card”数据集的不平衡比例为 1:578，“Bank Marketing”数据集不平衡比例为 1:8，各大模型的表现结果如表 4.21 所示。为了直观的观察模型在三组不平衡数据集上的分类表现，分别以 AUC 与 G-mean 作为纵坐标绘制柱状图如图 4.11、图 4.12 所示，结果显示无论是对于“Credit Card”数据集还是“Bank Marketing”数据集，RUS-XGBoost 模型都具有更令人满意的泛化性能。




图 4.11 各个模型的 AUC (三个数据集)

Fig. 4.11 The AUC of all models (Three data sets)




图 4.12 各个模型的 G-mean (三个数据集)

Fig. 4.12 The G-mean of all models (Three data sets)

结 论

本文主要研究了 RF 与 XGBoost 这两种以决策树为基学习器的集成模型在不平衡数据集上的分类表现,主要分为四大部分。第一部分简述了不平衡数据集的研究背景、研究现状以及论文架构;第二部分详细介绍了当前最常用的不平衡数据集的数据优化方法:随机欠采样、SMOTE 过采样以及 SMOTETomek 混合采样,简单介绍了算法优化方法——代价敏感学习以及采用的不平衡数据集的性能衡量指标;第三部分着重介绍了本文应用的主要算法 RF 与 XGBoost 以及决策树的理论基础;第四部分对三组不平衡程度不同的数据集“Adult”、“Credit Card”以及“Bank-Additional”进行实证分析。主要结论如下:

(1) 本文实证分析部分以 RF 与 XGBoost 作为参照模型,以 AUC 与 G-mean 作为性能评价指标,通过对比试验发现 RUS-XGBoost 模型在三组不平衡数据集上的综合表现最为优越。

(2) 针对三组不平衡数据集可以发现,随着不平衡比例的上升,RUS-XGBoost 模型的 AUC 与 G-Mean 的取值同样呈现上升趋势。显然,数据不平衡程度越严重,RUS-XGBoost 模型的泛化性能越好。

(3) 从总体来看,比起以随机森林作为基础算法的模型,以 XGBoost 模型作为基础算法的模型在不平衡数据集上的分类表现更好。

(4) 从数据重采样方法的角度看,采用随机欠采样的模型比采用 SMOTE 过采样或者 SMOTETomek 混合采样的模型分类效果更好,其原因可能是 SMOTE 过采样增加了类间重叠的可能性,SMOTETomek 仅删除了部分处于胶着状态的样本点,仍然存在样本重叠的问题。

此外,本文仍然存在不足之处,需要进一步的探索,主要有以下几点:

(1) 本文选用的三组数据集样本容量都比较充足,故而可以认为当样本容量较为充足时,RUS-XGBoost 模型在不平衡数据集上分类性能最好。接下来,需要进一步研究样本数量对模型分类性能的影响。

(2) 本文没有进一步研究不平衡数据集算法层面的优化方法——代价敏感学习,引入代价矩阵构造代价集成模型与 RUS-XGBoost 模型比较是下一步研究的重点。

参考文献

- [1] 周志华. 机器学习:发展与未来[J]. 中国计算机学会通讯, 2017, 013(001):44-51.
- [2] YU H, NI J, DAN Y, et al. Mining and Integrating Reliable Decision Rules for Imbalanced Cancer Gene Expression Data Sets[J]. Tsinghua Science & Technology, 2012, 17(006): 666-673.
- [3] EBO B K, KEUNG J, PHANNACHITTA P, et al. MAHAKIL: diversity based oversampling approach to alleviate the class imbalance issue in software defect prediction [J]. IEEE Transactions on Software Engineering, 2017, 44(6):534-550.
- [4] ANAND R, MEHROTRA K G, MOHAN C K, et al. An improved algorithm for neural network classification of imbalanced training sets [J]. IEEE Transactions on Neural Networks, 1993, 4(6):962-969.
- [5] CHAWLA N V, LAZAREVIC A, HALL L O, et al. SMOTEBoost:improving prediction of the minority class in boosting [C]//European Conference on Knowledge Discovery in Databases, 2003.
- [6] PRUSA J, KHOSHGOFTAAR T M, DITTMAN D J, et al. Using random under-sampling to alleviate class imbalance on tweet sentiment data [C]//Proceedings of the 2015 IEEE International Conference on Information Reuse and Integration. Piscataway, NJ: IEEE, 2015:197-202.
- [7] LIU X Y, WU J, ZHOU Z H. Exploratory undersampling for class-imbalance learning [M]//6th International Conference on Data Mining, 2006:965-969.
- [8] LIN W C, TSAI C F, HU Y H, et al. Clustering-based under sampling in class-imbalanced data [J]. Information Sciences, 2017, 409/410:17-26.
- [9] OFEK N, ROKACH L, STERN R, et al. Fast-CBUS : a fast clustering-based undersampling method for addressing the class imbalance problem [J]. Neurocomputing, 2017, 243:88-102.
- [10] HA J, LEE J S. A new under-sampling method using genetic algorithm for imbalanced data classification [C]//International Conference on Ubiquitous Information Management & Communication, 2016.
- [11] TOMEK I. An experiment with the edited nearest-neighbor rule [J]. IEEE Transactions on Systems Man & Cybernetics, 2007, 6(6):448-452.
- [12] THAI-NGHE N, SCHMIDT-THIEME L. Learning optimal threshold on resampling data to deal with class imbalance [Z]. 2010.
- [13] ESTABROOKS A, JO T, JAPKOWICZ N. A multiple resampling method for learning from imbalanced data sets [J]. Computational Intelligence, 2010, 20(1):18-36.
- [14] CHAWLA N V, BOWYER K W, HALL L O, et al. SMOTE:synthetic minority over-sampling technique [J]. Journal of Artificial Intelligence Research, 2002, 16(1):321-357.

- [15] HAN H, WANG W Y, MAO B H. Borderline-SMOTE: a new over-sampling method in imbalanced data sets learning [C]//International Conference on Advances in Intelligent Computing. Berlin:Springer-Verlag, 2005:878-887.
- [16] HE H, BAI Y, GARCIA E A, et al. ADASYN:adaptive synthetic sampling approach for imbalanced learning [C]// IEEE International Joint Conference on Neural Network, 2008:1322-1328.
- [17] 朱明, 陶新民. 基于随机下采样和 SMOTE 的不均衡 SVM 分类算法 [J]. 信息技术, 2012(1):39-43.
- [18] BATISTA G E A P A, PRATI R C, MONARD M C. A study of the behavior of several methods for balancing machine learning training data [J]. ACM SIGKDD Explorations Newsletter, 2004, 6(1):20-29.
- [19] FREUND Y, SCHAPIRE R E. A decision-theoretic generalization of on-line learning and an application to boosting [J]. Journal of Computer and System Sciences, 1997, 55(1):23-37.
- [20] WANG S, XIN Y. Diversity analysis on imbalanced data sets by using ensemble models [C]// IEEE Symposium on Computational Intelligence & Data Mining. IEEE, 2009.
- [21] BREIMAN L. Bagging predictors[J]. Machine Learning, 1996, 24:123-140.
- [22] CHEN C, BREIMAN L. Using random forest to learn imbalanced data [D]. Berkeley: University of California, 2004.
- [23] BREIMAN L. Random forests[J]. Machine Learning, 2001, 45(1):5-32.
- [24] 吴琼, 李运田, 郑献卫. 面向非平衡训练集分类的随机森林算法优化[J]. 工业控制计算机, 2013, 26(07):89-90.
- [25] 钟龙申. 随机森林算法处理不平衡数据的改进及其并行化[D]. 广东工业大学, 2016.
- [26] 赵锦阳, 卢会国, 蒋娟萍, 等. 一种非平衡数据分类的过采样随机森林算法[J]. 计算机应用与软件, 2019, 36(04):255-261+316.
- [27] 王磊, 刘雨, 刘志中, 等. 一种处理不平衡数据的聚类欠采样加权随机森林算法[J/OL]. 计算机应用研究:1-6[2021-04-11]. <https://doi.org/10.19734/j.issn.1001-3695.2020.05.0128>.
- [28] KANIMOZHI M A. A Multiple Resampling Method for Learning from Imbalanced Data Sets [J]. Computational Intelligence, 2010, 20(1):18-36.
- [29] 刘定祥, 乔少杰, 张永清, 等. 不平衡分类的数据采样方法综述[J]. 重庆理工大学学报 (自然科学), 2019, 33(07):102-112.
- [30] 向鸿鑫, 杨云. 不平衡数据挖掘方法综述[J]. 计算机工程与应用, 2019, 55(04):1-16.
- [31] 陈斌. SMOTE 不平衡数据过采样算法的改进与应用[D]. 广西大学, 2015.
- [32] PRUSA J, KHOSHGOFTAAR T M, DITTMAN D J, et al. Using Random Under-sampling to Alleviate Class Imbalance on Tweet Sentiment Data [C]//Proceedings of the 2015 IEEE International Conference on Information Reuse and Integration. Piscataway, NJ:IEEE, 2015:197-202.
- [33] 欧阳源遊. 基于混合采样的非平衡数据集分类研究[D]. 重庆:重庆大学, 2014.
- [34] 戴翔, 毛宇光. 基于集成混合采样的软件缺陷预测研究[J]. 计算机工程与科学, 2015, 37(5):930-936.

- [35] 薛薇. 非平衡数据集的改进 SMOTE 再抽样算法[J]. 统计研究, 2012, 29 (06):95-98.
- [36] 吴雨茜, 王俊丽, 杨丽, 等. 代价敏感深度学习方法研究综述[J]. 计算机科学, 2019, 46(05):1-12.
- [37] 王晶. 基于不平衡数据的 FL-lightgbm 算法研究及其应用[D]. 上海师范大学, 2020.
- [38] 徐玲玲, 迟冬祥. 面向不平衡数据集的机器学习分类策略[J]. 计算机工程与应用, 2020, 56(24): 12-27.
- [39] JOHN DURKIN, 蔡竞峰, 蔡自兴. 决策树技术及其当前研究方向[J]. 控制工程, 2005, 12 (1):15-19.
- [40] 周志华. 机器学习[M]. 北京:清华大学出版社, 2006.
- [41] 张腾飞, 张谦, 刘嘉勇. 基于 AdaBoost-Bayes 算法的 URL 分类方法[J]. 信息安全, 2017(03): 66-71.
- [42] KWOK S W, CARTER C. Multiple decision trees[EB/OL]. [2018-01-31]. <https://arxiv.org/abs/1304.2363>.
- [43] HO T K. The random subspace method for constructing decision forests[J]. IEEE transactions on pattern analysis and machine intelligence, 1998, 20(8):832-44.
- [44] CHEN T, HE T, BENESTY M. Xgboost: extreme gradient boosting [J]. R package version 0.4-2, 2015:1-4.
- [45] 钱力扬. 基于随机森林和 XGBoost 的大型风力机故障诊断方法研究[D]. 浙江大学, 2018.
- [46] 苏玉敏. 基于随机森林与 XGBoost 的上市公司财务预警研究[D]. 哈尔滨工业大学, 2019.

附录 A 混淆矩阵




图 A.1 “Credit Card” 数据集的混淆矩阵

Fig. A.1 Confusion matrix for Credit Card dataset




图 A.1 续
Fig. A.1 Cont




图 A.2 “Bank Marketing” 数据集的混淆矩阵
Fig. A.2 Confusion matrix for Bank Marketing dataset




图 A.2 续
Fig. A.2 Cont

致 谢

在大工的两年研究生生活，为我即将走完的学生时代留下了浓墨重彩的一笔，在这里我接触到了和蔼可亲的老师，永不言败不停奋斗的同学，这些都让我受益颇多，让我更有勇气去展望离开校园后的未来生活。今年是特殊的一年，新冠肺炎的肆虐并没有带来多少恐慌，反而带给了我更多的感动，让我感受到了生命的美好与珍贵。当我未离开校园时，我是被保护的一员，当我离开校园时，希望自己能够承担起自己的责任，为社会尽一份责任。值此论文完成之际，感谢所有给予我无私帮助的人。

首先，感谢所有授课的老师，感谢他们曾给我的教育和指导，让我感受到了数据分析的魅力，并找到了事业的方向。

其次，要感谢我的舍友们，给予我的善意与友情。友情不因时光短暂而黯淡，她们对我的包容让我感受到了宿舍生活的温暖。

再次，感谢我的父母。自从考研以来，爸妈从来没有给过我任何压力，即使是找工作期间，对于我的任何选择都给予支持的态度。面对早已成为成年人的我，他们没有迫切的希望我承担责任，而是为我遮挡了更久的风雨。

最后，感谢我的导师庞丽萍老师，在论文的撰写过程中，遇到了各种大大小小的问题和苦难，但是在老师的指导下一一得到了突破。衷心祝愿庞老师桃李缤纷，在以后的学术工作中取得更加瞩目的成就！祝愿我的同学们前程似锦，未来可期！祝愿我的父母身体健康，长命百岁！

大连理工大学学位论文独创性声明

作者郑重声明：所呈交的学位论文，是本人在导师的指导下进行研究工作所取得的成果。尽我所知，除文中已经注明引用内容和致谢的地方外，本论文不包含其他个人或集体已经发表的研究成果，也不包含其他已申请学位或其他用途使用过的成果。与我一同工作的同志对本研究所做的贡献均已在论文中做了明确的说明并表示了谢意。

若有不实之处，本人愿意承担相关法律责任。

学位论文题目： 基于集成学习的不平衡数据集分类问题研究

作者签名： 刘雅洁 日期： 2021 年 6 月 1 日

