

融合 LightGBM 与 SHAP 的糖尿病预测及其特征分析方法

王鑫¹, 廖彬¹, 李敏^{1,2}, 孙瑞娜^{1,3,4}

¹ (新疆财经大学统计与数据科学学院, 乌鲁木齐 830012)

² (新疆大学信息科学与工程学院, 乌鲁木齐 830008)

³ (中国科学院信息工程研究所, 北京 100093)

⁴ (中国科学院大学网络空间安全学院, 北京 100093)

E-mail: liaobin665@163.com

摘要: 人工智能在辅助医疗诊断方面得到广泛关注, 对糖尿病预测的相关研究是近年来关注的一个热点问题。以皮马印第安人糖尿病数据集为研究对象, 首先, 对原始数据进行缺失值填充、异常值分析、标准化处理等工作的基础上, 将预处理后的数据作为 LightGBM 训练模型的输入; 其次, 与已有工作中基于 SVM、随机森林、决策树以及 Xgboost 等多种机器学习模型进行实验对比, 结果表明本文模型在准确率、精确率、召回率、F1 值、AUC 值 5 项性能指标上均明显优于对比模型; 最后, 引入 SHAP 模型增强模型的可解释性, 同时综合比较了 LightGBM 和 Xgboost 的特征重要性排序结果, 识别出了影响糖尿病的主要因素, 为糖尿病的疾病诊断提供决策参考。

关键词: LightGBM 模型; SHAP 模型; 糖尿病预测; 特征分析

中图分类号: TP391

文献标识码: A

文章编号: 1000-1220(2022)09-1877-09

Combination of LightGBM and SHAP for Diabetes Prediction and Feature Analysis

WANG Xin¹, LIAO Bin¹, LI Min^{1,2}, SUN Rui-na^{1,3,4}

¹ (College of Statistics and Data Science, Xinjiang University of Finance and Economics, Urumqi 830012, China)

² (School of Information Science and Engineering, Xinjiang University, Urumqi 830008, China)

³ (Institute of Information Engineering, Chinese Academy of Sciences, Beijing 100093, China)

⁴ (School of Networks Security, University of Chinese Academy of Sciences, Beijing 100093, China)

Abstract: Artificial Intelligence has received widespread attention in assisted Medical Diagnosis, recently, specially research on Diabetes prediction is a hot issue. We taking the Pima Indian Diabetes Dataset as the research object. Firstly, based on the missing value filling, outlier analysis, and standardization of the original data, after feature extraction process, the data is used as the input of the LightGBM training model; There are experiments based on various machine learning models such as SVM, Random forest, Decision tree and Xgboost in this work. The results show that the model in this paper is excellent in Accuracy, Precision, Recall, F1 value and AUC value. Finally, the introduction of the SHAP model enhances the model's interpretability, integrates with the feature importance of LightGBM and Xgboost, which identified the key factors affecting Diabetes and provides decision-making reference for the Diagnosis.

Key words: LightGBM model; SHAP value; diabetes prediction; feature analysis

1 引言

目前, 医疗领域是人工智能技术发展相对较快的一个领域, 科技型公司推出医疗人工智能产品, 传统的医疗企业也大量引入人工智能专业人才和技术, 人工智能在医疗领域的应用范围得到不断的拓宽, “智慧医院”, “数字诊疗”等成为医疗新方向。机器学习是当下最炙手可热的人工智能技术, 各类预测算法被广泛应用于医疗大数据, 有利于对各种疾病进行探测^[1,2]、诊断^[3,4]、治疗^[5]和管理^[6,7]工作。

糖尿病严重危害着人们的身体健康, 是一种常见的慢性

疾病, 根据国际糖尿病联盟协会(IDF) 的数据统计: 2019 年全球大约有 4.63 亿成年人(20 岁~79 岁) 患有糖尿病; 已经导致 420 万人死亡^[1], 其中中国作为世界上糖尿病患者人数最多(大约 1.16 亿人) 的国家, 如果能够充分利用机器学习算法提高糖尿病预测模型的性能表现以及模型的可解释性, 这对于辅助医生进行糖尿病诊断工作具有重要的现实意义。虽然目前已有不少这方面的研究工作, 例如基于支持向量机(SVM) ^[8,9]、朴素贝叶斯^[10]、决策树^[10-12]、深度神经网络(DNN) ^[13]、随机森林^[14,15]、Xgboost^[16] 等的机器学习模型, 分别在皮马印第安人糖尿病数据集、加拿大保健预防监测中心

注: 本文数据及代码 URL 地址: <https://gitee.com/xxxstar/diabetes>

¹ <https://www.idf.org/aboutdiabetes/what-is-diabetes/facts-figures.html>

收稿日期: 2021-02-01 收修修改稿日期: 2021-03-22 基金项目: 国家自然科学基金项目(61562078) 资助; 新疆天山青年计划项目(2018Q073) 资助; 新疆高校研自科项目(XJEDU2021Y037) 资助。作者简介: 王鑫, 女, 1995 年生, 硕士研究生, 研究方向为机器学习; 廖彬(通讯作者), 男, 1986 年生, 博士, 副教授, 博士生导师, CCF 会员, 研究方向为绿色计算、数据挖掘及大数据计算模型等; 李敏, 女, 1990 年生, 博士研究生, 研究方向为机器学习及自然语言处理; 孙瑞娜, 女, 1982 年生, 博士研究生, 研究方向为数据挖掘、网络安全等。

等数据集上建立了预测模型,但是这些传统模型在准确率 (Accuracy)、精确率 (Precision) 等性能指标上基本都在 90% 以下,还未达到投入临床应用的性能要求.在此背景下,为了进一步提高对糖尿病预测的准确率、精确率、召回率 (Recall)、F1 值等性能指标,本文基于集成学习 LightGBM 算法,使用美国国家糖尿病、消化及肾脏疾病研究所提供的皮马印第安人糖尿病数据集 (Pima Indians Diabetes Data Set,以下简称 Pima 糖尿病数据集) 作为研究对象,在对其进行数据预处理、模型训练、超参数优化、泛化能力分析、模型性能分析、模型解释等工作的基础上,建立了性能更为出色的预测模型.本文工作主要集中在以下 3 个方面:

1) 基于 LightGBM 算法建立了糖尿病预测模型,并通过对比实验,比较了其他模型在准确率、精确率、召回率 (Recall)、F1 值等指标上的表现,验证了本文模型的性能优越性.

2) 通过网格搜索技术对模型超参数进行调优,进一步提高模型性能表现,同时通过对比各模型的学习曲线,证明了本文模型在样本量较少时,同样拥有不错的泛化能力.

表 1 已有分类算法相关研究综合比较

Table 1 Comprehensive comparison of classification algorithms

研究人员	算法名称	数据集	实验结果	特点
Annja 等 ^[8]	SVM	Pima 数据集	算法准确率为 78%	适用于小样本非线性及泛化性的学习,对于高维数据,需要耗费大量的空间内存和运算时间.
Aiswarya 等 ^[9]	决策树、朴素贝叶斯	Pima 数据集	算法准确率为 74.8%、79.5%	决策树的运行速度快,但容易产生过拟合;朴素贝叶斯对缺失的数据反应不敏感,更适用于小规模的数据实验.
Ashiquzzaman 等 ^[13]	深度神经网络 (DNN)	Pima 数据集	算法准确率为 88.41%	对非线性数据友好,具备很强的识别和记忆功能,但是解释性不足,并且需要的数据量较大.
李桃等 ^[14]	随机森林	临床数据	算法准确率为 80%	擅于处理高维、特征丢失和不平衡数据,当数据噪声比较大时,会产生过拟合.
曲文龙等 ^[15]	Xgboost	临床体检数据	算法平均绝对百分比误差下降到 8.75%	Xgboost 模型对损失函数采用了正则化处理,能够控制模型的复杂度,防止过拟合;但贪心算法耗时过长,占用内存大.
张富春等 ^[17]	CA_Xgboost	天池竞赛数据集	算法均方误差为 0.606	能处理分类变量,在小样本集上的稳定性较强,训练时所需计算资源较大.

李桃等^[14]基于随机森林 (RandomForest),在上海交大第六人民医院的 2 型糖尿病临床数据上建立预测模型,预测精度为 80%,优于传统的逻辑回归算法.曲文龙等^[15]采用 Xgboost 算法作用到 6000 多个体检人员的真实糖尿病体检数据中,对比 SVM 和随机森林的平均绝对百分比误差下降到 8.75%.张富春等人^[17]在原有集成算法 Xgboost 的基础上,利用遗传算法调参得到改进模型 GA_Xgboost 模型,对天池竞赛平台提供的糖尿病临床数据进行血糖值预测,算法的均方误差优于其他机器学习算法的同时缩短了调参时长.2016 年 Perveen^[18]等对比分析了 bagging 与 boosting 两类集成学习算法,在加拿大保健预防监测中心的数据集上的效果,结果发现 adaboost 优于 bagging 算法.已有基于集成算法的工作相比传统的机器学习模型,在准确率、精确率等性能表现上更为出色,但是同样也存在两个方面的问题:1) 由于模型复杂度增加,当数据样本量不足时,容易出现模型泛化能力较差的现象;2) 诸如文献^[14-16,19]中采用的诸如 Xgboost、随机森林等集成学习,以及文献^[13]中的深度神经网络均为黑箱机器

3) 在利用 LightGBM 算法保证预测性能的基础上,为了增强模型的可解释性,基于 SHAP 模型对影响糖尿病的关键因素进行了分析,为糖尿病的医疗诊断提供了决策参考.

2 相关研究

近年来,随着信息科技化的不断发展,国内外学者致力于利用机器学习算法辅助医疗诊断,对糖尿病预测研究方面进行深入探索,提出的部分预测模型及其在实验当中的表现效果汇总如表 1 所示.其中,Annja 等^[8]提出一种基于 SVM 的糖尿病预测模型,在 Pima 数据集上进行验证工作,模型的准确率达到 78%.Aiswarya 等^[9]分别使用决策树和朴素贝叶斯两个模型对糖尿病的诊断进行分类,同样应用在 Pima 糖尿病数据集上,决策树和朴素贝叶斯的分类准确率分别为 74.8% 和 79.5%.与文献^[10]类似,Ashiquzzaman 等^[13]利用深度神经网络 (DNN) 训练预测模型,在 Pima 数据集上将模型准确率指标提升到 88.41%.

学习模型,这使得建立的预测模型缺乏可解释性.

为了解决已有研究中存在的以上两点问题,本文在用 LightGBM 算法保证预测性能的基础上,引入 SHAP 增强模型的可解释性.本文与已有的研究工作不同之处在于:1) 预测模型不同,其中文献^[8-10]都是以 Pima 数据集为研究对象,采用 SVM、决策树、朴素贝叶斯以及深度神经网络作为预测模型,本文基于集成学习的 LightGBM 算法在准确率等性能指标上性能更优;2) 由于文献^[14-16]中均为黑箱的机器学习模型,对建立的预测模型缺乏可解释性,为了解决这一问题,本文通过引入 SHAP 模型,能够对患糖尿病的影响因素进行分析,为糖尿病诊断建议提供了决策参考.

3 模型构建方法

本章 3.1 节对 LightGBM 算法原理进行概述,3.2 节对 SHAP 模型进行了介绍,阐述了基于 LightGBM 的糖尿病风险预测及特征分析模型的实现过程,本文所用到的符号及其解

释如表 2 所示。

表 2 符号说明表
Table 2 Symbol description

编号	符号	含义
1	X^s	Pima 糖尿病特征空间
2	Y	输出空间
3	s	特征维度
4	I	训练集
5	N	总样本数量
6	n	样本个数
7	$\vec{X}_i$	样本
8	g_i	样本上的标记(是残差,也是负梯度)
9	$\bar{g}$	负梯度均值
10	j	拆分维度
11	d	拆分点
12	n_o	表示 O 节点中的样本总数
13	$n_{lo}(d)$	表示 O 节点的左子节点的样本总数
14	$n_{ro}(d)$	表示 O 节点的右子节点样本总数
15	$\frac{1-a}{b}$	表示修正因子(a 表示大梯度采样比, b 表示小梯度采样比, $a, b \in (0, 1)$)
16	mc_{ij}	特征的边际贡献
17	w_i	边的权重
18	$f(x_{ij})$	x_{ij} 的 SHAP 值

整个基于 LightGBM 的糖尿病风险预测及特征分析模型的构建流程如图 1 所示,主要包括数据处理、模型训练、超参数优化、模型性能比较分析、模型解释分析等核心模块。




图 1 糖尿病风险预测及特征分析模型流程图

Fig. 1 Flow chart of diabetes risk prediction and characteristic analysis model

3.1 模型构建流程

本实验选取 LightGBM 算法对 Pima 数据集进行是否患有糖尿病进行分类预测建模,轻量级梯度提升树(Light Gradient Boosting Machine, LightGBM)是一种基于决策树的梯度提升框架,起源于微软亚洲研究院在 NIPS 发表的系列文献[20,21]。其优点包括计算准确率高、运行速度快、支持并行处理、占用内存少和适用于大规模数据处理等,相较于现有的集成算法 Boosting 在模型的精度表现和运算速度上都有较大的提升,目前被广泛地应用到排序、分类等多种机器学习任务中,且表现优异。

LightGBM 模型与大多数决策树的节点生长分裂策略不同,不是简单地按照层次顺序进行生长(Level-wise),而是按照叶子进行分裂(Leaf-wise),首先找出当前侧所有叶子中分裂增益最大的叶子,在此叶子节点上进行分裂,然后再从全局所有叶子中找到分裂增益最大的一个叶子进行分裂,依次循环分裂,对另一侧也采用相同的策略,最终生成树。LightGBM 算法建立在基于直方图(Histogram algorithm)的划分点选择

基础上,通过两个方法降低训练学习过程中所需要的样本数量和特征数,分别是基于梯度的单边采样(Gradient-based one-side sampling, GOSS)和互斥特征绑定(exclusive feature bundling, EFB),目的是为了保持较高学习性能的同时还可以减少训练过程中对时间和空间的资源占用。设 X^s 为输入空间(包括血清胰岛素、血压、葡萄糖浓度等特征),特征维度为 s , Y 为输出空间,给定训练数据集为 $I = \{(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)\}$, 其中为输入实例表示为 $\vec{x}_i = (\vec{x}_i^{(1)}, \vec{x}_i^{(2)}, \dots, \vec{x}_i^{(s)})$, $i = 1, 2, \dots, n$, n 为样本个数,每次增强迭代时,相对模型输出的损失函数的负梯度方向表示为 $\{g_1, g_2, \dots, g_n\}$ 。

GOSS(Gradient-based One-Side Sampling)算法主要是基于训练梯度的样本采样,其主要思想是保留了所有大梯度样本,同时对小梯度样本进行采样,目的是用于减少训练样本的数量。采用原始的直方图算法计算节点的信息增益:令 O 为决策树在一个固定节点上的训练数据集,此节点在值为 d 处分割特征 j 的信息增益定义为:

$$V_{j|O}(d) = \frac{1}{n_o} \left(\frac{\left(\sum_{x_i \in O: x_{ij} \leq d} g_i \right)^2}{n_{lo}^j(d)} + \frac{\left(\sum_{x_i \in O: x_{ij} > d} g_i \right)^2}{n_{ro}^j(d)} \right) \quad (1)$$

其中, $n_o = \sum I(x_i \in O)$, $n_{lo}^j = \sum I(x_i \in O: x_{ij} \leq d)$ 并且 $n_{ro}^j = \sum I(x_i \in O: x_{ij} > d)$ 。

GOSS 采样策略的步骤包括:首先把训练样本按照梯度进行排序,然后选出梯度最大的 $a\%$ 样本,其次在剩余的小梯度数据中随机地选取 $b\%$ 个样本,最后开始计算信息增益的时,小梯度数据乘以修正因子 $\frac{1-a}{b}$, 目的就是为放大小梯度样本带来的信息增益。

$$V_{j|O}(d) = \frac{1}{n_o} \left(\frac{\left(\sum_{x_i \in A_l} g_i + \frac{1-a}{b} \sum_{x_i \in B_l} g_i \right)^2}{n_l^j(d)} + \frac{\left(\sum_{x_i \in A_r} g_i + \frac{1-a}{b} \sum_{x_i \in B_r} g_i \right)^2}{n_r^j(d)} \right) \quad (2)$$

其中 A 是大梯度样本集, B 是小梯度样本集中随机采样的结果, $A_l = x_i \in A: x_{ij} \leq d$ 表示左子节点被保留的重要样本集合, $A_r = x_i \in A: x_{ij} > d$ 表示右子节点被保留的重要样本集合; $B_l = x_i \in B: x_{ij} \leq d$ 表示左子节点被保留的不重要样本集合, $B_r = x_i \in B: x_{ij} > d$ 表示右子节点被保留的不重要样本集合, 糖尿病预测模型训练算法流程如算法 1 所示。

算法 1. Prediction model training algorithm

输入:

- Parameter1: I : 训练数据, d : 迭代步数
- Parameter2: a : 大梯度数据的采样率
- Parameter3: b : 小梯度数据的采样率
- Parameter4: $loss$: 损失函数, L : 弱学习器

输出:

Parameter: 训练好的模型

1. $models \leftarrow \{\}$
2. $fact \leftarrow \frac{1-a}{b}$
3. $top \leftarrow a \times \text{len}(I)$
4. $rand \leftarrow b \times \text{len}(I)$
5. for $i = 1$ to d do

```

6. preds ← models.predict(I)
7. g ← loss(I, preds)
8. w ← {1, 1, ...}
9. sorted ← GetSortedIndices(abs(g))
10. topSet ← sorted[1:topN]
11. randSet ← RandomPick(sorted[topN:len(I)], rand(N))
12. usedSet ← topSet + randSet
13. w[randSet] ×= fact // Assign weight fact to the small gradient data.
14. newModel ← L(I[usedSet], -g[usedSet], w[usedSet])
15. models.append(newModel)
16. return models

```

算法第 1-第 4 行主要是根据样本点的梯度绝对值大小比较,对训练样本进行降序排列,选取前 $a\%$ 的样本生成大梯度样本,对剩下的样本集合,也就是小梯度数据集中随机选取 $b\%$ 的样本点,生成小梯度样本;第 5-第 15 行表示将采样的大梯度样本和采样的小梯度样本进行合并,同时让小梯度样本乘上一个权重系数 $\frac{1-a}{b}$,使用上述采样出来的样本,学习一个新的学习器,不断进行重复计算,直至达到规定的迭代次数 d 为止。

3.2 SHAP 模型

基于 LightGBM 算法进行训练可以得到预测精度较高的预测模型,但是 LightGBM 相较于传统的统计模型,在模型的可解释性方面表现较差,几乎是一个黑箱模型。因此,本文采用 SHAP 值对模型中对糖尿病的影响因素进行解释分析,用来增强模型的可解释性。SHAP 模型第一次出现在 2017 年, Lundberg 和 Lee^[23] 提出了 SHAP 值这一广泛适用的方法,用以解释各种模型(分类以及回归),特别是难以理解的黑箱模型。SHAP 值的作用主要是用于量化每个特征对模型预测所做的贡献,源自博弈论中 Shapley value。其基本的设计思想是:首先计算一个特征加入到模型当中时的边际贡献,然后计算该特征在所有特征序列中不同的边际贡献,最后计算该特征的 SHAP 值,即该特征所有边际贡献的均值。

假设第 i 个样本为 x_i ,第 i 个样本的第 j 个特征为 x_{ij} ,特征的边际贡献为 mc_{ij} ,边的权重为 w_i ,其中 $f(x_{ij})$ 为 x_{ij} 的 SHAP 值,例如第 i 个样本的第 1 个特征的 SHAP 值计算如下:

$$f(x_{i1}) = mc_{i1}w_1 + \dots + mc_{i1}w_n \quad (3)$$

模型对该样本的预测值为 y_i ,整个模型的基线(通常是所有样本的目标变量的均值)为 y_{base} ,那么 SHAP value 服从以下等式:

$$y_i = y_{base} + f(x_{i1}) + f(x_{i2}) + \dots + f(x_{is}) \quad (4)$$

$f(x_i, 1)$ 就是第 i 个样本中第 1 个特征对最终预测值 y_i 的贡献值,每个特征的 SHAP 值表示以该特征为条件时模型预测的变化。对于每个功能,SHAP 值都说明了其所做贡献,以说明实例的平均模型预测与实际预测之间的差异。当 $f(x_i, 1) > 0$,说明该特征提升了预测值,反之,说明该特征使得贡献降低。LightGBM 利用传统的 Feature Importance 只能反映出特征的重要程度,但并不清楚该特征对预测结果的具体影响力。SHAP 值计算的最大优势就在于能够反映出样本中每一个特征对预测结果的影响力,而且还可以指出其影响程度的正负性。

4 模型构建及对比实验

4.1 模型评价指标

本文主要采用 5 项常见的分类性能指标来评估模型的优劣,分别是准确率(Accuracy)、精确率(Precision)、召回率(Recall)、F1 值和 AUC 值。其中准确率(Accuracy)作为最基本的一个评价指标,是针对所有样本而言,预测分类正确所占总体的百分比,公式表达见公式(5)。精确率(Precision)是仅针对预测结果而言的指标,分类为正类的样本中预测分类正确所占的百分比,见公式(6)。召回率(Recall)是针对原始样本而言,真实的正样本中预测分类正确所占百分比,也被称为查全率,其计算表达见公式(7)。F1 值是一个综合了 Precision 与 Recall 产出结果的指标,取值范围从 0~1,其中 1 代表模型的输出最佳,反之,0 代表模型的输出结果最差。通常将关注的类作为正类,其余类为负类,分类器在测试集数据上预测是否准确,可通过如表 3 所示的混淆矩阵进行表示。

表 3 分类结果混淆矩阵

Table 3 Confusion matrix of classification results

患病状态	预测患病	预测未患病
实际患病	TP	FN
实际未患病	FP	TN

Accuracy、Precision、Recall 和 F1 值作为评价指标具体公式如下:

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN} \times 100\% \quad (5)$$

$$Precision = \frac{TP}{TP + FP} \times 100\% \quad (6)$$

$$Recall = \frac{TP}{TP + FN} \times 100\% \quad (7)$$

$$F1 = \frac{2 \times Precision \times Recall}{Precision + Recall} \times 100\% \quad (8)$$

除了上述的 4 个评价指标之外,还用到了综合指标来评价模型性能,本文用到 ROC 曲线和 AUC 值。受试者工作特征曲线(Receiver Operating Characteristic Curve,ROC)利用混淆矩阵中的参数,逐步增大分类阈值,通过计算真正例率(TPR)和假正例率(FPR),绘制而成,其中:

$TPR(\text{True Positive Rate}) = TP / (TP + FN)$,即将正例分为正例的概率。

$FPR(\text{Fales Positive Rate}) = FP / (FP + TN)$,即将负例分为正例的概率。

AUC 值(Area Under Curve)是 ROC 曲线下方的面积总和,AUC 值越大,表示模型的精度也越高。

4.2 特征工程

本实验的 Pima 数据集来源于美国国家糖尿病、消化及肾脏疾病研究所所提供的美国亚利桑那州中南部的皮马印第安人糖尿病数据集(Pima Indians Diabetes Data Set)。该地区拥有较为详细的糖尿病数据资料的原因,是因为该种族是糖尿病的高发人群,有超过 30% 的皮马人都患有糖尿病。Pima 糖尿病数据集一共有 8 个特征和 1 个标签,共 768 例样本,数据基本特征属性如表 4 所示。

在 Pima 数据集中 268 例被诊断为患有糖尿病,占总体的

34.9% ,500 例不患糖尿病患病,占总体的65.1% . 使用

表 4 Pima 数据基本特征

Table 4 Basic characteristics of Pima data

编号	特征属性	特征属性含义	特征类型
1	Pregnancies	怀孕次数	数值型
2	Glucose	葡萄糖浓度	数值型
3	BloodPressure	血压(mm Hg)	数值型
4	SkinThickness	皮层厚度(mm)	数值型
5	Insulin	血清胰岛素(mu/ml)	数值型
6	BMI	身体质量指数	数值型
7	DiabetesPedigree Function	糖尿病家族影响指数, 即遗传因素	数值型
8	Age	年龄	数值型
9	Outcome	未来 5 年是否会患有糖尿病 (1 表示是,0 表示否)	数值型

python 当中 pandas 库 describe 函数对糖尿病原始数据进行描述性统计分析,结果如表 5 所示. 可以发现,各特征字段存在缺失值、数量不一、单位不同,均值和方差相差甚远,数据预处理作为机器学习应用过程中不可或缺的一环,关系着实验结果的好坏,因此需要对糖尿病数据进行缺失值填充、异常值分析、数据变换、数据标准化等特征工程操作.

表 5 糖尿病数据描述性统计

Table 5 Descriptive statistics of diabetes data

features	count	mean	std	min	0.25	0.5	0.75	max
Pregnancies	768	3.85	3.37	0.00	1.00	3.00	6.00	17.00
Glucose	763	120.89	31.97	0.00	99.00	117.00	140.25	199.00
BloodPressure	733	69.11	19.36	0.00	62.00	72.00	80.00	122.00
SkinThickness	541	20.54	15.95	0.00	0.00	23.00	32.00	99.00
Insulin	394	79.80	115.24	0.00	0.00	30.50	127.25	846.00
BMI	757	31.99	7.88	0.00	27.30	32.00	36.60	67.10
DiabetesPedigree Function	768	0.47	0.33	0.08	0.24	0.37	0.63	2.42
Age	768	33.24	11.76	21.00	24.00	29.00	41.00	81.00
Outcome	768	0.35	0.48	0.00	0.00	0.00	1.00	1.00

2) 异常值分析

采用数字异常值(Numeric Outlier) 方法筛选数据中的异常值,通过 IQR(Inter Quartile Range) 计算得到四分位数间距,将四分位数之外的数视为异常值. 为了给异常值同时也是真实值保留一定的缓冲空间,将异常值较多的特征进行数据变换处理.

3) 数据标准化

由于各个属性特征的单位不同,为了消除由于单位不同

表 6 标准化后的 Pima 数据

Table 6 Standardized Pima data

Outcome	Pregnancies	Glucose	BloodPressure	SkinThickness	Insulin	BMI	DiabetesPedigreeFunction	Age
1	0.60	0.77	0.00	1.00	1.00	0.17	0.67	1.24
0	-0.40	-0.79	-0.38	0.14	0.00	-0.60	-0.06	0.12
1	1.00	1.63	-0.50	0.57	1.00	-0.96	0.78	0.18
0	-0.40	-0.69	-0.38	0.71	-0.13	-0.43	-0.54	-0.47
1	-0.60	0.49	-2.00	1.00	0.98	1.21	5.01	0.24
0	0.40	-0.02	0.12	-0.14	0.00	-0.71	-0.45	0.06
1	0.00	-0.96	-1.38	0.57	-0.22	-0.12	-0.33	-0.18
0	1.40	-0.05	-0.12	-0.14	0.00	0.36	-0.62	0.00
1	-0.20	1.98	-0.12	2.43	6.57	-0.17	-0.56	1.41
1	1.00	0.20	1.50	0.57	1.00	0.25	-0.37	1.47

1) 缺失值填充

糖尿病数据进行缺失值可视化处理,结果见图2,白色代




图 2 特征缺失情况

Fig. 2 Feature missing

表数据缺失,全为黑色则表示特征完整,白色相对黑色占比越多证明缺失情况越严重. 可以看出特征 Glucose、BloodPressure、BMI、SkinThickness 和 Insulin 都存在缺失,其中 SkinThickness 和 Insulin 缺失程度较大,高达 29.6% 和 48.7%,其他特征没有缺失值. 对于缺失特征的填充工作,按照病人是否患有糖尿病进行中位数填充,将数据分为患病和不患病两类,根据患病类别的中位数和不患病类别的中位数进行分填充.

的影响,解决不同属性之间的差异性和不可比性,需要在实验前对数据进行标准化处理,由于 Pima 数据集中存在的离群值较多,所以使用稳健标准化(RobustScaler) 对数据进行标准化处理,能够最大限度地保留数据集中的异常值(离群点),根据四分间距(IQR) 缩放数据,来弱化异常值的影响. RobustScaler 的计算方法如下:

$$v_i' = \frac{v_i - median}{IQR} \quad (9)$$

其中, v_i 表示数据集中的某个值, median 表示数据的中位数, IQR 是数据的四分间距值. 标准化后的数据为如表 6 所示.

4.3 与已有工作的实验对比

本节将本文的 LGBM 与已有的基于逻辑回归 (LR)^[23]、KNN、SVM^[8]、随机森林 (RF)^[14]、决策树^[14] 以及 Xgboost^[14] 6 种模型进行对比. 为了提高模型之间对比的公平性及可靠性, 实验中采用了十折交叉验证方法进行性能评估, 如图 3 所示为以 Accuracy 值作为评价指标并绘制箱型图, 初步查看预测精度的分布情况, LGBM 模型比已有工作中的 6 种模型要高.




图 3 箱型图比较

Fig. 3 Comparison of box diagrams

本实验采用准确率 (Accuracy)、精确率 (Precision)、召回率 (Recall)、F1 值和 AUC 值 5 项常用的评价指标来评估模型

表 7 模型性能对比

Table 7 Performance comparison of model

模型	Accuracy	Precision	Recall	F1-score	AUC
LR ^[23]	0.850	0.807	0.763	0.785	0.916
KNN	0.824	0.759	0.745	0.752	0.869
SVM ^[8]	0.831	0.795	0.709	0.750	0.932
RF ^[14]	0.901	0.836	0.800	0.862	0.943
CART ^[14]	0.857	0.811	0.781	0.796	0.840
Xgboost ^[14]	0.906	0.875	0.833	0.860	0.958
LGBM	0.909	0.886	0.854	0.870	0.960
PLGBM	0.916	0.920	0.836	0.876	0.965

的优劣. 表 7 和图 4 是上述 7 种算法加上 PLGBM (参数优化后的 LGBM, 请参见 4.4 节) 的各项评价指标综合对比结果.




图 4 各算法性能对比

Fig. 4 Performance comparison of various algorithms

根据表 7 和图 4 的实验结果可知, 其中 LGBM 的预测准确率为 90.9%, 精确率为 88.6%, 召回率 85.4%, F1 值为 87%, AUC 值为 0.96, PLGBM 在准确率、精确度、F1 值和 AUC 值上都有提高. 相比其他机器学习算法, 集成类算法 RF、Xg-

boost、LGBM 在预测准确率上表现更好, 都在 90% 以上, 体现了集成算法的优越性. LGBM 在各项性能上与 Xgboost 算法最为接近, 但 LGBM 表现更优, 性能提高约 0.3% ~ 2.1%, 参数优化后性能提高约 0.3% ~ 4.5%, 原因在于 LGBM 保留了小样本的信息增益, 并且还具有支持高效并行的优势; Xgboost 的预排序算法不同于 GOSS 采样策略, 需要遍历每一个特征值, 并且每遍历一次都会根据需要进行一次分裂增益的计算, 预排序后还需要记录特征值及其对应样本的统计值索引, 而 LGBM 使用了直方图算法将特征值转变为 bin 值, 且不再需要记录特征到样本的索引, 并且在训练过程中采用互斥特征捆绑算法减少了特征数量, 将空间复杂度从 $O(2 \times \#data)$ 降低为 $O(\#bin)$, 极大地减少了内存的消耗. 由此可见, 在 7 个算法中, LGBM 的结果更为准确, 且占用内存更低, 运行速率更快, 其稳定性也相比其他算法更加优秀.

4.4 模型参数优化及泛化能力分析

LightGBM 有 6 个核心参数, 不同的参数具有不同的功能, 这些参数是否设定合理, 直接影响模型的好坏, 传统的调参方法依赖经验判断和遍历实验, 本文结合传统方法和网格搜索方法, 帮助确定最佳参数如表 8 所示.

表 8 LightGBM 最优参数及默认值

Table 8 LightGBM best parameters and default values

参数名	默认值	参数最优值	参数含义
learning_rate	0.1	0.01	学习率, 每次迭代更新权重时的步长
max_depth	3	9	决策树的最大深度, 值越大越容易过拟合
n_estimators	10	500	迭代次数, 也就是基学习器的个数
num_leaves	31	50	每个树上的叶子数, 值越大越容易过拟合
min_child_weight	1	12	最小叶子权重, 值越小越容易过拟合
gamma	0	0.35	惩罚项系数, 值越大算法结构越简单

将标准化后的 Pima 数据中的 614 条用作训练数据集, 剩余的 154 条作为测试集, 对比 LGBM 的默认参数组合和调参实验过后的最佳参数组合, 对患者未来 5 年内是否会患糖尿




图 5 LightGBM 算法调参前后 ROC 曲线比较

Fig. 5 Comparison of ROC curves before and after parameter tuning

病进行预测. 实验结果显示, 调参过后的 PLGBM 模型精确度提升至 91.6%, 明显优于默认参数下的精确度 90.9%, 模型的 ROC 曲线比较如图 5 所示.

判断模型是否好, 除了在训练集上表现良好, 还要在交叉验证中具有良好的泛化表现, 对新鲜的样本具有适应能力. 本

节主要通过学习曲线来分析来对模型进行收敛分析,图6为 LightGBM 与其他模型学习曲线的对比,其中包括 KNN、SVM

和 Xgboost 的学习曲线。

从图6中可以发现4种算法从拟合趋势上看,随着样本




图6 LightGBM 与各分类模型的学习曲线对比

Fig. 6 Performance comparison of LightGBM with Kr, SVM and Xgboost

量的不断增大,模型的交叉验证分数呈逐渐增加的趋势,测试得分只有 Xgboost 出现性能略微下降的现象。而 Xgboost 与 LightGBM 模型在任何样本量情况下,拟合情况与其他两个算法都存在差距,拟合效果都要优于 KNN 和 SVM。从拟合趋势上看,随着样本量的不断增大,LightGBM 逐步趋于稳定,并且模型能够达到更优的拟合效果。

4.5 基于 SHAP 的模型解释分析

图7显示了 SHAP 摘要图,该图根据要素对影响是否患有糖尿病的因素重要性进行排序。从图7可以看到: Insulin (血清胰岛素)、Glucose(葡萄糖浓度)、Age(年龄)、BMI(身体质量指数)、DiabetesPedigreeFunction(糖尿病家族影响指数,即遗传因素)等特征的差异对模型的影响较显著,并且这些因素对患有糖尿病都具有负面影响,随着该值的增加,患有糖尿病的风险越大。




图7 SHAP 特征分析

Fig. 7 Feature analysis

图8根据更改模型当中的特定特征,在x轴绘制了特征的值,在y轴上绘制特征的 SHAP 值,进行 SHAP 特征依赖分析,分别选取了 Insulin(血清胰岛素)、Glucose(葡萄糖浓度)、Age(年龄)、DiabetesPedigreeFunction(糖尿病家族影响指数,

即遗传因素)作为指定特征绘制图像。在图8中,Insulin(血清胰岛素)、Glucose(葡萄糖浓度)、Age(年龄)和 DiabetesPedigreeFunction(糖尿病家族影响指数,即遗传因素)都随着值的增加 SHAP 值也随之增加,对促成糖尿病具有正向影响。

根据图9,SHAP 模型、LightGBM 模型和 Xgboost 模型的特征重要性排序可以看出,排名的特征顺序并不完全相同,可以得出影响是否患有糖尿病的关键因素包括: Insulin(血清胰岛素)、Glucose(葡萄糖浓度)、Age(年龄)、DiabetesPedigreeFunction(糖尿病家族影响指数,即遗传因素)、BMI(身体质量指数)以及 SkinThickness(皮层厚度)。其中3种算法都将 Insulin(血清胰岛素)、Glucose(葡萄糖浓度)、Age(年龄)排在了前3位,可见这3个因素是影响是否患有糖尿病最关键的因素,胰岛素和葡萄糖浓度正是糖尿病的重要参考指标,研究表明,血清胰岛素、葡萄糖浓度是糖尿病血糖监测的重要临床指标,也是诊断患者是否患糖尿病的重要依据,如果空腹血糖大于 7.0mmol/L 或餐后两小时血糖大于 11.1mmol/L,就存在患病的可能^[24]。年龄的因素应该也要列入医疗诊断的考虑当中,糖尿病的发病率还会随着年龄的增长而增长。其次 DiabetesPedigreeFunction(糖尿病家族影响指数,即遗传因素)、BMI(身体质量指数)以及 SkinThickness(皮层厚度),其重要程度在 LightGBM 和 Xgboost 算法中排名均在前,此外其他因素需要在诊断时进行综合分析。

5 结论及下一步工作

中国作为糖尿病患病人数最多的国家,利用机器学习算法提高糖尿病预测模型性能及可解释性,对于辅助医生的诊断工作具有重要的现实意义。在此背景下,为了进一步解决已有基于集成算法的相关工作中存在的泛化能力不足以及解释力不强的问题,本文基于 LightGBM 算法构建糖尿病预测模型,同时引入 SHAP 模型进一步增强模型的可解释性。首先,




图8 SHAP 特征依赖分析

Fig. 8 Feature dependence analysis




图9 特征重要性(分别是 SHAP、LightGBM、Xgboost)

Fig. 9 Feature importance(Respectively SHAP, LightGBM, Xgboost)

在对 Pima 糖尿病数据集进行特征工程的基础上,将处理后的

数据作为 LightGBM 训练模型的输入,将训练后的模型用于预测是否患有糖尿病;然后,通过网格搜索方法寻找 LightGBM 算法的最优参数,并且通过与逻辑回归(LR)、KNN 算法、SVM、随机森林(RF)、决策树以及 Xgboost 等六种机器学习模型的对比实验,证明了 LightGBM 算法的有效性。最后利用 SHAP 模型进行特征解释分析,同时通过 Xgboost 和 LightGBM 的特征重要性排序,识别出了影响患糖尿病的关键因素是 Insulin(血清胰岛素)、Glucose(葡萄糖浓度)、Age(年龄)、DiabetesPedigreeFunction(糖尿病家族影响指数,即遗传因素)、BMI(身体质量指数)以及 SkinThickness(皮肤厚度);模型可解释性的增强、预测性能的提高,对降低机器学习辅助诊断糖尿病的误诊率,提高诊断效率,具有重要的应用价值。

下一步工作主要是将模型推广到临床实践场景,并根据真实应用场景的需求,对特征工程、模型训练、超参数优化、误差及偏差分析等内容进一步优化。

References:

- [1] Wang Xin-lei, Wang Zhi-qiong, Wang Zhong-yang, et al. Multi-frequency fused graph kernel of brain network for Alzheimer's disease [J]. Chinese Journal of Computers, 2020, 43(1): 64-77.
- [2] Wang Zhen-fei, Chen Jin-lei, Zheng Zhi-yun, et al. Adaptive modularized neural network prediction model for cardiovascular Disease [J]. Journal of Chinese Computer Systems, 2019, 40(1): 232-235.
- [3] Cui Ya-xuan, Xu Yi, Fu Qiang. Survey of machine learning applications in the clinical diagnosis of spinal diseases [J]. Journal of Chinese Computer Systems, 2020, 41(11): 211-219.
- [4] Sun Fu-quan, Cong Cheng-long, Zhang Kun, et al. Benign and malignant diagnosis of breast cancer histopathological image based on

- multi-model neural network [J]. Journal of Chinese Computer Systems, 2020, 41(4): 732-735.
- [5] Liu Meng-meng, Guo Song, Gao Ying-qi, et al. Learnable method for labeling hard exudates [J]. Journal of Chinese Computer Systems, 2019, 40(12): 2657-2661.
- [6] Ning Shang-ming, Teng Fei, Li Tian-rui. Multi-channel self-attention mechanism for relation extraction in clinical records [J]. Chinese Journal of Computers, 2020, 43(5): 916-929.
- [7] Lu Shu-qi, Dou Zhi-cheng, Wen Ji-rong. Research on structural data extraction in surgical cases [J]. Chinese Journal of Computers, 2019, 42(12): 2754-2768.
- [8] Chitra J. Classification of diabetes disease using support vector machine [J]. International Journal of Engineering Research and Applications, 2013, 3(2): 1797-1801.
- [9] Santhanam T, Padmavathi M S. Application of K-means and genetic algorithms for dimension reduction by integrating SVM for diabetes diagnosis [J]. Procedia Computer Science, 2015, 47: 76-83.
- [10] Iyer A, Jeyalatha S, Sumbaly R. Diagnosis of diabetes using classification mining techniques [J]. International Journal of Data Mining & Knowledge Management Process, 2015, 5(1): 1-14.
- [11] Hou Yu-mei, Zhu Ya-nan, Zhu Li-chun, et al. Application of decision tree model in risk prediction of type 2 diabetes mellitus [J]. Chinese Journal of Health Statistics, 2016, 33(6): 976-978.
- [12] Yang Guang, Ma Er-li. Application of decision tree model in prediction of type 2 diabetes [J]. Journal of Shenyang Normal University(Natural Science Edition), 2018, 36(3): 233-236.
- [13] Ashiquzzaman, A, Tushar K, Islam A K, et al. Reduction of overfitting in diabetes prediction using deep learning neural network [J]. IT Convergence and Security, 2017, 449: 35-43.
- [14] Li Tao, Jiang Fu-song, Chen Ting, et al. Establishment of machine learning model for predicting carotid plaque in type 2 diabetes mellitus [J]. Chinese Medical Equipment Journal, 2020, 41(1): 7-11 + 24.
- [15] Yang Mei-jie, Tang Jian-jun. Study on predictions of diabetes mellitus based on random forest algorithm [J]. Journal of Medical Intelligence, 2019, 40(9): 47-49.
- [16] Qu Wen-long, Li Yi-yi, Zhou Lei. Application of XGBoost algorithm in diabetic blood glucose prediction [J]. Jilin Normal University Journal(Natural Science Edition), 2019, 40(4): 118-125.
- [17] Zhang Chun-fu, Wang Song, Wu Ya-dong, et al. Diabetes risk prediction based on GA_Xgboost model [J]. Computer Engineering, 2020, 46(3): 315-320.
- [18] Perveen S, Shahbaz M, Guergachi A, et al. Performance analysis of data mining classification techniques to predict diabetes [J]. Procedia Computer Science, 2016, 82: 115-121.
- [19] Zhou Song-qi, Bai Ying. Disease risk prediction based on stacking integrated learning algorithm using data of gestational diabetes [J]. Statistics and Application, 2020, 9(3): 345-356.
- [20] Qi M, Guolin K, Taifeng W, et al. A Communication-efficient parallel algorithm for decision tree [C] // 30th Conference on Neural Information Processing Systems(NIPS'16), 2016, 29: 1279-1287.
- [21] Guolin K, Qi M, Thomas Finley, et al. LightGBM: a highly efficient gradient boosting decision tree [C] // Proceedings of the 31st International Conference on Neural Information Processing Systems (NIPS'17), 2017, 30: 3149-3157.
- [22] Lundberg S M, Lee S I. A unified approach to interpreting model predictions [C] // Proceedings of the 31st International Conference on Neural Information Processing Systems(NIPS'17), 2017, 31: 4768-4777.
- [23] Zhong X, Jing Y, Lin H, et al. A simple tool detected diabetes and prediabetes in rural Chinese [J]. Journal of Clinical Epidemiology, 2010, 63(9): 1030-1035.
- [24] Chinese Diabetes Society. Guidelines for the clinical application of continuous glucose monitoring in China(2017 Edition) [J]. Chinese Journal of Diabetes Mellitus, 2017, 9(11): 667-675.

附中文参考文献:

- [1] 汪新蕾, 王之琼, 王中阳, 等. 面向阿尔茨海默病的脑网络多频融合图核 [J]. 计算机学报, 2020, 43(1): 64-77.
- [2] 王振飞, 陈金磊, 郑志蕴, 等. 面向心血管疾病的自适应模块化神经网络预测模型 [J]. 小型微型计算机系统, 2019, 40(1): 232-235.
- [3] 崔亚轩, 胥义, 付强. 机器学习在脊柱疾病临床诊断中的应用研究进展 [J]. 小型微型计算机系统, 2020, 41(11): 211-219.
- [4] 孙福权, 丛成龙, 张琨, 等. 基于多模型卷积神经网络的乳腺癌病理医疗图像良恶性诊断 [J]. 小型微型计算机系统, 2020, 41(4): 732-735.
- [5] 刘蒙蒙, 郭松, 高颖琪, 等. 可学习的硬性渗出病变点标注方法 [J]. 小型微型计算机系统, 2019, 40(12): 2657-2661.
- [6] 宁尚明, 滕飞, 李天瑞. 基于多通道自注意力机制的电子病历实体关系抽取 [J]. 计算机学报, 2020, 43(5): 916-929.
- [7] 卢淑祺, 窦志成, 文继荣. 手术病例中结构化数据抽取研究 [J]. 计算机学报, 2019, 42(12): 2754-2768.
- [1] 侯玉梅, 朱亚楠, 朱立春, 等. 决策树模型在 2 型糖尿病患病风险预测中的应用 [J]. 中国卫生统计, 2016, 33(6): 976-978.
- [2] 杨光, 马尔丽. 决策树模型在 2 型糖尿病预测中的应用 [J]. 沈阳师范大学学报(自然科学版), 2018, 36(3): 233-236.
- [4] 李桃, 蒋伏松, 陈鑫, 等. 预测 2 型糖尿病并发颈动脉斑块的机器学习模型的建立 [J]. 医疗卫生装备, 2020, 41(1): 7-11 + 24.
- [5] 杨美洁, 唐建军. 基于随机森林算法的糖尿病预测研究 [J]. 医学信息学杂志, 2019, 40(9): 47-49.
- [6] 曲文龙, 李一漪, 周磊. XGBoost 算法在糖尿病血糖预测中的应用 [J]. 吉林师范大学学报(自然科学版), 2019, 40(4): 118-125.
- [7] 张春富, 王松, 吴亚东, 等. 基于 GA_Xgboost 模型的糖尿病风险预测 [J]. 计算机工程, 2020, 46(3): 315-320.
- [9] 周颂奇, 白颖. 基于 Stacking 集成学习算法的疾病风险预测——以妊娠糖尿病为例 [J]. 统计学与应用, 2020, 9(3): 345-356.
- [24] 中华医学会糖尿病学分会. 中国持续葡萄糖监测临床应用指南(2017 年版) [J]. 中华糖尿病杂志, 2017, 9(11): 667-675.