

《基于改进LightGBM的上市公司财务风险预警系统设计》

2026年7月20日 12:11

毕设整体框架（推荐最终版）

第一章 绪论（约8%）

重点

介绍项目背景，而不是大量金融理论。

包括：

- 研究背景
 - 上市公司ST制度
 - 财务风险预警的重要性
 - 传统人工分析效率低
 - 机器学习在风险预测中的应用
- 国内外研究现状
 - Logistic Regression
 - Random Forest
 - XGBoost
 - LightGBM
 - 当前研究存在的问题
- 研究目标

说明本文主要解决：

如何提高上市公司ST风险预测精度，并开发可视化预测系统。

第二章 相关技术与理论基础（约22%）

这一章是计算机毕设的重要基础。

不是简单介绍概念，而是讲清楚原理。

2.1 决策树

讲：

为什么可以分类

信息增益

Gini指数

树如何生成

2.2 GBDT

重点:

Boosting思想

残差学习

每棵树拟合什么

为什么越来越准确

最好画流程图。

2.3 XGBoost

讲:

为什么比GBDT快

目标函数

正则化

剪枝

2.4 LightGBM (重点)

必须详细讲:

Histogram

为什么快

时间复杂度

空间复杂度

画桶 (Bin) 的示意图。

Leaf-wise

为什么不是Level-wise

为什么容易过拟合

为什么训练速度快

画两棵树对比。

GOSS

为什么保留大梯度样本

为什么舍弃小梯度样本

为什么不会影响结果

EFB

为什么可以绑定稀疏特征

为什么减少维度

2.5 SMOTE

讲:

SMOTE生成过程

数学公式

普通SMOTE缺点

为什么Adaptive SMOTE更适合本课题（如果确实采用Adaptive版本）。

2.6 Variance Threshold

讲：

方差计算

为什么方差小说明区分能力差

为什么可以删除

2.7 SHAP

讲：

Shapley Value

为什么：

机器学习需要可解释

金融为什么更需要解释

第三章 改进LightGBM模型设计（约20%）

这一章开始进入你的创新。

3.1 数据集构建

介绍：

数据来源

数据结构

标签定义（ST/非ST）

训练集

测试集

建议说明时间划分方式（例如按年份划分），这样更符合预测任务。

3.2 数据预处理

包括：

缺失值

异常值

标准化（说明哪些算法需要，哪些不需要）

类别编码

3.3 特征选择

Variance Threshold

为什么：

删除低方差特征

减少噪声

提高训练速度

3.4 类别不平衡处理

Adaptive SMOTE

为什么：

ST少

正常公司多

为什么：

Recall低

所以：

SMOTE

3.5 LightGBM优化

Class Weight


参数优化

交叉验证（建议加入）

Early Stopping（可加入）

3.6 模型整体流程

建议画流程图：



第四章 实验与结果分析（约20%）

这一章不能只是放图。

必须：

解释原因。

建议实验：

实验一

逻辑回归

实验二

随机森林

实验三

LightGBM

实验四

改进LightGBM

评价：

Accuracy

Precision

Recall

F1

AUC

PR曲线（如果正负样本很不均衡，PR曲线也很有价值）。

图：

ROC

混淆矩阵

柱状图

折线图

SHAP图

分析：

为什么Recall提高？

为什么AUC提高？

不是：

“因为模型更好。”

而是：

因为：

SMOTE

Class Weight

共同提高了少数类识别能力。

第五章 B/S系统设计与实现（约20%）

包括：

系统架构

Vue
↓
SpringBoot
↓
Python模型
↓
MySQL

建议说明 Java 与 Python 模型如何通信（REST API、HTTP 调用等）。

数据库

建议至少四张表：

用户表

企业信息表

财务指标表

预测结果表

如果有预测日志，也可以单独建表。

功能模块

登录

企业管理

Excel导入

模型预测

风险分析

历史查询

数据导出

页面展示

登录

Dashboard

预测

图表

导出

每个页面截图。

第六章 总结与展望（约10%）

总结：
模型优势
系统优势
不足
未来：
Transformer
图神经网络
大模型辅助分析
多源数据融合

创新点（建议控制在3项）

创新点1

针对类别不平衡问题，引入 Adaptive SMOTE + **类别权重** 优化 LightGBM 对少数类 ST 企业的识别能力。

创新点2

结合 Variance Threshold 进行特征筛选，降低冗余特征对模型训练效率和预测性能的影响。

创新点3

设计并实现 SpringBoot + Vue + Python **模型服务** 的 B/S 财务风险预警系统，实现数据管理、模型预测、结果可视化和报表导出的一体化流程。

建议避免宣称“提出新的LightGBM算法”，因为你的工作属于**基于已有算法的改进与工程实现**，这对于本科毕设是完全合理且容易自圆其说的。

问题

建议准备的回答方向

为什么选择LightGBM?

与Random Forest、XGBoost对比，说明速度、内存、效果优势

Histogram为什么快?

从分桶思想、减少排序和计算复杂度解释

Leaf-wise为什么准确率高? 为什么可能过拟合?

对比Level-wise，结合树结构说明

为什么要用SMOTE?

类别不平衡会导致模型偏向多数类，影响Recall

为什么不用Accuracy作为唯一指标?

不平衡数据下Accuracy可能具有误导性，应综合Recall、F1、AUC

SHAP解决了什么问题?

提供模型可解释性，说明哪些特征推动了预测结果

SpringBoot为什么不直接运行LightGBM?

模型训练与Web服务职责分离，Python生态更适合机器学习，Java通过API调用模型服务更清晰、易维护

一定要注意的事项（非常重要）

1. 不要过度堆砌算法

建议控制为：

Variance Threshold → Adaptive SMOTE → LightGBM (Class Weight) → SHAP

这条主线已经足够完整。

2. 数据处理流程必须正确

一定注意顺序，例如：

数据划分 → 在训练集上进行特征筛选和SMOTE → 训练模型 → 将同样的特征处理应用到测试集 → 测试模型

避免测试集信息泄漏到训练过程中。

3. 保证实验可复现

记录：

- 数据来源
- 数据时间范围
- 特征列表
- 随机种子（如使用）
- LightGBM主要参数

让别人能够重复实验。

4. 原理要能讲，不要只会调用库

老师往往不会问你API，而会问：

为什么这样设计？

因此，论文和答辩都应围绕**原理、设计理由和实验验证**展开，而不是停留在代码调用层面。

我对这个课题的最终评价

如果按照这套框架完成，它会形成一个比较标准的计算机本科毕设结构：

算法原理（讲清楚） → 模型改进（有创新） → 实验验证（有数据支撑） → 系统实现（可演示）